

# Solutions to Chapter 11 — *Structured Distributions*

姚宇倬

2025 年 9 月 14 日

*Based on the textbook Deep Learning: Foundations and Concepts*

## 练习题中文译文及解答

**练习 11.1 (★)** 通过按顺序将各变量边缘化消去，证明：若有向图的每个条件分布都已归一，则其联合分布的表示式 (11.6) 必然也是归一化的。

**练习 11.2 (★)** 证明：在有向图中“不存在有向环”的性质，可由以下陈述推出：存在一种对全部节点的编号，使得每条有向边都只指向编号较大的节点；亦即对任何节点，都没有指向编号更小节点的连边。

**练习 11.3 (★★)** 设三元二值随机变量  $a, b, c \in \{0, 1\}$  的联合分布如表 1 所示。直接计算并验证：

(1) 边缘分布下  $a$  与  $b$  相关，即  $p(a, b) \neq p(a)p(b)$ ；

(2) 条件在  $c$  上时二者独立，即

$$p(a, b | c) = p(a | c)p(b | c),$$

对于  $c = 0$  与  $c = 1$  均成立。

**练习 11.4 (★★)** 以表 1 的联合分布为例，计算  $p(a)$ 、 $p(b | c)$ 、 $p(c | a)$ 。进一步证明：

$$p(a, b, c) = p(a)p(c | a)p(b | c).$$

并画出对应的有向图。

**练习 11.5 (★)** 对于图 11.6 所示的模型，我们已知，通过使用 logistic sigmoid 表示法 (11.8)，指定条件分布  $p(y | x_1, \dots, x_M)$ （其中  $x_i \in \{0, 1\}$ ）所需的参数数量可以从  $2^M$  个减少到  $M + 1$  个。一种替代表示法 (Pearl, 1988) 由下式给出：

$$p(y = 1 | x_1, \dots, x_M) = 1 - (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i} \quad (11.49)$$

表 1: 三元二值变量  $(a, b, c)$  的联合概率 (练习 11.3 与 11.4 所需)。

| $a$ | $b$ | $c$ | $p(a, b, c)$ |
|-----|-----|-----|--------------|
| 0   | 0   | 0   | 0.192        |
| 0   | 0   | 1   | 0.144        |
| 0   | 1   | 0   | 0.048        |
| 0   | 1   | 1   | 0.216        |
| 1   | 0   | 0   | 0.192        |
| 1   | 0   | 1   | 0.064        |
| 1   | 1   | 0   | 0.048        |
| 1   | 1   | 1   | 0.096        |

其中, 参数  $\mu_i$  表示概率  $p(x_i = 1)$ , 而  $\mu_0$  是一个满足  $0 \leq \mu_0 \leq 1$  的附加参数。该条件分布 (11.49) 被称为**含噪或 (noisy-OR)**。请证明, 该模型可以被解释为逻辑“或”函数的一种“软”(概率性)形式(即, 只要至少有一个  $x_i = 1$ , 该函数就给出  $y = 1$ )。并讨论  $\mu_0$  的含义。

**练习 11.6 (★★)** 从条件分布的定义式 (11.9) 出发, 推导线性-高斯模型的联合分布的均值所满足的递推关系式 (11.12)。

**练习 11.7 (★★)** 同样从 (11.9) 出发, 推导线性-高斯模型的联合分布的协方差矩阵所满足的递推关系式 (11.13)。

**练习 11.8 (★★)** 证明: 对于一个由 (11.9) 式定义的、包含  $D$  个变量的**全连接**线性高斯图模型(即每个节点的父节点为所有编号更低的节点), 其协方差矩阵的参数数量为

$$\frac{D(D+1)}{2}.$$

**练习 11.9 (★★)** 利用递推关系 (11.12) 与 (11.13), 求出图 11.7 所示三元线性-高斯图的均值 (11.14) 与协方差 (11.15)。

**练习 11.10 (★★)** 验证: 若图中每个节点都是一维线性-高斯分布 (11.16), 则整张图上向量值变量的联合分布仍为多元高斯。

**练习 11.11 (★)** 证明: 若  $a \perp\!\!\!\perp b \mid c$  且  $c \perp\!\!\!\perp d$ , 则可推出

$$a \perp\!\!\!\perp b \mid d.$$

**练习 11.12 (★)** 结合 d-分离标准, 证明: 在有向图中, 若条件于某节点的 Markov 毯, 则该节点的条件分布与图中其它所有节点独立。

练习 11.13 (★) 考察图 11.32 (初始无任何节点观测)。证明

$$a \perp\!\!\!\perp b \mid \emptyset.$$

随后观测  $d$ ，说明一般情况下

$$a \not\perp\!\!\!\perp b \mid d.$$

练习 11.14 (★★) 基于图 11.20 的汽车燃油系统：现不直接观测  $G$ ，而由驾驶员  $D$  报告读数，且

$$p(D = 1 \mid G = 1) = 0.9, \quad p(D = 0 \mid G = 0) = 0.9.$$

- (1) 仅观测到  $D = 0$ ，求油箱为空 ( $F = 0$ ) 的后验概率。
- (2) 再额外观测到电池没电 ( $B = 0$ )，计算此时油箱为空的概率，并阐述该概率降低的直观原因，与图 11.32 进行对照。

练习 11.15 (★★) 训练 Naive Bayes：设每类条件密度  $p(\mathbf{x}^{(l)} \mid C_k)$  由参数  $\mathbf{w}^{(l)}$  控制。证明极大似然解为：分别对每类使用其标记样本拟合密度，然后先验  $p(C_k)$  取各类在训练集中的相对频率。

练习 11.16 (★★) 考查与图 11.29 的有向图相对应的联合概率分布 (11.44)。请使用概率的加和规则与乘积规则，验证该联合分布对于  $n = 2, \dots, N$  满足条件独立性质 (11.45)。

类似地，证明由联合分布 (11.46) 所描述的二阶马尔可夫模型，对于  $n = 3, \dots, N$  满足如下的条件独立性质：

$$p(\mathbf{x}_n \mid \mathbf{x}_1, \dots, \mathbf{x}_{n-1}) = p(\mathbf{x}_n \mid \mathbf{x}_{n-1}, \mathbf{x}_{n-2}). \quad (11.52)$$

练习 11.17 (★) 请使用第 11.2 节讨论的 d-分离，验证：图 11.29 所示、共含  $N$  个节点的马尔可夫模型，对  $n = 2, \dots, N$  满足条件独立性性质式 (11.45)。同样地，证明：图 11.30 所示、共含  $N$  个节点的模型，对  $n = 3, \dots, N$  满足条件独立性性质式 (11.52)。

练习 11.18 (★) 设二阶 Markov 链如图 11.30。通过将相邻变量配对，证明其可被视作新变量上的一阶 Markov 过程。

练习 11.19 (★) 利用 d-分离，证明图 11.31 的状态-空间模型，对观测序列

$$p(x_1, \dots, x_N)$$

不满足任何有限阶 Markov 条件独立性。

下面将进行详细解答！

## 练习 11.1 解答

依次对各变量做积分（或求和）并加以消去，证明：若有向图的每个条件分布都已归一，则其联合分布的表示式 (11.6) 必然也是归一化的。

设一张包含  $K$  个随机变量的有向无环图 (DAG) 的联合分布因子化为

$$p(x_1, \dots, x_K) = \prod_{k=1}^K p(x_k | \text{pa}(k)), \quad (11.6)$$

其中  $\text{pa}(k)$  为节点  $x_k$  的父节点集合，并已知对每个  $k$  都有

$$\sum_{x_k} p(x_k | \text{pa}(k)) = 1 \quad (\text{或} \quad \int p(x_k | \text{pa}(k)) dx_k = 1).$$

证明：

1. **拓扑排序** 因为图为 DAG，可给节点重新编号，使得父节点编号总小于子节点编号。下文假设  $x_1, \dots, x_K$  恰为这种拓扑序。

2. **递归边缘化** 用符号  $\sum$  同时代表对离散变量求和或对连续变量积分。令

$$P_K = \sum_{x_1, \dots, x_K} \prod_{k=1}^K p(x_k | \text{pa}(k)).$$

消去  $x_K$ ：由于  $x_K$  无子节点，它只出现在单个因子  $p(x_K | \text{pa}(K))$  中，

$$\sum_{x_K} p(x_K | \text{pa}(K)) = 1.$$

故

$$P_K = \sum_{x_1, \dots, x_{K-1}} \left[ \prod_{k=1}^{K-1} p(x_k | \text{pa}(k)) \right] \left( \sum_{x_K} p(x_K | \text{pa}(K)) \right) = P_{K-1}.$$

归纳步骤：假设已将最后  $m$  个变量消去，得到

$$P_{K-m} = \sum_{x_1, \dots, x_{K-m}} \prod_{k=1}^{K-m} p(x_k | \text{pa}(k)).$$

现对  $x_{K-m}$  做同样处理，可得  $P_{K-m} = P_{K-m-1}$ 。

结束：重复上述过程直至  $m = K$ ，全部变量被消去，得到

$$P_0 = 1.$$

因此

$$\sum_{x_1, \dots, x_K} p(x_1, \dots, x_K) = 1,$$

或在连续情形下

$$\int \cdots \int p(x_1, \dots, x_K) dx_1 \cdots dx_K = 1.$$

□

评注：

- 证明只用到两点：(i) 图无环，故可做拓扑排序；(ii) 每个条件分布对自身变量归一。因而对离散、连续或混合变量皆成立。
- 式 (11.6) 可视为链式法则 (chain rule) 的 DAG 版本，本题说明：若各局部分布合法，则链式法则自动给出合法 (归一化) 的联合分布。
- 若存在有向环，则无法选择单调拓扑序，从而上述递推失败；这正与练习 11.2 的结论相呼应。

## 练习 11.2 解答

### 命题

设一幅有向图的结点可重新编号为

$$1, 2, \dots, N,$$

且对每条有向边  $(u \rightarrow v)$  都满足

$$\text{index}(u) < \text{index}(v).$$

则该图不含任何有向环，即它是一张 **DAG** (directed acyclic graph)。

### 证明：

设图  $G = (V, E)$  满足上述编号条件。若存在有向环

$$v_0 \xrightarrow{e_1} v_1 \xrightarrow{e_2} v_2 \xrightarrow{e_3} \cdots \xrightarrow{e_k} v_k = v_0, \quad k \geq 1,$$

其中  $e_i = (v_{i-1} \rightarrow v_i)$ ，则按编号规则

$$\text{index}(v_{i-1}) < \text{index}(v_i), \quad i = 1, \dots, k.$$

从而得到严格递增链

$$\text{index}(v_0) < \text{index}(v_1) < \cdots < \text{index}(v_k).$$

但  $v_k = v_0$  必须满足  $\text{index}(v_k) = \text{index}(v_0)$ ，与严格不等式矛盾。故假设不成立，图中无有向环。  $\square$

**评注：** 编号满足“所有箭头从小号指向大号” 图可作拓扑排序。拓扑排序存在当且仅当图无环，因此“可编号”与“无向环”互为充要。

## 练习 11.3 解答

题目回顾 设  $a, b, c \in \{0, 1\}$  的联合分布如表 2. 证明: (1)  $a$  与  $b$  边缘相关; (2) 给定  $c$  时二者独立。

表 2: 练习 11.3 联合分布

| $a$ | $b$ | $c$ | $p(a, b, c)$ |
|-----|-----|-----|--------------|
| 0   | 0   | 0   | 0.192        |
| 0   | 0   | 1   | 0.144        |
| 0   | 1   | 0   | 0.048        |
| 0   | 1   | 1   | 0.216        |
| 1   | 0   | 0   | 0.192        |
| 1   | 0   | 1   | 0.064        |
| 1   | 1   | 0   | 0.048        |
| 1   | 1   | 1   | 0.096        |

### 1 边缘相关性

$$p_{00} = p(a=0, b=0) = 0.192 + 0.144 = 0.336, \quad p(a=0) = 0.600, \quad p(b=0) = 0.592.$$

若  $a, b$  独立应有  $p_{00} = 0.600 \times 0.592 = 0.3552 \neq 0.336$ , 故  $a, b$  边缘相关。

### 2 条件独立性

(a)  $c = 0$ .

$$p(c=0) = 0.48, \quad p(a, b \mid c=0) = \frac{p(a, b, c=0)}{0.48} = \begin{cases} 0.40, & (0, 0) \\ 0.10, & (0, 1) \\ 0.40, & (1, 0) \\ 0.10, & (1, 1) \end{cases}$$

$$p(a \mid c=0) = 0.5, \quad p(b \mid c=0) = 0.8.$$

验证可得  $p(a, b \mid c=0) = p(a \mid c=0)p(b \mid c=0)$ 。

(b)  $c = 1$ .

$$p(c = 1) = 0.52, \quad p(a, b \mid c = 1) = \frac{p(a, b, c = 1)}{0.52} = \begin{cases} 0.276923, \\ 0.415385, \\ 0.123077, \\ 0.184615 \end{cases}$$

$$p(a \mid c = 1) = 0.692307, \quad p(b \mid c = 1) = 0.4.$$

同样满足  $p(a, b \mid c = 1) = p(a \mid c = 1)p(b \mid c = 1)$ , 说明给定  $c$  时  $a, b$  条件独立。

### 3 结论

$$p(a, b) \neq p(a)p(b), \quad p(a, b \mid c) = p(a \mid c)p(b \mid c) \ (c = 0, 1).$$

证毕。

□



## 练习 11.4 解答 (★★)

题目 (见表 11.1) 计算  $p(a)$ ,  $p(b | c)$ ,  $p(c | a)$ , 验证  $p(a, b, c) = p(a)p(c | a)p(b | c)$ , 并画出对应的有向图。

### 1 边缘分布 $p(a)$

| $a$ | 行概率求和                           | $p(a)$      |
|-----|---------------------------------|-------------|
| 0   | $0.192 + 0.144 + 0.048 + 0.216$ | <b>0.60</b> |
| 1   | $0.192 + 0.064 + 0.048 + 0.096$ | <b>0.40</b> |

### 2 条件分布 $p(c | a)$

$$p(c = 0 | a) = \frac{\sum_b p(a, b, 0)}{p(a)}, \quad p(c = 1 | a) = 1 - p(c = 0 | a).$$

| $a$ | $\sum_b p(a, b, 0)$     | $p(c = 0   a)$ | $p(c = 1   a)$ |
|-----|-------------------------|----------------|----------------|
| 0   | $0.192 + 0.048 = 0.240$ | <b>0.40</b>    | 0.60           |
| 1   | $0.192 + 0.048 = 0.240$ | <b>0.60</b>    | 0.40           |

### 3 条件分布 $p(b | c)$

先得  $p(c = 0) = 0.48$ ,  $p(c = 1) = 0.52$ 。

| $c$ | $\sum_a p(a, 0, c)$     | $p(b = 0   c)$ | $p(b = 1   c)$ |
|-----|-------------------------|----------------|----------------|
| 0   | $0.192 + 0.192 = 0.384$ | <b>0.80</b>    | 0.20           |
| 1   | $0.144 + 0.064 = 0.208$ | <b>0.40</b>    | 0.60           |


### 4 验证乘积分解

| $(a, b, c)$ | $p(a)$ | $p(c   a)$ | $p(b   c)$ | 乘积           | 表 11.1 |
|-------------|--------|------------|------------|--------------|--------|
| 0,0,0       | 0.60   | 0.40       | 0.80       | <b>0.192</b> | 0.192  |
| 0,0,1       | 0.60   | 0.60       | 0.40       | <b>0.144</b> | 0.144  |
| 0,1,0       | 0.60   | 0.40       | 0.20       | <b>0.048</b> | 0.048  |
| 0,1,1       | 0.60   | 0.60       | 0.60       | <b>0.216</b> | 0.216  |
| 1,0,0       | 0.40   | 0.60       | 0.80       | <b>0.192</b> | 0.192  |
| 1,0,1       | 0.40   | 0.40       | 0.40       | <b>0.064</b> | 0.064  |
| 1,1,0       | 0.40   | 0.60       | 0.20       | <b>0.048</b> | 0.048  |
| 1,1,1       | 0.40   | 0.40       | 0.60       | <b>0.096</b> | 0.096  |

$$p(a, b, c) = p(a)p(c | a)p(b | c)$$

## 5 对应的有向图

因子化结构：  $a \rightarrow c \rightarrow b$ 。



总结 (1)  $p(a) = \{0.60, 0.40\}$ ; (2)  $p(c | a)$  与  $p(b | c)$  如上表; (3) 乘积分解完全成立, 对应 DAG 如上。

## 练习 11.5 解答 (★)

**题目要点** 本题探讨图 11.6 所示模型，其包含  $M$  个二元父结点  $\mathbf{x} = (x_1, \dots, x_M)$  ( $x_i \in \{0, 1\}$ ) 与一个二元子结点  $y \in \{0, 1\}$ 。Pearl (1988) 提出了如下所示的 *noisy-OR* (含噪或) 条件分布模型：

$$p(y = 1 \mid \mathbf{x}) = 1 - (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i}. \quad (1)$$

题干的字面描述将参数  $\mu_i$  定义为父节点的边缘概率  $p(x_i = 1)$ 。然而，要理解此公式的内在生成机理，通常将  $\mu_i$  解释为“连边概率” (link probability)，即当原因  $x_i = 1$  存在时，它能成功触发结果  $y = 1$  的概率。本解答将基于后一种更通用的生成式解释来证明其性质，并视题干的描述为一种施加在模型上的特殊参数共享约束。参数  $\mu_0$  为“泄露 (leak)”或背景触发概率。本解答旨在证明式 (1) 是逻辑“或” (OR) 的概率化版本，并深入讨论其参数含义。

### 1 生成式解释与模型推导

该模型可通过一个独立的“因果成功/失败”生成过程来精确描述和推导。

- (1) **引入潜在“因果开关”**：对每个父变量  $x_i$  引入一个潜在的二元“开关”变量  $z_i \in \{0, 1\}$ ，并引入一个代表背景原因的“漏开关”  $z_0 \in \{0, 1\}$ 。
- (2) **定义开关概率（连边概率）**：设这些开关成功的概率（即“连边概率”）分别为：

$$\Pr(z_i = 1) = \mu_i \quad (i = 1, \dots, M), \quad \Pr(z_0 = 1) = \mu_0.$$

并假设所有这些开关  $z_0, z_1, \dots, z_M$  在给定  $\mathbf{x}$  时相互独立。

- (3) **定义输出逻辑**：子结点  $y$  的值被定义为：只要背景开关成功，或者任何一个在场的父节点 ( $x_i = 1$ ) 对应的开关成功，则  $y = 1$ 。用数学语言表达为：

$$y = \mathbb{I}(z_0 = 1 \text{ 或 } \exists i \text{ 使得 } x_i = 1 \text{ 且 } z_i = 1).$$

其中  $\mathbb{I}(\cdot)$  是指示函数。

- (4) **推导  $p(y = 1 \mid \mathbf{x})$** ： $y = 0$  发生的唯一可能是所有相关机制全部失败：即  $z_0$  失败，且对于所有  $x_i = 1$  的父节点，其对应的  $z_i$  也失败。根据独立性假设：

$$\begin{aligned} p(y = 0 \mid \mathbf{x}) &= \Pr(z_0 = 0, \text{ 且对所有满足 } x_i = 1 \text{ 的 } i, z_i = 0) \\ &= \Pr(z_0 = 0) \prod_{i: x_i = 1} \Pr(z_i = 0) \\ &= (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i}. \end{aligned}$$

取其补事件的概率，即得最终的 noisy-OR 公式：

$$p(y = 1 \mid \mathbf{x}) = 1 - p(y = 0 \mid \mathbf{x}) = 1 - (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i}.$$

这个推导清晰地表明，该模型是“各有效原因独立尝试激活输出，只要任一成功，输出即为1”这一物理过程的直接数学体现。

## 2 “软 OR” 性质与极限情况

- **单调性：** 将任一  $x_i$  从 0 置为 1 时， $p(y = 1 \mid \mathbf{x})$  的增量为：

$$\Delta_i = (1 - \mu_0) \left[ \prod_{j \neq i} (1 - \mu_j)^{x_j} \right] \mu_i \geq 0.$$

因为增量非负，所以激活任何一个父变量都会单调不减地提高输出为 1 的概率。这正是对逻辑 OR 的“软化”表达。

- **退化到确定性 OR：** 在极限情况下，若设置  $\mu_0 = 0$  (无泄露) 且所有  $\mu_i = 1$  (原因100%有效)，则模型退化为：

$$p(y = 1 \mid \mathbf{x}) = 1 - \prod_{i=1}^M (1 - 1)^{x_i} = \begin{cases} 0, & \text{若所有 } x_i = 0, \\ 1, & \text{若存在 } x_i = 1. \end{cases}$$

这与确定性的逻辑 OR 函数  $\text{OR}(x_1, \dots, x_M)$  完全等价。

## 3 参数 $\mu_0$ 的含义与讨论

- **Leak (泄露) 概率：**  $\mu_0$  是在所有显式原因都缺席时 ( $\mathbf{x} = \mathbf{0}$ )， $y$  仍被激活的概率：

$$\mu_0 = p(y = 1 \mid \mathbf{x} = \mathbf{0}).$$

它代表了所有模型外未显式建模的背景原因或随机噪声的综合影响。

- **类比与解释：**  $\mu_0$  的角色类似于：
  - 在 OR 门上接入一个永远开启的虚拟父结点  $x_0 \equiv 1$ ，其连边成功概率为  $\mu_0$ 。
  - 逻辑回归模型中的偏置项（或截距），决定了当所有输入特征为零时的基准输出概率。
- **典型取值：**
  - $\mu_0 = 0$ : 无泄露。 $y = 1$  的发生必然归因于至少一个  $x_i = 1$ 。
  - $\mu_0 \rightarrow 1$ : 强泄露。 $y$  几乎必然为 1，此时模型对输入  $\mathbf{x}$  基本没有响应。

综上，式 (1) 精确描述了一个带有背景泄露的、各原因独立起作用的概率“或”模型。

## 练习 11.6 解答 (★★)

题目 在线性-高斯图模型中, 每个节点  $x_i$  的条件分布设为

$$p(x_i \mid \text{pa}(i)) = \mathcal{N}\left(x_i \mid \underbrace{\sum_{j \in \text{pa}(i)} w_{ij} x_j + b_i}_{\text{条件均值}}, v_i\right), \quad (11.9)$$

其中  $\text{pa}(i)$  是  $x_i$  的父节点集合,  $w_{ij}$ 、 $b_i$  为参数,  $v_i$  为条件方差。要求推出均值递推关系

$$\boxed{\mu_i = \sum_{j \in \text{pa}(i)} w_{ij} \mu_j + b_i} \quad (i = 1, \dots, D), \quad (11.12)$$

其中  $\mu_k = \mathbb{E}[x_k]$ 。

### 1 全期望公式

$$\mu_i = \mathbb{E}[x_i] = \mathbb{E}_{\text{pa}(i)}[\mathbb{E}[x_i \mid \text{pa}(i)]].$$

### 2 代入条件均值并利用期望线性性

$$\begin{aligned} \mu_i &= \mathbb{E}_{\text{pa}(i)} \left[ \sum_{j \in \text{pa}(i)} w_{ij} x_j + b_i \right] \\ &= \sum_{j \in \text{pa}(i)} w_{ij} \underbrace{\mathbb{E}[x_j]}_{\mu_j} + b_i = \sum_{j \in \text{pa}(i)} w_{ij} \mu_j + b_i, \end{aligned}$$

即得递推式 (11.12)。 □

### 3 如何使用递推式

按拓扑序遍历 DAG:

1. 根节点（无父节点）的均值直接为其偏置:  $\mu_i = b_i$ ; 2. 之后节点按 (11.12) 逐一求出, 直到得到整张图的均值向量  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_D)^\top$ 。

## 练习 11.7 解答 (★★)

题目 在线性-高斯图模型中, 从条件分布

$$p(x_j \mid \text{pa}(j)) = \mathcal{N}\left(x_j \mid \sum_{k \in \text{pa}(j)} w_{jk} x_k + b_j, v_j\right) \quad (11.9)$$

推导联合协方差递推式

$$\boxed{\text{cov}[x_i, x_j] = \sum_{k \in \text{pa}(j)} w_{jk} \text{cov}[x_i, x_k] + \delta_{ij} v_j} \quad (i, j = 1, \dots, D), \quad (11.13)$$

其中  $\delta_{ij}$  为 Kronecker 符号。

### 1 把条件分布改写为显式噪声模型

设

$$x_j = \underbrace{\sum_{k \in \text{pa}(j)} w_{jk} x_k + b_j}_{\text{线性部分}} + \varepsilon_j, \quad \varepsilon_j \sim \mathcal{N}(0, v_j),$$

且  $\varepsilon_j$  与  $\text{pa}(j)$  独立。

### 2 计算协方差 $\Sigma_{ij}$

$$\begin{aligned} \Sigma_{ij} &:= \text{cov}[x_i, x_j] \\ &= \text{cov}\left[x_i, \sum_{k \in \text{pa}(j)} w_{jk} x_k + \varepsilon_j\right] \\ &= \sum_{k \in \text{pa}(j)} w_{jk} \underbrace{\text{cov}[x_i, x_k]}_{\Sigma_{ik}} + \underbrace{\text{cov}[x_i, \varepsilon_j]}_{0 \text{ 若 } i \neq j}. \end{aligned}$$

\* 若  $i \neq j$ ,  $\varepsilon_j$  与  $x_i$  独立, 故该项为 0; \* 若  $i = j$ ,  $\text{cov}[x_j, \varepsilon_j] = \text{var}[\varepsilon_j] = v_j$ 。

因此得到递推关系 (11.13)。  $\square$

### 3 计算策略 (与均值递推配合)

1. 按 DAG 的拓扑序自下而上 (父  $\rightarrow$  子) 填表: **对角元** 先设  $\Sigma_{ii} = v_i$  (根节点) 或用 (11.13) 计算。 **非对角元** 对每一对子  $i < j$  用 (11.13)。 2. 整理得联合协方差矩阵  $\Sigma$ 。

这样即可与练习 11.6 的均值递推一起, 递归求出整张图的多元高斯参数。

## 练习 11.8 解答 (★★)

**题目** 证明：由式 (11.9) 定义、含  $D$  个变量的完全连通线性-高斯图模型，其联合分布的协方差矩阵所含独立参数个数为

$$\frac{D(D+1)}{2}.$$

### 1 结构方程与协方差形式

按拓扑序给结点重新编号，使得完全连通意味着  $\text{pa}(i) = \{1, \dots, i-1\}$ . 去均值后（不影响协方差），式 (11.9) 等价于结构方程

$$x_i = \sum_{j < i} w_{ij} x_j + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, v_i), \quad \varepsilon \text{ 彼此独立.}$$

令  $W = [w_{ij}]$  为严格下三角矩阵（对角为零）， $V = \text{diag}(v_1, \dots, v_D)$ 。写成向量式：

$$(\mathbf{I} - W) \mathbf{x} = \boldsymbol{\varepsilon}, \quad \Rightarrow \quad \mathbf{x} = (\mathbf{I} - W)^{-1} \boldsymbol{\varepsilon}.$$

于是联合协方差为

$$\Sigma = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] = (\mathbf{I} - W)^{-1} V (\mathbf{I} - W)^{-\top}. \quad (2)$$

### 2 参数计数的上界： $D(D+1)/2$

完全连通时， $W$  在对角线下共有  $\frac{D(D-1)}{2}$  个自由参数， $V$  有  $D$  个对角参数。由 (2) 可知  $\Sigma$  完全由  $\{w_{ij} : i > j\}$  与  $\{v_i\}$  决定，因此协方差矩阵至多含有

$$\frac{D(D-1)}{2} + D = \frac{D(D+1)}{2}$$

个独立自由度。

### 3 可达性（下界）：与 Cholesky 分解一一对应

对任意对称正定协方差矩阵  $\Sigma$ ，取其 Cholesky 分解

$$\Sigma = LL^\top, \quad L \text{ 为下三角且 } \ell_{ii} > 0.$$

令  $D^{1/2} = \text{diag}(\ell_{11}, \dots, \ell_{DD})$ ，取

$$(\mathbf{I} - W)^{-1} \stackrel{\text{定义}}{=} L D^{-1/2}, \quad V \stackrel{\text{定义}}{=} D^{1/2} D^{1/2} = \text{diag}(\ell_{11}^2, \dots, \ell_{DD}^2).$$

注意  $L D^{-1/2}$  为下三角且对角恒等于 1（因  $\ell_{ii}/\ell_{ii} = 1$ ），故存在唯一的严格下三角矩阵  $W = \mathbf{I} - (L D^{-1/2})^{-1}$ 。由此代回 (2) 立得

$$(\mathbf{I} - W)^{-1} V (\mathbf{I} - W)^{-\top} = (L D^{-1/2}) D (L D^{-1/2})^\top = LL^\top = \Sigma.$$

这表明：对任意  $\Sigma \succ 0$ ，都能唯一地选取参数  $(W, V)$  使 (2) 成立。因此模型对  $\Sigma$  的参数化与 Cholesky 分解同构，其自由度正是下三角矩阵  $L$  的参数个数，即  $D$ （对角）+  $\frac{D(D-1)}{2}$ （下三角）=  $\frac{D(D+1)}{2}$ 。

## 4 结论

在完全连通的线性-高斯图模型中，联合协方差矩阵不受额外约束，具有一般对称正定矩阵的全部自由度；其独立参数个数恰为

$$\boxed{\frac{D(D+1)}{2}}.$$

□



## 练习 11.9 解答 (★★)

题目 利用递推公式

$$\mathbb{E}[x_i] = \sum_{j \in \text{pa}(i)} w_{ij} \mathbb{E}[x_j] + b_i \quad (11.12)$$

$$\text{cov}[x_i, x_j] = \sum_{k \in \text{pa}(j)} w_{jk} \text{cov}[x_i, x_k] + \delta_{ij} v_j \quad (11.13)$$

求出图 11.7 ( $x_1 \rightarrow x_2 \rightarrow x_3$ , 缺边  $x_1 \not\rightarrow x_3$ ) 的联合均值向量  $\boldsymbol{\mu}$  与协方差矩阵  $\Sigma$ , 并验证它们与教材公式 (11.14)、(11.15) 一致。

### 1 均值递推

递推式 (11.12)  $\mu_j = \sum_{k \in \text{pa}(j)} w_{jk} \mu_k + b_j$  从最根部结点开始:

$$\mu_1 = b_1,$$

$$\mu_2 = w_{21} \mu_1 + b_2 = b_2 + w_{21} b_1,$$

$$\mu_3 = w_{32} \mu_2 + b_3 = b_3 + w_{32} b_2 + w_{32} w_{21} b_1.$$

$$\boldsymbol{\mu} = (b_1, b_2 + w_{21} b_1, b_3 + w_{32} b_2 + w_{32} w_{21} b_1)^\top \quad (11.14)$$

### 2 协方差递推

记  $\Sigma_{ij} = \text{cov}[x_i, x_j]$ ; (11.13) 给出  $\Sigma_{ij} = \sum_{k \in \text{pa}(j)} w_{jk} \Sigma_{ik} + \delta_{ij} v_j$ .

(a) 第一列 / 行:

$$\Sigma_{11} = v_1, \quad \Sigma_{21} = w_{21} \Sigma_{11} = w_{21} v_1, \quad \Sigma_{31} = w_{32} \Sigma_{21} = w_{32} w_{21} v_1.$$

(b) 第二列 / 行:

$$\Sigma_{22} = w_{21} \Sigma_{21} + v_2 = v_2 + w_{21}^2 v_1, \quad \Sigma_{32} = w_{32} \Sigma_{22} = w_{32} (v_2 + w_{21}^2 v_1).$$

(c) 第三对角元:

$$\Sigma_{33} = w_{32} \Sigma_{32} + v_3 = v_3 + w_{32}^2 (v_2 + w_{21}^2 v_1).$$

$$\Sigma = \begin{pmatrix} v_1 & w_{21} v_1 & w_{32} w_{21} v_1 \\ w_{21} v_1 & v_2 + w_{21}^2 v_1 & w_{32} (v_2 + w_{21}^2 v_1) \\ w_{32} w_{21} v_1 & w_{32} (v_2 + w_{21}^2 v_1) & v_3 + w_{32}^2 (v_2 + w_{21}^2 v_1) \end{pmatrix} \quad (11.15)$$

### 3 结论

所得  $\mu$  与  $\Sigma$  完全符合教材公式 (11.14)、(11.15)，故递推关系 (11.12)、(11.13) 对图 11.7 的线性-高斯模型适用。  $\square$

## 练习 11.10 解答 (★)

题目 设一张有向无环图的每个结点  $x_i \in \mathbb{R}^{d_i}$  (允许不同维度), 且条件分布为

$$p(x_i | \text{pa}(i)) = \mathcal{N}(x_i \mid \mathbf{W}_{ij}x_j + b_i, \Sigma_i), \quad (11.16)$$

其中  $\mathbf{W}_{ij}$  为矩阵 (若  $x_j$  维度与  $x_i$  不同则是非方阵),  $b_i$  为偏置向量,  $\Sigma_i \succ 0$  为协方差矩阵, 且  $\text{pa}(i)$  表示所有父结点的集合。证明所有结点的联合分布  $p(x_1, \dots, x_D)$  依然是一个高斯分布。

### 1 写出联合对数密度

由于图为 DAG, 联合分布因子化为

$$\ln p(\mathbf{x}) = \sum_{i=1}^D \ln p(x_i | \text{pa}(i)) = -\frac{1}{2} \sum_{i=1}^D (x_i - \mu_i)^\top \Sigma_i^{-1} (x_i - \mu_i) + \text{const},$$

其中  $\mu_i = \sum_{j \in \text{pa}(i)} \mathbf{W}_{ij}x_j + b_i$  为条件均值。

### 2 展开得到整体二次型

将所有结点拼成长向量  $\mathbf{x} = (x_1^\top, \dots, x_D^\top)^\top$  并按拓扑序逐项展开:

$$\begin{aligned} \sum_{i=1}^D (x_i - \mu_i)^\top \Sigma_i^{-1} (x_i - \mu_i) &= \underbrace{\sum_{i=1}^D x_i^\top \Sigma_i^{-1} x_i}_{\text{纯二次项}} - 2 \sum_{i=1}^D x_i^\top \Sigma_i^{-1} \left( \sum_{j \in \text{pa}(i)} \mathbf{W}_{ij}x_j \right) \\ &\quad + \sum_{i=1}^D \left( \sum_{j \in \text{pa}(i)} \mathbf{W}_{ij}x_j + b_i \right)^\top \Sigma_i^{-1} \left( \sum_{k \in \text{pa}(i)} \mathbf{W}_{ik}x_k + b_i \right). \end{aligned}$$

该表达式仅含  $\mathbf{x}$  的二次项 ( $x_k^\top A x_\ell$ ) 和一次项 ( $c^\top \mathbf{x}$ ), 不含更高次幂; 常数项被吸收到 “const’”。因此

$$\ln p(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^\top A \mathbf{x} + c^\top \mathbf{x} + \text{const},$$

其中  $A$  为对称正定矩阵 (因各  $\Sigma_i^{-1} \succ 0$  且加权求和保持正定)。这正是多元高斯分布的标准对数形式:

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid A^{-1}c, A^{-1}).$$

### 3 结论

无论各结点是标量还是  $d_i$  维向量, 只要满足条件 (11.16) (线性均值 + 高斯噪声), 整张图的联合分布必为一个多元高斯分布, 均值与协方差可由矩阵  $A^{-1}c$ 、 $A^{-1}$  显式给出。□

## 练习 11.11 解答 (★)

命题 若

$$a \perp\!\!\!\perp \{b, c\} \mid d, \quad (\text{P})$$

则必有

$$a \perp\!\!\!\perp b \mid d. \quad (\text{C})$$

### 1 概率定义证明

由 (P) 的条件独立定义,

$$p(a, b, c \mid d) = p(a \mid d) p(b, c \mid d). \quad (1)$$

两边对  $c$  求和 / 积分

$$\sum_c p(a, b, c \mid d) = p(a, b \mid d) \quad \text{且} \quad \sum_c p(b, c \mid d) = p(b \mid d).$$

将式 (1) 对  $c$  求和得

$$p(a, b \mid d) = p(a \mid d) p(b \mid d),$$

这正是 (C) 的定义形式, 故命题得证。  $\square$

### 2 图论视角 (半 Graphoid 公理)

在信息图论中, 条件独立满足 分解 (*decomposition*) 公理:

$$X \perp\!\!\!\perp Y \cup Z \mid W \implies X \perp\!\!\!\perp Y \mid W \quad \text{及} \quad X \perp\!\!\!\perp Z \mid W.$$

令  $X = a, Y = b, Z = c, W = d$  即可得到所需结论。这一公理连同对称、弱并、收缩等, 统称为 半 Graphoid 性质。

### 3 小结

无论经由概率定义还是半 Graphoid 公理, 都可直接推出  $a \perp\!\!\!\perp b, c \mid d \implies a \perp\!\!\!\perp b \mid d$ 。因此命题成立。

## 练习 11.12 解答 (★)

**题目** 使用 d-分离 (d-separation) 证明: 在有向图中, 若对节点  $x_i$  条件于其 *Markov* 毯 (父、子及子之父), 则  $x_i$  与图中其余所有变量独立。

### 1 Markov 毯的定义

$$\mathcal{M}(x_i) = \underbrace{\text{pa}(x_i)}_{\text{父}} \cup \underbrace{\text{ch}(x_i)}_{\text{子}} \cup \underbrace{(\text{pa}(\text{ch}(x_i)) \setminus \{x_i\})}_{\text{子之父}}.$$

### 2 d-分离判定回顾

给定节点集  $Z$ , 一条无向路径被阻断当且仅当

- (i) 路径上存在 链/分叉 节点落在  $Z$  中; 或
- (ii) 路径上存在 合流 (*v-structure*) 节点不在  $Z$  中, 且其后代均不在  $Z$  中。

### 3 阻断所有连至 $x_i$ 的路径

令  $Z = \mathcal{M}(x_i)$ , 对连接  $x_i$  与任意  $y \notin \{x_i\} \cup Z$  的无向路径分类:

#### (a) 经父节点进入 $x_i$

$$\cdots \rightarrow \text{父}(x_i) \rightarrow x_i.$$

父节点  $\in Z$ , 属 (i), 路径阻断。

#### (b) 从 $x_i$ 经子节点离开

$$x_i \rightarrow \text{子}(x_i) \rightarrow \cdots.$$

子节点  $\in Z$ , 属 (i), 路径阻断。

#### (c) 以子节点为合流

$$\text{共父} \rightarrow \text{子}(x_i) \leftarrow x_i.$$

子节点  $\in Z$ , v-结构被激活, 但共父亦  $\in Z$ , 作为链节点再度阻断。

**(d) 其它更长路径** 任何路径最终都会首次遇到 (a)–(c) 中的某类节点, 因此同样被阻断。

故给定  $Z$  后,  $x_i$  与所有  $y \notin \{x_i\} \cup Z$  之间无未阻断路径, 得到

$$x_i \perp\!\!\!\perp y \mid \mathcal{M}(x_i).$$

## 4 概率意义与因子分解说明

由 d-分离得到的独立性可写为


$$p\left(x_i \mid \mathcal{M}(x_i), \mathbf{x}_{\setminus(\{x_i\} \cup \mathcal{M}(x_i))}\right) = p(x_i \mid \mathcal{M}(x_i)).$$

补充说明：亦可从联合分布的因子分解  $p(\mathbf{x}) = \prod_k p(x_k \mid \text{pa}(k))$  出发，在  $p(x_i \mid \mathbf{x}_{\setminus i}) = \frac{p(\mathbf{x})}{\int p(\mathbf{x}) dx_i}$  中将与  $x_i$  无关的因子于分子、分母相抵，直接得到  $p(x_i \mid \mathbf{x}_{\setminus i}) = p(x_i \mid \mathcal{M}(x_i))$ ，与 Figure 11.25 的文字解释完全一致。  $\square$

## 练习 11.13 解答 (★)

题目 如图 11.32 所示的有向图中，四个变量  $a, b, c, d$  均未观测。

- (a) 证明在此情形下  $a \perp\!\!\!\perp b \mid \emptyset$ ;
- (b) 若观测后代  $d$ ，说明一般情况下  $a \not\perp\!\!\!\perp b \mid d$ 。



如上，图 11.32 由一个 头-对-头 (collider) 结构  $a \rightarrow c \leftarrow b$  及其后代  $c \rightarrow d$  组成。

### 1 未观测时： $a \perp b$

在有向图中，若路径  $\dots \rightarrow c \leftarrow \dots$  的合流节点 及其任一后代 均未被观测，该路径被 d-分离规则阻断。此处从  $a$  到  $b$  的唯一无向路径为

$$a \rightarrow c \leftarrow b.$$

因为既未观测  $c$  也未观测其后代  $d$ ，故路径封闭；于是

$$a \perp\!\!\!\perp b \mid \emptyset.$$

### 2 观测后代 $d$ ：路径被激活

观测  $d$  等价于将  $d \in Z$  置入条件集。d-分离规则对“合流”给出：

- 若合流节点自身 或其某个后代 被观测，则合流路径被“激活”而不再阻断。

由于  $d$  是  $c$  的后代，条件化  $d$  会激活  $a \rightarrow c \leftarrow b$  这一条路径。从而  $a$  与  $b$  之间出现未阻断路径，一般导致

$$a \not\perp\!\!\!\perp b \mid d.$$

(只有在特殊对称参数或概率取值下才可能“意外”保持独立。)

### 3 概率层面的直观推导

图的因子分解为

$$p(a, b, c, d) = p(a) p(b) p(c \mid a, b) p(d \mid c).$$

(i) 未观测 边缘化  $c, d$ :

$$p(a, b) = \iint p(a) p(b) p(c | a, b) p(d | c) dc dd = p(a) p(b) \implies a \perp b.$$

(ii) 给定  $d$

$$p(a, b | d) = \frac{\int p(a) p(b) p(c | a, b) p(d | c) dc}{\iint p(a) p(b) p(c | a, b) p(d | c) da db dc}.$$

由于  $p(c | a, b)$  依赖  $(a, b)$ , 分子中的  $(a, b)$  不再可分离, 故一般  $p(a, b | d) \neq p(a | d) p(b | d)$ ; 即  $a$  与  $b$  不独立。  $\square$



## 练习 11.14 解答 (★★)

题目 在图 11.20 的汽车燃油系统中，三元二值随机变量分别为

$$B \in \{0, 1\}, \quad F \in \{0, 1\}, \quad G \in \{0, 1\},$$

其中  $B$  表示电池是否有电 (1=有电)， $F$  表示油箱是否加满 (1=满油)， $G$  为电动油表读数 (1=显示满油)。先验独立且

$$p(B = 1) = p(F = 1) = 0.9.$$

给定  $(B, F)$  时油表的可靠性为 (见教材 Figure 11.20)

|                       | $F = 1$ | $F = 0$ |                                    |
|-----------------------|---------|---------|------------------------------------|
| $B = 1: p(G=1 \cdot)$ | 0.8     | 0.2     | $p(G=0 \cdot) = 1 - p(G=1 \cdot).$ |
| $B = 0: p(G=1 \cdot)$ | 0.2     | 0.1     |                                    |

现在不再直接观测  $G$ ，而是由驾驶员  $D$  读表后向我们口头报告：

$$p(D = 0 | G = 0) = 0.9, \quad p(D = 0 | G = 1) = 0.1. \quad (11.50-11.51)$$

- (1) 已观测  $D = 0$  (司机报告“空”)，计算油箱为空  $F = 0$  的后验概率。
- (2) 若再额外观测电池没电  $B = 0$ ，计算  $p(F = 0 | D = 0, B = 0)$ ，并解释两者差异，将结果与图 11.32 的“解释消除”现象联系起来。

网络结构与概率表

$$B \longrightarrow G \longleftarrow F, \quad G \longrightarrow D.$$

- 先验独立：  $p(B = 1) = p(F = 1) = 0.9 \Rightarrow p(B = 0) = p(F = 0) = 0.1$ .
- 电动油表  $G$  的可靠性 (教材 Figure 11.20)

|                         | $F = 1$ | $F = 0$ |                                        |
|-------------------------|---------|---------|----------------------------------------|
| $B = 1: p(G = 1 \cdot)$ | 0.8     | 0.2     | $p(G = 0 \cdot) = 1 - p(G = 1 \cdot).$ |
| $B = 0: p(G = 1 \cdot)$ | 0.2     | 0.1     |                                        |

- 司机  $D$  读取油表：  $p(D = 0 | G = 0) = 0.9, p(D = 0 | G = 1) = 0.1$  (式 11.50-11.51)。

(1) 仅观测  $D = 0$ ：求  $p(F = 0 \mid D = 0)$

① 计算  $p(D = 0)$

$$\begin{aligned} p(D = 0) &= \sum_{b,f} p(b) p(f) \left[ 0.9 p(G = 0 \mid b, f) + 0.1 p(G = 1 \mid b, f) \right] \\ &= 0.352. \end{aligned}$$

② 计算联合  $p(F = 0, D = 0)$

$$\begin{aligned} p(F = 0, D = 0) &= \sum_b p(b) p(F = 0) \left[ 0.9 p(G = 0 \mid b, F = 0) + 0.1 p(G = 1 \mid b, F = 0) \right] \\ &= 0.0748. \end{aligned}$$

③ 后验概率

$$p(F = 0 \mid D = 0) = \frac{0.0748}{0.352} \approx 0.2125.$$

(2) 再观测  $B = 0$ ：求  $p(F = 0 \mid D = 0, B = 0)$

$$\begin{aligned} p(B = 0, D = 0) &= \sum_f p(B = 0) p(f) \left[ 0.9 p(G = 0 \mid B = 0, f) + 0.1 p(G = 1 \mid B = 0, f) \right] \\ &= 0.0748, \end{aligned}$$

$$p(F = 0, B = 0, D = 0) = 0.0082.$$

$$p(F = 0 \mid D = 0, B = 0) = \frac{0.0082}{0.0748} \approx 0.109.$$

(3) 直觉及与 Figure 11.32 的关联

- $p(F = 0 \mid D = 0) = 0.2125 > p(F = 0) = 0.1$ ：司机报“油表空”提高了油箱为空的可信度。
- 当再得知  $B = 0$ （电池没电）时， $p(F = 0 \mid D = 0, B = 0) = 0.109$  甚至低于 0.2125，这正是“解释消除”（explaining-away）效应。
- 图 11.32 对应结构  $B \rightarrow G \leftarrow F, G \rightarrow D$ 。观测后代  $D$  打开了  $B$  与  $F$  之间通过合流点  $G$  的依赖路径；进一步观测  $B = 0$  抑制了“油箱空”这一备选解释，因此后验概率下降。

□

## 练习 11.15 解答 (★)

**题目** 在朴素贝叶斯 (Naive Bayes) 模型中, 设输入向量  $\mathbf{x} = (x^{(1)}, \dots, x^{(L)})^\top$  属于  $K$  个类之一,  $C_k, k = 1, \dots, K$ 。对每个类  $C_k$ , 假设条件密度分解为

$$p(\mathbf{x} | C_k) = \prod_{l=1}^L p(x^{(l)} | C_k; w_k^{(l)}), \quad (11.37)$$

且每一因子由互不共享的独立参数  $w_k^{(l)}$  控制。证明: 极大似然 (ML) 训练只需

1. 分别对每个类  $C_k$  用其训练样本  $\mathcal{D}_k = \{\mathbf{x}_n : t_n = k\}$  最大化  $\prod_{\mathbf{x} \in \mathcal{D}_k} p(\mathbf{x} | C_k)$  以估计  $\hat{\mathbf{w}}_k$ ; 2. 类先验取为该样本在训练集中的相对频率  $\hat{\pi}_k = N_k/N$  (其中  $N_k = |\mathcal{D}_k|$ ,  $N$  为总样本数)。

### 1 记号与完整对数似然

$$\mathcal{D} = \{(\mathbf{x}_n, t_n)\}_{n=1}^N, \quad t_n \in \{1, \dots, K\}.$$

记  $\pi_k := p(C_k)$ ,  $\mathbf{w}_k := (w_k^{(1)}, \dots, w_k^{(L)})$ 。则联合似然

$$\mathcal{L}(\{\pi_k\}, \{\mathbf{w}_k\}) = \prod_{n=1}^N p(\mathbf{x}_n, t_n) = \prod_{n=1}^N \pi_{t_n} p(\mathbf{x}_n | C_{t_n}; \mathbf{w}_{t_n}).$$

取对数并按类汇总

$$\ln \mathcal{L} = \sum_{k=1}^K \underbrace{\left[ \sum_{\mathbf{x} \in \mathcal{D}_k} \ln p(\mathbf{x} | C_k; \mathbf{w}_k) + N_k \ln \pi_k \right]}_{\text{仅含 } \mathbf{w}_k}. \quad (1)$$

### 2 优化类条件参数 $\mathbf{w}_k$

式 (1) 中每一项  $\sum_{\mathbf{x} \in \mathcal{D}_k} \ln p(\mathbf{x} | C_k; \mathbf{w}_k)$  只依赖类  $k$  的数据与参数, 彼此独立。因此可分别求

$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w}_k} \prod_{\mathbf{x} \in \mathcal{D}_k} p(\mathbf{x} | C_k; \mathbf{w}_k) \quad (k = 1, \dots, K). \quad (2)$$

### 3 优化类先验 $\pi_k$

加入约束  $\sum_k \pi_k = 1$  的拉格朗日函数

$$\mathcal{J} = \sum_{k=1}^K N_k \ln \pi_k + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right).$$

对  $\pi_k$  求偏导并置零:  $\partial \mathcal{J} / \partial \pi_k = N_k / \pi_k + \lambda = 0 \Rightarrow \pi_k = -N_k / \lambda$ . 由约束得  $\lambda = -N$ , 遂得

$$\hat{\pi}_k = \frac{N_k}{N}, \quad k = 1, \dots, K. \quad (3)$$

## 4 结论

极大似然估计可分解为两步：

- 1) 类条件密度独立拟合 对每个类  $k$  单独使用其标注样本  $\mathcal{D}_k$  求解 (2)。各类之间无耦合。
- 2) 类先验为样本频率 由 (3)  $\hat{\pi}_k = N_k/N$ 。

这正是所要证明的结论。

□

## 练习 11.16 解答 (★★)

### 题目

(1) 设一阶 Markov 链的联合分布

$$p(x_1, \dots, x_N) = p(x_1) \prod_{n=2}^N p(x_n | x_{n-1}) \quad (11.44)$$

对应图 11.29。证明它满足条件独立性质

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}), \quad n = 2, \dots, N. \quad (11.45)$$

(2) 对二阶 Markov 链

$$p(x_1, \dots, x_N) = p(x_1)p(x_2 | x_1) \prod_{n=3}^N p(x_n | x_{n-1}, x_{n-2}) \quad (11.46)$$

证明其满足

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}, x_{n-2}), \quad n = 3, \dots, N. \quad (11.52)$$

## 1 一阶 Markov 性质 (11.45)

(a) 取  $n \geq 2$  的前缀联合

$$p(x_1, \dots, x_n) = p(x_1) \prod_{k=2}^n p(x_k | x_{k-1}). \quad (1)$$

(b) 取  $n-1$  个变量的前缀

$$p(x_1, \dots, x_{n-1}) = p(x_1) \prod_{k=2}^{n-1} p(x_k | x_{k-1}). \quad (2)$$

(c) 计算条件分布

$$\begin{aligned} p(x_n | x_1, \dots, x_{n-1}) &= \frac{p(x_1, \dots, x_n)}{p(x_1, \dots, x_{n-1})} \\ &= \frac{p(x_1) \prod_{k=2}^n p(x_k | x_{k-1})}{p(x_1) \prod_{k=2}^{n-1} p(x_k | x_{k-1})} \\ &= p(x_n | x_{n-1}). \end{aligned}$$

乘积中除最后一因子外全部相消，故 (11.45) 成立。  $\square$

## 2 二阶 Markov 性质 (11.52)

(a) 取  $n \geq 3$  的前缀联合

$$p(x_1, \dots, x_n) = p(x_1)p(x_2 \mid x_1) \prod_{k=3}^n p(x_k \mid x_{k-1}, x_{k-2}). \quad (3)$$

(b) 取  $n-1$  个变量的前缀

$$p(x_1, \dots, x_{n-1}) = p(x_1)p(x_2 \mid x_1) \prod_{k=3}^{n-1} p(x_k \mid x_{k-1}, x_{k-2}). \quad (4)$$

(c) 计算条件分布

$$\begin{aligned} p(x_n \mid x_1, \dots, x_{n-1}) &= \frac{p(x_1, \dots, x_n)}{p(x_1, \dots, x_{n-1})} \\ &= \frac{p(x_1)p(x_2 \mid x_1) \prod_{k=3}^n p(x_k \mid x_{k-1}, x_{k-2})}{p(x_1)p(x_2 \mid x_1) \prod_{k=3}^{n-1} p(x_k \mid x_{k-1}, x_{k-2})} \\ &= p(x_n \mid x_{n-1}, x_{n-2}), \end{aligned}$$

证得 (11.52)。

证毕。

□

## 练习 11.17 解答 (★)

### 题目

- (1) 使用 d-分离证明：图 11.29 的一阶 Markov 链  $x_1 \rightarrow x_2 \rightarrow \cdots \rightarrow x_N$  满足条件独立式

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}), \quad n = 2, \dots, N. \quad (11.45)$$

- (2) 同理，用 d-分离证明：图 11.30 的二阶 Markov 链  $x_{n-2} \rightarrow x_n, x_{n-1} \rightarrow x_n$  ( $n \geq 3$ ) 满足

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}, x_{n-2}), \quad n = 3, \dots, N. \quad (11.52)$$

### 1 一阶 Markov 链的 d-分离推导




图 1: 一阶 Markov 链 (节选)

令条件集

$$Z = \{x_{n-1}\}.$$

对任意更早节点  $x_i$  ( $1 \leq i \leq n-2$ ), 唯一的无向路径是

$$x_i - x_{i+1} - \dots - x_{n-1} - x_n.$$

在该路径上  $x_{n-1}$  是链型节点且属于  $Z$ , 故整条路径被 d-分离规则阻断。于是

$$x_n \perp\!\!\!\perp \{x_1, \dots, x_{n-2}\} \mid x_{n-1},$$

即得 (11.45)。 □

### 2 二阶 Markov 链的 d-分离推导




图 2: 二阶 Markov 链 (节选)

设

$$Z = \{x_{n-1}, x_{n-2}\}, \quad n \geq 3.$$

### 要证路径全阻断

任取  $x_i$  ( $1 \leq i \leq n-3$ ). 任何从  $x_i$  通向  $x_n$  的无向路径都必须先进入  $Z$ , 因为指向  $x_n$  的有向边只来自  $x_{n-1}$  与  $x_{n-2}$ .

- 若路径先到  $x_{n-2}$ , 则  $x_{n-2} \in Z$  且在路径中充当链节点, 路径被阻断;
- 若路径绕过  $x_{n-2}$  直接到  $x_{n-1}$ , 则  $x_{n-1} \in Z$  亦为链节点, 路径同样被阻断。

因此  $x_n$  与  $\{x_1, \dots, x_{n-3}\}$  被  $Z$  d-分离。

### 得到条件独立式 (11.52)

将  $\{x_1, \dots, x_{n-3}\}$  与  $Z$  合并入条件集即可得到

$$p(x_n \mid x_1, \dots, x_{n-1}) = p(x_n \mid x_{n-1}, x_{n-2}), \quad n = 3, \dots, N,$$

即式 (11.52).

至此, 一阶与二阶 *Markov* 链的  $d$ -分离证明均已给出。

□



## 练习 11.18 解答 (★)

题目 设二阶 Markov 链

$$p(x_1, \dots, x_N) = p(x_1) p(x_2 | x_1) \prod_{n=3}^N p(x_n | x_{n-1}, x_{n-2}). \quad (3)$$

令

$$z_n := (x_{n-1}, x_n), \quad n = 2, \dots, N,$$

证明序列  $\mathbf{z} = (z_2, \dots, z_N)$  构成一阶 Markov 链, 即  $p(z_n | z_2, \dots, z_{n-1}) = p(z_n | z_{n-1})$ .

### 1 新状态的确定性约束

写  $z_n = (u_n, v_n)$ , 则

$$u_n = x_{n-1}, \quad v_n = x_n.$$

因此对  $n \geq 3$  有确定性关系

$$u_n = v_{n-1}. \quad (4)$$

### 2 直接计算转移概率

对  $n \geq 3$  考察

$$p(z_n | z_{n-1}) = p(u_n, v_n | u_{n-1}, v_{n-1}).$$

根据 (4), 已知  $u_{n-1} = x_{n-2}$ ,  $v_{n-1} = x_{n-1}$ , 而  $u_n = x_{n-1} = v_{n-1}$  是确定的, 故

$$p(u_n | u_{n-1}, v_{n-1}) = \delta_{u_n, v_{n-1}} \text{ (值恒为 1)}.$$

于是

$$\begin{aligned} p(z_n | z_{n-1}) &= \underbrace{p(v_n | v_{n-1}, u_{n-1})}_{= p(x_n | x_{n-1}, x_{n-2})} \times 1. \\ &= p(x_n | x_{n-1}, x_{n-2}) \end{aligned}$$

右端只含  $(x_{n-1}, x_{n-2})$ , 亦即只依赖  $z_{n-1}$  而与更早状态无关。

### 3 结论

因为对所有  $n \geq 3$ ,  $p(z_n | z_{n-1}) = p(z_n | z_2, \dots, z_{n-1})$ , 故  $\mathbf{z}$  满足一阶 Markov 性质; 换言之, 二阶链通过把相邻变量打包为  $z_n = (x_{n-1}, x_n)$  成功降阶为一阶链。□

**直观解释** 把  $(x_{n-1}, x_n)$  视为单一“超状态”, 原先依赖  $(x_{n-1}, x_{n-2})$  的二阶转移转化为超状态仅依赖上一超状态的信息, 阶数自然降低。


## 练习 11.19 解答 (★)

**题目** 如图 11.31 所示的状态空间模型 (state-space model) 由隐藏链  $\mathbf{z} = (z_1, \dots, z_N)$  与观测序列  $\mathbf{x} = (x_1, \dots, x_N)$  构成, 其联合分布

$$p(\mathbf{x}, \mathbf{z}) = p(z_1) \left[ \prod_{n=2}^N p(z_n | z_{n-1}) \right] \left[ \prod_{n=1}^N p(x_n | z_n) \right].$$

利用 d-分离证明: 边缘分布  $p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z}$  不满足任何条件独立关系, 因而  $\mathbf{x}$  在任意有限阶都不具备 Markov 性。

### 1 图结构回顾



- 链:  $z_1 \rightarrow z_2 \rightarrow \dots \rightarrow z_N$
- 测量:  $z_n \rightarrow x_n$  (每个  $x_n$  仅依赖本时刻隐藏状态)

### 2 任意两观测量始终 d-连通

取任意  $i < j \leq N$ , 只看结点  $\{x_i, z_i, \dots, z_j, x_j\}$ :

$$x_i \leftarrow z_i \rightarrow z_{i+1} \rightarrow \dots \rightarrow z_j \rightarrow x_j.$$

(a) **路径类型与是否阻断** 这条无向路径上所有中间结点  $z_{i+1}, \dots, z_{j-1}$  都是 **链型** ( $\rightarrow z_k \rightarrow$ ), 而我们对它们既不观测也不设为条件; 因此根据 d-分离规则**不会被阻断**。

(b) 若附加条件集  $S \subseteq \{x_1, \dots, x_N\}$  - 路径并未经过任何除两端以外的  $x$ -结点; - 条件仅包含  $\mathbf{x}$ , 不包含任何  $z_k$ ; 故链型结点  $z_k \notin S$  依然不阻断路径。于是无论给定多少其它观测量,  $x_i$  与  $x_j$  仍 d-连通。

$$\Rightarrow x_i \not\perp\!\!\!\perp x_j \mid S, \quad \forall S \subseteq \{x_1, \dots, x_N\} \setminus \{x_i, x_j\}.$$

### 3 不存在任何条件独立性质

因为对所有  $i \neq j$  都能找到一条在任何观测条件下开放的路径, 观测边缘图上两结点间从不 d-分离。故边缘分布  $p(\mathbf{x})$  不满足任何条件独立性。

## 4 无有限阶 Markov 性

若  $\mathbf{x}$  存在阶数为  $M$  的 Markov 性，则应有  $p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-M}, \dots, x_{n-1})$ 。这等价于  $x_n \perp\!\!\!\perp x_{n-M-1} | x_{n-M}, \dots, x_{n-1}$ ，与上节结论矛盾。因此对任何有限  $M$ ，观测序列均不满足 Markov 条件。

状态空间模型的观测序列在任何有限阶都不是 Markov 链

□

注 若加入潜变量并一起考虑，则  $\mathbf{z}$  自身是一阶 Markov 链，而  $\mathbf{x}$  仅通过  $\mathbf{z}$  间接耦合。这正是“隐藏 Markov 模型 / 线性动态系统”与显式 Markov 链的根本区别。