

Solutions to Chapter 11 — *Structured Distributions*

姚宇倬

July , 2025

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 11.1 (★) 通过按顺序将各变量边缘化消去，证明：若有向图的每个条件分布都已归一，则其联合分布的表示式 (11.6) 必然也是归一化的。

练习 11.2 (★) 证明：在有向图中“不存在有向环”的性质，可由以下陈述推出：存在一种对全部节点的编号，使得每条有向边都只指向编号较大的节点；亦即对任何节点，都没有指向编号更小节点的连边。

练习 11.3 (★★) 设三元二值随机变量 $a, b, c \in \{0, 1\}$ 的联合分布如表 1 所示。直接计算并验证：

(1) 边缘分布下 a 与 b 相关，即 $p(a, b) \neq p(a)p(b)$ ；

(2) 条件在 c 上时二者独立，即

$$p(a, b | c) = p(a | c)p(b | c),$$

对于 $c = 0$ 与 $c = 1$ 均成立。

练习 11.4 (★★) 以表 1 的联合分布为例，计算 $p(a)$ 、 $p(b | c)$ 、 $p(c | a)$ 。进一步证明：

$$p(a, b, c) = p(a)p(c | a)p(b | c).$$

并画出对应的有向图。

练习 11.5 (★) 对于图 11.6 所示的模型，我们已知，通过使用 logistic sigmoid 表示法 (11.8)，指定条件分布 $p(y | x_1, \dots, x_M)$ （其中 $x_i \in \{0, 1\}$ ）所需的参数数量可以从 2^M 个减少到 $M + 1$ 个。一种替代表示法 (Pearl, 1988) 由下式给出：

$$p(y = 1 | x_1, \dots, x_M) = 1 - (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i} \quad (11.49)$$

表 1: 三元二值变量 (a, b, c) 的联合概率 (练习 11.3 与 11.4 所需)。

a	b	c	$p(a, b, c)$
0	0	0	0.192
0	0	1	0.144
0	1	0	0.048
0	1	1	0.216
1	0	0	0.192
1	0	1	0.064
1	1	0	0.048
1	1	1	0.096

其中, 参数 μ_i 表示概率 $p(x_i = 1)$, 而 μ_0 是一个满足 $0 \leq \mu_0 \leq 1$ 的附加参数。该条件分布 (11.49) 被称为**含噪或 (noisy-OR)**。请证明, 该模型可以被解释为逻辑“或”函数的一种“软”(概率性)形式(即, 只要至少有一个 $x_i = 1$, 该函数就给出 $y = 1$)。并讨论 μ_0 的含义。

练习 11.6 (★★) 从条件分布的定义式 (11.9) 出发, 推导线性-高斯模型的联合分布的均值所满足的递推关系式 (11.12)。

练习 11.7 (★★) 同样从 (11.9) 出发, 推导线性-高斯模型的联合分布的协方差矩阵所满足的递推关系式 (11.13)。

练习 11.8 (★★) 证明: 对于一个由 (11.9) 式定义的、包含 D 个变量的**全连接**线性高斯图模型(即每个节点的父节点为所有编号更低的节点), 其协方差矩阵的参数数量为

$$\frac{D(D+1)}{2}.$$

练习 11.9 (★★) 利用递推关系 (11.12) 与 (11.13), 求出图 11.7 所示三元线性-高斯图的均值 (11.14) 与协方差 (11.15)。

练习 11.10 (★★) 验证: 若图中每个节点都是一维线性-高斯分布 (11.16), 则整张图上向量值变量的联合分布仍为多元高斯。

练习 11.11 (★) 证明: 若 $a \perp\!\!\!\perp b \mid c$ 且 $c \perp\!\!\!\perp d$, 则可推出

$$a \perp\!\!\!\perp b \mid d.$$

练习 11.12 (★) 结合 d-分离标准, 证明: 在有向图中, 若条件于某节点的 Markov 毯, 则该节点的条件分布与图中其它所有节点独立。

练习 11.13 (★) 考察图 11.32 (初始无任何节点观测)。证明

$$a \perp\!\!\!\perp b \mid \emptyset.$$

随后观测 d ，说明一般情况下

$$a \not\perp\!\!\!\perp b \mid d.$$

练习 11.14 (★★) 基于图 11.20 的汽车燃油系统：现不直接观测 G ，而由驾驶员 D 报告读数，且

$$p(D = 1 \mid G = 1) = 0.9, \quad p(D = 0 \mid G = 0) = 0.9.$$

- (1) 仅观测到 $D = 0$ ，求油箱为空 ($F = 0$) 的后验概率。
- (2) 再额外观测到电池没电 ($B = 0$)，计算此时油箱为空的后验概率，并阐述该概率降低的直观原因，与图 11.32 进行对照。

练习 11.15 (★★) 训练 Naive Bayes：设每类条件密度 $p(\mathbf{x}^{(l)} \mid C_k)$ 由参数 $\mathbf{w}^{(l)}$ 控制。证明极大似然解为：分别对每类使用其标记样本拟合密度，然后先验 $p(C_k)$ 取各类在训练集中的相对频率。

练习 11.16 (★★) 考查与图 11.29 的有向图相对应的联合概率分布 (11.44)。请使用概率的加和规则与乘积规则，验证该联合分布对于 $n = 2, \dots, N$ 满足条件独立性质 (11.45)。

类似地，证明由联合分布 (11.46) 所描述的二阶马尔可夫模型，对于 $n = 3, \dots, N$ 满足如下的条件独立性质：

$$p(\mathbf{x}_n \mid \mathbf{x}_1, \dots, \mathbf{x}_{n-1}) = p(\mathbf{x}_n \mid \mathbf{x}_{n-1}, \mathbf{x}_{n-2}). \quad (11.52)$$

练习 11.17 (★) 请使用第 11.2 节讨论的 d-分离，验证：图 11.29 所示、共含 N 个节点的马尔可夫模型，对 $n = 2, \dots, N$ 满足条件独立性性质式 (11.45)。同样地，证明：图 11.30 所示、共含 N 个节点的模型，对 $n = 3, \dots, N$ 满足条件独立性性质式 (11.52)。

练习 11.18 (★) 设二阶 Markov 链如图 11.30。通过将相邻变量配对，证明其可被视作新变量上的一阶 Markov 过程。

练习 11.19 (★) 利用 d-分离，证明图 11.31 的状态-空间模型，对观测序列

$$p(x_1, \dots, x_N)$$

不满足任何有限阶 Markov 条件独立性。

下面将进行详细解答！

练习 11.1 解答

依次对各变量做积分（或求和）并加以消去，证明：若有向图的每个条件分布都已归一，则其联合分布的表示式 (11.6) 必然也是归一化的。

设一张包含 K 个随机变量的有向无环图 (DAG) 的联合分布因子化为

$$p(x_1, \dots, x_K) = \prod_{k=1}^K p(x_k \mid \text{pa}(k)), \quad (11.6)$$

其中 $\text{pa}(k)$ 为节点 x_k 的父节点集合，并已知对每个 k 都有

$$\sum_{x_k} p(x_k \mid \text{pa}(k)) = 1 \quad (\text{或} \quad \int p(x_k \mid \text{pa}(k)) dx_k = 1).$$

证明：

1. **拓扑排序** 因为图为 DAG，可给节点重新编号，使得父节点编号总小于子节点编号。下文假设 $x_1, \dots, x_K$ 恰为这种拓扑序。

2. **递归边缘化** 用符号 $\sum$ 同时代表对离散变量求和或对连续变量积分。令

$$P_K = \sum_{x_1, \dots, x_K} \prod_{k=1}^K p(x_k \mid \text{pa}(k)).$$

消去 x_K ：由于 x_K 无子节点，它只出现在单个因子 $p(x_K \mid \text{pa}(K))$ 中，

$$\sum_{x_K} p(x_K \mid \text{pa}(K)) = 1.$$

故

$$P_K = \sum_{x_1, \dots, x_{K-1}} \left[\prod_{k=1}^{K-1} p(x_k \mid \text{pa}(k)) \right] \left(\sum_{x_K} p(x_K \mid \text{pa}(K)) \right) = P_{K-1}.$$

归纳步骤：假设已将最后 m 个变量消去，得到

$$P_{K-m} = \sum_{x_1, \dots, x_{K-m}} \prod_{k=1}^{K-m} p(x_k \mid \text{pa}(k)).$$

现对 x_{K-m} 做同样处理，可得 $P_{K-m} = P_{K-m-1}$ 。

结束：重复上述过程直至 $m = K$ ，全部变量被消去，得到

$$P_0 = 1.$$

因此

$$\sum_{x_1, \dots, x_K} p(x_1, \dots, x_K) = 1,$$

或在连续情形下

$$\int \cdots \int p(x_1, \dots, x_K) dx_1 \cdots dx_K = 1.$$

□

评注：

- 证明只用到两点：(i) 图无环，故可做拓扑排序；(ii) 每个条件分布对自身变量归一。因而对离散、连续或混合变量皆成立。
- 式 (11.6) 可视为链式法则 (chain rule) 的 DAG 版本，本题说明：若各局部分布合法，则链式法则自动给出合法 (归一化) 的联合分布。
- 若存在有向环，则无法选择单调拓扑序，从而上述递推失败；这正与练习 11.2 的结论相呼应。

练习 11.2 解答

命题

设一幅有向图的结点可重新编号为

$$1, 2, \dots, N,$$

且对每条有向边 $(u \rightarrow v)$ 都满足

$$\text{index}(u) < \text{index}(v).$$

则该图不含任何有向环，即它是一张 **DAG** (directed acyclic graph)。

证明：

设图 $G = (V, E)$ 满足上述编号条件。若存在有向环

$$v_0 \xrightarrow{e_1} v_1 \xrightarrow{e_2} v_2 \xrightarrow{e_3} \cdots \xrightarrow{e_k} v_k = v_0, \quad k \geq 1,$$

其中 $e_i = (v_{i-1} \rightarrow v_i)$ ，则按编号规则

$$\text{index}(v_{i-1}) < \text{index}(v_i), \quad i = 1, \dots, k.$$

从而得到严格递增链

$$\text{index}(v_0) < \text{index}(v_1) < \cdots < \text{index}(v_k).$$

但 $v_k = v_0$ 必须满足 $\text{index}(v_k) = \text{index}(v_0)$ ，与严格不等式矛盾。故假设不成立，图中无有向环。 $\square$

评注： 编号满足“所有箭头从小号指向大号” 图可作拓扑排序。拓扑排序存在当且仅当图无环，因此“可编号”与“无向环”互为充要。

练习 11.3 解答

题目回顾 设 $a, b, c \in \{0, 1\}$ 的联合分布如表 2. 证明: (1) a 与 b 边缘相关; (2) 给定 c 时二者独立。

表 2: 练习 11.3 联合分布

a	b	c	$p(a, b, c)$
0	0	0	0.192
0	0	1	0.144
0	1	0	0.048
0	1	1	0.216
1	0	0	0.192
1	0	1	0.064
1	1	0	0.048
1	1	1	0.096

1 边缘相关性

$$p_{00} = p(a=0, b=0) = 0.192 + 0.144 = 0.336, \quad p(a=0) = 0.600, \quad p(b=0) = 0.592.$$

若 a, b 独立应有 $p_{00} = 0.600 \times 0.592 = 0.3552 \neq 0.336$, 故 a, b 边缘相关。

2 条件独立性

(a) $c = 0$.

$$p(c=0) = 0.48, \quad p(a, b \mid c=0) = \frac{p(a, b, c=0)}{0.48} = \begin{cases} 0.40, & (0, 0) \\ 0.10, & (0, 1) \\ 0.40, & (1, 0) \\ 0.10, & (1, 1) \end{cases}$$

$$p(a \mid c=0) = 0.5, \quad p(b \mid c=0) = 0.8.$$

验证可得 $p(a, b \mid c=0) = p(a \mid c=0)p(b \mid c=0)$ 。

(b) $c = 1$.

$$p(c = 1) = 0.52, \quad p(a, b \mid c = 1) = \frac{p(a, b, c = 1)}{0.52} = \begin{cases} 0.276923, \\ 0.415385, \\ 0.123077, \\ 0.184615 \end{cases}$$

$$p(a \mid c = 1) = 0.692307, \quad p(b \mid c = 1) = 0.4.$$

同样满足 $p(a, b \mid c = 1) = p(a \mid c = 1)p(b \mid c = 1)$, 说明给定 c 时 a, b 条件独立。

3 结论

$$p(a, b) \neq p(a)p(b), \quad p(a, b \mid c) = p(a \mid c)p(b \mid c) \ (c = 0, 1).$$

证毕。

□

练习 11.4 解答 (★★)

题目 (见表 11.1) 计算 $p(a)$, $p(b | c)$, $p(c | a)$, 验证 $p(a, b, c) = p(a)p(c | a)p(b | c)$, 并画出对应的有向图。

1 边缘分布 $p(a)$

a	行概率求和	$p(a)$
0	$0.192 + 0.144 + 0.048 + 0.216$	0.60
1	$0.192 + 0.064 + 0.048 + 0.096$	0.40

2 条件分布 $p(c | a)$

$$p(c = 0 | a) = \frac{\sum_b p(a, b, 0)}{p(a)}, \quad p(c = 1 | a) = 1 - p(c = 0 | a).$$

a	$\sum_b p(a, b, 0)$	$p(c = 0 a)$	$p(c = 1 a)$
0	$0.192 + 0.048 = 0.240$	0.40	0.60
1	$0.192 + 0.048 = 0.240$	0.60	0.40

3 条件分布 $p(b | c)$

先得 $p(c = 0) = 0.48$, $p(c = 1) = 0.52$ 。

c	$\sum_a p(a, 0, c)$	$p(b = 0 c)$	$p(b = 1 c)$
0	$0.192 + 0.192 = 0.384$	0.80	0.20
1	$0.144 + 0.064 = 0.208$	0.40	0.60


4 验证乘积分解

(a, b, c)	$p(a)$	$p(c a)$	$p(b c)$	乘积	表 11.1
0,0,0	0.60	0.40	0.80	0.192	0.192
0,0,1	0.60	0.60	0.40	0.144	0.144
0,1,0	0.60	0.40	0.20	0.048	0.048
0,1,1	0.60	0.60	0.60	0.216	0.216
1,0,0	0.40	0.60	0.80	0.192	0.192
1,0,1	0.40	0.40	0.40	0.064	0.064
1,1,0	0.40	0.60	0.20	0.048	0.048
1,1,1	0.40	0.40	0.60	0.096	0.096

$$p(a, b, c) = p(a)p(c | a)p(b | c)$$

5 对应的有向图

因子化结构： $a \rightarrow c \rightarrow b$ 。



总结 (1) $p(a) = \{0.60, 0.40\}$; (2) $p(c | a)$ 与 $p(b | c)$ 如上表; (3) 乘积分解完全成立, 对应 DAG 如上。

练习 11.5 解答 (★)

题目要点 本题探讨图 11.6 所示模型，其包含 M 个二元父结点 $\mathbf{x} = (x_1, \dots, x_M)$ ($x_i \in \{0, 1\}$) 与一个二元子结点 $y \in \{0, 1\}$ 。Pearl (1988) 提出了如下所示的 *noisy-OR* (含噪或) 条件分布模型：

$$p(y = 1 \mid \mathbf{x}) = 1 - (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i}. \quad (1)$$

题干的字面描述将参数 μ_i 定义为父节点的边缘概率 $p(x_i = 1)$ 。然而，要理解此公式的内在生成机理，通常将 μ_i 解释为“连边概率” (link probability)，即当原因 $x_i = 1$ 存在时，它能成功触发结果 $y = 1$ 的概率。本解答将基于后一种更通用的生成式解释来证明其性质，并视题干的描述为一种施加在模型上的特殊参数共享约束。参数 μ_0 为“泄露 (leak)”或背景触发概率。本解答旨在证明式 (1) 是逻辑“或” (OR) 的概率化版本，并深入讨论其参数含义。

1 生成式解释与模型推导

该模型可通过一个独立的“因果成功/失败”生成过程来精确描述和推导。

- (1) **引入潜在“因果开关”：** 对每个父变量 x_i 引入一个潜在的二元“开关”变量 $z_i \in \{0, 1\}$ ，并引入一个代表背景原因的“漏开关” $z_0 \in \{0, 1\}$ 。
- (2) **定义开关概率（连边概率）：** 设这些开关成功的概率（即“连边概率”）分别为：

$$\Pr(z_i = 1) = \mu_i \quad (i = 1, \dots, M), \quad \Pr(z_0 = 1) = \mu_0.$$

并假设所有这些开关 $z_0, z_1, \dots, z_M$ 在给定 $\mathbf{x}$ 时相互独立。

- (3) **定义输出逻辑：** 子结点 y 的值被定义为：只要背景开关成功，或者任何一个在场的父节点 ($x_i = 1$) 对应的开关成功，则 $y = 1$ 。用数学语言表达为：

$$y = \mathbb{I}(z_0 = 1 \text{ 或 } \exists i \text{ 使得 } x_i = 1 \text{ 且 } z_i = 1).$$

其中 $\mathbb{I}(\cdot)$ 是指示函数。

- (4) **推导 $p(y = 1 \mid \mathbf{x})$ ：** $y = 0$ 发生的唯一可能是所有相关机制全部失败：即 z_0 失败，且对于所有 $x_i = 1$ 的父节点，其对应的 z_i 也失败。根据独立性假设：

$$\begin{aligned} p(y = 0 \mid \mathbf{x}) &= \Pr(z_0 = 0, \text{ 且对所有满足 } x_i = 1 \text{ 的 } i, z_i = 0) \\ &= \Pr(z_0 = 0) \prod_{i: x_i = 1} \Pr(z_i = 0) \\ &= (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i}. \end{aligned}$$

取其补事件的概率，即得最终的 noisy-OR 公式：

$$p(y = 1 \mid \mathbf{x}) = 1 - p(y = 0 \mid \mathbf{x}) = 1 - (1 - \mu_0) \prod_{i=1}^M (1 - \mu_i)^{x_i}.$$

这个推导清晰地表明，该模型是“各有效原因独立尝试激活输出，只要任一成功，输出即为1”这一物理过程的直接数学体现。

2 “软 OR” 性质与极限情况

- **单调性：** 将任一 x_i 从 0 置为 1 时， $p(y = 1 \mid \mathbf{x})$ 的增量为：

$$\Delta_i = (1 - \mu_0) \left[\prod_{j \neq i} (1 - \mu_j)^{x_j} \right] \mu_i \geq 0.$$

因为增量非负，所以激活任何一个父变量都会单调不减地提高输出为 1 的概率。这正是对逻辑 OR 的“软化”表达。

- **退化到确定性 OR：** 在极限情况下，若设置 $\mu_0 = 0$ (无泄露) 且所有 $\mu_i = 1$ (原因100%有效)，则模型退化为：

$$p(y = 1 \mid \mathbf{x}) = 1 - \prod_{i=1}^M (1 - 1)^{x_i} = \begin{cases} 0, & \text{若所有 } x_i = 0, \\ 1, & \text{若存在 } x_i = 1. \end{cases}$$

这与确定性的逻辑 OR 函数 $\text{OR}(x_1, \dots, x_M)$ 完全等价。

3 参数 μ_0 的含义与讨论

- **Leak (泄露) 概率：** μ_0 是在所有显式原因都缺席时 ($\mathbf{x} = \mathbf{0}$)， y 仍被激活的概率：

$$\mu_0 = p(y = 1 \mid \mathbf{x} = \mathbf{0}).$$

它代表了所有模型外未显式建模的背景原因或随机噪声的综合影响。

- **类比与解释：** μ_0 的角色类似于：

- 在 OR 门上接入一个永远开启的虚拟父结点 $x_0 \equiv 1$ ，其连边成功概率为 μ_0 。
- 逻辑回归模型中的偏置项（或截距），决定了当所有输入特征为零时的基准输出概率。

- **典型取值：**

$\mu_0 = 0$: 无泄露。 $y = 1$ 的发生必然归因于至少一个 $x_i = 1$ 。

$\mu_0 \rightarrow 1$: 强泄露。 y 几乎必然为 1，此时模型对输入 $\mathbf{x}$ 基本没有响应。

综上，式 (1) 精确描述了一个带有背景泄露的、各原因独立起作用的概率“或”模型。

练习 11.6 解答 (★★)

题目 在线性-高斯图模型中, 每个节点 x_i 的条件分布设为

$$p(x_i \mid \text{pa}(i)) = \mathcal{N}\left(x_i \mid \underbrace{\sum_{j \in \text{pa}(i)} w_{ij} x_j + b_i}_{\text{条件均值}}, v_i\right), \quad (11.9)$$

其中 $\text{pa}(i)$ 是 x_i 的父节点集合, w_{ij} 、 b_i 为参数, v_i 为条件方差。要求推出均值递推关系

$$\boxed{\mu_i = \sum_{j \in \text{pa}(i)} w_{ij} \mu_j + b_i} \quad (i = 1, \dots, D), \quad (11.12)$$

其中 $\mu_k = \mathbb{E}[x_k]$ 。

1 全期望公式

$$\mu_i = \mathbb{E}[x_i] = \mathbb{E}_{\text{pa}(i)}[\mathbb{E}[x_i \mid \text{pa}(i)]].$$

2 代入条件均值并利用期望线性性

$$\begin{aligned} \mu_i &= \mathbb{E}_{\text{pa}(i)} \left[\sum_{j \in \text{pa}(i)} w_{ij} x_j + b_i \right] \\ &= \sum_{j \in \text{pa}(i)} w_{ij} \underbrace{\mathbb{E}[x_j]}_{\mu_j} + b_i = \sum_{j \in \text{pa}(i)} w_{ij} \mu_j + b_i, \end{aligned}$$

即得递推式 (11.12)。 □

3 如何使用递推式

按拓扑序遍历 DAG:

1. 根节点（无父节点）的均值直接为其偏置: $\mu_i = b_i$; 2. 之后节点按 (11.12) 逐一求出, 直到得到整张图的均值向量 $\boldsymbol{\mu} = (\mu_1, \dots, \mu_D)^\top$ 。

练习 11.7 解答 (★★)

题目 在线性-高斯图模型中, 从条件分布

$$p(x_j \mid \text{pa}(j)) = \mathcal{N}\left(x_j \mid \sum_{k \in \text{pa}(j)} w_{jk} x_k + b_j, v_j\right) \quad (11.9)$$

推导联合协方差递推式

$$\boxed{\text{cov}[x_i, x_j] = \sum_{k \in \text{pa}(j)} w_{jk} \text{cov}[x_i, x_k] + \delta_{ij} v_j} \quad (i, j = 1, \dots, D), \quad (11.13)$$

其中 δ_{ij} 为 Kronecker 符号。

1 把条件分布改写为显式噪声模型

设

$$x_j = \underbrace{\sum_{k \in \text{pa}(j)} w_{jk} x_k + b_j}_{\text{线性部分}} + \varepsilon_j, \quad \varepsilon_j \sim \mathcal{N}(0, v_j),$$

且 ε_j 与 $\text{pa}(j)$ 独立。

2 计算协方差 Σ_{ij}

$$\begin{aligned} \Sigma_{ij} &:= \text{cov}[x_i, x_j] \\ &= \text{cov}\left[x_i, \sum_{k \in \text{pa}(j)} w_{jk} x_k + \varepsilon_j\right] \\ &= \sum_{k \in \text{pa}(j)} w_{jk} \underbrace{\text{cov}[x_i, x_k]}_{\Sigma_{ik}} + \underbrace{\text{cov}[x_i, \varepsilon_j]}_{0 \text{ 若 } i \neq j}. \end{aligned}$$

* 若 $i \neq j$, ε_j 与 x_i 独立, 故该项为 0; * 若 $i = j$, $\text{cov}[x_j, \varepsilon_j] = \text{var}[\varepsilon_j] = v_j$ 。
因此得到递推关系 (11.13)。 □

3 计算策略 (与均值递推配合)

1. 按 DAG 的拓扑序自下而上 (父 $\rightarrow$ 子) 填表: **对角元** 先设 $\Sigma_{ii} = v_i$ (根节点) 或用 (11.13) 计算。 **非对角元** 对每一对子 $i < j$ 用 (11.13)。 2. 整理得联合协方差矩阵 Σ 。

这样即可与练习 11.6 的均值递推一起, 递归求出整张图的多元高斯参数。

练习 11.8 解答 (★★)

题目 证明：由式 (11.9) 定义、含 D 个变量的完全连通线性-高斯图模型，其联合分布的协方差矩阵所含独立参数个数为

$$\frac{D(D+1)}{2}.$$

1 结构方程与协方差形式

按拓扑序给结点重新编号，使得完全连通意味着 $\text{pa}(i) = \{1, \dots, i-1\}$. 去均值后（不影响协方差），式 (11.9) 等价于结构方程

$$x_i = \sum_{j < i} w_{ij} x_j + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, v_i), \quad \varepsilon \text{ 彼此独立.}$$

令 $W = [w_{ij}]$ 为严格下三角矩阵（对角为零）， $V = \text{diag}(v_1, \dots, v_D)$ 。写成向量式：

$$(\mathbf{I} - W) \mathbf{x} = \boldsymbol{\varepsilon}, \quad \Rightarrow \quad \mathbf{x} = (\mathbf{I} - W)^{-1} \boldsymbol{\varepsilon}.$$

于是联合协方差为

$$\Sigma = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] = (\mathbf{I} - W)^{-1} V (\mathbf{I} - W)^{-\top}. \quad (2)$$

2 参数计数的上界： $D(D+1)/2$

完全连通时， W 在对角线下共有 $\frac{D(D-1)}{2}$ 个自由参数， V 有 D 个对角参数。由 (2) 可知 Σ 完全由 $\{w_{ij} : i > j\}$ 与 $\{v_i\}$ 决定，因此协方差矩阵至多含有

$$\frac{D(D-1)}{2} + D = \frac{D(D+1)}{2}$$

个独立自由度。

3 可达性（下界）：与 Cholesky 分解一一对应

对任意对称正定协方差矩阵 Σ ，取其 Cholesky 分解

$$\Sigma = LL^\top, \quad L \text{ 为下三角且 } \ell_{ii} > 0.$$

令 $D^{1/2} = \text{diag}(\ell_{11}, \dots, \ell_{DD})$ ，取

$$(\mathbf{I} - W)^{-1} \stackrel{\text{定义}}{=} L D^{-1/2}, \quad V \stackrel{\text{定义}}{=} D^{1/2} D^{1/2} = \text{diag}(\ell_{11}^2, \dots, \ell_{DD}^2).$$

注意 $L D^{-1/2}$ 为下三角且对角恒等于 1（因 $\ell_{ii}/\ell_{ii} = 1$ ），故存在唯一的严格下三角矩阵 $W = \mathbf{I} - (L D^{-1/2})^{-1}$ 。由此代回 (2) 立得

$$(\mathbf{I} - W)^{-1} V (\mathbf{I} - W)^{-\top} = (L D^{-1/2}) D (L D^{-1/2})^\top = LL^\top = \Sigma.$$

这表明：对任意 $\Sigma \succ 0$ ，都能唯一地选取参数 (W, V) 使 (2) 成立。因此模型对 Σ 的参数化与 Cholesky 分解同构，其自由度正是下三角矩阵 L 的参数个数，即 D （对角）+ $\frac{D(D-1)}{2}$ （下三角）= $\frac{D(D+1)}{2}$ 。

4 结论

在完全连通的线性-高斯图模型中，联合协方差矩阵不受额外约束，具有一般对称正定矩阵的全部自由度；其独立参数个数恰为

$$\boxed{\frac{D(D+1)}{2}}.$$

□

练习 11.9 解答 (★★)

题目 利用递推公式

$$\mathbb{E}[x_i] = \sum_{j \in \text{pa}(i)} w_{ij} \mathbb{E}[x_j] + b_i \quad (11.12)$$

$$\text{cov}[x_i, x_j] = \sum_{k \in \text{pa}(j)} w_{jk} \text{cov}[x_i, x_k] + \delta_{ij} v_j \quad (11.13)$$

求出图 11.7 ($x_1 \rightarrow x_2 \rightarrow x_3$, 缺边 $x_1 \not\rightarrow x_3$) 的联合均值向量 $\boldsymbol{\mu}$ 与协方差矩阵 Σ , 并验证它们与教材公式 (11.14)、(11.15) 一致。

1 均值递推

递推式 (11.12) $\mu_j = \sum_{k \in \text{pa}(j)} w_{jk} \mu_k + b_j$ 从最根部结点开始:

$$\mu_1 = b_1,$$

$$\mu_2 = w_{21} \mu_1 + b_2 = b_2 + w_{21} b_1,$$

$$\mu_3 = w_{32} \mu_2 + b_3 = b_3 + w_{32} b_2 + w_{32} w_{21} b_1.$$

$$\boldsymbol{\mu} = (b_1, b_2 + w_{21} b_1, b_3 + w_{32} b_2 + w_{32} w_{21} b_1)^\top \quad (11.14)$$

2 协方差递推

记 $\Sigma_{ij} = \text{cov}[x_i, x_j]$; (11.13) 给出 $\Sigma_{ij} = \sum_{k \in \text{pa}(j)} w_{jk} \Sigma_{ik} + \delta_{ij} v_j$.

(a) 第一列 / 行:

$$\Sigma_{11} = v_1, \quad \Sigma_{21} = w_{21} \Sigma_{11} = w_{21} v_1, \quad \Sigma_{31} = w_{32} \Sigma_{21} = w_{32} w_{21} v_1.$$

(b) 第二列 / 行:

$$\Sigma_{22} = w_{21} \Sigma_{21} + v_2 = v_2 + w_{21}^2 v_1, \quad \Sigma_{32} = w_{32} \Sigma_{22} = w_{32} (v_2 + w_{21}^2 v_1).$$

(c) 第三对角元:

$$\Sigma_{33} = w_{32} \Sigma_{32} + v_3 = v_3 + w_{32}^2 (v_2 + w_{21}^2 v_1).$$

$$\Sigma = \begin{pmatrix} v_1 & w_{21} v_1 & w_{32} w_{21} v_1 \\ w_{21} v_1 & v_2 + w_{21}^2 v_1 & w_{32} (v_2 + w_{21}^2 v_1) \\ w_{32} w_{21} v_1 & w_{32} (v_2 + w_{21}^2 v_1) & v_3 + w_{32}^2 (v_2 + w_{21}^2 v_1) \end{pmatrix} \quad (11.15)$$

3 结论

所得 μ 与 Σ 完全符合教材公式 (11.14)、(11.15)，故递推关系 (11.12)、(11.13) 对图 11.7 的线性-高斯模型适用。□

练习 11.10 解答 (★)

题目 设一张有向无环图的每个结点 $x_i \in \mathbb{R}^{d_i}$ (允许不同维度), 且条件分布为

$$p(x_i | \text{pa}(i)) = \mathcal{N}(x_i \mid \mathbf{W}_{ij}x_j + b_i, \Sigma_i), \quad (11.16)$$

其中 $\mathbf{W}_{ij}$ 为矩阵 (若 x_j 维度与 x_i 不同则是非方阵), b_i 为偏置向量, $\Sigma_i \succ 0$ 为协方差矩阵, 且 $\text{pa}(i)$ 表示所有父结点的集合。证明所有结点的联合分布 $p(x_1, \dots, x_D)$ 依然是一个高斯分布。

1 写出联合对数密度

由于图为 DAG, 联合分布因子化为

$$\ln p(\mathbf{x}) = \sum_{i=1}^D \ln p(x_i | \text{pa}(i)) = -\frac{1}{2} \sum_{i=1}^D (x_i - \mu_i)^\top \Sigma_i^{-1} (x_i - \mu_i) + \text{const},$$

其中 $\mu_i = \sum_{j \in \text{pa}(i)} \mathbf{W}_{ij}x_j + b_i$ 为条件均值。

2 展开得到整体二次型

将所有结点拼成长向量 $\mathbf{x} = (x_1^\top, \dots, x_D^\top)^\top$ 并按拓扑序逐项展开:

$$\begin{aligned} \sum_{i=1}^D (x_i - \mu_i)^\top \Sigma_i^{-1} (x_i - \mu_i) &= \underbrace{\sum_{i=1}^D x_i^\top \Sigma_i^{-1} x_i}_{\text{纯二次项}} - 2 \sum_{i=1}^D x_i^\top \Sigma_i^{-1} \left(\sum_{j \in \text{pa}(i)} \mathbf{W}_{ij}x_j \right) \\ &\quad + \sum_{i=1}^D \left(\sum_{j \in \text{pa}(i)} \mathbf{W}_{ij}x_j + b_i \right)^\top \Sigma_i^{-1} \left(\sum_{k \in \text{pa}(i)} \mathbf{W}_{ik}x_k + b_i \right). \end{aligned}$$

该表达式仅含 $\mathbf{x}$ 的二次项 ($x_k^\top A x_\ell$) 和一次项 ($c^\top \mathbf{x}$), 不含更高次幂; 常数项被吸收到 “const”。因此

$$\ln p(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^\top A \mathbf{x} + c^\top \mathbf{x} + \text{const},$$

其中 A 为对称正定矩阵 (因各 $\Sigma_i^{-1} \succ 0$ 且加权求和保持正定)。这正是多元高斯分布的标准对数形式:

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid A^{-1}c, A^{-1}).$$

3 结论

无论各结点是标量还是 d_i 维向量, 只要满足条件 (11.16) (线性均值 + 高斯噪声), 整张图的联合分布必为一个多元高斯分布, 均值与协方差可由矩阵 $A^{-1}c$ 、 A^{-1} 显式给出。□

练习 11.11 解答 (★)

命题 若

$$a \perp\!\!\!\perp \{b, c\} \mid d, \quad (\text{P})$$

则必有

$$a \perp\!\!\!\perp b \mid d. \quad (\text{C})$$

1 概率定义证明

由 (P) 的条件独立定义,

$$p(a, b, c \mid d) = p(a \mid d) p(b, c \mid d). \quad (1)$$

两边对 c 求和 / 积分

$$\sum_c p(a, b, c \mid d) = p(a, b \mid d) \quad \text{且} \quad \sum_c p(b, c \mid d) = p(b \mid d).$$

将式 (1) 对 c 求和得

$$p(a, b \mid d) = p(a \mid d) p(b \mid d),$$

这正是 (C) 的定义形式, 故命题得证。 $\square$

2 图论视角 (半 Graphoid 公理)

在信息图论中, 条件独立满足 分解 (*decomposition*) 公理:

$$X \perp\!\!\!\perp Y \cup Z \mid W \implies X \perp\!\!\!\perp Y \mid W \quad \text{及} \quad X \perp\!\!\!\perp Z \mid W.$$

令 $X = a, Y = b, Z = c, W = d$ 即可得到所需结论。这一公理连同对称、弱并、收缩等, 统称为 半 Graphoid 性质。

3 小结

无论经由概率定义还是半 Graphoid 公理, 都可直接推出 $a \perp\!\!\!\perp b, c \mid d \implies a \perp\!\!\!\perp b \mid d$ 。因此命题成立。

练习 11.12 解答 (★)

题目 使用 d-分离 (d-separation) 证明: 在有向图中, 若对节点 x_i 条件于其 *Markov* 毯 (父、子及子之父), 则 x_i 与图中其余所有变量独立。

1 Markov 毯的定义

$$\mathcal{M}(x_i) = \underbrace{\text{pa}(x_i)}_{\text{父}} \cup \underbrace{\text{ch}(x_i)}_{\text{子}} \cup \underbrace{(\text{pa}(\text{ch}(x_i)) \setminus \{x_i\})}_{\text{子之父}}.$$

2 d-分离判定回顾

给定节点集 Z , 一条无向路径被阻断当且仅当

- (i) 路径上存在 链/分叉 节点落在 Z 中; 或
- (ii) 路径上存在 合流 (*v-structure*) 节点不在 Z 中, 且其后代均不在 Z 中。

3 阻断所有连至 x_i 的路径

令 $Z = \mathcal{M}(x_i)$, 对连接 x_i 与任意 $y \notin \{x_i\} \cup Z$ 的无向路径分类:

(a) 经父节点进入 x_i

$$\cdots \rightarrow \text{父}(x_i) \rightarrow x_i.$$

父节点 $\in Z$, 属 (i), 路径阻断。

(b) 从 x_i 经子节点离开

$$x_i \rightarrow \text{子}(x_i) \rightarrow \cdots.$$

子节点 $\in Z$, 属 (i), 路径阻断。

(c) 以子节点为合流

$$\text{共父} \rightarrow \text{子}(x_i) \leftarrow x_i.$$

子节点 $\in Z$, v-结构被激活, 但共父亦 $\in Z$, 作为链节点再度阻断。

(d) 其它更长路径 任何路径最终都会首次遇到 (a)–(c) 中的某类节点, 因此同样被阻断。

故给定 Z 后, x_i 与所有 $y \notin \{x_i\} \cup Z$ 之间无未阻断路径, 得到

$$x_i \perp\!\!\!\perp y \mid \mathcal{M}(x_i).$$

4 概率意义与因子分解说明

由 d-分离得到的独立性可写为


$$p\left(x_i \mid \mathcal{M}(x_i), \mathbf{x}_{\setminus(\{x_i\} \cup \mathcal{M}(x_i))}\right) = p(x_i \mid \mathcal{M}(x_i)).$$

补充说明：亦可从联合分布的因子分解 $p(\mathbf{x}) = \prod_k p(x_k \mid \text{pa}(k))$ 出发，在 $p(x_i \mid \mathbf{x}_{\setminus i}) = \frac{p(\mathbf{x})}{\int p(\mathbf{x}) dx_i}$ 中将与 x_i 无关的因子于分子、分母相抵，直接得到 $p(x_i \mid \mathbf{x}_{\setminus i}) = p(x_i \mid \mathcal{M}(x_i))$ ，与 Figure 11.25 的文字解释完全一致。 $\square$

练习 11.13 解答 (★)

题目 如图 11.32 所示的有向图中，四个变量 a, b, c, d 均未观测。

- (a) 证明在此情形下 $a \perp\!\!\!\perp b \mid \emptyset$;
- (b) 若观测后代 d ，说明一般情况下 $a \not\perp\!\!\!\perp b \mid d$ 。



如上，图 11.32 由一个 头-对-头 (collider) 结构 $a \rightarrow c \leftarrow b$ 及其后代 $c \rightarrow d$ 组成。

1 未观测时： $a \perp\!\!\!\perp b$

在有向图中，若路径 $\dots \rightarrow c \leftarrow \dots$ 的合流节点 及其任一后代 均未被观测，该路径被 d-分离规则阻断。此处从 a 到 b 的唯一无向路径为

$$a \rightarrow c \leftarrow b.$$

因为既未观测 c 也未观测其后代 d ，故路径封闭；于是

$$a \perp\!\!\!\perp b \mid \emptyset.$$

2 观测后代 d ：路径被激活

观测 d 等价于将 $d \in Z$ 置入条件集。d-分离规则对“合流”给出：

- 若合流节点自身 或其某个后代 被观测，则合流路径被“激活”而不再阻断。

由于 d 是 c 的后代，条件化 d 会激活 $a \rightarrow c \leftarrow b$ 这一条路径。从而 a 与 b 之间出现未阻断路径，一般导致

$$a \not\perp\!\!\!\perp b \mid d.$$

(只有在特殊对称参数或概率取值下才可能“意外”保持独立。)

3 概率层面的直观推导

图的因子分解为

$$p(a, b, c, d) = p(a) p(b) p(c \mid a, b) p(d \mid c).$$

(i) 未观测 边缘化 c, d :

$$p(a, b) = \iint p(a) p(b) p(c | a, b) p(d | c) dc dd = p(a) p(b) \implies a \perp b.$$

(ii) 给定 d

$$p(a, b | d) = \frac{\int p(a) p(b) p(c | a, b) p(d | c) dc}{\iint p(a) p(b) p(c | a, b) p(d | c) da db dc}.$$

由于 $p(c | a, b)$ 依赖 (a, b) , 分子中的 (a, b) 不再可分离, 故一般 $p(a, b | d) \neq p(a | d) p(b | d)$; 即 a 与 b 不独立。 $\square$

练习 11.14 解答 (★★)

题目 在图 11.20 的汽车燃油系统中，三元二值随机变量分别为

$$B \in \{0, 1\}, \quad F \in \{0, 1\}, \quad G \in \{0, 1\},$$

其中 B 表示电池是否有电 (1=有电)， F 表示油箱是否加满 (1=满油)， G 为电动油表读数 (1=显示满油)。先验独立且

$$p(B = 1) = p(F = 1) = 0.9.$$

给定 (B, F) 时油表的可靠性为 (见教材 Figure 11.20)

	$F = 1$	$F = 0$	
$B = 1: p(G=1 \cdot)$	0.8	0.2	$p(G=0 \cdot) = 1 - p(G=1 \cdot).$
$B = 0: p(G=1 \cdot)$	0.2	0.1	

现在不再直接观测 G ，而是由驾驶员 D 读表后向我们口头报告：

$$p(D = 0 \mid G = 0) = 0.9, \quad p(D = 0 \mid G = 1) = 0.1. \quad (11.50-11.51)$$

- (1) 已观测 $D = 0$ (司机报告“空”)，计算油箱为空 $F = 0$ 的后验概率。
- (2) 若再额外观测电池没电 $B = 0$ ，计算 $p(F = 0 \mid D = 0, B = 0)$ ，并解释两者差异，将结果与图 11.32 的“解释消除”现象联系起来。

网络结构与概率表

$$B \longrightarrow G \longleftarrow F, \quad G \longrightarrow D.$$

- 先验独立： $p(B = 1) = p(F = 1) = 0.9 \Rightarrow p(B = 0) = p(F = 0) = 0.1$.
- 电动油表 G 的可靠性 (教材 Figure 11.20)

	$F = 1$	$F = 0$	
$B = 1: p(G = 1 \cdot)$	0.8	0.2	$p(G = 0 \cdot) = 1 - p(G = 1 \cdot).$
$B = 0: p(G = 1 \cdot)$	0.2	0.1	

- 司机 D 读取油表： $p(D = 0 \mid G = 0) = 0.9, p(D = 0 \mid G = 1) = 0.1$ (式 11.50-11.51)。

(1) 仅观测 $D = 0$ ：求 $p(F = 0 \mid D = 0)$

① 计算 $p(D = 0)$

$$\begin{aligned} p(D = 0) &= \sum_{b,f} p(b) p(f) \left[0.9 p(G = 0 \mid b, f) + 0.1 p(G = 1 \mid b, f) \right] \\ &= 0.352. \end{aligned}$$

② 计算联合 $p(F = 0, D = 0)$

$$\begin{aligned} p(F = 0, D = 0) &= \sum_b p(b) p(F = 0) \left[0.9 p(G = 0 \mid b, F = 0) + 0.1 p(G = 1 \mid b, F = 0) \right] \\ &= 0.0748. \end{aligned}$$

③ 后验概率

$$p(F = 0 \mid D = 0) = \frac{0.0748}{0.352} \approx 0.2125.$$

(2) 再观测 $B = 0$ ：求 $p(F = 0 \mid D = 0, B = 0)$

$$\begin{aligned} p(B = 0, D = 0) &= \sum_f p(B = 0) p(f) \left[0.9 p(G = 0 \mid B = 0, f) + 0.1 p(G = 1 \mid B = 0, f) \right] \\ &= 0.0748, \end{aligned}$$

$$p(F = 0, B = 0, D = 0) = 0.0082.$$

$$p(F = 0 \mid D = 0, B = 0) = \frac{0.0082}{0.0748} \approx 0.109.$$

(3) 直觉及与 Figure 11.32 的关联

- $p(F = 0 \mid D = 0) = 0.2125 > p(F = 0) = 0.1$ ：司机报“油表空”提高了油箱为空的可信度。
- 当再得知 $B = 0$ （电池没电）时， $p(F = 0 \mid D = 0, B = 0) = 0.109$ 甚至低于 0.2125，这正是“解释消除”（explaining-away）效应。
- 图 11.32 对应结构 $B \rightarrow G \leftarrow F, G \rightarrow D$ 。观测后代 D 打开了 B 与 F 之间通过合流点 G 的依赖路径；进一步观测 $B = 0$ 抑制了“油箱空”这一备选解释，因此后验概率下降。

□

练习 11.15 解答 (★)

题目 在朴素贝叶斯 (Naive Bayes) 模型中, 设输入向量 $\mathbf{x} = (x^{(1)}, \dots, x^{(L)})^\top$ 属于 K 个类之一, $C_k, k = 1, \dots, K$ 。对每个类 C_k , 假设条件密度分解为

$$p(\mathbf{x} | C_k) = \prod_{l=1}^L p(x^{(l)} | C_k; w_k^{(l)}), \quad (11.37)$$

且每一因子由互不共享的独立参数 $w_k^{(l)}$ 控制。证明: 极大似然 (ML) 训练只需

1. 分别对每个类 C_k 用其训练样本 $\mathcal{D}_k = \{\mathbf{x}_n : t_n = k\}$ 最大化 $\prod_{\mathbf{x} \in \mathcal{D}_k} p(\mathbf{x} | C_k)$ 以估计 $\hat{\mathbf{w}}_k$; 2. 类先验取为该样本在训练集中的相对频率 $\hat{\pi}_k = N_k/N$ (其中 $N_k = |\mathcal{D}_k|$, N 为总样本数)。

1 记号与完整对数似然

$$\mathcal{D} = \{(\mathbf{x}_n, t_n)\}_{n=1}^N, \quad t_n \in \{1, \dots, K\}.$$

记 $\pi_k := p(C_k)$, $\mathbf{w}_k := (w_k^{(1)}, \dots, w_k^{(L)})$ 。则联合似然

$$\mathcal{L}(\{\pi_k\}, \{\mathbf{w}_k\}) = \prod_{n=1}^N p(\mathbf{x}_n, t_n) = \prod_{n=1}^N \pi_{t_n} p(\mathbf{x}_n | C_{t_n}; \mathbf{w}_{t_n}).$$

取对数并按类汇总

$$\ln \mathcal{L} = \sum_{k=1}^K \underbrace{\left[\sum_{\mathbf{x} \in \mathcal{D}_k} \ln p(\mathbf{x} | C_k; \mathbf{w}_k) + N_k \ln \pi_k \right]}_{\text{仅含 } \mathbf{w}_k}. \quad (1)$$

2 优化类条件参数 $\mathbf{w}_k$

式 (1) 中每一项 $\sum_{\mathbf{x} \in \mathcal{D}_k} \ln p(\mathbf{x} | C_k; \mathbf{w}_k)$ 只依赖类 k 的数据与参数, 彼此独立。因此可分别求

$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w}_k} \prod_{\mathbf{x} \in \mathcal{D}_k} p(\mathbf{x} | C_k; \mathbf{w}_k) \quad (k = 1, \dots, K). \quad (2)$$

3 优化类先验 π_k

加入约束 $\sum_k \pi_k = 1$ 的拉格朗日函数

$$\mathcal{J} = \sum_{k=1}^K N_k \ln \pi_k + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right).$$

对 π_k 求偏导并置零: $\partial \mathcal{J} / \partial \pi_k = N_k / \pi_k + \lambda = 0 \Rightarrow \pi_k = -N_k / \lambda$ 。由约束得 $\lambda = -N$, 遂得

$$\hat{\pi}_k = \frac{N_k}{N}, \quad k = 1, \dots, K. \quad (3)$$

4 结论

极大似然估计可分解为两步：

- 1) 类条件密度独立拟合 对每个类 k 单独使用其标注样本 $\mathcal{D}_k$ 求解 (2)。各类之间无耦合。
- 2) 类先验为样本频率 由 (3) $\hat{\pi}_k = N_k/N$ 。

这正是所要证明的结论。

□

练习 11.16 解答 (★★)

题目

(1) 设一阶 Markov 链的联合分布

$$p(x_1, \dots, x_N) = p(x_1) \prod_{n=2}^N p(x_n | x_{n-1}) \quad (11.44)$$

对应图 11.29。证明它满足条件独立性质

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}), \quad n = 2, \dots, N. \quad (11.45)$$

(2) 对二阶 Markov 链

$$p(x_1, \dots, x_N) = p(x_1)p(x_2 | x_1) \prod_{n=3}^N p(x_n | x_{n-1}, x_{n-2}) \quad (11.46)$$

证明其满足

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}, x_{n-2}), \quad n = 3, \dots, N. \quad (11.52)$$

1 一阶 Markov 性质 (11.45)

(a) 取 $n \geq 2$ 的前缀联合

$$p(x_1, \dots, x_n) = p(x_1) \prod_{k=2}^n p(x_k | x_{k-1}). \quad (1)$$

(b) 取 $n-1$ 个变量的前缀

$$p(x_1, \dots, x_{n-1}) = p(x_1) \prod_{k=2}^{n-1} p(x_k | x_{k-1}). \quad (2)$$

(c) 计算条件分布

$$\begin{aligned} p(x_n | x_1, \dots, x_{n-1}) &= \frac{p(x_1, \dots, x_n)}{p(x_1, \dots, x_{n-1})} \\ &= \frac{p(x_1) \prod_{k=2}^n p(x_k | x_{k-1})}{p(x_1) \prod_{k=2}^{n-1} p(x_k | x_{k-1})} \\ &= p(x_n | x_{n-1}). \end{aligned}$$

乘积中除最后一因子外全部相消，故 (11.45) 成立。 $\square$

2 二阶 Markov 性质 (11.52)

(a) 取 $n \geq 3$ 的前缀联合

$$p(x_1, \dots, x_n) = p(x_1)p(x_2 \mid x_1) \prod_{k=3}^n p(x_k \mid x_{k-1}, x_{k-2}). \quad (3)$$

(b) 取 $n-1$ 个变量的前缀

$$p(x_1, \dots, x_{n-1}) = p(x_1)p(x_2 \mid x_1) \prod_{k=3}^{n-1} p(x_k \mid x_{k-1}, x_{k-2}). \quad (4)$$

(c) 计算条件分布

$$\begin{aligned} p(x_n \mid x_1, \dots, x_{n-1}) &= \frac{p(x_1, \dots, x_n)}{p(x_1, \dots, x_{n-1})} \\ &= \frac{p(x_1)p(x_2 \mid x_1) \prod_{k=3}^n p(x_k \mid x_{k-1}, x_{k-2})}{p(x_1)p(x_2 \mid x_1) \prod_{k=3}^{n-1} p(x_k \mid x_{k-1}, x_{k-2})} \\ &= p(x_n \mid x_{n-1}, x_{n-2}), \end{aligned}$$

证得 (11.52)。

证毕。

□

练习 11.17 解答 (★)

题目

- (1) 使用 d-分离证明：图 11.29 的一阶 Markov 链 $x_1 \rightarrow x_2 \rightarrow \cdots \rightarrow x_N$ 满足条件独立式

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}), \quad n = 2, \dots, N. \quad (11.45)$$

- (2) 同理，用 d-分离证明：图 11.30 的二阶 Markov 链 $x_{n-2} \rightarrow x_n, x_{n-1} \rightarrow x_n$ ($n \geq 3$) 满足

$$p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-1}, x_{n-2}), \quad n = 3, \dots, N. \quad (11.52)$$

1 一阶 Markov 链的 d-分离推导




图 1: 一阶 Markov 链 (节选)

令条件集

$$Z = \{x_{n-1}\}.$$

对任意更早节点 x_i ($1 \leq i \leq n-2$), 唯一的无向路径是

$$x_i - x_{i+1} - \dots - x_{n-1} - x_n.$$

在该路径上 x_{n-1} 是链型节点且属于 Z , 故整条路径被 d-分离规则阻断。于是

$$x_n \perp\!\!\!\perp \{x_1, \dots, x_{n-2}\} \mid x_{n-1},$$

即得 (11.45)。 □

2 二阶 Markov 链的 d-分离推导




图 2: 二阶 Markov 链 (节选)

设

$$Z = \{x_{n-1}, x_{n-2}\}, \quad n \geq 3.$$

要证路径全阻断

任取 x_i ($1 \leq i \leq n-3$). 任何从 x_i 通向 x_n 的无向路径都必须先进入 Z , 因为指向 x_n 的有向边只来自 x_{n-1} 与 x_{n-2} .

- 若路径先到 x_{n-2} , 则 $x_{n-2} \in Z$ 且在路径中充当链节点, 路径被阻断;
- 若路径绕过 x_{n-2} 直接到 x_{n-1} , 则 $x_{n-1} \in Z$ 亦为链节点, 路径同样被阻断。

因此 x_n 与 $\{x_1, \dots, x_{n-3}\}$ 被 Z d-分离。

得到条件独立式 (11.52)

将 $\{x_1, \dots, x_{n-3}\}$ 与 Z 合并入条件集即可得到

$$p(x_n \mid x_1, \dots, x_{n-1}) = p(x_n \mid x_{n-1}, x_{n-2}), \quad n = 3, \dots, N,$$

即式 (11.52).

至此, 一阶与二阶 *Markov* 链的 d -分离证明均已给出。

□

练习 11.18 解答 (★)

题目 设二阶 Markov 链

$$p(x_1, \dots, x_N) = p(x_1) p(x_2 | x_1) \prod_{n=3}^N p(x_n | x_{n-1}, x_{n-2}). \quad (3)$$

令

$$z_n := (x_{n-1}, x_n), \quad n = 2, \dots, N,$$

证明序列 $\mathbf{z} = (z_2, \dots, z_N)$ 构成一阶 Markov 链, 即 $p(z_n | z_2, \dots, z_{n-1}) = p(z_n | z_{n-1})$.

1 新状态的确定性约束

写 $z_n = (u_n, v_n)$, 则

$$u_n = x_{n-1}, \quad v_n = x_n.$$

因此对 $n \geq 3$ 有确定性关系

$$u_n = v_{n-1}. \quad (4)$$

2 直接计算转移概率

对 $n \geq 3$ 考察

$$p(z_n | z_{n-1}) = p(u_n, v_n | u_{n-1}, v_{n-1}).$$

根据 (4), 已知 $u_{n-1} = x_{n-2}$, $v_{n-1} = x_{n-1}$, 而 $u_n = x_{n-1} = v_{n-1}$ 是确定的, 故

$$p(u_n | u_{n-1}, v_{n-1}) = \delta_{u_n, v_{n-1}} \text{ (值恒为 1)}.$$

于是

$$\begin{aligned} p(z_n | z_{n-1}) &= \underbrace{p(v_n | v_{n-1}, u_{n-1})}_{= p(x_n | x_{n-1}, x_{n-2})} \times 1. \\ &= p(x_n | x_{n-1}, x_{n-2}) \end{aligned}$$

右端只含 (x_{n-1}, x_{n-2}) , 亦即只依赖 z_{n-1} 而与更早状态无关。

3 结论

因为对所有 $n \geq 3$, $p(z_n | z_{n-1}) = p(z_n | z_2, \dots, z_{n-1})$, 故 $\mathbf{z}$ 满足一阶 Markov 性质; 换言之, 二阶链通过把相邻变量打包为 $z_n = (x_{n-1}, x_n)$ 成功降阶为一阶链。□

直观解释 把 (x_{n-1}, x_n) 视为单一“超状态”, 原先依赖 (x_{n-1}, x_{n-2}) 的二阶转移转化为超状态仅依赖上一超状态的信息, 阶数自然降低。


练习 11.19 解答 (★)

题目 如图 11.31 所示的状态空间模型 (state-space model) 由隐藏链 $\mathbf{z} = (z_1, \dots, z_N)$ 与观测序列 $\mathbf{x} = (x_1, \dots, x_N)$ 构成, 其联合分布

$$p(\mathbf{x}, \mathbf{z}) = p(z_1) \left[\prod_{n=2}^N p(z_n | z_{n-1}) \right] \left[\prod_{n=1}^N p(x_n | z_n) \right].$$

利用 d-分离证明: 边缘分布 $p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z}$ 不满足任何条件独立关系, 因而 $\mathbf{x}$ 在任意有限阶都不具备 Markov 性。

1 图结构回顾



- 链: $z_1 \rightarrow z_2 \rightarrow \dots \rightarrow z_N$
- 测量: $z_n \rightarrow x_n$ (每个 x_n 仅依赖本时刻隐藏状态)

2 任意两观测量始终 d-连通

取任意 $i < j \leq N$, 只看结点 $\{x_i, z_i, \dots, z_j, x_j\}$:

$$x_i \leftarrow z_i \rightarrow z_{i+1} \rightarrow \dots \rightarrow z_j \rightarrow x_j.$$

(a) 路径类型与是否阻断 这条无向路径上所有中间结点 $z_{i+1}, \dots, z_{j-1}$ 都是 **链型** ($\rightarrow z_k \rightarrow$), 而我们对它们既不观测也不设为条件; 因此根据 d-分离规则**不会被阻断**。

(b) 若附加条件集 $S \subseteq \{x_1, \dots, x_N\}$ - 路径并未经过任何除两端以外的 x -结点; - 条件仅包含 $\mathbf{x}$, 不包含任何 z_k ; 故链型结点 $z_k \notin S$ 依然不阻断路径。于是无论给定多少其它观测量, x_i 与 x_j 仍 d-连通。

$$\Rightarrow x_i \not\perp\!\!\!\perp x_j \mid S, \quad \forall S \subseteq \{x_1, \dots, x_N\} \setminus \{x_i, x_j\}.$$

3 不存在任何条件独立性质

因为对所有 $i \neq j$ 都能找到一条在任何观测条件下开放的路径, 观测边缘图 上两结点间从不 d-分离。故边缘分布 $p(\mathbf{x})$ 不满足任何条件独立性。

4 无有限阶 Markov 性

若 $\mathbf{x}$ 存在阶数为 M 的 Markov 性，则应有 $p(x_n | x_1, \dots, x_{n-1}) = p(x_n | x_{n-M}, \dots, x_{n-1})$ 。这等价于 $x_n \perp\!\!\!\perp x_{n-M-1} | x_{n-M}, \dots, x_{n-1}$ ，与上节结论矛盾。因此对任何有限 M ，观测序列均不满足 Markov 条件。

状态空间模型的观测序列在任何有限阶都不是 Markov 链

□

注 若加入潜变量并一起考虑，则 $\mathbf{z}$ 自身是一阶 Markov 链，而 $\mathbf{x}$ 仅通过 $\mathbf{z}$ 间接耦合。这正是“隐藏 Markov 模型 / 线性动态系统”与显式 Markov 链的根本区别。