

Solutions to Chapter 12 — *Transformer*

姚宇倬

2025 年 9 月 16 日

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 12.1 (★★) 设一组系数 a_{nm} (其中 $m = 1, \dots, N$), 满足

$$a_{nm} \geq 0 \quad (12.39)$$

$$\sum_m a_{nm} = 1. \quad (12.40)$$

(见附录 C) 使用拉格朗日乘子法证明这些系数还必须满足

$$a_{nm} \leq 1 \quad (\text{对 } n = 1, \dots, N). \quad (12.41)$$

练习 12.2 (★) 验证: Softmax 函数 (12.5) 对任意向量 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 都满足约束 (12.3) 与 (12.4)。

练习 12.3 (★) 考虑由式 (12.2) 所定义的简单变换中的输入向量 $\mathbf{x}_n$, 其中的权重系数 a_{nm} 由式 (12.5) 定义。证明: 如果所有的输入向量都是正交的, 即当 $n \neq m$ 时 $\mathbf{x}_n^\top \mathbf{x}_m = 0$, 那么输出向量将恒等于输入向量, 即对于 $n = 1, \dots, N$, 都有 $\mathbf{y}_n = \mathbf{x}_n$ 。

练习 12.4 (★) 设 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^D$ 为独立随机向量, 且均服从零均值、单位协方差的高斯分布 $\mathcal{N}(\cdot | \mathbf{0}, \mathbf{I})$ 。证明 $\mathbb{E}[(\mathbf{a}^\top \mathbf{b})^2] = D$ 。

练习 12.5 (★★★) 证明: 多头注意力 (12.19) 可改写为

$$\mathbf{Y} = \sum_{h=1}^H \mathbf{H}_h \mathbf{X} \mathbf{W}^{(h)}, \quad (12.42)$$

其中 $\mathbf{H}_h$ 由 (12.15) 给出, 并定义

$$\mathbf{W}^{(h)} = \mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)}. \quad (12.43)$$

这里将矩阵 $\mathbf{W}^{(o)}$ 按水平方向分块为子矩阵 $\mathbf{W}_h^{(o)}$, 每个块维度为 $D_v \times D$, 对应于拼接后的注意力矩阵的竖向分段。由于通常 $D_v < D$ (例如常取 $D_v = D/H$), 因此组合矩阵的秩不足。于是用一个完全自由 (满秩) 的矩阵去替代 $\mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)}$ 并不等价于正文中的原始表述。

练习 12.6 (★★) 将自注意力函数 (12.14) 表达为一个全连接网络：把完整输入序列（连接后的词向量）映射为同维度的输出向量，可写成单个大矩阵作用。注意该矩阵参数量为 $\mathcal{O}(N^2 D^2)$ 。证明：自注意力网络对应于这个大矩阵的稀疏且共享参数的版本。画出该矩阵的结构草图，指出哪些参数块被共享、哪些块恒为零。

练习 12.7 (★) 证明：若省略输入向量的位置编码，则按 (12.19) 定义的多头注意力层的输出对输入序列的重排是等变的。

练习 12.8 (★★★) 设 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^D$ 为单位向量 ($\|\mathbf{a}\| = \|\mathbf{b}\| = 1$)，从关于原点各向同性（只依赖到原点距离、不依赖方向）的分布中独立抽取。证明：当 D 很大时，两向量夹角的余弦的绝对值接近 0，因此在高维空间中随机单位向量几乎正交。提示：取一组正交归一基 $\{\mathbf{u}_i\}$ ($\mathbf{u}_i^\top \mathbf{u}_j = \delta_{ij}$)，并将 $\mathbf{a}, \mathbf{b}$ 在该基下展开。

练习 12.9 (★) 若位置编码的做法是将输入 token 向量 $\mathbf{x}$ 与位置向量 $\mathbf{e}$ 拼接，证明：当拼接后的向量经由一个一般的线性变换（矩阵乘法）时，结果可写为“对输入的线性变换”与“对位置向量的线性变换”之和。

练习 12.10 (★★) 证明：按式 (12.25) 定义的位置编码具有如下性质：对固定的偏移 k ，位置 $n+k$ 的编码可表示为位置 n 的编码的线性组合，且系数只依赖于 k 、与 n 无关。为此可使用三角恒等式

$$\cos(A+B) = \cos A \cos B - \sin A \sin B, \quad (12.44)$$

$$\sin(A+B) = \cos A \sin B + \sin A \cos B. \quad (12.45)$$

进一步说明：若编码只用正弦（不用余弦），则上述性质不再成立。

练习 12.11 (★) 考查词袋模型 (12.28)，其中每个分量分布 $p(\mathbf{x}_n)$ 由一个在所有词上共享的通用概率表定义。请证明，对于给定的一个向量训练集，该模型的最大似然解所对应的概率表，其条目即为每个词在训练集中的出现频率。

练习 12.12 (★) 考查由式 (12.31) 给出的自回归语言模型，并假设其右侧的项 $p(\mathbf{x}_n | \mathbf{x}_1, \dots, \mathbf{x}_{n-1})$ 是用通用的概率表来表示的。请证明，这些概率表中的条目数量随 n 的值呈指数级增长。

练习 12.13 (★) 在使用 n-gram 模型时，通常的我们做法是同时训练 n-gram 模型和 (n-1)-gram 模型，然后使用概率的乘积法则，以下列形式计算条件概率：

$$p(\mathbf{x}_n | \mathbf{x}_{n-L+1}, \dots, \mathbf{x}_{n-1}) = \frac{p_L(\mathbf{x}_{n-L+1}, \dots, \mathbf{x}_n)}{p_{L-1}(\mathbf{x}_{n-L+1}, \dots, \mathbf{x}_{n-1})}. \quad (12.46)$$

请解释为什么这种方法比直接存储左侧的条件概率更方便，并证明：为了获得正确的概率，在计算 $p_{L-1}(\dots)$ 时，必须省略掉每个序列的最后一个词元 (token)。

练习 12.14 (★) 按图 12.13 的结构, 写出在已训练 RNN 上进行推断 (生成) 的伪代码。

练习 12.15 (★★) 考查一个由两个词元 (token) y_1 和 y_2 组成的序列, 其中每个词元都可以取状态 A 或 B 。下表给出了其联合概率分布 $p(y_1, y_2)$:

	$y_1 = A$	$y_1 = B$
$y_2 = A$	0.36	0.09
$y_2 = B$	0.15	0.40

我们可以看到, 最可能的序列是 $y_1 = B, y_2 = B$, 其概率为 0.4。(注意: 该题按个人修正后的题目解答)。请使用概率的加和规则与乘积规则, 写出边际分布 $p(y_1)$ 和条件分布 $p(y_2|y_1)$ 的值。

证明: 如果我们首先最大化 $p(y_1)$ 得到一个值 y_1^* , 然后接着最大化 $p(y_2|y_1^*)$, 那么我们得到的序列将不同于全局最可能的序列。求这个 (通过贪心法得到的) 新序列的概率。

练习 12.16 (★) BERT-Large (Devlin *et al.*, 2018) 最大输入长度为 512 个 token, 嵌入维度 $D = 1024$, 词表大小为 30,000。模型含 24 个 Transformer 层, 每层有 16 个自注意力头, 且 $D_q = D_k = D_v = 64$; MLP 的逐位置前馈网络为两层、隐藏单元数 4,096。证明: 该 BERT 编码器式语言模型的参数总量约为 3.4 亿。

下面将进行详细解答!

练习 12.1 解答 (★★)

题目 给定对每个固定的 n , 系数列 $\{a_{nm}\}_{m=1}^N$ 满足

$$a_{nm} \geq 0, \quad \sum_{m=1}^N a_{nm} = 1.$$

需证: 对所有 m 都有 $a_{nm} \leq 1$ (因而 $0 \leq a_{nm} \leq 1$)。

方法一: 直接不等式 (最简)

由于每一项 $a_{nm} \geq 0$ 且它们的和为 1,

$$a_{nm} \leq \sum_{m'=1}^N a_{nm'} = 1.$$

故对任意 m 均有 $a_{nm} \leq 1$ 。证毕。 □

方法二: 拉格朗日乘子 (KKT)

为与题注“附录 C: 用拉格朗日乘子”一致, 我们把问题表述为在可行域

$$\sum_{m=1}^N a_{nm} = 1, \quad a_{nm} \geq 0$$

上最大化某一固定分量 a_{nq} ($q \in \{1, \dots, N\}$)。若能证明 $\max a_{nq} = 1$, 则对任意可行点必有 $a_{nq} \leq 1$, 由于 q 任意, 即得结论。

构造拉格朗日函数 (把不等式写成 $-a_{nm} \leq 0$):

$$\mathcal{L}(\mathbf{a}, \lambda, \boldsymbol{\mu}) = a_{nq} + \lambda \left(1 - \sum_{m=1}^N a_{nm} \right) - \sum_{m=1}^N \mu_m a_{nm},$$

其中 $\mu_m \geq 0$ 。KKT 条件包括

(i) 驻点:

$$\frac{\partial \mathcal{L}}{\partial a_{nq}} = 1 - \lambda - \mu_q = 0, \quad \frac{\partial \mathcal{L}}{\partial a_{nm}} = -\lambda - \mu_m = 0 \quad (m \neq q).$$

(ii) 原始可行: $\sum_m a_{nm} = 1, a_{nm} \geq 0$. (iii) 互补松弛: $\mu_m a_{nm} = 0$ 。

由 $-\lambda - \mu_m = 0$ ($m \neq q$) 得 $\mu_m = -\lambda$ 。因 $\mu_m \geq 0$, 故 $\lambda \leq 0$ 。再由 $1 - \lambda - \mu_q = 0$ 得 $\mu_q = 1 - \lambda \geq 0$ 。

若 $\lambda < 0$, 则对所有 $m \neq q$ 有 $\mu_m = -\lambda > 0$, 由互补松弛式得 $a_{nm} = 0$ ($m \neq q$), 再由和为 1 得 $a_{nq} = 1$ 。于是最优值为 1。

若 $\lambda = 0$, 则 $m \neq q$ 时 $\mu_m = 0$; 而 $\mu_q = 1$, 互补松弛给出 $a_{nq} = 0$, 此时目标值 $0 < 1$, 不是最大值。

因此 $\max a_{nq} = 1$, 且当且仅当 $a_{nq} = 1, a_{nm} = 0 (m \neq q)$ 取到。由极大值原理, 任意可行点都满足 $a_{nq} \leq 1$ 。因为 q 任取, 故

$$0 \leq a_{nm} \leq 1 \quad \text{对所有 } m、n .$$

□

练习 12.2 解答 (★)

题目 验证 softmax 权重

$$a_{nm} = \frac{\exp(\mathbf{x}_n^\top \mathbf{x}_m)}{\sum_{m'=1}^N \exp(\mathbf{x}_n^\top \mathbf{x}_{m'})} \quad (12.5)$$

对任意给定的向量集合 $\mathbf{x}_1, \dots, \mathbf{x}_N$ 都满足

$$a_{nm} \geq 0 \quad \text{以及} \quad \sum_{m=1}^N a_{nm} = 1. \quad (12.3-12.4)$$

证明

记 $s_{nm} := \mathbf{x}_n^\top \mathbf{x}_m \in \mathbb{R}$ 。则

$$a_{nm} = \frac{e^{s_{nm}}}{\sum_{m'} e^{s_{nm'}}}.$$

(i) 非负性: 对任何实数 t , 有 $e^t > 0$ 。因此分子、分母均严格为正, 从而 $a_{nm} > 0$, 特别地 $a_{nm} \geq 0$, 满足 (12.3)。同时也得到 $a_{nm} \leq 1$ (因分母 $\geq$ 分子), 但此处只需 (12.3)。

(ii) 和为 1:

$$\sum_{m=1}^N a_{nm} = \sum_{m=1}^N \frac{e^{s_{nm}}}{\sum_{m'} e^{s_{nm'}}} = \frac{\sum_{m=1}^N e^{s_{nm}}}{\sum_{m'=1}^N e^{s_{nm'}}} = 1,$$

满足 (12.4)。

因为以上推导与 $\{\mathbf{x}_m\}$ 的具体取值无关 (只用到指数函数恒为正、分母是正数之和不为零), 结论对任意向量集合均成立。证毕。

练习 12.3 解答 (★)

题目回顾 简单变换

$$\mathbf{y}_n = \sum_{m=1}^N a_{nm} \mathbf{x}_m \quad (12.2)$$

的权系数由

$$a_{nm} = \frac{\exp(\mathbf{x}_n^\top \mathbf{x}_m)}{\sum_{m'=1}^N \exp(\mathbf{x}_n^\top \mathbf{x}_{m'})} \quad (12.5)$$

给出。设输入向量两两正交，即 $\mathbf{x}_n^\top \mathbf{x}_m = 0$ ($n \neq m$)。证明输出向量满足 $\mathbf{y}_n = \mathbf{x}_n$ 。

直接计算 令 $s_n := \mathbf{x}_n^\top \mathbf{x}_n = \|\mathbf{x}_n\|^2 > 0$ 。两两正交 $\Rightarrow \mathbf{X}\mathbf{X}^\top$ 为对角阵，且对固定的 n

$$a_{nn} = \frac{e^{s_n}}{e^{s_n} + (N-1)e^0}, \quad a_{nm} = \frac{e^0}{e^{s_n} + (N-1)e^0} \quad (m \neq n).$$

于是

$$\mathbf{y}_n = a_{nn} \mathbf{x}_n + \sum_{m \neq n} a_{nm} \mathbf{x}_m.$$

由于 $\{\mathbf{x}_m\}$ 彼此正交， $\mathbf{y}_n = \mathbf{x}_n$ 要想逐分量成立，必须有 $a_{nn} = 1$ 且 $a_{nm} = 0$ ($m \neq n$)。然而对有限的 s_n 上式给出的 a_{nm} 并不满足这一点（例如 $e^0 = 1$ 使得 $a_{nm} > 0$ ）。因此按(12.5)在有限尺度下，一般并不能得到 $\mathbf{y}_n = \mathbf{x}_n$ 的严格等式。

如何得到题目所述等式 在注意力实践中常使用带温度（或等价缩放） $\beta > 0$ 的 softmax:

$$a_{nm}(\beta) = \frac{\exp(\beta \mathbf{x}_n^\top \mathbf{x}_m)}{\sum_{m'} \exp(\beta \mathbf{x}_n^\top \mathbf{x}_{m'})}.$$

当 $\mathbf{x}_n^\top \mathbf{x}_m = 0$ ($m \neq n$) 而 $\mathbf{x}_n^\top \mathbf{x}_n = s_n > 0$ 时，

$$\lim_{\beta \rightarrow \infty} a_{nn}(\beta) = 1, \quad \lim_{\beta \rightarrow \infty} a_{nm}(\beta) = 0 \quad (m \neq n),$$

从而

$$\lim_{\beta \rightarrow \infty} \mathbf{y}_n(\beta) = \mathbf{x}_n.$$

也就是说，在“硬注意力极限”（softmax 变得非常尖锐，或把相似度整体乘以一个很大的正数）下，当输入向量两两正交时，输出向量确实收敛到对应的输入向量：

$\mathbf{y}_n \rightarrow \mathbf{x}_n$ 。

备注 若将(12.5)中的指数改为“归一化点积” $a_{nm} = \frac{\mathbf{x}_n^\top \mathbf{x}_m}{\sum_{m'} \mathbf{x}_n^\top \mathbf{x}_{m'}}$ （当两两正交时分母为 $s_n > 0$ ），则立即得到 $a_{nn} = 1$, $a_{nm} = 0$ ($m \neq n$)，从而 $\mathbf{y}_n = \mathbf{x}_n$ 严格成立。但按教材(12.5)的指数形式，只有在上文所述的尖锐极限下才得到同样的结论。□

练习 12.4 解答 (★)

题目 设 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^D$ 为相互独立的随机向量, 且 $\mathbf{a} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\mathbf{b} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。证明

$$\mathbb{E}[(\mathbf{a}^\top \mathbf{b})^2] = D.$$

证明

令 $S = \mathbf{a}^\top \mathbf{b} = \sum_{i=1}^D a_i b_i$ 。则

$$\begin{aligned}\mathbb{E}[S^2] &= \mathbb{E}\left[\left(\sum_{i=1}^D a_i b_i\right) \left(\sum_{j=1}^D a_j b_j\right)\right] = \sum_{i=1}^D \sum_{j=1}^D \mathbb{E}[a_i a_j b_i b_j] \\ &\stackrel{\text{独立}}{=} \sum_{i=1}^D \sum_{j=1}^D \mathbb{E}[a_i a_j] \mathbb{E}[b_i b_j].\end{aligned}$$

由于 $\mathbf{a}, \mathbf{b}$ 的协方差均为 $\mathbf{I}$, 有 $\mathbb{E}[a_i a_j] = \delta_{ij}$, $\mathbb{E}[b_i b_j] = \delta_{ij}$ 。故

$$\mathbb{E}[S^2] = \sum_{i=1}^D \sum_{j=1}^D \delta_{ij} \delta_{ij} = \sum_{i=1}^D 1 = D.$$

因此 $\boxed{\mathbb{E}[(\mathbf{a}^\top \mathbf{b})^2] = D}$ 。

□

(等价迹形式)

$$\mathbb{E}[(\mathbf{a}^\top \mathbf{b})^2] = \mathbb{E}[\mathbf{a}^\top \mathbf{b} \mathbf{b}^\top \mathbf{a}] = \mathbb{E}[\text{tr}(\mathbf{a} \mathbf{a}^\top \mathbf{b} \mathbf{b}^\top)] = \text{tr}(\mathbb{E}[\mathbf{a} \mathbf{a}^\top] \mathbb{E}[\mathbf{b} \mathbf{b}^\top]) = \text{tr}(\mathbf{I} \mathbf{I}) = D.$$

练习 12.5 解答 (★★★)

题目 证明按式 (12.19) 定义的多头注意力可改写为

$$\mathbf{Y} = \sum_{h=1}^H \mathbf{A}_h \mathbf{X} \mathbf{W}^{(h)}, \quad (12.42)$$

其中

$$\mathbf{A}_h = \text{Softmax}\left(\frac{\mathbf{Q}_h \mathbf{K}_h^\top}{\sqrt{D_k}}\right) \in \mathbb{R}^{N \times N}, \quad \mathbf{W}^{(h)} = \mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)}. \quad (12.43)$$

说明 $\mathbf{W}^{(o)}$ 被按行（垂直）分块为 $\{\mathbf{W}_h^{(o)}\}_{h=1}^H$ ，每块维度 $D_v \times D$ ；由于通常 $D_v < D$ （常取 $D_v = D/H$ ）， $\mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)}$ 均为低秩矩阵，因此用任意自由的 $D \times D$ 矩阵替代它们不等价于正文中的原始表述。

证明

1) 记号与形状 输入 $\mathbf{X} \in \mathbb{R}^{N \times D}$ 。对第 h 个头

$$\mathbf{Q}_h = \mathbf{X} \mathbf{W}_h^{(q)} \in \mathbb{R}^{N \times D_k}, \quad \mathbf{K}_h = \mathbf{X} \mathbf{W}_h^{(k)} \in \mathbb{R}^{N \times D_k}, \quad \mathbf{V}_h = \mathbf{X} \mathbf{W}_h^{(v)} \in \mathbb{R}^{N \times D_v}. \quad (12.16-12.18)$$

缩放点积注意力给出（逐行 softmax）

$$\mathbf{A}_h = \text{Softmax}\left(\frac{\mathbf{Q}_h \mathbf{K}_h^\top}{\sqrt{D_k}}\right) \in \mathbb{R}^{N \times N}, \quad \mathbf{H}_h = \mathbf{A}_h \mathbf{V}_h = \mathbf{A}_h \mathbf{X} \mathbf{W}_h^{(v)} \in \mathbb{R}^{N \times D_v}. \quad (12.14, 12.15)$$

多头输出（按特征维拼接后经 $\mathbf{W}^{(o)}$ ）为

$$\mathbf{Y} = \underbrace{[\mathbf{H}_1 \ \mathbf{H}_2 \ \cdots \ \mathbf{H}_H]}_{N \times (HD_v)} \underbrace{\mathbf{W}^{(o)}}_{(HD_v) \times D}. \quad (12.19)$$

2) 将 $\mathbf{W}^{(o)}$ 按行分块并化为求和 把 $\mathbf{W}^{(o)}$ 沿行（垂直）方向分为 H 个子块

$$\mathbf{W}^{(o)} = \begin{bmatrix} \mathbf{W}_1^{(o)} \\ \mathbf{W}_2^{(o)} \\ \vdots \\ \mathbf{W}_H^{(o)} \end{bmatrix}, \quad \mathbf{W}_h^{(o)} \in \mathbb{R}^{D_v \times D}.$$

由分块矩阵乘法，

$$\mathbf{Y} = \sum_{h=1}^H \mathbf{H}_h \mathbf{W}_h^{(o)} = \sum_{h=1}^H (\mathbf{A}_h \mathbf{X} \mathbf{W}_h^{(v)}) \mathbf{W}_h^{(o)} = \sum_{h=1}^H \mathbf{A}_h \mathbf{X} \underbrace{(\mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)})}_{\mathbf{W}^{(h)}}.$$

于是得到所需形式 (12.42)–(12.43):

$$\boxed{\mathbf{Y} = \sum_{h=1}^H \mathbf{A}_h \mathbf{X} \mathbf{W}^{(h)}, \quad \mathbf{W}^{(h)} = \mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)}}.$$

3) 关于秩与非等价性的说明 每个 $\mathbf{W}^{(h)} = \mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)} \in \mathbb{R}^{D \times D}$ 是乘积分解，其秩满足

$$\text{rank}(\mathbf{W}^{(h)}) \leq \min\{\text{rank}(\mathbf{W}_h^{(v)}), \text{rank}(\mathbf{W}_h^{(o)})\} \leq D_v.$$

由于通常 $D_v < D$ (如 $D_v = D/H$)，故每个头贡献的映射均为低秩。把 $\mathbf{W}^{(o)}$ 分块后， $\mathbf{Y} = \sum_h \mathbf{A}_h \mathbf{X} \mathbf{W}^{(h)}$ 等价于若干秩至多为 D_v 的映射之和，体现了多头注意力的参数共享与结构约束。

若以任意自由矩阵 $\widetilde{\mathbf{W}}^{(h)} \in \mathbb{R}^{D \times D}$ 替换 $\mathbf{W}_h^{(v)} \mathbf{W}_h^{(o)}$ ，则打破了上述低秩与分块结构：原式强制每个头先以 $\mathbf{W}_h^{(v)}$ 将信息投到 D_v -维子空间，再由 $\mathbf{W}_h^{(o)}$ 映回 D -维；自由矩阵可实现任意秩（最高 D ）的映射，因而与原多头注意力不等价。

□

练习 12.6 解答 (★★)

题目 将单头自注意力 (式 (12.14))

$$\mathbf{Y} = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{D_k}}\right) \mathbf{V}, \quad \mathbf{Q} = \mathbf{X}\mathbf{W}^{(q)}, \mathbf{K} = \mathbf{X}\mathbf{W}^{(k)}, \mathbf{V} = \mathbf{X}\mathbf{W}^{(v)} \quad (12.14)$$

表示成把整段输入 (拼接后的词向量) $\mathbf{X} \in \mathbb{R}^{N \times D}$ 映射为同维度输出 $\mathbf{Y} \in \mathbb{R}^{N \times D}$ 的单个大矩阵。说明这样一个完全连接矩阵共有 $\mathcal{O}(N^2 D^2)$ 个独立参数; 并证明自注意力等价于该大矩阵的一个稀疏且参数共享的版本。最后给出该矩阵结构的草图, 标明共享的参数块与恒为零的块。

解答思路 写出把整段序列向量化后的线性算子形式, 并用 Kronecker 积与分块对角矩阵刻画参数共享与稀疏性。

1. 把序列拼接成大向量

将序列按位置逐个拼接为

$$\bar{\mathbf{x}} := \text{vec}(\mathbf{X}) \in \mathbb{R}^{ND}, \quad \bar{\mathbf{y}} := \text{vec}(\mathbf{Y}) \in \mathbb{R}^{ND}.$$

记 $\text{Diag}(\mathbf{W}) := \text{diag}(\underbrace{\mathbf{W}, \dots, \mathbf{W}}_{N \text{ 次}}) \in \mathbb{R}^{ND \times ND}$ 为以 $\mathbf{W}$ 重复 N 次的分块对角矩阵 (对角块为 $\mathbf{W}$, 非对角块为全零)。

则三次线性投影可统一为 (省略与 vec 相关的转置细节, 不影响块结构)

$$\bar{\mathbf{q}} = \text{Diag}(\mathbf{W}^{(q)}) \bar{\mathbf{x}}, \quad \bar{\mathbf{k}} = \text{Diag}(\mathbf{W}^{(k)}) \bar{\mathbf{x}}, \quad \bar{\mathbf{v}} = \text{Diag}(\mathbf{W}^{(v)}) \bar{\mathbf{x}}. \quad (1)$$

2. 固定注意力权重时的整体线性映射

令 $\mathbf{A} = \text{Softmax}(\mathbf{Q}\mathbf{K}^\top / \sqrt{D_k}) \in \mathbb{R}^{N \times N}$ 为注意力权重矩阵 (每行归一化)。在给定 $\mathbf{A}$ 的一次前向传播中, $\mathbf{Y} = \mathbf{A}\mathbf{V}$ 对 $\mathbf{V}$ 是线性的。向量化后

$$\bar{\mathbf{y}} = (\mathbf{A} \otimes \mathbf{I}_D) \bar{\mathbf{v}} = \underbrace{(\mathbf{A} \otimes \mathbf{I}_D) \text{Diag}(\mathbf{W}^{(v)})}_{\mathbf{M}(\mathbf{X})} \bar{\mathbf{x}}. \quad (2)$$

其中 $\otimes$ 是 Kronecker 积。于是得到一个把 $\bar{\mathbf{x}}$ 映射到 $\bar{\mathbf{y}}$ 的大矩阵

$$\boxed{\mathbf{M}(\mathbf{X}) = (\mathbf{A}(\mathbf{X}) \otimes \mathbf{I}_D) \text{Diag}(\mathbf{W}^{(v)})} \in \mathbb{R}^{ND \times ND}.$$

其分块形式为

$$\mathbf{M}(\mathbf{X}) = \begin{pmatrix} \alpha_{11} \mathbf{W}^{(v)} & \alpha_{12} \mathbf{W}^{(v)} & \cdots & \alpha_{1N} \mathbf{W}^{(v)} \\ \alpha_{21} \mathbf{W}^{(v)} & \alpha_{22} \mathbf{W}^{(v)} & \cdots & \alpha_{2N} \mathbf{W}^{(v)} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{N1} \mathbf{W}^{(v)} & \alpha_{N2} \mathbf{W}^{(v)} & \cdots & \alpha_{NN} \mathbf{W}^{(v)} \end{pmatrix}, \quad \alpha_{ij} := \mathbf{A}_{ij}. \quad (3)$$

可见每个 (i, j) 位置的 $D \times D$ 子块都与 $\mathbf{W}^{(v)}$ 同形，仅差一个标量系数 α_{ij} 。

3. 与完全连接大矩阵的参数规模对比

若直接用一个完全连接层 $\widetilde{\mathbf{M}} \in \mathbb{R}^{ND \times ND}$ 来实现同样的输入–输出映射，它由 N^2 个独立的 $D \times D$ 子块组成，总参数量为

$$\#\text{param}(\widetilde{\mathbf{M}}) = N^2 D^2 = \mathcal{O}(N^2 D^2).$$

而自注意力中的可学习参数仅来自三个位置无关的投影矩阵 $\mathbf{W}^{(q)}, \mathbf{W}^{(k)}, \mathbf{W}^{(v)} \in \mathbb{R}^{D \times D}$ （此处取输出维与输入维相同以满足“同维度输出”的设定），因而

$$\#\text{param}(\text{attn}) = 3D^2 = \mathcal{O}(D^2),$$

与序列长度 N 无关。式 (??) 中这些投影由 $\text{Diag}(\mathbf{W}^{(\cdot)})$ 实现——它们是分块对角（稀疏）矩阵，且每个对角块 $\mathbf{W}^{(\cdot)}$ 在所有位置共享。式 (??) 中的 $\mathbf{A}$ 则由 $\mathbf{Q}, \mathbf{K}$ 计算得到，并不引入新的可学习参数。

4. 结论：稀疏性与参数共享

- 稀疏性： $\text{Diag}(\mathbf{W}^{(q)}), \text{Diag}(\mathbf{W}^{(k)}), \text{Diag}(\mathbf{W}^{(v)})$ 的非对角块全为零；- 参数共享：所有位置共享同一组 $\mathbf{W}^{(q)}, \mathbf{W}^{(k)}, \mathbf{W}^{(v)}$ ；在等效大矩阵 $\mathbf{M}(\mathbf{X})$ 中，每个 $D \times D$ 子块都与 $\mathbf{W}^{(v)}$ 同形，仅被不同的数据依赖系数 α_{ij} 缩放（并非独立可学）。

这表明自注意力网络正是“完全连接大矩阵”的一个参数极大共享的稀疏实现，把 $\mathcal{O}(N^2 D^2)$ 的自由度压缩到了 $\mathcal{O}(D^2)$ 。

5. 结构草图（分块矩阵）——第 1 页

$\text{Diag}(\mathbf{W}^{(v)})$

$\mathbf{0}$	$\mathbf{0}$	$\mathbf{W}^{(v)}$
$\mathbf{0}$	$\mathbf{W}^{(v)}$	$\mathbf{0}$
$\mathbf{W}^{(v)}$	$\mathbf{0}$	$\mathbf{0}$



$\mathbf{A} \otimes \mathbf{I}_D$

$\alpha_{2+1,0+1} \mathbf{I}$	$\alpha_{2+1,1+1} \mathbf{I}$	$\alpha_{2+1,2+1} \mathbf{I}$
$\alpha_{1+1,0+1} \mathbf{I}$	$\alpha_{1+1,1+1} \mathbf{I}$	$\alpha_{1+1,2+1} \mathbf{I}$
$\alpha_{0+1,0+1} \mathbf{I}$	$\alpha_{0+1,1+1} \mathbf{I}$	$\alpha_{0+1,2+1} \mathbf{I}$

5. 结构草图（分块矩阵）——第 2 页

$$=$$

$$\downarrow$$

$$\mathbf{M}(\mathbf{X})$$

$\alpha_{2+1,0+1} \mathbf{W}^{(v)}$	$\alpha_{2+1,1+1} \mathbf{W}^{(v)}$	$\alpha_{2+1,2+1} \mathbf{W}^{(v)}$
$\alpha_{1+1,0+1} \mathbf{W}^{(v)}$	$\alpha_{1+1,1+1} \mathbf{W}^{(v)}$	$\alpha_{1+1,2+1} \mathbf{W}^{(v)}$
$\alpha_{0+1,0+1} \mathbf{W}^{(v)}$	$\alpha_{0+1,1+1} \mathbf{W}^{(v)}$	$\alpha_{0+1,2+1} \mathbf{W}^{(v)}$

上图（两页）中：第一页的分块对角矩阵展示了恒为零的非对角块与共享的对角块 $\mathbf{W}^{(v)}$ ；同页的 $\mathbf{A} \otimes \mathbf{I}_D$ 不含可学习参数。第二页为等效大矩阵 $\mathbf{M}(\mathbf{X})$ ，其每个子块皆为同一 $\mathbf{W}^{(v)}$ 的缩放版，体现参数共享而非独立自由度。

□

练习 12.7 解答 (★)

题目 若省略位置编码，证明按

$$\mathbf{Y}(\mathbf{X}) = \text{Concat}(\mathbf{H}_1, \dots, \mathbf{H}_H) \mathbf{W}^{(o)}, \quad \mathbf{H}_h = \text{Softmax}\left(\frac{\mathbf{Q}_h \mathbf{K}_h^\top}{\sqrt{D_k}}\right) \mathbf{V}_h,$$

且

$$\mathbf{Q}_h = \mathbf{X} \mathbf{W}_h^{(q)}, \quad \mathbf{K}_h = \mathbf{X} \mathbf{W}_h^{(k)}, \quad \mathbf{V}_h = \mathbf{X} \mathbf{W}_h^{(v)}$$

定义的多头注意力层对输入序列的任意重排是等变的，即

$$\mathbf{Y}(\mathbf{P}\mathbf{X}) = \mathbf{P} \mathbf{Y}(\mathbf{X})$$

对任意置换矩阵 $\mathbf{P} \in \mathbb{R}^{N \times N}$ 都成立。

证明. 置换矩阵左乘 $\mathbf{P}\mathbf{X}$ 仅重排 $\mathbf{X}$ 的行 (token 次序)。因此

$$\mathbf{Q}'_h = \mathbf{P}\mathbf{X}\mathbf{W}_h^{(q)} = \mathbf{P}\mathbf{Q}_h, \quad \mathbf{K}'_h = \mathbf{P}\mathbf{K}_h, \quad \mathbf{V}'_h = \mathbf{P}\mathbf{V}_h.$$

令

$$\mathbf{L}_h = \frac{\mathbf{Q}_h \mathbf{K}_h^\top}{\sqrt{D_k}} \in \mathbb{R}^{N \times N}, \quad \mathbf{L}'_h = \frac{\mathbf{Q}'_h \mathbf{K}'_h{}^\top}{\sqrt{D_k}} = \frac{(\mathbf{P}\mathbf{Q}_h)(\mathbf{P}\mathbf{K}_h)^\top}{\sqrt{D_k}} = \mathbf{P} \mathbf{L}_h \mathbf{P}^\top.$$

引理: 记 $\text{Softmax}[\cdot]$ 为按行作用的 softmax (对每一行向量逐行归一化)。对任意置换矩阵 $\mathbf{P}$ 与任意矩阵 $\mathbf{L}$, 有

$$\text{Softmax}(\mathbf{P}\mathbf{L}\mathbf{P}^\top) = \mathbf{P} \text{Softmax}(\mathbf{L}) \mathbf{P}^\top.$$

证明引理: 左乘 $\mathbf{P}$ 仅重排行; 右乘 $\mathbf{P}^\top$ 仅重排列。对任意行向量 $\mathbf{r}$ 与置换矩阵 $\mathbf{P}$, 有

$$\text{softmax}(\mathbf{r}\mathbf{P}^\top) = \mathbf{r}\mathbf{P}^\top \text{逐分量取指数并按和归一} = \text{softmax}(\mathbf{r}) \mathbf{P}^\top,$$

因为置换仅重排分量而不改变它们的值与总和。逐行应用可得上述矩阵形式结论。 $\square$

由引理得

$$\text{Softmax}(\mathbf{L}'_h) = \text{Softmax}(\mathbf{P}\mathbf{L}_h\mathbf{P}^\top) = \mathbf{P} \text{Softmax}(\mathbf{L}_h) \mathbf{P}^\top.$$

于是每个头的输出

$$\mathbf{H}'_h = \text{Softmax}(\mathbf{L}'_h) \mathbf{V}'_h = (\mathbf{P} \text{Softmax}(\mathbf{L}_h) \mathbf{P}^\top) (\mathbf{P}\mathbf{V}_h) = \mathbf{P} \text{Softmax}(\mathbf{L}_h) \mathbf{V}_h = \mathbf{P} \mathbf{H}_h.$$

将各头按列拼接并再右乘 $\mathbf{W}^{(o)}$, 注意左乘 $\mathbf{P}$ 与按列拼接可交换 (都只是对行做同样的置换), 故

$$\mathbf{Y}(\mathbf{P}\mathbf{X}) = \text{Concat}(\mathbf{H}'_1, \dots, \mathbf{H}'_H) \mathbf{W}^{(o)} = \mathbf{P} \text{Concat}(\mathbf{H}_1, \dots, \mathbf{H}_H) \mathbf{W}^{(o)} = \mathbf{P} \mathbf{Y}(\mathbf{X}).$$

命题得证。 $\blacksquare$

注: 上式表明没有位置编码时, 自注意力只把输入序列当作无序集合来处理; 对输入做任何相同的置换, 输出会以同样方式置换 (等变), 模型无法区分不同的顺序。

练习 12.8 解答 (★★★)

题目 设 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^D$ 为独立的 D 维随机单位向量, 满足 $\|\mathbf{a}\| = \|\mathbf{b}\| = 1$, 并且其分布关于原点各向同性 (仅依赖到原点的距离, 与方向无关)。证明: 当 D 很大时, 两向量夹角的余弦的绝对值 $|\cos \theta| = |\mathbf{a}^\top \mathbf{b}|$ 以高概率接近于 0, 即在高维空间中随机单位向量几乎互相正交。提示: 取一组正交归一基 $\{\mathbf{u}_i\}_{i=1}^D$, 其中 $\mathbf{u}_i^\top \mathbf{u}_j = \delta_{ij}$, 并在此基下展开 $\mathbf{a}$ 与 $\mathbf{b}$ 。

证明

1) 记号与展开 在基 $\{\mathbf{u}_i\}$ 下写作

$$\mathbf{a} = \sum_{i=1}^D \alpha_i \mathbf{u}_i, \quad \mathbf{b} = \sum_{i=1}^D \beta_i \mathbf{u}_i.$$

各向同性 $\Rightarrow$ 系数的分布对坐标轴无偏, 因而

$$\mathbb{E}[\alpha_i] = \mathbb{E}[\beta_i] = 0, \quad \mathbb{E}[\alpha_i \alpha_j] = \mathbb{E}[\beta_i \beta_j] = c \delta_{ij}.$$

由单位范数 $\mathbb{E}[\|\mathbf{a}\|^2] = \sum_i \mathbb{E}[\alpha_i^2] = 1$ 知 $Dc = 1$, 故 $c = 1/D$; 同理对 β 亦然。

2) 一阶与二阶矩 角度余弦为点积

$$\cos \theta = \mathbf{a}^\top \mathbf{b} = \sum_{i=1}^D \alpha_i \beta_i.$$

由独立性与零均值值得

$$\mathbb{E}[\cos \theta] = \sum_{i=1}^D \mathbb{E}[\alpha_i] \mathbb{E}[\beta_i] = 0.$$

计算二阶矩 (亦即方差, 因为均值为零):

$$\mathbb{E}[(\mathbf{a}^\top \mathbf{b})^2] = \sum_{i,j} \mathbb{E}[\alpha_i \alpha_j] \mathbb{E}[\beta_i \beta_j] = \sum_{i,j} \frac{\delta_{ij}}{D} \cdot \frac{\delta_{ij}}{D} = \sum_{i=1}^D \frac{1}{D^2} = \frac{1}{D}.$$

于是 $\text{sd}(\mathbf{a}^\top \mathbf{b}) = 1/\sqrt{D}$ 。

3) 高维近似正交 由 Chebyshev 不等式, 对任意 $\varepsilon > 0$,

$$\Pr(|\cos \theta| \geq \varepsilon) = \Pr(|\mathbf{a}^\top \mathbf{b}| \geq \varepsilon) \leq \frac{\mathbb{E}[(\mathbf{a}^\top \mathbf{b})^2]}{\varepsilon^2} = \frac{1}{D\varepsilon^2} \xrightarrow{D \rightarrow \infty} 0.$$

因此当维数 D 足够大时, $|\cos \theta|$ 以高概率趋近于 0, 即两独立随机单位向量在高维空间中几乎正交。

□

练习 12.9 解答 (★★)

题目 考虑一种位置编码：将输入 token 向量 $\mathbf{x}$ 与一个位置向量 $\mathbf{e}$ 拼接得到 $[\mathbf{x}; \mathbf{e}]$ 。证明：当该拼接向量经过任意线性变换（右乘某矩阵）时，结果可以表示为对输入向量的线性变换与对位置向量的线性变换之和。

证明

1) 记号与形状 设

$$\mathbf{x} \in \mathbb{R}^{1 \times D_x}, \quad \mathbf{e} \in \mathbb{R}^{1 \times D_e},$$

拼接（按特征维连接）为

$$[\mathbf{x}; \mathbf{e}] \in \mathbb{R}^{1 \times (D_x + D_e)}.$$

令线性变换矩阵 $\mathbf{W} \in \mathbb{R}^{(D_x + D_e) \times D}$ 。将 $\mathbf{W}$ 沿行（竖直）方向分块为

$$\mathbf{W} = \begin{bmatrix} \mathbf{W}_x \\ \mathbf{W}_e \end{bmatrix}, \quad \mathbf{W}_x \in \mathbb{R}^{D_x \times D}, \quad \mathbf{W}_e \in \mathbb{R}^{D_e \times D}.$$

2) 分块矩阵乘法 对输出 $\mathbf{y}$ 有

$$\mathbf{y} = [\mathbf{x}; \mathbf{e}] \mathbf{W} = [\mathbf{x}; \mathbf{e}] \begin{bmatrix} \mathbf{W}_x \\ \mathbf{W}_e \end{bmatrix} = \mathbf{x} \mathbf{W}_x + \mathbf{e} \mathbf{W}_e.$$

右端显然是两项之和：第一项只依赖 $\mathbf{x}$ ，第二项只依赖 $\mathbf{e}$ ，且二者均为线性变换。

3) 批量形式（可选） 若将 N 个 token 组成矩阵 $\mathbf{X} \in \mathbb{R}^{N \times D_x}$ 、位置矩阵 $\mathbf{E} \in \mathbb{R}^{N \times D_e}$ ，则有

$$[\mathbf{X} \ \mathbf{E}] \mathbf{W} = \mathbf{X} \mathbf{W}_x + \mathbf{E} \mathbf{W}_e,$$

同样得到“输入线性变换 + 位置线性变换”的分解。

□

练习 12.10 解答 (★★)

题目 按式 (12.25) 给出的位置编码

$$r_{ni} = \begin{cases} \sin(n/L^{i/D}), & i \text{ 为偶数}, \\ \cos(n/L^{(i-1)/D}), & i \text{ 为奇数}, \end{cases}$$

证明: 对任意固定偏移 k , 位置 $n+k$ 的编码 r_{n+k} 可以表示为位置 n 的编码 r_n 的线性组合, 且线性系数只依赖于 k 而与 n 无关; 并说明若只使用正弦而无余弦时, 该性质一般不成立。

证明

为方便起见, 用从零开始的偶奇索引来配对同一频率的 $\sin$ 与 $\cos$ 项。令

$$\omega_j = L^{-\frac{2j}{D}}, \quad j = 0, 1, \dots, \frac{D}{2} - 1,$$

则式 (12.25) 等价于对每个 j 在向量 r_n 中包含一对分量

$$s_j(n) = \sin(\omega_j n), \quad c_j(n) = \cos(\omega_j n).$$

于是

$$r_n = [s_0(n), c_0(n), s_1(n), c_1(n), \dots, s_{D/2-1}(n), c_{D/2-1}(n)]^\top.$$

(1) 单一频率的线性可表示性 由三角恒等式

$$\sin(A+B) = \sin A \cos B + \cos A \sin B, \quad \cos(A+B) = \cos A \cos B - \sin A \sin B,$$

对任意 j 与固定 k 有

$$\begin{bmatrix} s_j(n+k) \\ c_j(n+k) \end{bmatrix} = \underbrace{\begin{bmatrix} \cos(\omega_j k) & \sin(\omega_j k) \\ -\sin(\omega_j k) & \cos(\omega_j k) \end{bmatrix}}_{R_j(k)} \begin{bmatrix} s_j(n) \\ c_j(n) \end{bmatrix}.$$

矩阵 $R_j(k)$ 仅依赖于 k (更准确地说依赖于 $\omega_j k$), 因此每一对分量在从 n 变到 $n+k$ 时都经历一个与 n 无关的线性变换。

(2) 堆叠得到整体线性变换 将所有频率的关系按块对角堆叠, 得

$$r_{n+k} = \underbrace{\text{blkdiag}(R_0(k), R_1(k), \dots, R_{D/2-1}(k))}_{B(k)} r_n.$$

故存在一矩阵 $B(k)$ (仅依赖 k) 使得 $r_{n+k} = B(k)r_n$ 。这就证明了: 对任意固定偏移 k , 位置编码在从 n 到 $n+k$ 的变化是对 r_n 施加一个与 n 无关的线性变换, 即题目所述性质成立。

(3) 仅用正弦时性质不成立 若位置编码只有正弦分量 $r_n = [\sin(\omega_0 n), \dots, \sin(\omega_{D-1} n)]^\top$, 设存在与 n 无关的系数使

$$\sin(\omega n + \omega k) = \sum_j \alpha_j(k) \sin(\omega_j n) \quad \text{对所有 } n \text{ 都成立.}$$

先看一维情形: $\sin(\omega(n+k)) = \alpha(k) \sin(\omega n)$ 。用恒等式展开得

$$\cos(\omega n) \sin(\omega k) + \sin(\omega n) \cos(\omega k) = \alpha(k) \sin(\omega n).$$

要对所有 n 恒成立, 必须有 $\sin(\omega k) = 0$ 且 $\alpha(k) = \cos(\omega k)$, 即仅当 k 为周期的整数倍才可能成立; 一般 k 下不成立。高维情形同理: 展开 $\sin(\omega_i(n+k))$ 必然出现 $\cos(\omega_i n)$, 而这些 $\cos$ 项无法用与 n 无关的线性组合 $\sum_j \alpha_j(k) \sin(\omega_j n)$ 表示, 从而得到矛盾。因此若没有与每个频率配对的余弦分量, 就不能用只依赖 k 的线性变换把 r_n 映到 r_{n+k} (除非在少数退化的 k 上)。

□

练习 12.11 解答 (★)

题目 考虑词袋模型

$$p(\mathbf{x}_1, \dots, \mathbf{x}_N) = \prod_{n=1}^N p(\mathbf{x}_n) \quad (12.28)$$

其中各分量分布 $p(\mathbf{x}_n)$ 由跨所有词共享的一张通用概率表给出。证明：给定一组训练向量后，极大似然解就是把该表每个条目设为该词在训练集中出现次数占比（出现频率）。

证明

设词表大小为 V ，用 $\pi_j := p(\mathbf{x} = \text{词 } j)$ 表示通用概率表在词 j 上的概率，满足 $\pi_j \geq 0$ 且 $\sum_{j=1}^V \pi_j = 1$ 。把全部训练数据（可以由多条序列组成、长度各异）合在一起统计词频，记

$$c_j := \text{词 } j \text{ 在整个训练集中出现的次数}, \quad N_{\text{tot}} := \sum_{j=1}^V c_j \quad (\text{训练集中 token 总数}).$$

则训练数据的对数似然为

$$\mathcal{L}(\boldsymbol{\pi}) = \sum_n \log p(\mathbf{x}_n) = \sum_{j=1}^V c_j \log \pi_j,$$

在约束 $\sum_j \pi_j = 1$ 下最大化。构造拉格朗日函数

$$\mathcal{J}(\boldsymbol{\pi}, \lambda) = \sum_{j=1}^V c_j \log \pi_j + \lambda \left(\sum_{j=1}^V \pi_j - 1 \right).$$

对每个 π_j 求偏导并令其为零，得到

$$\frac{\partial \mathcal{J}}{\partial \pi_j} = \frac{c_j}{\pi_j} + \lambda = 0 \quad \implies \quad \pi_j = -\frac{c_j}{\lambda}.$$

两边对 j 求和并利用约束 $\sum_j \pi_j = 1$ ，得

$$1 = \sum_{j=1}^V \pi_j = -\frac{1}{\lambda} \sum_{j=1}^V c_j = -\frac{N_{\text{tot}}}{\lambda} \quad \implies \quad \lambda = -N_{\text{tot}}.$$

代回上式，极大似然解为

$$\pi_j^{\text{MLE}} = \frac{c_j}{N_{\text{tot}}}, \quad j = 1, \dots, V.$$

这表明通用概率表的每个条目等于该词在训练集中出现的频率。若某个词在训练集未出现，则 $c_j = 0$ 从而 $\pi_j^{\text{MLE}} = 0$ （实际应用中常用平滑避免零概率）。□

练习 12.12 解答 (★)

题目 考虑式 (12.31) 给出的自回归语言模型

$$p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n \mid x_1, \dots, x_{n-1}),$$

并设右侧各项 $p(x_n \mid x_1, \dots, x_{n-1})$ 由通用概率表（不作任何参数共享假设）表示。证明：这些概率表中的表项数随 n 呈指数级增长。

解答

设词表大小为 V ，每个 token $x_n \in \{1, \dots, V\}$ 。

1) 表项数（存储所有概率的条目数） 在位置 n ：

- 历史（条件） $(x_1, \dots, x_{n-1})$ 的有序取值种数为 V^{n-1} ；
- 给定每个历史，需要为下一个词 x_n 的 V 个可能值存储概率。

因此，位置 n 的概率表共有

$$\boxed{\text{表项数} = V^{n-1} \times V = V^n}$$

个条目。显然这是关于 n 的指数函数（底数为 $V \geq 2$ ）。

2) 自由参数个数（考虑归一化约束） 若只统计独立参数，则对每个历史有 V 个概率且需满足 $\sum_{v=1}^V p(x_n=v \mid x_{1:n-1}) = 1$ ，因此每个历史只有 $V-1$ 个自由度。于是位置 n 的自由参数总数为

$$\boxed{\text{自由参数数} = V^{n-1}(V-1) = \Theta(V^n)}.$$

3) 结论 无论按表项数 V^n 还是自由参数数 $V^{n-1}(V-1)$ 计量，所需规模均随 n 指数级增长（底数为词表大小 V ）。这解释了在没有参数共享的情形下，直接用通用概率表表示 $p(x_n \mid x_{1:n-1})$ 会在 n 稍大时变得不可行。

补充（与 n -gram 的关系） 若改为 L 阶 Markov 近似（ n -gram），每一表仅依赖最近 L 个词，则表项数降为 V^{L+1} 、自由参数数为 $V^L(V-1)$ ，仍随 L 指数增长，但与 n 无关。□

练习 12.13 解答 (★)

题目 在同时训练 n -gram 与 $(n-1)$ -gram (记历史长度 $L := n - 1$) 时, 常用

$$p(x_n | x_{n-L+1}, \dots, x_{n-1}) = \frac{p_L(x_{n-L+1}, \dots, x_n)}{p_{L-1}(x_{n-L+1}, \dots, x_{n-1})} \quad (12.46)$$

来计算条件概率。说明: 为何这比直接存储左端更方便? 并证明: 为得到正确概率, 在估计 $p_{L-1}(\cdot)$ 时必须从每个序列中去掉最后一个 token。

更方便的原因

- 只需保存两张计数表: 所有长度为 L 的 L -gram 计数表与长度为 $L+1$ 的 $(L+1)$ -gram 计数表。由它们即可构造 任意历史的条件分布, 无需为每个历史存一整行条件概率。
- 共享归一化: 对固定历史 h , 分母 $p_{L-1}(h)$ 对所有候选下一个词共用, 计算/存储上都更经济, 并便于与平滑或回退相结合。

正确性的证明 语料含 R 条序列 $s^{(r)}$, 第 r 条长度为 N_r 。记

$c_L(h, x) :=$ 在语料中出现的 $(L+1)$ -gram (h, x) 的次数, $c_{L-1}(h) :=$ 出现的 L -gram h 的次数。

总片段数 对长度为 N_r 的序列:

$$\#(L+1)\text{-gram} = N_r - (L+1) + 1 = N_r - L, \quad \#L\text{-gram} = N_r - L + 1.$$

因而全语料

$$T_L = \sum_{r=1}^R (N_r - L), \quad T_{L-1} = \sum_{r=1}^R (N_r - L + 1) = T_L + R.$$

用相对频率的 MLE 若用极大似然估计 (对所有同阶片段做全局归一化)

$$p_L(h, x) = \frac{c_L(h, x)}{T_L}, \quad p_{L-1}(h) = \frac{c_{L-1}(h)}{T_{L-1}},$$

则由 (12.46)

$$\frac{p_L(h, x)}{p_{L-1}(h)} = \frac{c_L(h, x)/T_L}{c_{L-1}(h)/T_{L-1}} = \frac{T_{L-1}}{T_L} \cdot \frac{c_L(h, x)}{c_{L-1}(h)}. \quad (1)$$

真正的条件概率的 MLE 对每个历史 h ,

$$p(x | h)_{\text{MLE}} = \frac{c_L(h, x)}{\sum_{x'} c_L(h, x')} = \frac{c_L(h, x)}{c_{L-1}^+(h)}, \quad (2)$$

其中 $c_{L-1}^+(h) := \sum_{x'} c_L(h, x')$ 是那些确实有后继词的 L -gram 的计数 (即作为 $(L+1)$ -gram 前缀出现的次数)。

为什么要“去掉每条序列的最后一个 token” 若直接用全部 L -gram 计数 $c_{L-1}(h)$ 来估计 $p_{L-1}(h)$ ，则每条序列的最后一个 L -gram 没有后继词与之配对，于是

$$T_{L-1} = T_L + R, \quad c_{L-1}(h) \geq c_{L-1}^+(h),$$

并且 (1) 与 (2) 相差一个因子 $T_{L-1}/T_L > 1$ ，导致 $\sum_x \frac{p_L(h, x)}{p_{L-1}(h)} < 1$ ，所得到的“条件分布”不再归一化。

解决方法：在估计 $p_{L-1}(h)$ 时忽略每条序列的最后一个 L -gram（等价于从每条序列中去掉最后一个 token 以构造 L -gram 表）。此时

$$T_{L-1}^+ = T_L, \quad c_{L-1}^+(h) = \sum_{x'} c_L(h, x'),$$

从而

$$p(x_n | h) = \frac{p_L(h, x_n)}{p_{L-1}^+(h)} = \frac{c_L(h, x_n)}{c_{L-1}^+(h)}$$

与基于相对频率的条件概率完全一致，且对所有 h 都严格归一化。

备注 若在词表中加入句子结束符 $\langle \text{EOS} \rangle$ ，则每条序列的最后一个 L -gram 也会与 $\langle \text{EOS} \rangle$ 形成一个 $(L+1)$ -gram，自然满足 $T_{L-1} = T_L$ ，无需手工去掉最后一个 token。 $\square$

练习 12.14 解答 (★★)

题目 写出在已训练 RNN 上进行推断的伪代码，RNN 结构如图 12.13：给定输入序列 $\{x_1, \dots, x_N\}$ ，递推产生隐状态 $\{z_n\}$ 与输出 $\{y_n\}$ 。

记号约定

- 训练后模型参数记为 $\mathbf{w}$ 。为便于书写，用一个 RNN 单元记为

$$(z_n, y_n) = \text{RNNCell}_{\mathbf{w}}(x_n, z_{n-1}),$$

其内部可为简单 RNN/GRU/LSTM 等任意已训练结构。

- 若需要显式形式，一个常见的简单 RNN 为

$$\begin{aligned} z_n &= \phi(W_{xz}x_n + W_{zz}z_{n-1} + b_z), \\ \ell_n &= W_{yz}z_n + b_y, \quad y_n = g(\ell_n), \end{aligned}$$

其中 $\phi(\cdot)$ 为非线性， $g(\cdot)$ 为输出映射（如分类时的 *softmax*）。

伪代码（前向推断 / 评分模式）

Input: 已训练参数 $\mathbf{w}$ ；输入序列 $x_{1:N}$ ；初始隐状态 z_0 （如零向量）

Output: 输出序列 $y_{1:N}$ （及可选的对数似然或 logits）

1. 设 $z \leftarrow z_0$
2. **for** $n = 1$ **to** N **do**
3. $(z, y) \leftarrow \text{RNNCell}_{\mathbf{w}}(x_n, z)$ % 计算 z_n, y_n
4. 记录 $z_n \leftarrow z$, $y_n \leftarrow y$
5. **end for**
6. 返回 $\{y_n\}_{n=1}^N$ （以及需要的话 $\{z_n\}_{n=1}^N$ ）

说明

- 上述流程用于条件推断/评分：已知整段输入 $x_{1:N}$ ，逐步计算对应的输出 $y_{1:N}$ 。
- 若任务是自回归生成，只需把第 2 行改为使用上一步输出作为下一步输入（或经采样的 token）：

$$x_n \leftarrow \text{PostProcess}(y_{n-1}) \quad (\text{如 } x_n = \arg \max(y_{n-1}) \text{ 或从 } \text{softmax}(y_{n-1}) \text{ 采样}),$$

其余相同。起始输入通常为特殊起始符 (BOS)。

- 复杂度：时间 $O(N \cdot C_{\text{cell}})$ ，其中 C_{cell} 为单步 RNN 单元的计算开销；空间按需保存 $\{z_n\}$ 或仅保留最后状态以节省内存。

□

练习 12.15 解答 (★★)

题目 (按图中数据更正) 设两步序列 (y_1, y_2) , 每一步取 A 或 B 。其联合分布 $p(y_1, y_2)$ 为

	$y_1 = A$	$y_1 = B$
$y_2 = A$	0.36	0.09
$y_2 = B$	0.15	0.40

可见整体最可能序列为 $(y_1 = B, y_2 = B)$, 概率 0.40。

(1) 边缘分布 $p(y_1)$ 由求和法则得

$$p(y_1 = A) = 0.36 + 0.15 = 0.51,$$

$$p(y_1 = B) = 0.09 + 0.40 = 0.49.$$

(2) 条件分布 $p(y_2 | y_1)$ 由乘法/条件概率定义 $p(y_2 | y_1) = \frac{p(y_1, y_2)}{p(y_1)}$, 得

$$p(y_2 = A | y_1 = A) = \frac{0.36}{0.51} = \frac{12}{17} \approx 0.7059, \quad p(y_2 = B | y_1 = A) = \frac{0.15}{0.51} = \frac{5}{17} \approx 0.2941,$$

$$p(y_2 = A | y_1 = B) = \frac{0.09}{0.49} = \frac{9}{49} \approx 0.1837, \quad p(y_2 = B | y_1 = B) = \frac{0.40}{0.49} = \frac{40}{49} \approx 0.8163.$$

(3) “先选 y_1 再选 y_2 ” 的贪心解 先最大化 $p(y_1)$ 得 $y_1^* = A$ (因为 $0.51 > 0.49$)。再在 y_1^* 下最大化 $p(y_2 | y_1^*)$, 由上式知取 $y_2^* = A$ 。于是贪心序列为 (A, A) , 其概率

$$p(A, A) = p(y_1 = A) p(y_2 = A | y_1 = A) = 0.51 \times \frac{12}{17} = 0.36.$$

(4) 与全局最优比较 联合分布中最大的单元是 $p(B, B) = 0.40$, 对应全局最可能序列 (B, B) 。贪心序列为 (A, A) , 概率 0.36, 与全局最优不同, 且概率更低。

□

练习 12.16 解答 (★)

题目要点 BERT-Large: 词表大小 $V = 30,000$, 最大长度 512; 隐藏维度 (嵌入维) $D = 1024$; 共有 24 个 Transformer 编码层; 每层有 $H = 16$ 个注意力头, 且每头的 $D_q = D_k = D_v = 64$; 逐位置前馈 (FFN) 为两层、隐藏单元数 4096。求参数总量, 说明其约为 3.4×10^8 。

分块计数

(A) 嵌入层 (Embeddings)

$$\text{Token Embedding} : V \times D = 30,000 \times 1024 = 30,720,000,$$

$$\text{Position Embedding} : 512 \times D = 524,288,$$

$$\text{Token-Type Embedding} : 2 \times D = 2,048,$$

$$\text{LayerNorm} (\gamma, \beta) : 2D = 2,048.$$

Embeddings 总计 $\approx 31,248,384$

(B) 单个编码层 (Self-Attention + FFN + LN)

- 自注意力线性映射 (按头分开实现, 与合并为 $D \times D$ 等价):

$$\underbrace{D \times D_k}_{W^{(q)}} \times H + \underbrace{D \times D_k}_{W^{(k)}} \times H + \underbrace{D \times D_v}_{W^{(v)}} \times H + \underbrace{(HD_v) \times D}_{W^{(o)}} = 3 \cdot 1024 \cdot 64 \cdot 16 + 1024 \cdot 1024 = 4,194,304.$$

对应偏置 $4D = 4096$ 。

- 逐位置前馈 ($D \rightarrow 4096 \rightarrow D$):

$$1024 \times 4096 + 4096 \times 1024 = 8,388,608, \quad \text{偏置 } 4096 + 1024 = 5120.$$

- 两个 LayerNorm 的缩放与平移: $2 \times 2D = 4096$ 。

每层参数 $\approx 4,194,304 + 8,388,608 + 4,096 + 5,120 + 4,096 = 12,596,224$

(C) 24 个编码层合计

$24 \times 12,596,224 = 302,309,376$

(D) 池化 (Pooler, CLS 映射)

$$D \times D + D = 1024 \times 1024 + 1024 = 1,049,600$$

总计

$$\begin{aligned}\text{总参数} &= \text{Embeddings} + 24 \text{ 层} + \text{Pooler} \\ &\approx 31,248,384 + 302,309,376 + 1,049,600 \\ &= 334,607,360 \approx 3.35 \times 10^8 \approx \mathbf{3.4 \times 10^8}.\end{aligned}$$

备注

- 若使用更常见的词表大小 $V=30,522$ ，或在语言模型头 (MLM) 中加入额外的仿射变换与词表偏置 (权重通常与词嵌入权重共享，只新增 $\sim V$ 的偏置)，总量会再上调 $\sim (0.5-1.1)\text{M}$ ，从而更接近文献中常见的“ $\approx 340\text{M}$ ”表述。
- 以上已计入所有线性层偏置与 LayerNorm 的 γ/β ，故数量级稳健。

□