

Solutions to Chapter 13 — *Graph Neural Networks*

姚宇倬

August , 2025

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 13.1 (★) 证明：图 13.2 中两种节点编号 (A, B, C, D, E) 与 (C, E, A, D, B) 之间的置换

$$(A, B, C, D, E) \longrightarrow (C, E, A, D, B)$$

可以用式 (13.5) 的形式表示，其中所用的置换矩阵按式 (13.1) 给出。

练习 13.2 (★★) 设 $\mathbf{A}$ 为图的邻接矩阵。证明：图中每个节点所连接的边数（即该节点的度）等于矩阵 $\mathbf{A}^2$ 的相应对角线元素。

练习 13.3 (★) 画出其邻接矩阵为

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{pmatrix}. \quad (13.42)$$

练习 13.4 (★★) 证明：用由式 (13.3) 定义的置换矩阵 $\mathbf{P}$ 去左乘数据矩阵 $\mathbf{X}$ ，所得到的新数据矩阵 $\tilde{\mathbf{X}}$ 正如式 (13.4) 给出的那样，其各行按照置换函数 $\pi(\cdot)$ 进行了重排。

练习 13.5 (★★) 证明：由式 (13.5) 给出的邻接矩阵变换

$$\tilde{\mathbf{A}} = \mathbf{P} \mathbf{A} \mathbf{P}^\top,$$

其中置换矩阵 $\mathbf{P}$ 由式 (13.3) 定义。说明：相对于原邻接矩阵 $\mathbf{A}$ ，变换后的矩阵 $\tilde{\mathbf{A}}$ 的行与列都按照置换函数 $\pi(\cdot)$ 被重排。

练习 13.6 (★★) 在本题中，我们把更新方程 (13.16) 用矩阵写成图层面的等式。为避免符号臃肿，省略层索引 l 。首先，将结点嵌入向量 $\{\mathbf{h}_n\}$ 收集成一个 $N \times D$ 的矩阵 $\mathbf{H}$ ，其中第 n 行为 $\mathbf{h}_n^\top$ 。随后证明：由

$$\mathbf{z}_n = \sum_{m \in \mathcal{N}(n)} \mathbf{h}_m \quad (13.43)$$

给出的邻域聚合向量可写成矩阵形式 $\mathbf{Z} = \mathbf{A} \mathbf{H}$ ，其中 $\mathbf{Z}$ 为 $N \times D$ 矩阵且其第 n 行为 $\mathbf{z}_n^\top$ ， $\mathbf{A}$ 为邻接矩阵。最后，证明 (13.16) 中非线性激活函数的输入可以写成如下矩阵形式：

$$\mathbf{A} \mathbf{H} \mathbf{W}_{\text{neigh}} + \mathbf{H} \mathbf{W}_{\text{self}} + \mathbf{1}_D \mathbf{b}^\top \quad (13.44)$$

其中 $\mathbf{1}_D$ 是一个所有元素均为 1 的 D 维列向量。

练习 13.7 (★★) 利用深度图卷积网络第 l 层的等变性质 (13.19)，以及结点变量在置换下的关系式 (13.4)，证明：由式 (13.18) 定义的完整深度图卷积网络同样是等变的。

练习 13.8 (★★) 解释：当聚合算子按式 (13.24) 定义、且注意力权重由式 (13.28) 给出时，为何该聚合在对图中结点进行任意重排时仍保持等变。

练习 13.9 (★) 证明：若图注意力网络（Graph Attention Network）所用的图是完全图（任意一对结点之间都有一条边），则该网络与标准的 Transformer 架构是等价的。

练习 13.10 (★★) 当坐标系发生平移时，由该坐标系定义的某个物体的位置向量按下式变换：

$$\tilde{\mathbf{r}} = \mathbf{r} + \mathbf{c}. \quad (13.45)$$

其中 $\mathbf{c}$ 为描述平移的固定向量。类似地，若坐标系发生旋转和/或镜像反射，则该物体的位置向量按

$$\tilde{\mathbf{r}} = \mathbf{R} \mathbf{r}, \quad (13.46)$$

其中 $\mathbf{R}$ 是一个正交矩阵，其逆等于其转置，即

$$\mathbf{R} \mathbf{R}^\top = \mathbf{R}^\top \mathbf{R} = \mathbf{I}. \quad (13.47)$$

利用上述性质，证明：在平移、旋转与反射这三类变换下，式 (13.38)、(13.40) 与 (13.41) 中的“消息”保持不变（invariant）；而式 (13.39) 给出的坐标嵌入对这些变换等变（equivariant）。

下面将进行详细解答！

练习 13.1 解答 (★)

题目 证明：图 13.2 中两种结点次序

$$(A, B, C, D, E) \longrightarrow (C, E, A, D, B)$$

所对应的置换可以用式(13.5) $\tilde{\mathbf{A}} = \mathbf{P} \mathbf{A} \mathbf{P}^\top$ 表示，其中置换矩阵 $\mathbf{P}$ 按照(13.1)给出。

解答 将原始结点标号记为

$$A=1, \quad B=2, \quad C=3, \quad D=4, \quad E=5.$$

新结点次序为 $(C, E, A, D, B) = (3, 5, 1, 4, 2)$ 。按(13.3)定义的置换函数 $\pi(\cdot)$ 将新索引映射到旧索引：

$$\pi(1) = 3, \quad \pi(2) = 5, \quad \pi(3) = 1, \quad \pi(4) = 4, \quad \pi(5) = 2.$$

于是置换矩阵为（第 n 行是标准基向量 $\mathbf{u}_{\pi(n)}^\top$ ）

$$\mathbf{P} = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{pmatrix}. \quad (13.1)$$

行、列的置换形式 对任意矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$ ，利用 $\mathbf{P}_{ni} = \delta_{i, \pi(n)}$ 与 $\mathbf{P}_{jm}^\top = \delta_{j, \pi(m)}$ ，有

$$(\mathbf{P} \mathbf{A} \mathbf{P}^\top)_{nm} = \sum_{i,j} \mathbf{P}_{ni} A_{ij} \mathbf{P}_{jm}^\top = \sum_{i,j} \delta_{i, \pi(n)} A_{ij} \delta_{j, \pi(m)} = A_{\pi(n), \pi(m)}.$$

这表明： $\mathbf{P}$ 左乘将行按 $\pi(\cdot)$ 置换，右乘 $\mathbf{P}^\top$ 将列按同一置换置换，从而把矩阵的行、列同时改为新的结点次序。

应用到邻接矩阵 令 $\mathbf{A}$ 为原结点次序 (A, B, C, D, E) 的邻接矩阵，则按(13.5)

$$\boxed{\tilde{\mathbf{A}} = \mathbf{P} \mathbf{A} \mathbf{P}^\top} \quad (13.5)$$

得到的 $\tilde{\mathbf{A}}$ 的第 n 行第 m 列元素等于 $A_{\pi(n), \pi(m)}$ ，恰对应于把结点顺序改为 (C, E, A, D, B) 后的邻接矩阵。因此，题设置换确可表示为(13.5)所述的形式，且置换矩阵由(13.1)给出。 $\square$

练习 13.2 解答 (★★)

题目 证明：对一个图的每个结点，其连接的边数等于邻接矩阵 A 的平方 A^2 在该结点对应的对角元素；即 $(A^2)_{ii}$ 等于结点 i 的度。

解题假设与记号 按本章默认的简单无向图（至多一条边、无自环）： $A \in \mathbb{R}^{N \times N}$ 满足 $A_{ij} = A_{ji} \in \{0, 1\}$, $A_{ii} = 0$ 。记结点 i 的度为

$$\deg(i) = \sum_{j=1}^N A_{ij}.$$

核心计算 考察 A^2 的对角元：

$$(A^2)_{ii} = \sum_{j=1}^N A_{ij} A_{ji} \stackrel{A=A^\top}{=} \sum_{j=1}^N A_{ij}^2 \stackrel{A_{ij} \in \{0,1\}}{=} \sum_{j=1}^N A_{ij} = \deg(i).$$

因此， A^2 的第 i 个对角元素正好等于结点 i 的度，即 $(A^2)_{ii} = \deg(i)$ 。

向量式（等价表述） 设 $\mathbf{1} \in \mathbb{R}^N$ 为全 1 向量， $\text{diag}(\cdot)$ 返回矩阵主对角线向量，则

$$\text{diag}(A^2) = A \mathbf{1},$$

右侧正是每一行元素之和，亦即各结点的度向量。

□

练习 13.3 解答 (★)

题目要点 给定邻接矩阵

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \end{pmatrix} \quad (13.42)$$


要求画出对应的无向图。

作图与验证 矩阵对称且对角为零, 说明图是无向简单图 (无自环)。令顶点依次为 A, B, C, D, E 。由 $\mathbf{A}$ 的非零元读取边, 得到

$$\mathcal{E} = \{AB, AC, AE, BC, BD, BE, CD\}.$$

各顶点度数 (等于该行元素和) 为 $\deg(A) = 3$, $\deg(B) = 4$, $\deg(C) = 3$, $\deg(D) = 2$, $\deg(E) = 2$, 与上面的边集一致。

TikZ 作图



上图即为与邻接矩阵 (13.42) 完全对应的无向图。

□

练习 13.4 解答 (★★)

题目 设置换函数 $\pi: \{1, \dots, N\} \rightarrow \{1, \dots, N\}$, 并按(13.3) 定义对应的置换矩阵

$$\mathbf{P} = \begin{bmatrix} \mathbf{u}_{\pi(1)}^\top \\ \mathbf{u}_{\pi(2)}^\top \\ \vdots \\ \mathbf{u}_{\pi(N)}^\top \end{bmatrix},$$

其中 $\mathbf{u}_k$ 为标准基向量。证明: 对任意数据矩阵 $\mathbf{X} \in \mathbb{R}^{N \times D}$, 预乘 $\mathbf{P}$ 的结果

$$\tilde{\mathbf{X}} = \mathbf{P} \mathbf{X} \tag{13.4}$$

就是将 $\mathbf{X}$ 的各行按照 $\pi(\cdot)$ 进行重排后的矩阵。

证明 记 $\mathbf{X}$ 的第 k 行为 $\mathbf{X}_{k:}$ 。由置换矩阵的定义可写

$$P_{ik} = \begin{cases} 1, & k = \pi(i), \\ 0, & \text{否则}. \end{cases}$$

于是对 $\tilde{\mathbf{X}} = \mathbf{P} \mathbf{X}$ 的第 i 行有

$$\tilde{\mathbf{X}}_{i:} = (\mathbf{P} \mathbf{X})_{i:} = \sum_{k=1}^N P_{ik} \mathbf{X}_{k:} = \mathbf{X}_{\pi(i):}$$

即 $\tilde{\mathbf{X}}$ 的第 i 行等于 $\mathbf{X}$ 的第 $\pi(i)$ 行, 恰为将 $\mathbf{X}$ 的行按置换 $\pi(\cdot)$ 重排之结果。故(13.4) 成立。 $\square$

练习 13.5 解答 (★★)

题目要点 设 $\mathbf{P}$ 为由置换函数 $\pi(\cdot)$ 定义的置换矩阵 (见式(13.3)), 邻接矩阵在节点重标记后的变换为

$$\tilde{\mathbf{A}} = \mathbf{P} \mathbf{A} \mathbf{P}^\top \quad (13.5)$$

证明: $\tilde{\mathbf{A}}$ 相对于原邻接矩阵 $\mathbf{A}$ 的行与列都按同一置换 $\pi(\cdot)$ 同时被重排。

思路 先证左乘 $\mathbf{P}$ 将矩阵行按 π 重排; 再证右乘 $\mathbf{P}^\top$ 将列按 π 重排; 两者合并即得结论。

证明 按(13.3)的构造, $\mathbf{P}$ 的第 n 行是标准基向量 $\mathbf{u}_{\pi(n)}^\top$, 故

$$P_{ni} = \delta_{i, \pi(n)} \quad (n, i = 1, \dots, N).$$

于是对任意矩阵 $\mathbf{X}$ 有

$$(\mathbf{P}\mathbf{X})_{nm} = \sum_i P_{ni} X_{im} = \sum_i \delta_{i, \pi(n)} X_{im} = X_{\pi(n), m}, \quad (1)$$

$$(\mathbf{X}\mathbf{P}^\top)_{nm} = \sum_j X_{nj} P_{jm}^\top = \sum_j X_{nj} P_{mj} = \sum_j X_{nj} \delta_{j, \pi(m)} = X_{n, \pi(m)}. \quad (2)$$

式(1)指出左乘 $\mathbf{P}$ 将行按 π 重排; 式(2)指出右乘 $\mathbf{P}^\top$ 将列按 π 重排。

将二者合并于(13.5):

$$\tilde{A}_{nm} = (\mathbf{P}\mathbf{A}\mathbf{P}^\top)_{nm} = \sum_{i,j} P_{ni} A_{ij} P_{jm}^\top = \sum_{i,j} \delta_{i, \pi(n)} A_{ij} \delta_{j, \pi(m)} = A_{\pi(n), \pi(m)}. \quad (3)$$

因此对所有 n, m ,

$$\boxed{\tilde{A}_{nm} = A_{\pi(n), \pi(m)}}$$

即 $\tilde{\mathbf{A}}$ 的行与列均相对于 $\mathbf{A}$ 按同一置换 π 同时被重排。证毕。 $\square$

备注 $\mathbf{P}$ 为正交矩阵 (置换矩阵), 满足 $\mathbf{P}^\top \mathbf{P} = \mathbf{I}$ 。若 $\mathbf{A}$ 为无向图的对称邻接矩阵, 则 $\tilde{\mathbf{A}}$ 亦对称; 两者仅在节点顺序上不同, 图结构完全相同。

练习 13.6 解答 (★★)

题目要点 为简洁起见省略层索引。将节点嵌入向量 $\{\mathbf{h}_n\}_{n=1}^N$ 叠为矩阵 $\mathbf{H} \in \mathbb{R}^{N \times D}$ (第 n 行为 $\mathbf{h}_n^\top$)，设无向图的邻接矩阵为 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 。需证明

$$\mathbf{z}_n = \sum_{m \in \mathcal{N}(n)} \mathbf{h}_m \iff \mathbf{Z} = \mathbf{A}\mathbf{H}, \quad (13.43)$$

并把式 (13.16) 的非线性之前的仿射部分写成

$$\boxed{\mathbf{A}\mathbf{H}\mathbf{W}_{\text{neigh}} + \mathbf{H}\mathbf{W}_{\text{self}} + \mathbf{1}_N\mathbf{b}^\top} \quad (13.44)$$

其中 $\mathbf{W}_{\text{neigh}}, \mathbf{W}_{\text{self}} \in \mathbb{R}^{D \times D}$, $\mathbf{b} \in \mathbb{R}^D$, $\mathbf{1}_N$ 为 N 维全 1 列向量 (就维度一致性而言偏置项应为 $\mathbf{1}_N\mathbf{b}^\top$)。

(1) 证明 $\mathbf{Z} = \mathbf{A}\mathbf{H}$ 按矩阵乘法定义,

$$(\mathbf{A}\mathbf{H})_{n:} = \sum_{m=1}^N A_{nm} \mathbf{H}_{m:} = \sum_{m=1}^N A_{nm} \mathbf{h}_m^\top = \sum_{m \in \mathcal{N}(n)} \mathbf{h}_m^\top = \mathbf{z}_n^\top.$$

各行拼装即得 $\mathbf{Z} = \mathbf{A}\mathbf{H}$, 与 (13.43) 等价。

(2) 式 (13.16) 的矩阵化 逐点更新为

$$\mathbf{h}_n^{(+)} = f(\mathbf{W}_{\text{self}}\mathbf{h}_n + \mathbf{W}_{\text{neigh}}\mathbf{z}_n + \mathbf{b}).$$

把全部节点合并,

$$\underbrace{\begin{bmatrix} \mathbf{h}_1^{(+)\top} \\ \vdots \\ \mathbf{h}_N^{(+)\top} \end{bmatrix}}_{\mathbf{H}^{(+)}} = f\left(\underbrace{\begin{bmatrix} (\mathbf{W}_{\text{self}}\mathbf{h}_1)^\top \\ \vdots \\ (\mathbf{W}_{\text{self}}\mathbf{h}_N)^\top \end{bmatrix}}_{\mathbf{H}\mathbf{W}_{\text{self}}} + \underbrace{\begin{bmatrix} (\mathbf{W}_{\text{neigh}}\mathbf{z}_1)^\top \\ \vdots \\ (\mathbf{W}_{\text{neigh}}\mathbf{z}_N)^\top \end{bmatrix}}_{(\mathbf{A}\mathbf{H})\mathbf{W}_{\text{neigh}}} + \underbrace{\begin{bmatrix} \mathbf{b}^\top \\ \vdots \\ \mathbf{b}^\top \end{bmatrix}}_{\mathbf{1}_N\mathbf{b}^\top} \right),$$

故非线性前的仿射项正是 $\mathbf{A}\mathbf{H}\mathbf{W}_{\text{neigh}} + \mathbf{H}\mathbf{W}_{\text{self}} + \mathbf{1}_N\mathbf{b}^\top$, 即 (13.44)。

形状校验 $\mathbf{A}\mathbf{H}$, $\mathbf{H} \in \mathbb{R}^{N \times D}$, 三项经右乘 $\mathbf{W}_{\text{neigh}}, \mathbf{W}_{\text{self}} \in \mathbb{R}^{D \times D}$ 后仍为 $N \times D$; $\mathbf{1}_N\mathbf{b}^\top \in \mathbb{R}^{N \times D}$, 故可逐元素相加。

□

练习 13.7 解答 (★★)

题目要点 利用单层等变性质式(13.19)与节点变量在置换下的变换式(13.4)，证明按式(13.18)堆叠得到的整网（多层图卷积网络）仍然是等变的。

记号 用粗体大写表示按行堆叠的节点嵌入矩阵。网络第 l 层的变换写为（式(13.18)）

$$\mathbf{H}^{(l)} = \mathbf{F}(\mathbf{H}^{(l-1)}, \mathbf{A}, \mathbf{W}^{(l)}), \quad \mathbf{H}^{(0)} = \mathbf{X}.$$

给定由置换函数 $\pi(\cdot)$ 诱导的置换矩阵 $\mathbf{P}$ ，置换后的输入为（式(13.4)、(13.5)）

$$\tilde{\mathbf{X}} = \mathbf{P}\mathbf{X}, \quad \tilde{\mathbf{A}} = \mathbf{P}\mathbf{A}\mathbf{P}^\top.$$

记用置换后输入/邻接得到的各层表示为 $\tilde{\mathbf{H}}^{(l)} = \mathbf{F}(\tilde{\mathbf{H}}^{(l-1)}, \tilde{\mathbf{A}}, \mathbf{W}^{(l)}), \tilde{\mathbf{H}}^{(0)} = \tilde{\mathbf{X}}$. 单层等变性质给出（式(13.19)）

$$\boxed{\mathbf{P}\mathbf{H}^{(l)} = \mathbf{F}(\mathbf{P}\mathbf{H}^{(l-1)}, \mathbf{P}\mathbf{A}\mathbf{P}^\top, \mathbf{W}^{(l)})} \quad (\star)$$

证明（归纳法） 我们证明对所有 $l = 0, 1, \dots, L$ 都有 $\tilde{\mathbf{H}}^{(l)} = \mathbf{P}\mathbf{H}^{(l)}$ 。

基例 $l = 1$ 由定义与 $(\star)$ 式，

$$\tilde{\mathbf{H}}^{(1)} = \mathbf{F}(\tilde{\mathbf{X}}, \tilde{\mathbf{A}}, \mathbf{W}^{(1)}) = \mathbf{F}(\mathbf{P}\mathbf{X}, \mathbf{P}\mathbf{A}\mathbf{P}^\top, \mathbf{W}^{(1)}) = \mathbf{P}\mathbf{H}^{(1)}.$$

归纳步 设对某一 $l - 1 (\geq 1)$ 已有 $\tilde{\mathbf{H}}^{(l-1)} = \mathbf{P}\mathbf{H}^{(l-1)}$ 。则

$$\tilde{\mathbf{H}}^{(l)} = \mathbf{F}(\tilde{\mathbf{H}}^{(l-1)}, \tilde{\mathbf{A}}, \mathbf{W}^{(l)}) = \mathbf{F}(\mathbf{P}\mathbf{H}^{(l-1)}, \mathbf{P}\mathbf{A}\mathbf{P}^\top, \mathbf{W}^{(l)}) = \mathbf{P}\mathbf{H}^{(l)},$$

其中最后一步由 $(\star)$ 式得出。归纳完成。

因此对最终层有

$$\boxed{\tilde{\mathbf{H}}^{(L)} = \mathbf{P}\mathbf{H}^{(L)}}$$

即由(13.18)堆叠的整个深层图卷积网络在任意节点置换 $\mathbf{P}$ 下保持等变性。 $\square$

备注 若在末层再接一个逐节点、参数共享的读出层（如式(13.20) 的线性+softmax），由于该读出对每行独立同分布且与节点顺序无关，输出同样满足 $\tilde{\mathbf{Y}} = \mathbf{P}\mathbf{Y}$ ，从而整条节点级预测链路保持等变。

练习 13.8 解答 (★★)

题目 说明为何由

$$\mathbf{z}_n^{(l)} = \text{Aggregate}(\{\mathbf{h}_m^{(l)} : m \in \mathcal{N}(n)\}) = \sum_{m \in \mathcal{N}(n)} A_{nm} \mathbf{h}_m^{(l)} \quad (13.24)$$

定义的聚合器在注意力权重

$$A_{nm} = \frac{\exp\{\text{MLP}(\mathbf{h}_n^{(l)}, \mathbf{h}_m^{(l)})\}}{\sum_{m' \in \mathcal{N}(n)} \exp\{\text{MLP}(\mathbf{h}_n^{(l)}, \mathbf{h}_{m'}^{(l)})\}} \quad (13.28)$$

下, 对图的节点重排是等变 (equivariant) 的。

证明 设节点置换由置换矩阵 $\mathbf{P}$ 表示, 对应的重排为

$$\mathbf{H}' = \mathbf{P}\mathbf{H}, \quad \mathbf{A}' = \mathbf{P}\mathbf{A}\mathbf{P}^\top,$$

其中 $\mathbf{H}$ 的第 n 行是 $\mathbf{h}_n^{(l)\top}$ 。令 $\pi(\cdot)$ 为置换函数, 则

$$\mathbf{h}'_{\pi(n)} = \mathbf{h}_n, \quad \mathcal{N}'(\pi(n)) = \pi(\mathcal{N}(n)). \quad (1)$$

(a) 注意力权重的等变性 记打分函数 $s(\mathbf{u}, \mathbf{v}) := \text{MLP}(\mathbf{u}, \mathbf{v})$, 它在所有节点上参数共享, 且对交换输入不变 (文中假设)。由(1) 得

$$s(\mathbf{h}'_{\pi(n)}, \mathbf{h}'_{\pi(m)}) = s(\mathbf{h}_n, \mathbf{h}_m). \quad (2)$$

考虑在重排图中对节点 $\pi(n)$ 的 softmax 归一化, 其分母在集合 $\mathcal{N}'(\pi(n)) = \pi(\mathcal{N}(n))$ 上求和, 只是把原来 $\{s(\mathbf{h}_n, \mathbf{h}_{m'})\}_{m' \in \mathcal{N}(n)}$ 按 π 重新排列一次。因此 softmax 输出也被同样地重排, 即

$$A'_{\pi(n)\pi(m)} = A_{nm}. \quad (3)$$

(b) 聚合结果的等变性 将(3) 代入(13.24) 的重排版本并用(1) 改变求和指标, 得

$$\begin{aligned} \mathbf{z}'_{\pi(n)} &= \sum_{m' \in \mathcal{N}'(\pi(n))} A'_{\pi(n)m'} \mathbf{h}'_{m'} = \sum_{m \in \mathcal{N}(n)} A'_{\pi(n)\pi(m)} \mathbf{h}'_{\pi(m)} \\ &= \sum_{m \in \mathcal{N}(n)} A_{nm} \mathbf{h}_m = \mathbf{z}_n. \end{aligned}$$

把所有 $\mathbf{z}_n$ 按行堆叠为矩阵 $\mathbf{Z}$, 上述等式等价于

$$\boxed{\mathbf{Z}' = \mathbf{P}\mathbf{Z}},$$

即在节点重排下, 聚合输出仅被同一置换重排——这正是等变性的定义。

因而, 由(13.24) 与(13.28) 定义的注意力聚合在节点重排下是等变的。 $\square$

练习 13.9 解答 (★)

题目 证明：当图是完全连通（任意结点对之间都有一条边，并含自环）时，图注意力网络（GAT）等价于标准的多头自注意力（Transformer）层。

证明思路 写出一层 GAT 的一般形式，并在完全图上选取与 Transformer 相同的打分与消息函数，得到完全一致的矩阵表达。

1) GAT 的一般一层形式 设第 l 层的结点嵌入按行向量堆叠为 $\mathbf{H} \in \mathbb{R}^{N \times D}$ ，第 n 行为 $\mathbf{h}_n^\top$ 。对第 h 个注意力头，取任意可学习的 打分函数 $s_h(\cdot, \cdot)$ 与消息映射 $\phi_h(\cdot)$ ，并令

$$a_{nm}^{(h)} = \frac{\exp(s_h(\mathbf{h}_n, \mathbf{h}_m))}{\sum_{m'=1}^N \exp(s_h(\mathbf{h}_n, \mathbf{h}_{m'}))}, \quad \mathbf{z}_n^{(h)} = \sum_{m=1}^N a_{nm}^{(h)} \phi_h(\mathbf{h}_m).$$

将各头输出按列拼接并作线性投影，得一层输出

$$\mathbf{Y} = [\mathbf{Z}^{(1)} \cdots \mathbf{Z}^{(H)}] \mathbf{W}^{(o)}, \quad \mathbf{Z}^{(h)} = [\mathbf{z}_1^{(h)} \cdots \mathbf{z}_N^{(h)}]^\top. \quad (\text{GAT})$$

2) 选取与 Transformer 相同的参数化 在完全图上， $\mathcal{N}(n) = \{1, \dots, N\}$ 。对每个头 h ，令

$$\mathbf{Q}_h = \mathbf{H} \mathbf{W}_h^{(q)}, \quad \mathbf{K}_h = \mathbf{H} \mathbf{W}_h^{(k)}, \quad \mathbf{V}_h = \mathbf{H} \mathbf{W}_h^{(v)},$$

并取

$$s_h(\mathbf{h}_n, \mathbf{h}_m) = \frac{(\mathbf{q}_n^{(h)})(\mathbf{k}_m^{(h)})^\top}{\sqrt{D_k}}, \quad \phi_h(\mathbf{h}_m) = \mathbf{h}_m \mathbf{W}_h^{(v)} = \mathbf{v}_m^{(h)},$$

其中 $\mathbf{q}_n^{(h)}$ 为 $\mathbf{Q}_h$ 的第 n 行， $\mathbf{k}_m^{(h)}$ 、 $\mathbf{v}_m^{(h)}$ 类同。于是注意力权重矩阵与聚合为

$$\mathbf{A}_h = \text{Softmax}\left(\frac{\mathbf{Q}_h \mathbf{K}_h^\top}{\sqrt{D_k}}\right), \quad \mathbf{Z}^{(h)} = \mathbf{A}_h \mathbf{V}_h.$$

把各头拼接并线性映射，得

$$\boxed{\mathbf{Y} = [\mathbf{A}_1 \mathbf{V}_1 \cdots \mathbf{A}_H \mathbf{V}_H] \mathbf{W}^{(o)}} \quad (1)$$

3) 与标准 Transformer 的一致性 式 (1) 与标准多头自注意力完全同形：对每个头先由 $\mathbf{W}_h^{(q)}, \mathbf{W}_h^{(k)}, \mathbf{W}_h^{(v)}$ 生成 $\mathbf{Q}_h, \mathbf{K}_h, \mathbf{V}_h$ ，再用缩放点积与 softmax 得 $\mathbf{A}_h$ ，加权求和得 $\mathbf{A}_h \mathbf{V}_h$ ，最后拼接并乘 $\mathbf{W}^{(o)}$ 。这正是 Transformer 注意力层（参见式(12.14)–(12.19)）的计算流程。

因此，当图为完全连通（包含自环）时，多头 GAT 的一层注意力与标准 Transformer 的多头自注意力等价。若再接上逐点前馈、残差与层归一化，即得到完整的 Transformer 编码器块。

□

练习 13.10 解答 (★★)

题目 坐标系平移与旋转/镜像时, 坐标向量变换为

$$\tilde{\mathbf{r}} = \mathbf{r} + \mathbf{c} \quad (13.45)$$

$$\tilde{\mathbf{r}} = \mathbf{R} \mathbf{r}, \quad \mathbf{R}^\top \mathbf{R} = \mathbf{I} \quad (13.46-13.47)$$

利用这些性质, 证明: 在 (13.38)、(13.40)、(13.41) 式中的消息在上述变换下不变, 而 (13.39) 式给出的坐标嵌入在上述变换下等变。为便于引用, 记

$$\mathbf{e}_{nm}^{(\ell+1)} = \text{Update}_{\text{edge}}(\mathbf{e}_{nm}^{(\ell)}, \mathbf{h}_n^{(\ell)}, \mathbf{h}_m^{(\ell)}, \|\mathbf{r}_n^{(\ell)} - \mathbf{r}_m^{(\ell)}\|^2), \quad (13.38)$$

$$\mathbf{r}_n^{(\ell+1)} = \mathbf{r}_n^{(\ell)} + C \sum_{(n,m) \in \mathcal{E}} (\mathbf{r}_n^{(\ell)} - \mathbf{r}_m^{(\ell)}) \phi(\mathbf{e}_{nm}^{(\ell+1)}), \quad (13.39)$$

$$\mathbf{z}_n^{(\ell)} = \text{Aggregate}_{\text{node}}(\{\mathbf{e}_{nm}^{(\ell+1)} : m \in \mathcal{N}(n)\}), \quad (13.40)$$

$$\mathbf{h}_n^{(\ell+1)} = \text{Update}_{\text{node}}(\mathbf{h}_n^{(\ell)}, \mathbf{z}_n^{(\ell)}). \quad (13.41)$$

关键不变量 对任意 $\mathbf{c}$ 与正交矩阵 $\mathbf{R}$, 有

$$\|\tilde{\mathbf{r}}_n - \tilde{\mathbf{r}}_m\|^2 = \|\mathbf{r}_n + \mathbf{c} - \mathbf{r}_m - \mathbf{c}\|^2 = \|\mathbf{r}_n - \mathbf{r}_m\|^2,$$

$$\|\tilde{\mathbf{r}}_n - \tilde{\mathbf{r}}_m\|^2 = \|\mathbf{R}(\mathbf{r}_n - \mathbf{r}_m)\|^2 = (\mathbf{r}_n - \mathbf{r}_m)^\top \mathbf{R}^\top \mathbf{R} (\mathbf{r}_n - \mathbf{r}_m) = \|\mathbf{r}_n - \mathbf{r}_m\|^2.$$

因此, 两点间的平方距离在平移与旋转/镜像下保持不变。

(a) 消息的不变性 (13.38)、(13.40)、(13.41) 对层 ℓ 做归纳: 假设 $\mathbf{e}_{nm}^{(\ell)}$ 、 $\mathbf{h}_n^{(\ell)}$ 已在上述几何变换下不变, 且 $\mathbf{r}_n^{(\ell)}$ 等变 (见(b))。则:

- 边消息 (13.38) 仅依赖于不变的 $\mathbf{e}_{nm}^{(\ell)}$ 、 $\mathbf{h}_n^{(\ell)}$ 、 $\mathbf{h}_m^{(\ell)}$ 与不变量 $\|\mathbf{r}_n^{(\ell)} - \mathbf{r}_m^{(\ell)}\|^2$ 。故

$$\tilde{\mathbf{e}}_{nm}^{(\ell+1)} = \mathbf{e}_{nm}^{(\ell+1)}$$

在平移与旋转/镜像下不变。

- 节点聚合 (13.40) 的输入集合 $\{\mathbf{e}_{nm}^{(\ell+1)}\}_{m \in \mathcal{N}(n)}$ 与上式相同, 且 $\text{Aggregate}_{\text{node}}$ 对输入集合的排列不敏感 (置换不变)。故

$$\tilde{\mathbf{z}}_n^{(\ell)} = \mathbf{z}_n^{(\ell)}$$

- 节点更新 (13.41) 的两项输入 $\mathbf{h}_n^{(\ell)}$ 、 $\mathbf{z}_n^{(\ell)}$ 在变换下均不变, 因此

$$\tilde{\mathbf{h}}_n^{(\ell+1)} = \mathbf{h}_n^{(\ell+1)}$$

由归纳起点（ $\ell = 0$ 时的初始边/节点特征与函数选择与坐标变换无关或仅依赖距离）成立，可得对所有层消息均不变。

(b) 坐标嵌入的等变性 (13.39) 先看平移：由 $\tilde{\mathbf{r}}_n^{(\ell)} = \mathbf{r}_n^{(\ell)} + \mathbf{c}$ 与 $\tilde{\mathbf{e}}_{nm}^{(\ell+1)} = \mathbf{e}_{nm}^{(\ell+1)}$ 得

$$\tilde{\mathbf{r}}_n^{(\ell+1)} = \tilde{\mathbf{r}}_n^{(\ell)} + C \sum_{(n,m)} (\tilde{\mathbf{r}}_n^{(\ell)} - \tilde{\mathbf{r}}_m^{(\ell)}) \phi(\tilde{\mathbf{e}}_{nm}^{(\ell+1)}) = \left[\mathbf{r}_n^{(\ell)} + C \sum_{(n,m)} (\mathbf{r}_n^{(\ell)} - \mathbf{r}_m^{(\ell)}) \phi(\mathbf{e}_{nm}^{(\ell+1)}) \right] + \mathbf{c} = \mathbf{r}_n^{(\ell+1)} + \mathbf{c}.$$

再看旋转/镜像：利用 $\tilde{\mathbf{r}}_n^{(\ell)} = \mathbf{R} \mathbf{r}_n^{(\ell)}$ 与线性性，

$$\tilde{\mathbf{r}}_n^{(\ell+1)} = \mathbf{R} \mathbf{r}_n^{(\ell)} + C \sum_{(n,m)} (\mathbf{R} \mathbf{r}_n^{(\ell)} - \mathbf{R} \mathbf{r}_m^{(\ell)}) \phi(\mathbf{e}_{nm}^{(\ell+1)}) = \mathbf{R} \left[\mathbf{r}_n^{(\ell)} + C \sum_{(n,m)} (\mathbf{r}_n^{(\ell)} - \mathbf{r}_m^{(\ell)}) \phi(\mathbf{e}_{nm}^{(\ell+1)}) \right] = \mathbf{R} \mathbf{r}_n^{(\ell+1)}.$$

于是

$$\tilde{\mathbf{r}}_n^{(\ell+1)} = \mathbf{r}_n^{(\ell+1)} + \mathbf{c} \quad (\text{平移}), \quad \tilde{\mathbf{r}}_n^{(\ell+1)} = \mathbf{R} \mathbf{r}_n^{(\ell+1)} \quad (\text{旋转/镜像})$$

即坐标嵌入对平移与正交变换等变。

结论 由以上(a)(b) 得出：对任意平移 $\mathbf{c}$ 与任意旋转/镜像（正交）矩阵 $\mathbf{R}$,

$$(13.38)、(13.40)、(13.41) \text{ 中的消息在变换下不变； } (13.39) \text{ 中的坐标嵌入等变。}$$

这正是几何深度学习中对平移与欧氏正交群 $O(d)$ 的不变/等变要求。 $\square$