

Solutions to Chapter 15 — *Discrete Latent Variables*

姚宇倬

August , 2025

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 15.1 (★) 考虑第 15.1 节讨论的 K -means 算法。证明：由于离散指示变量 r_{nk} 的可能赋值个数是有限的，并且对每一种这样的赋值， $\{\mu_k\}$ 都有唯一的最优解，因此 K -means 算法必将在有限次数的迭代后收敛。

练习 15.2 (★★) 在本题中推导 K -means 算法的顺序（在线）形式。每一步考虑一个新的数据点 $\mathbf{x}_n$ ，并且只更新与 $\mathbf{x}_n$ 最近的原型向量。以批量情形下原型向量的表达式 (15.4) 为起点，将最后一个数据点 $\mathbf{x}_n$ 对该表达式的贡献单独分离出来。通过对公式作代数整理，证明该更新可写成式 (15.5)。注意：由于推导过程中没有做任何近似，所得到的原型向量满足：每个原型都等于被分配给它的所有数据向量的均值。

练习 15.3 (★) 考虑一个高斯混合模型，其中潜在变量的边缘分布 $p(\mathbf{z})$ 由式 (15.9) 给出，观测变量的条件分布 $p(\mathbf{x} | \mathbf{z})$ 由式 (15.10) 给出。证明：将 $p(\mathbf{z})p(\mathbf{x} | \mathbf{z})$ 在 $\mathbf{z}$ 的所有可能取值上求和得到的边缘分布 $p(\mathbf{x})$ 是形如式 (15.6) 的高斯混合分布。

练习 15.4 (★) 证明：在具有 K 个分量的混合模型中，由于分量可互换所带来的对称性，等价的参数设置数量为 $K!$ 。

练习 15.5 (★★) 设我们希望使用 EM 算法来最大化含有潜在变量的模型在参数上的后验分布 $p(\boldsymbol{\theta} | \mathbf{X})$ ，其中 $\mathbf{X}$ 为观测数据集。证明：E 步与极大似然情形相同；而在 M 步中，需最大化的量为

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) + \ln p(\boldsymbol{\theta}),$$

其中 $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})$ 由式 (15.23) 定义。

练习 15.6 (★) 考虑图 15.9 所示的高斯混合模型的有向图。利用 d-分离准则，证明潜在变量的后验分布可在不同数据点之间因子化，即

$$p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}) = \prod_{n=1}^N p(\mathbf{z}_n | \mathbf{x}_n, \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}). \quad (15.62)$$

练习 15.7 (★★) 考虑高斯混合模型的一个特例，其中各个分量的协方差矩阵 $\boldsymbol{\Sigma}_k$ 都被约束为同一个公共取值 $\boldsymbol{\Sigma}$ 。在这种模型下，推导用于极大化似然函数的 EM 方程。

练习 15.8 (★★) 验证：对于高斯混合模型，最大化完全数据对数似然 (15.26) 将导致如下结果——每个分量的均值与协方差可以在其对应的数据点分组上彼此独立地拟合；并且混合系数由各组中数据点所占的比例给出（即 $\pi_k = N_k/N$ ）。

练习 15.9 (★★) 在保持“责任” $\gamma(z_{nk})$ 固定的条件下，对式 (15.30) 关于 μ_k 进行最大化，证明可得到式 (15.16) 所给出的闭式解。

练习 15.10 (★★) 在保持“责任” $\gamma(z_{nk})$ 固定的条件下，对式 (15.30) 分别关于 Σ_k 与 π_k 进行最大化，证明可得到式 (15.18) 和式 (15.21) 所给出的闭式解。

练习 15.11 (★★) 考虑由混合分布给出的密度模型

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | k). \quad (15.63)$$

设将向量 $\mathbf{x}$ 划分为两部分，使得 $\mathbf{x} = (\mathbf{x}_a, \mathbf{x}_b)$ 。证明：条件密度 $p(\mathbf{x}_b | \mathbf{x}_a)$ 本身也是一个混合分布；并写出其混合系数与各分量密度的显式表达式。

练习 15.12 (★) 在第 15.3.2 节中，我们通过考虑一个所有分量的协方差都等于 $\epsilon \mathbf{I}$ 的混合模型，建立了 K -means 与用于高斯混合的 EM 之间的关系。证明：当 $\epsilon \rightarrow 0$ 时，对该模型的期望完整数据对数似然（式 15.30）进行最大化，与对 K -means 算法的误差度量 J （式 15.1）进行最小化是等价的。

练习 15.13 (★★) 验证：伯努利分布的均值与协方差分别由式 (15.35) 与式 (15.36) 给出。

练习 15.14 (★★) 考虑如下形式的混合分布

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | k), \quad (15.64)$$

其中向量 $\mathbf{x}$ 的各个分量可以是离散的、连续的，或二者的组合。记条件分布 $p(\mathbf{x} | k)$ 的均值与协方差分别为 $\boldsymbol{\mu}_k$ 与 $\boldsymbol{\Sigma}_k$ 。利用练习 15.13 的结论，证明该混合分布的均值与协方差分别由式 (15.39) 与式 (15.40) 给出。

练习 15.15 (★★) 利用 EM 算法的重估 (M 步) 方程, 证明: 当伯努利混合模型的参数取到极大似然解时, 其期望满足

$$\mathbb{E}[\mathbf{x}] = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \equiv \bar{\mathbf{x}}. \quad (15.65)$$

进一步证明: 若用满足所有分量均具有相同均值的方式来初始化该模型的参数, 即 $\mu_k = \hat{\mu}$ (对 $k = 1, \dots, K$), 则无论初始混合系数 $\{\pi_k\}$ 如何取值, EM 算法都将在一次迭代后收敛到 $\mu_k = \bar{\mathbf{x}}$ 的解。注意, 这对应于一种退化情形: 混合模型中的所有分量完全相同; 在实践中通常通过合适的初始化来避免这样的解。

练习 15.16 (★) 考虑伯努利模型中隐变量与观测变量的联合分布, 由 (15.42) 给出的 $p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu})$ 与 (15.43) 给出的 $p(\mathbf{z} | \boldsymbol{\pi})$ 的乘积得到。证明: 将该联合分布对 $\mathbf{z}$ 积分 (求和) 消去隐变量后, 可得到式 (15.37)。

练习 15.17 (★) 证明: 对于伯努利分布的混合模型, 将期望完整数据对数似然函数 (15.45) 关于 μ_k 最大化, 可得到 M 步更新方程 (15.49)。

练习 15.18 (★) 证明: 对于伯努利分布的混合模型, 将期望完整数据对数似然函数 (15.45) 关于混合系数 π_k 最大化, 并采用拉格朗日乘子来满足求和约束, 即可得到 M 步更新方程 (15.50)。

练习 15.19 (★) 证明: 由于离散变量 x_n 的条件概率满足约束 $0 \leq p(x_n | \boldsymbol{\mu}_k) \leq 1$, 因此对伯努利分布混合模型而言, 其不完全数据的对数似然函数是有上界的; 从而不存在使似然函数发散到无穷大的奇异性。

练习 15.20 (★★★) 设有一个 D 维随机变量 $\mathbf{x}$, 其中每个分量 i 本身都是一个具有 M 个类别的多项 (one-hot) 变量。因而 $\mathbf{x}$ 可写成由二元指示量 x_{ij} 组成的向量 (或矩阵), 其中 $i = 1, \dots, D, j = 1, \dots, M$, 并满足对所有 i 都有 $\sum_j x_{ij} = 1$ 的约束。设这些变量的分布由若干离散多项分布的混合给出, 即

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | \boldsymbol{\mu}_k). \quad (15.66)$$

其中

$$p(\mathbf{x} | \boldsymbol{\mu}_k) = \prod_{i=1}^D \prod_{j=1}^M \mu_{kij}^{x_{ij}}. \quad (15.67)$$

参数 μ_{kij} 表示条件概率 $p(x_{ij} = 1 | \boldsymbol{\mu}_k)$, 需满足 $0 \leq \mu_{kij} \leq 1$, 并且对所有的 k, i 都有 $\sum_j \mu_{kij} = 1$ 。给定观测数据集 $\{\mathbf{x}_n\}$ ($n = 1, \dots, N$), 请推导 EM 算法在极大似然估计下用于优化混合系数 π_k 与各分量参数 μ_{kij} 的 E 步与 M 步更新公式。

练习 15.21 (★) 验证式 (15.52) 成立, 其中 $\mathcal{L}(q, \boldsymbol{\theta})$ 与 $\text{KL}(q||p)$ 分别由式 (15.53) 与 (15.54) 给出。

练习 15.22 (★) 证明：当取 $q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\theta}^{\text{old}})$ 时，由式 (15.53) 给出的下界 $\mathcal{L}(q, \boldsymbol{\theta})$ 在 $\boldsymbol{\theta} = \boldsymbol{\theta}^{\text{old}}$ 处，关于 $\boldsymbol{\theta}$ 的梯度与对数似然 $\ln p(\mathbf{X} \mid \boldsymbol{\theta})$ 的梯度相同。

练习 15.23 (★★) 考虑用于高斯混合模型的 EM 算法的增量式形式，其中只对某个特定数据点 $\mathbf{x}_m$ 重新计算责任值 (posterior responsibilities)。从 M 步的公式 (15.16) 与 (15.17) 出发，推导用于更新各分量均值的结果式 (15.60) 与 (15.61)。

练习 15.24 (★★) 当责任值以增量方式更新时，推导高斯混合模型在 M 步中用于更新协方差矩阵与混合系数的公式，做法与用于更新均值的式 (15.60) 相同 (类比得到)。

下面将进行详细解答！

练习 15.1 解答 (★)

题目 考虑第 15.1 节中的 K -means 算法。由于离散指示变量 $\{r_{nk}\}$ 的可能赋值只有有限个，并且对每一组固定的赋值 $\{r_{nk}\}$ ，关于 $\{\mu_k\}$ 的最优解是唯一的，证明： K -means 算法必将在有限次迭代后收敛。

记号与目标函数 K -means 的失真（目标）函数为

$$J(\mathbf{r}, \boldsymbol{\mu}) = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2,$$

其中 $r_{nk} \in \{0, 1\}$ 且 $\sum_k r_{nk} = 1$ 。

(1) 赋值数目是有限的

对每个样本 n ， $r_{n\cdot}$ 只能取 K 种 one-hot 形式，因此整体赋值 $\mathbf{r} = \{r_{nk}\}$ 的可能性至多为 K^N 个（有限个）。

(2) 固定赋值时 $\{\mu_k\}$ 的唯一最优解

对固定的 $\mathbf{r}$ ，目标函数对不同 k 可分离：

$$J(\mathbf{r}, \boldsymbol{\mu}) = \sum_{k=1}^K \sum_n r_{nk} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2.$$

当第 k 类包含的样本数 $N_k = \sum_n r_{nk} > 0$ 时，上述关于 $\boldsymbol{\mu}_k$ 是严格凸的二次函数，其唯一极小点由

$$\frac{\partial J}{\partial \boldsymbol{\mu}_k} = -2 \sum_n r_{nk} (\mathbf{x}_n - \boldsymbol{\mu}_k) = 0 \implies \boxed{\boldsymbol{\mu}_k^* = \frac{\sum_n r_{nk} \mathbf{x}_n}{\sum_n r_{nk}}} \quad (15.4)$$

给出，即各簇样本的均值（ $N_k = 0$ 的空簇可按实现细节保持原值或重置；以下论证只需对 $N_k > 0$ 的簇唯一性成立）。

(3) 每个子步都使 J 非增，并且若发生变化则严格下降

- **M 步**：固定 $\mathbf{r}$ ，把 $\boldsymbol{\mu}$ 更新为 $\boldsymbol{\mu}^*(\mathbf{r})$ 是对 J 的全局最小化，因而 $J(\mathbf{r}, \boldsymbol{\mu}^*) \leq J(\mathbf{r}, \boldsymbol{\mu})$ ，若 $\boldsymbol{\mu} \neq \boldsymbol{\mu}^*$ 则严格 $<$ 。
- **E 步**：固定 $\boldsymbol{\mu}$ ，把每个样本指派给最近的中心 $k = \arg \min_j \|\mathbf{x}_n - \boldsymbol{\mu}_j\|^2$ ，等价于对 $\mathbf{r}$ 逐点最小化 J ，因此 $J(\mathbf{r}^{\text{new}}, \boldsymbol{\mu}) \leq J(\mathbf{r}^{\text{old}}, \boldsymbol{\mu})$ ，只要有样本的指派发生改变，就有严格 $<$ （若出现等距并规定确定性的并列打破规则，则 E 步不会在等价赋值间震荡）。

于是每一轮 E+M 之后， J 单调非增，且只要 $\mathbf{r}$ 或 $\boldsymbol{\mu}$ 有所改变便严格下降。

(4) 有限次终止

把每轮“E 步 + M 步”视作把赋值 $\mathbf{r}$ 映射到新的赋值 $\Phi(\mathbf{r})$ ，并在 M 步上始终取唯一最优中心 $\boldsymbol{\mu}^*(\mathbf{r})$ 。由(3)知

$$J(\Phi(\mathbf{r}), \boldsymbol{\mu}^*(\Phi(\mathbf{r}))) < J(\mathbf{r}, \boldsymbol{\mu}^*(\mathbf{r})) \quad \text{只要 } \Phi(\mathbf{r}) \neq \mathbf{r}.$$

而可取的赋值 $\mathbf{r}$ 只有有限个（至多 K^N 个）。因此赋值序列 $\mathbf{r}^{(0)}, \mathbf{r}^{(1)}, \dots$ 不可能无限次地发生严格下降；否则会在有限集合上形成循环，与严格下降矛盾。故在有限步后必须出现 $\mathbf{r}^{(t+1)} = \mathbf{r}^{(t)}$ ，此时 M 步给出 $\boldsymbol{\mu}^{(t+1)} = \boldsymbol{\mu}^*(\mathbf{r}^{(t)})$ ，再执行 E 步也不再改变赋值，算法终止。

结论 由于 (i) 赋值状态有限；(ii) 对每一赋值 $\mathbf{r}$ ， J 关于 $\boldsymbol{\mu}$ 的唯一极小点为簇均值；(iii) 每当状态改变时 J 严格下降；故 K -means 在有限次迭代后必然收敛于一个不再改变的 $(\mathbf{r}, \boldsymbol{\mu})$ （即 J 的一个局部极小点）。□

备注 若实现中出现空簇，可按常见做法重置 $\boldsymbol{\mu}_k$ （例如随机挑点或分裂最大簇），这对应于改变赋值，仍保持上述“有限状态+严格下降”的结论，从而不影响有限步收敛性。

练习 15.2 解答 (★★)

目标 把 K -means 的批量更新式 (式(15.4))

$$\mu_k = \frac{\sum_{i=1}^N r_{ik} \mathbf{x}_i}{\sum_{i=1}^N r_{ik}} \quad (r_{ik} \in \{0, 1\}, \sum_k r_{ik} = 1)$$

改写为顺序/增量形式。每一步只拿新到达的数据点 $\mathbf{x}_n$ 来更新与其最近的原型向量。

推导 将式(15.4)中对簇 k 的求和按最后一个样本 $\mathbf{x}_n$ 与其余样本分离。记

$$N_k^{\text{old}} = \sum_{i=1}^{n-1} r_{ik}, \quad \mu_k^{\text{old}} = \frac{1}{N_k^{\text{old}}} \sum_{i=1}^{n-1} r_{ik} \mathbf{x}_i.$$

若 $\mathbf{x}_n$ 的最近簇为 k^* (即 $r_{nk^*} = 1$, 其余 $k \neq k^*$ 时 $r_{nk} = 0$), 则更新后的计数为

$$N_{k^*}^{\text{new}} = N_{k^*}^{\text{old}} + 1, \quad N_k^{\text{new}} = N_k^{\text{old}} \quad (k \neq k^*).$$

由式(15.4)得对胜出簇 k^* 的新原型

$$\begin{aligned} \mu_{k^*}^{\text{new}} &= \frac{\sum_{i=1}^{n-1} r_{ik^*} \mathbf{x}_i + \mathbf{x}_n}{N_{k^*}^{\text{old}} + 1} = \frac{N_{k^*}^{\text{old}} \mu_{k^*}^{\text{old}} + \mathbf{x}_n}{N_{k^*}^{\text{new}}} \\ &= \mu_{k^*}^{\text{old}} + \frac{1}{N_{k^*}^{\text{new}}} (\mathbf{x}_n - \mu_{k^*}^{\text{old}}). \end{aligned}$$

而对其余簇 $k \neq k^*$, 由于 $r_{nk} = 0$, 有

$$\mu_k^{\text{new}} = \mu_k^{\text{old}}.$$

于是顺序式更新为

$$\mu_k^{\text{new}} = \begin{cases} \mu_k^{\text{old}} + \frac{1}{N_k^{\text{new}}} (\mathbf{x}_n - \mu_k^{\text{old}}), & \text{若 } k = \arg \min_j \|\mathbf{x}_n - \mu_j^{\text{old}}\|, \\ \mu_k^{\text{old}}, & \text{否则,} \end{cases} \quad (15.5)$$

其中 N_k^{new} 是到当前时刻 (包含 $\mathbf{x}_n$) 为止分到簇 k 的样本数。

性质 上式未作任何近似。用数学归纳法可证: 若对簇 k 依次见到被分配到它的 $\{\mathbf{x}_{i_1}, \dots, \mathbf{x}_{i_{N_k}}\}$, 则反复应用(15.5)得到的 μ_k 等于这些点的算术平均:

$$\mu_k = \frac{1}{N_k} \sum_{t=1}^{N_k} \mathbf{x}_{i_t}.$$

因此顺序形式与批量形式严格等价, 只是把“求和再平均”改为“逐点更新的均值”。

□

练习 15.3 解答 (★)

题目 设高斯混合模型的潜变量 $\mathbf{z} = (z_1, \dots, z_K)^\top$ 采用 1-of- K 表示 (即 $z_k \in \{0, 1\}$ 且 $\sum_{k=1}^K z_k = 1$)。其先验与条件分布分别为

$$p(\mathbf{z}) = \prod_{k=1}^K \pi_k^{z_k}, \quad (15.9)$$

$$p(\mathbf{x} | \mathbf{z}) = \prod_{k=1}^K \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)^{z_k}. \quad (15.10)$$

证明边缘分布 $p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{z}) p(\mathbf{x} | \mathbf{z})$ 是形如

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (15.6)$$

的高斯混合。

证明 由乘法法则得联合分布

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{z}) p(\mathbf{x} | \mathbf{z}) = \prod_{k=1}^K \left[\pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right]^{z_k}.$$

由于 $\mathbf{z}$ 为 1-of- K 指示向量, 求和 $\sum_{\mathbf{z}}$ 等价于对 K 个状态 $\mathbf{z} = \mathbf{e}_k$ (第 k 个分量为 1, 其余为 0) 求和。对每个这样的 $\mathbf{z}$,

$$p(\mathbf{x}, \mathbf{z} = \mathbf{e}_k) = \left[\pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right]^1 \prod_{j \neq k} \left[\pi_j \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) \right]^0 = \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k).$$

因此

$$p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k),$$

即得所需的高斯混合形式 (15.6)。 □

练习 15.4 解答 (★)

题设 考虑 K 个分量的混合模型

$$p(\mathbf{x} \mid \Theta) = \sum_{k=1}^K \pi_k p(\mathbf{x} \mid \theta_k), \quad \Theta = \{(\pi_k, \theta_k)\}_{k=1}^K, \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1.$$

结论 由于标签置换 (*interchange / label switching*) 对称性, 该模型存在 $K!$ 组等价的参数设置。

证明 对任意一个置换 σ 属于对称群 S_K , 定义

$$\Theta^\sigma = \{(\pi_{\sigma(k)}, \theta_{\sigma(k)})\}_{k=1}^K.$$

则

$$p(\mathbf{x} \mid \Theta^\sigma) = \sum_{k=1}^K \pi_{\sigma(k)} p(\mathbf{x} \mid \theta_{\sigma(k)}) = \sum_{j=1}^K \pi_j p(\mathbf{x} \mid \theta_j) = p(\mathbf{x} \mid \Theta),$$

其中第二步把求和指标作了更名 $j = \sigma(k)$ 。因此, 对任意数据集 $\mathcal{X} = \{\mathbf{x}_n\}_{n=1}^N$,

$$\mathcal{L}(\Theta^\sigma) = \prod_{n=1}^N p(\mathbf{x}_n \mid \Theta^\sigma) = \prod_{n=1}^N p(\mathbf{x}_n \mid \Theta) = \mathcal{L}(\Theta),$$

即似然 (以及对数似然) 在任意置换 σ 下都保持不变, 对应的参数设置两两等价。

可数的这类对称操作正是 S_K 的全部元素, 其基数为 $|S_K| = K!$ 。在非退化情形 (各分量参数互异且 $\pi_k > 0$) 下, 不同置换产生的参数向量彼此不同, 从而给出恰好 $K!$ 组等价设置。(若某些分量完全相同或某些 $\pi_k = 0$, 则若干置换可能重合, 等价设置个数不超过 $K!$, 但由置换产生的对称性仍由 S_K 描述。)

混合模型的标签置换对称群为 S_K , 其大小为 $K!$

这也解释了混合模型中常见的“标签置换问题”: 似然面上存在 $K!$ 个等价的极值。 □

练习 15.5 解答 (★★)

题目 希望用 EM 算法最大化带先验的后验分布 $p(\boldsymbol{\theta} \mid \mathbf{X})$ (模型含隐变量)。证明: E 步与极大似然情形相同; 而在 M 步中需要最大化的量变为 $Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) + \ln p(\boldsymbol{\theta})$, 其中

$$Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) = \sum_{\mathbf{Z}} p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\theta}^{\text{old}}) \ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta}) \quad (15.23)$$

为标准 EM 中的 Q 函数。

证明

要最大化的后验对数为

$$\ln p(\boldsymbol{\theta} \mid \mathbf{X}) = \ln p(\mathbf{X} \mid \boldsymbol{\theta}) + \ln p(\boldsymbol{\theta}) - \ln p(\mathbf{X}) = \ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta}) + \ln p(\boldsymbol{\theta}) + \text{const.} \quad (1)$$

对任意分布 $q(\mathbf{Z})$ (对 $\mathbf{Z}$ 归一化), 由 Jensen 不等式得

$$\ln \sum_{\mathbf{Z}} p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta}) = \ln \sum_{\mathbf{Z}} q(\mathbf{Z}) \frac{p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta})}{q(\mathbf{Z})} \geq \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \frac{p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta})}{q(\mathbf{Z})} \equiv \mathcal{L}(q, \boldsymbol{\theta}), \quad (2)$$

其中

$$\mathcal{L}(q, \boldsymbol{\theta}) = \underbrace{\sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta})}_{\text{依赖 } \boldsymbol{\theta}} + \underbrace{H(q)}_{\text{与 } \boldsymbol{\theta} \text{ 无关}}, \quad H(q) = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln q(\mathbf{Z}).$$

于是 (忽略与 $\boldsymbol{\theta}$ 无关的常数) 有后验的下界

$$\ln p(\boldsymbol{\theta} \mid \mathbf{X}) \geq \mathcal{L}(q, \boldsymbol{\theta}) + \ln p(\boldsymbol{\theta}) + \text{const.} \quad (3)$$

E 步 (与 ML 相同) 固定参数为 $\boldsymbol{\theta}^{\text{old}}$, 最大化关于 q 的 $\mathcal{L}(q, \boldsymbol{\theta}^{\text{old}})$ 。由标准变分结论 (或直接带入 KL 分解)

$$q^*(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\theta}^{\text{old}}),$$

即把 q 置为后验责任。注意 $\ln p(\boldsymbol{\theta})$ 不依赖 $\mathbf{Z}$, 因此对 q 的最优化与极大似然情形完全一致——这就证明了 E 步保持不变。

M 步 (带先验的最大化) 将 q 固定为上式的 q^* , 最大化 (3) 的右端对 $\boldsymbol{\theta}$:

$$\arg \max_{\boldsymbol{\theta}} \left\{ \underbrace{\sum_{\mathbf{Z}} q^*(\mathbf{Z}) \ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\theta})}_{= Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}})} + \ln p(\boldsymbol{\theta}) \right\}.$$

因为熵项 $H(q^*)$ 与 $\boldsymbol{\theta}$ 无关, 上式即为

$$\boldsymbol{\theta}^{\text{new}} = \arg \max_{\boldsymbol{\theta}} \left[Q(\boldsymbol{\theta}, \boldsymbol{\theta}^{\text{old}}) + \ln p(\boldsymbol{\theta}) \right].$$

这表明: 与极大似然 EM 相比, MAP (带先验) EM 的 M 步只是在 Q 函数上额外加上 $\ln p(\boldsymbol{\theta})$ 项, 而 E 步保持不变。证毕。 $\square$

练习 15.6 解答 (★)

题目 考虑图 15.9 所示的高斯混合模型的有向图。利用 d-分离准则证明：给定观测 $\mathbf{X} = \{\mathbf{x}_n\}_{n=1}^N$ 与参数 $\{\boldsymbol{\mu}, \{\boldsymbol{\Sigma}_k\}, \boldsymbol{\pi}\}$ ，潜在变量的后验分布在样本之间可因子化：

$$p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}) = \prod_{n=1}^N p(\mathbf{z}_n \mid \mathbf{x}_n, \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}). \quad (15.62)$$

证明 (d-分离视角)

图 15.9 的结构为（并在 n 上置板）： $\boldsymbol{\pi} \rightarrow \mathbf{z}_n$ ， $\mathbf{z}_n \rightarrow \mathbf{x}_n$ ，以及 $\boldsymbol{\mu} \rightarrow \mathbf{x}_n$ 、 $\boldsymbol{\Sigma} \rightarrow \mathbf{x}_n$ 。在给定 $\mathbf{X}$ 与参数 $\theta := (\boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi})$ 的条件下，任取 $n \neq m$ ，我们考察 $\mathbf{z}_n$ 与 $\mathbf{z}_m$ 之间所有可能路径：

- 通过先验节点的路径： $\mathbf{z}_n \leftarrow \boldsymbol{\pi} \rightarrow \mathbf{z}_m$ 。其中 $\boldsymbol{\pi}$ 是非合流点，且被条件化（我们给定了参数），故该路径被阻断。
- 通过观测与参数的路径： $\mathbf{z}_n \rightarrow \mathbf{x}_n \leftarrow \boldsymbol{\mu} \rightarrow \mathbf{x}_m \leftarrow \mathbf{z}_m$ （或把 $\boldsymbol{\mu}$ 换成 $\boldsymbol{\Sigma}$ ）。在该路径上， $\boldsymbol{\mu} / \boldsymbol{\Sigma}$ 为非合流点且被条件化，因而阻断路径； $\mathbf{x}_n, \mathbf{x}_m$ 是合流点，虽然它们被条件化会打开“ $\mathbf{z}_n \dashrightarrow \boldsymbol{\mu}$ ”与“ $\boldsymbol{\mu} \dashrightarrow \mathbf{z}_m$ ”两段，但整个路径仍在 $\boldsymbol{\mu}$ （或 $\boldsymbol{\Sigma}$ ）处被阻断。

因此，任意 $n \neq m$ 都有 $\mathbf{z}_n \perp\!\!\!\perp \mathbf{z}_m \mid (\mathbf{X}, \theta)$ 。于是 $p(\mathbf{Z} \mid \mathbf{X}, \theta)$ 在样本维度上因子化，得到 (15.62)。

等价推导（由联合分布因式分解）

亦可直接由联合分布得到同样结论。给定参数 θ ，联合分布可写为

$$p(\mathbf{X}, \mathbf{Z} \mid \theta) = \prod_{n=1}^N p(\mathbf{z}_n \mid \boldsymbol{\pi}) p(\mathbf{x}_n \mid \mathbf{z}_n, \boldsymbol{\mu}, \boldsymbol{\Sigma}).$$

由 Bayes 公式

$$p(\mathbf{Z} \mid \mathbf{X}, \theta) = \frac{p(\mathbf{X}, \mathbf{Z} \mid \theta)}{p(\mathbf{X} \mid \theta)} \propto \prod_{n=1}^N p(\mathbf{z}_n \mid \boldsymbol{\pi}) p(\mathbf{x}_n \mid \mathbf{z}_n, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \prod_{n=1}^N p(\mathbf{z}_n \mid \mathbf{x}_n, \theta),$$

再对每个 n 归一化即可得到 $p(\mathbf{Z} \mid \mathbf{X}, \theta) = \prod_{n=1}^N p(\mathbf{z}_n \mid \mathbf{x}_n, \theta)$ ，与式 (15.62) 一致。 $\square$

练习 15.7 解答 (★★)

题目 考虑高斯混合模型的一个特例：各分量的协方差矩阵 $\{\Sigma_k\}_{k=1}^K$ 被约束为共同值 Σ (即 $\Sigma_k \equiv \Sigma$)。在该约束下，推导极大化（不完全数据）对数似然的 EM 方程。

解 观测数据为 $\{\mathbf{x}_n\}_{n=1}^N \subset \mathbb{R}^D$ ，模型

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \Sigma), \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1.$$

E 步 在参数 $\{\pi_k, \boldsymbol{\mu}_k, \Sigma\}$ 给定时，第 n 个样本由第 k 个分量生成的后验责任度为

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \Sigma)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \Sigma)}.$$

M 步 令

$$N_k = \sum_{n=1}^N \gamma(z_{nk}), \quad \sum_{k=1}^K N_k = N.$$

最大化期望完备对数似然

$$Q = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \Sigma) \right\}$$

得到闭式更新式：

(1) 均值更新

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$$

(2) 混合系数更新 (用拉格朗日乘子满足 $\sum_k \pi_k = 1$)

$$\pi_k = \frac{N_k}{N}$$

(3) 共享协方差更新 仅保留与 Σ 有关的项并令 $\partial Q / \partial \Sigma^{-1} = \mathbf{0}$ ，利用 $\partial \ln |\Sigma| / \partial \Sigma^{-1} = -\Sigma$ 、 $\partial \text{tr}(\Sigma^{-1} \mathbf{S}) / \partial \Sigma^{-1} = \mathbf{S}$ 可得

$$\sum_{n,k} \gamma(z_{nk}) [(\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top - \Sigma] = \mathbf{0}$$

从而

$$\Sigma = \frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top$$

其分母为 N (而非 N_k) 体现了协方差在各分量间共享地估计。

结论 带共有协方差的高斯混合模型的 EM 迭代为

$$\text{E步: } \gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma})}{\sum_j \pi_j \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_j, \boldsymbol{\Sigma})};$$

$$\begin{aligned} \text{M步: } N_k &= \sum_n \gamma(z_{nk}), \quad \pi_k = \frac{N_k}{N}, \quad \boldsymbol{\mu}_k = \frac{1}{N_k} \sum_n \gamma(z_{nk}) \mathbf{x}_n, \\ \boldsymbol{\Sigma} &= \frac{1}{N} \sum_n \sum_k \gamma(z_{nk}) (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \end{aligned}$$

□

练习 15.8 解答 (★★)

题目 验证：对高斯混合模型的完全数据对数似然

$$\ln p(\mathbf{X}, \mathbf{Z} \mid \{\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \pi_k\}_{k=1}^K) = \sum_{n=1}^N \sum_{k=1}^K z_{nk} \left\{ \ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\} \quad (15.26)$$

进行极大化时，各分量的均值与协方差可在各自被指派的数据子集上独立拟合，而混合系数等于各组样本所占比例。

解 令

$$\mathcal{L}_c(\{\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \pi_k\}) := \sum_{n=1}^N \sum_{k=1}^K z_{nk} \left\{ \ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\}.$$

由于 $z_{nk} \in \{0, 1\}$ 且对每个 n 有 $\sum_k z_{nk} = 1$ ，定义第 k 组（被指派到第 k 个分量的样本） $\mathcal{G}_k := \{n : z_{nk} = 1\}$ 及样本数 $N_k := \sum_{n=1}^N z_{nk} = |\mathcal{G}_k|$ 。则

$$\mathcal{L}_c = \sum_{k=1}^K \left[N_k \ln \pi_k + \sum_{n \in \mathcal{G}_k} \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right].$$

可以看出，关于 $\{\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k\}$ 的项与 k 分离，因此每个分量的 $(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ 可在各自数据子集 $\mathcal{G}_k$ 上独立极大化。下面给出标准推导。

(i) 均值的极大似然估计 写出高斯对数密度并去掉与参数无关的常数：

$$\sum_{n \in \mathcal{G}_k} \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = -\frac{N_k}{2} \ln |\boldsymbol{\Sigma}_k| - \frac{1}{2} \sum_{n \in \mathcal{G}_k} (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_k) + \text{const.}$$

对 $\boldsymbol{\mu}_k$ 求导并置零（用 $\nabla_{\boldsymbol{\mu}} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = -2\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ ）：

$$\sum_{n \in \mathcal{G}_k} \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_k) = \mathbf{0} \implies N_k \boldsymbol{\mu}_k = \sum_{n \in \mathcal{G}_k} \mathbf{x}_n \implies \boxed{\boldsymbol{\mu}_k^{\text{ML}} = \frac{1}{N_k} \sum_{n \in \mathcal{G}_k} \mathbf{x}_n}.$$

(ii) 协方差的极大似然估计 为简洁，用 $\mathbf{S}_k := \sum_{n \in \mathcal{G}_k} (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top$ ，对 $\boldsymbol{\Sigma}_k^{-1}$ 求导（矩阵恒等式 $\partial \ln |\boldsymbol{\Sigma}| / \partial \boldsymbol{\Sigma}^{-1} = -\boldsymbol{\Sigma}$ 与 $\partial \text{tr}(\boldsymbol{\Sigma}^{-1} \mathbf{A}) / \partial \boldsymbol{\Sigma}^{-1} = \mathbf{A}^\top$ ）：

$$\frac{\partial}{\partial \boldsymbol{\Sigma}_k^{-1}} \left[-\frac{N_k}{2} \ln |\boldsymbol{\Sigma}_k| - \frac{1}{2} \text{tr}(\boldsymbol{\Sigma}_k^{-1} \mathbf{S}_k) \right] = \frac{N_k}{2} \boldsymbol{\Sigma}_k - \frac{1}{2} \mathbf{S}_k = \mathbf{0},$$

于是

$$\boxed{\boldsymbol{\Sigma}_k^{\text{ML}} = \frac{1}{N_k} \sum_{n \in \mathcal{G}_k} (\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{ML}})(\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{ML}})^\top}.$$

(iii) 混合系数的极大似然估计 在约束 $\sum_{k=1}^K \pi_k = 1, \pi_k \geq 0$ 下, 对 $\sum_k N_k \ln \pi_k$ 构造拉格朗日函数 $\mathcal{J}(\boldsymbol{\pi}, \lambda) = \sum_k N_k \ln \pi_k + \lambda (\sum_k \pi_k - 1)$. 令偏导为零得

$$\frac{\partial \mathcal{J}}{\partial \pi_k} = \frac{N_k}{\pi_k} + \lambda = 0 \implies \pi_k = -\frac{N_k}{\lambda}.$$

由约束 $\sum_k \pi_k = 1$ 知 $-\lambda = \sum_k N_k = N$, 故

$$\pi_k^{\text{ML}} = \frac{N_k}{N}.$$

结论 完全数据对数似然 (15.26) 的极大化把参数按分量 k 解耦, 从而每个分量的均值、协方差分别等于其对应样本子集 $\mathcal{G}_k$ 的样本均值与样本协方差, 而混合系数等于该子集占全部样本的比例:

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n \in \mathcal{G}_k} \mathbf{x}_n, \quad \boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{n \in \mathcal{G}_k} (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top, \quad \pi_k = \frac{N_k}{N}.$$

这即证明了题述性质。

练习 15.9 解答 (★★)

题目 在保持“责任度” $\gamma(z_{nk})$ 不变的情况下, 对式 (15.30) 的期望完全数据对数似然关于均值参数 $\boldsymbol{\mu}_k$ 最大化, 证明可得到闭式解 (15.16)。

解 式 (15.30) 为

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi})] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\}. \quad (15.30)$$

在固定 $\gamma(z_{nk})$ 、 π_k 与 $\boldsymbol{\Sigma}_k$ 时, 与 $\boldsymbol{\mu}_k$ 相关的仅是第二项 $\ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ 。展开高斯对数密度 (省略与 $\boldsymbol{\mu}_k$ 无关的常数项) 得

$$\ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = -\frac{1}{2}(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n - \boldsymbol{\mu}_k) + \text{const.}$$

因此, 对 $\boldsymbol{\mu}_k$ 需要最大化的目标等价于最小化

$$J_k(\boldsymbol{\mu}_k) = \frac{1}{2} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n - \boldsymbol{\mu}_k).$$

对 $\boldsymbol{\mu}_k$ 求梯度 (利用 $\boldsymbol{\Sigma}_k^{-1}$ 对称与 $\nabla_{\boldsymbol{\mu}} \frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top A(\mathbf{x} - \boldsymbol{\mu}) = A(\boldsymbol{\mu} - \mathbf{x})$):

$$\nabla_{\boldsymbol{\mu}_k} J_k(\boldsymbol{\mu}_k) = \sum_{n=1}^N \gamma(z_{nk}) \boldsymbol{\Sigma}_k^{-1}(\boldsymbol{\mu}_k - \mathbf{x}_n).$$

令梯度为零得一阶最优条件

$$\boldsymbol{\Sigma}_k^{-1} \left(\sum_{n=1}^N \gamma(z_{nk}) \boldsymbol{\mu}_k - \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \right) = \mathbf{0}.$$

乘去可逆矩阵 $\boldsymbol{\Sigma}_k$, 并记

$$N_k = \sum_{n=1}^N \gamma(z_{nk}), \quad (15.17)$$

即可解出

$$\boxed{\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n} \quad (15.16)$$

这正是式 (15.16)。由于 J_k 为二次凸函数, 上述驻点即为全局极大点 (对应于对数似然的全局极大)。□

练习 15.10 解答 (★★)

题目 证明：在保持职责（后验概率） $\gamma(z_{nk})$ 不变的情况下，最大化期望完整数据对数似然

$$\mathcal{Q}(\theta, \theta^{\text{old}}) = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right\} \quad (15.30)$$

关于 $\{\boldsymbol{\Sigma}_k\}$ 与 $\{\pi_k\}$ ，可得到闭式解

$$\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top, \quad \pi_k = \frac{N_k}{N}, \quad (15.18, 15.21)$$

其中 $N_k = \sum_{n=1}^N \gamma(z_{nk})$ 。

证明

记 $\gamma_{nk} := \gamma(z_{nk})$ 。将高斯对数密度展开并忽略与 $\boldsymbol{\Sigma}_k, \pi_k$ 无关的常数项，有

$$\mathcal{Q} = \sum_{k=1}^K \left[\sum_{n=1}^N \gamma_{nk} \ln \pi_k + \sum_{n=1}^N \gamma_{nk} \left(-\frac{1}{2} \ln |\boldsymbol{\Sigma}_k| - \frac{1}{2} (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} (\mathbf{x}_n - \boldsymbol{\mu}_k) \right) \right] + \text{const.}$$

(a) 关于协方差 $\boldsymbol{\Sigma}_k$ 的最大化。对每个 k ，只保留与 $\boldsymbol{\Sigma}_k$ 有关的项并令

$$\mathbf{S}_k := \sum_{n=1}^N \gamma_{nk} (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top, \quad N_k := \sum_{n=1}^N \gamma_{nk}.$$

则

$$\mathcal{Q}_k(\boldsymbol{\Sigma}_k) = -\frac{N_k}{2} \ln |\boldsymbol{\Sigma}_k| - \frac{1}{2} \text{tr}(\boldsymbol{\Sigma}_k^{-1} \mathbf{S}_k) + \text{const.}$$

令 $\boldsymbol{\Lambda}_k = \boldsymbol{\Sigma}_k^{-1}$ ，利用 $\ln |\boldsymbol{\Sigma}_k| = -\ln |\boldsymbol{\Lambda}_k|$ ，上式化为

$$\tilde{\mathcal{Q}}_k(\boldsymbol{\Lambda}_k) = \frac{N_k}{2} \ln |\boldsymbol{\Lambda}_k| - \frac{1}{2} \text{tr}(\boldsymbol{\Lambda}_k \mathbf{S}_k) + \text{const.}$$

对 $\boldsymbol{\Lambda}_k$ 求导并令其为零：

$$\frac{\partial \tilde{\mathcal{Q}}_k}{\partial \boldsymbol{\Lambda}_k} = \frac{N_k}{2} \boldsymbol{\Lambda}_k^{-T} - \frac{1}{2} \mathbf{S}_k = \mathbf{0} \implies N_k \boldsymbol{\Lambda}_k^{-1} = \mathbf{S}_k.$$

由于 $\boldsymbol{\Lambda}_k^{-1} = \boldsymbol{\Sigma}_k$ ，得到

$$\boxed{\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top} \quad (15.18)$$

即为所求。

(b) 关于混合系数 π_k 的最大化。取与 $\{\pi_k\}$ 有关的部分，并加入约束 $\sum_k \pi_k = 1$ 的拉格朗日乘子 λ ，得到

$$\mathcal{L}(\boldsymbol{\pi}, \lambda) = \sum_{k=1}^K N_k \ln \pi_k + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right).$$

对 π_k 求导并令其为零：

$$\frac{\partial \mathcal{L}}{\partial \pi_k} = \frac{N_k}{\pi_k} + \lambda = 0 \implies \pi_k = -\frac{N_k}{\lambda}.$$

两边对 k 求和并利用 $\sum_k \pi_k = 1$ 与 $\sum_k N_k = N$ ，得 $\lambda = -N$ ，于是

$$\boxed{\pi_k = \frac{N_k}{N}} \tag{15.21}$$

成立。

综上，在固定职责 $\gamma(z_{nk})$ 下，最大化式 (15.30) 关于 $\boldsymbol{\Sigma}_k$ 与 π_k 的结果正是式 (15.18) 与 (15.21)。□

练习 15.11 解答 (★★)

题目 设密度模型为混合分布

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | k), \quad (15.63)$$

并把向量分解为 $\mathbf{x} = (\mathbf{x}_a, \mathbf{x}_b)$ 。证明条件密度 $p(\mathbf{x}_b | \mathbf{x}_a)$ 仍是一个混合分布，并写出其混合系数与分量条件密度的显式表达式。

解 由定义

$$p(\mathbf{x}_b | \mathbf{x}_a) = \frac{p(\mathbf{x}_a, \mathbf{x}_b)}{p(\mathbf{x}_a)} = \frac{\sum_{k=1}^K \pi_k p(\mathbf{x}_a, \mathbf{x}_b | k)}{\sum_{j=1}^K \pi_j p(\mathbf{x}_a | j)}.$$

在分子中对每一项乘除 $p(\mathbf{x}_a | k)$ ，得

$$\begin{aligned} p(\mathbf{x}_b | \mathbf{x}_a) &= \sum_{k=1}^K \frac{\pi_k p(\mathbf{x}_a | k)}{\underbrace{\sum_{j=1}^K \pi_j p(\mathbf{x}_a | j)}_{\tilde{\pi}_k(\mathbf{x}_a)}} \underbrace{\frac{p(\mathbf{x}_a, \mathbf{x}_b | k)}{p(\mathbf{x}_a | k)}}_{p(\mathbf{x}_b | \mathbf{x}_a, k)} \\ &= \sum_{k=1}^K \tilde{\pi}_k(\mathbf{x}_a) p(\mathbf{x}_b | \mathbf{x}_a, k). \end{aligned}$$

因此 $p(\mathbf{x}_b | \mathbf{x}_a)$ 是一个以

$$\tilde{\pi}_k(\mathbf{x}_a) = \frac{\pi_k p(\mathbf{x}_a | k)}{\sum_{j=1}^K \pi_j p(\mathbf{x}_a | j)} = p(k | \mathbf{x}_a)$$

为混合系数、以

$$p(\mathbf{x}_b | \mathbf{x}_a, k) = \frac{p(\mathbf{x}_a, \mathbf{x}_b | k)}{p(\mathbf{x}_a | k)}$$

为分量条件密度的混合分布。容易验证 $\sum_{k=1}^K \tilde{\pi}_k(\mathbf{x}_a) = 1$ ，且 $\tilde{\pi}_k(\mathbf{x}_a) \geq 0$ ，故它们是合法的混合权重。

(可选) 高斯情形 若每个分量都是高斯 $p(\mathbf{x} | k) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$ ，把 $\boldsymbol{\mu}_k = \begin{pmatrix} \mu_{a,k} \\ \mu_{b,k} \end{pmatrix}$ ， $\boldsymbol{\Sigma}_k = \begin{pmatrix} \Sigma_{aa,k} & \Sigma_{ab,k} \\ \Sigma_{ba,k} & \Sigma_{bb,k} \end{pmatrix}$ 按 (a, b) 分块，则

$$p(\mathbf{x}_b | \mathbf{x}_a, k) = \mathcal{N}(\mathbf{x}_b | \boldsymbol{\mu}_{b|a,k}, \boldsymbol{\Sigma}_{b|a,k}),$$

其中

$$\boldsymbol{\mu}_{b|a,k} = \boldsymbol{\mu}_{b,k} + \boldsymbol{\Sigma}_{ba,k} \boldsymbol{\Sigma}_{aa,k}^{-1} (\mathbf{x}_a - \boldsymbol{\mu}_{a,k}), \quad \boldsymbol{\Sigma}_{b|a,k} = \boldsymbol{\Sigma}_{bb,k} - \boldsymbol{\Sigma}_{ba,k} \boldsymbol{\Sigma}_{aa,k}^{-1} \boldsymbol{\Sigma}_{ab,k}.$$

此时仍有 $p(\mathbf{x}_b | \mathbf{x}_a) = \sum_k \tilde{\pi}_k(\mathbf{x}_a) \mathcal{N}(\cdot | \boldsymbol{\mu}_{b|a,k}, \boldsymbol{\Sigma}_{b|a,k})$ 。 □

练习 15.12 解答 (★)

题目 在§15.3.2 中, 我们通过考虑各分量协方差都为 $\Sigma_k = \varepsilon \mathbf{I}$ 的高斯混合模型, 建立了 K -means 与高斯混合 EM 的联系。证明: 当 $\varepsilon \rightarrow 0$ 时, 对该模型最大化期望完全数据对数似然

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \{\Sigma_k\}, \boldsymbol{\pi})] \quad (\text{式 (15.30)})$$

等价于最小化 K -means 的误差度量

$$J(\boldsymbol{\mu}, \mathbf{r}) = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2 \quad (\text{式 (15.1)}).$$

证明

令 $\Sigma_k = \varepsilon \mathbf{I}$, 则对数高斯密度为

$$\ln \mathcal{N}(\mathbf{x}_n \mid \boldsymbol{\mu}_k, \varepsilon \mathbf{I}) = -\frac{D}{2} \ln(2\pi\varepsilon) - \frac{1}{2\varepsilon} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2.$$

将其代入式 (15.30) 得 (记 $\gamma_{nk} \equiv \gamma(z_{nk})$)

$$\begin{aligned} \mathcal{F}_\varepsilon(\boldsymbol{\mu}, \boldsymbol{\pi}, \gamma) &:= \mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \varepsilon \mathbf{I}, \boldsymbol{\pi})] \\ &= \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} \left\{ \ln \pi_k - \frac{1}{2\varepsilon} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2 \right\} - \frac{ND}{2} \ln(2\pi\varepsilon). \end{aligned}$$

E 步的职责由 (15.32) 给出:

$$\gamma_{nk} = \frac{\pi_k \exp\{-\|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2/(2\varepsilon)\}}{\sum_{j=1}^K \pi_j \exp\{-\|\mathbf{x}_n - \boldsymbol{\mu}_j\|^2/(2\varepsilon)\}}.$$

当 $\varepsilon \rightarrow 0$ 时, 分母中的指数项由距离最小的那一项主导, 于是得到硬分配

$$\gamma_{nk} \longrightarrow r_{nk} \in \{0, 1\}, \quad r_{nk} = \begin{cases} 1, & k = \arg \min_j \|\mathbf{x}_n - \boldsymbol{\mu}_j\|^2, \\ 0, & \text{否则}. \end{cases}$$

令 $N_k = \sum_n r_{nk}$, 则有

$$\mathcal{F}_\varepsilon(\boldsymbol{\mu}, \boldsymbol{\pi}, \gamma) \xrightarrow{\varepsilon \rightarrow 0} -\frac{1}{2\varepsilon} J(\boldsymbol{\mu}, \mathbf{r}) + \sum_{k=1}^K N_k \ln \pi_k - \frac{ND}{2} \ln(2\pi\varepsilon). \quad (*)$$

上式中最后一项与参数无关, 是常数; 第二项仅与 $\boldsymbol{\pi}$ 有关。在给定 $\mathbf{r}$ 时, 最大化 $\sum_k N_k \ln \pi_k$ 且满足 $\sum_k \pi_k = 1$ 的解为

$$\pi_k^* = \frac{N_k}{N} \quad (\text{拉格朗日乘子可得}).$$

代回后该项为 $\sum_k N_k \ln(N_k/N)$, 其量级为 $O(N)$, 而第一项的系数为 $-1/(2\varepsilon)$, 当 $\varepsilon \rightarrow 0$ 时占主导。

因此，极大化 $\mathcal{F}_\varepsilon$ 等价于极小化

$$J(\boldsymbol{\mu}, \mathbf{r}) = \sum_{n,k} r_{nk} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|^2,$$

即与 K -means 的目标 (15.1) 完全一致。进一步，对固定的 $\mathbf{r}$ ，最优 $\boldsymbol{\mu}$ 由

$$\frac{\partial J}{\partial \boldsymbol{\mu}_k} = 2 \sum_n r_{nk} (\boldsymbol{\mu}_k - \mathbf{x}_n) = 0 \Rightarrow \boldsymbol{\mu}_k = \frac{1}{N_k} \sum_n r_{nk} \mathbf{x}_n,$$

正是 K -means 的 M 步更新 (15.4)。由此得到结论：当 $\varepsilon \rightarrow 0$ 时，最大化式 (15.30) 与最小化 K -means 误差 J 等价。 $\square$

备注 将上式写作极限形式即得到教材 (15.33)：

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} \mid \boldsymbol{\mu}, \varepsilon \mathbf{I}, \boldsymbol{\pi})] \xrightarrow{\varepsilon \rightarrow 0} -\frac{1}{2} J(\boldsymbol{\mu}, \mathbf{r}) \cdot \frac{1}{\varepsilon} + \text{const},$$

因此在该极限下，优化准则仅由 J 决定。

练习 15.13 解答 (★★)

题目 验证伯努利分布均值与协方差的结果 (15.35) 与 (15.36)。设 $\mathbf{x} = (x_1, \dots, x_D)^\top \in \{0, 1\}^D$, 且在参数 $\boldsymbol{\mu} = (\mu_1, \dots, \mu_D)^\top$ 下独立,

$$p(\mathbf{x} \mid \boldsymbol{\mu}) = \prod_{i=1}^D \mu_i^{x_i} (1 - \mu_i)^{(1-x_i)}. \quad (15.34)$$

解 因为各分量独立且 $x_i \in \{0, 1\}$, 单个分量的边缘分布为

$$\Pr(x_i = 1) = \mu_i, \quad \Pr(x_i = 0) = 1 - \mu_i.$$

于是

$$\mathbb{E}[x_i] = \sum_{x_i \in \{0, 1\}} x_i \Pr(x_i) = 0 \cdot (1 - \mu_i) + 1 \cdot \mu_i = \mu_i.$$

将各分量排成向量, 便得

$$\boxed{\mathbb{E}[\mathbf{x}] = \boldsymbol{\mu}} \quad (\text{即式 (15.35)}).$$

再求协方差矩阵。由于 $x_i^2 = x_i$ (0-1 变量),

$$\text{Var}(x_i) = \mathbb{E}[x_i^2] - (\mathbb{E}[x_i])^2 = \mu_i - \mu_i^2 = \mu_i(1 - \mu_i).$$

对 $i \neq j$, 独立性给出

$$\text{Cov}(x_i, x_j) = \mathbb{E}[x_i x_j] - \mathbb{E}[x_i] \mathbb{E}[x_j] = \mathbb{E}[x_i] \mathbb{E}[x_j] - \mathbb{E}[x_i] \mathbb{E}[x_j] = 0.$$

综上,

$$\boxed{\text{cov}[\mathbf{x}] = \text{diag}\{\mu_i(1 - \mu_i)\}_{i=1}^D} \quad (\text{即式 (15.36)}).$$

□

练习 15.14 解答 (★★)

题目 考虑混合分布

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | k) \quad (15.64)$$

其中 $\mathbf{x}$ 的各分量可以是离散、连续或二者的混合。记每个条件分布 $p(\mathbf{x} | k)$ 的均值与协方差分别为 $\boldsymbol{\mu}_k$ 与 $\boldsymbol{\Sigma}_k$ 。利用练习 15.13 的结果，证明混合分布的均值与协方差为

$$\mathbb{E}[\mathbf{x}] = \sum_{k=1}^K \pi_k \boldsymbol{\mu}_k \quad (15.39)$$

$$\text{cov}[\mathbf{x}] = \sum_{k=1}^K \pi_k (\boldsymbol{\Sigma}_k + \boldsymbol{\mu}_k \boldsymbol{\mu}_k^\top) - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{x}]^\top. \quad (15.40)$$

解答

令隐变量 $Z \in \{1, \dots, K\}$ 表示成分索引，且 $\mathbb{P}(Z = k) = \pi_k$ ，则 $p(\mathbf{x}) = \sum_k \mathbb{P}(Z = k) p(\mathbf{x} | Z = k)$ 与（全期望定律、全协方差定律）在本题均适用。注意 $\mathbf{x}$ 可以是离散或连续向量，下面的“期望”与“积分/求和”均按相应情形理解即可。

均值 (15.39) 由全期望定律，

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}_Z[\mathbb{E}[\mathbf{x} | Z]] = \sum_{k=1}^K \pi_k \mathbb{E}[\mathbf{x} | Z = k] = \sum_{k=1}^K \pi_k \boldsymbol{\mu}_k,$$

即得 (15.39)。

协方差 (15.40) 记总体二阶矩为 $\mathbb{E}[\mathbf{x}\mathbf{x}^\top]$ ，则

$$\text{cov}[\mathbf{x}] = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{x}]^\top.$$

同样利用全期望定律，

$$\mathbb{E}[\mathbf{x}\mathbf{x}^\top] = \mathbb{E}_Z[\mathbb{E}[\mathbf{x}\mathbf{x}^\top | Z]] = \sum_{k=1}^K \pi_k \mathbb{E}[\mathbf{x}\mathbf{x}^\top | Z = k].$$

对任一成分 k ，由练习 15.13 所用到的恒等式（对任意随机向量都成立）：

$$\text{cov}[\mathbf{x} | Z = k] = \mathbb{E}[\mathbf{x}\mathbf{x}^\top | Z = k] - \boldsymbol{\mu}_k \boldsymbol{\mu}_k^\top = \boldsymbol{\Sigma}_k,$$

于是得到

$$\mathbb{E}[\mathbf{x}\mathbf{x}^\top | Z = k] = \boldsymbol{\Sigma}_k + \boldsymbol{\mu}_k \boldsymbol{\mu}_k^\top.$$

代回可得

$$\mathbb{E}[\mathbf{x}\mathbf{x}^\top] = \sum_{k=1}^K \pi_k (\boldsymbol{\Sigma}_k + \boldsymbol{\mu}_k \boldsymbol{\mu}_k^\top).$$

再减去 $\mathbb{E}[\mathbf{x}]\mathbb{E}[\mathbf{x}]^\top$ (其中 $\mathbb{E}[\mathbf{x}]$ 已由 (15.39) 给出), 便得到

$$\text{cov}[\mathbf{x}] = \sum_{k=1}^K \pi_k (\boldsymbol{\Sigma}_k + \boldsymbol{\mu}_k \boldsymbol{\mu}_k^\top) - \left(\sum_{k=1}^K \pi_k \boldsymbol{\mu}_k \right) \left(\sum_{j=1}^K \pi_j \boldsymbol{\mu}_j \right)^\top,$$

这正是 (15.40)。

□

等价表述 (全协方差分解) 上述结果亦可写成

$$\text{cov}[\mathbf{x}] = \underbrace{\sum_{k=1}^K \pi_k \boldsymbol{\Sigma}_k}_{\mathbb{E}[\text{cov}(\mathbf{x}|Z)]} + \underbrace{\sum_{k=1}^K \pi_k (\boldsymbol{\mu}_k - \mathbb{E}[\mathbf{x}])(\boldsymbol{\mu}_k - \mathbb{E}[\mathbf{x}])^\top}_{\text{cov}(\mathbb{E}[\mathbf{x}|Z])},$$

即 “类内协方差 + 类间协方差” 的形式。

练习 15.15 解答 (★★)

目标 利用 EM 的重估公式证明：对伯努利混合模型，当参数取极大似然解时

$$\mathbb{E}[\mathbf{x}] = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \equiv \bar{\mathbf{x}}. \quad (15.65)$$

进一步证明：若把所有分量的均值初始化为同一向量 $\boldsymbol{\mu}_k^{(0)} = \hat{\boldsymbol{\mu}} \ (k = 1, \dots, K)$ ，则无论初始混合系数 $\{\pi_k^{(0)}\}$ 如何（只需满足 $\sum_k \pi_k^{(0)} = 1$ ），EM 在一次迭代后收敛到满足 $\boldsymbol{\mu}_k = \bar{\mathbf{x}}$ 的解。

第一部分：极大似然解满足 $\mathbb{E}[\mathbf{x}] = \bar{\mathbf{x}}$

设观测为 $\{\mathbf{x}_n\}_{n=1}^N$ ，每个分量条件分布为 D 维伯努利：

$$p(\mathbf{x} | k) = \prod_{i=1}^D \mu_{ki}^{x_i} (1 - \mu_{ki})^{(1-x_i)}, \quad \boldsymbol{\mu}_k = (\mu_{k1}, \dots, \mu_{kD})^\top.$$

令责任度（后验）为

$$\gamma(z_{nk}) = \frac{\pi_k p(\mathbf{x}_n | k)}{\sum_{j=1}^K \pi_j p(\mathbf{x}_n | j)}, \quad \sum_{k=1}^K \gamma(z_{nk}) = 1.$$

EM 的 M 步重估式为（对每个分量、逐坐标成立）

$$N_k = \sum_{n=1}^N \gamma(z_{nk}), \quad \boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n, \quad \pi_k = \frac{N_k}{N}.$$

混合模型下的模型期望为

$$\mathbb{E}[\mathbf{x}] = \sum_{k=1}^K \pi_k \boldsymbol{\mu}_k.$$

将上式代入 EM 的重估解：

$$\sum_{k=1}^K \pi_k \boldsymbol{\mu}_k = \sum_{k=1}^K \frac{N_k}{N} \cdot \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n = \frac{1}{N} \sum_{n=1}^N \left(\sum_{k=1}^K \gamma(z_{nk}) \right) \mathbf{x}_n = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n = \bar{\mathbf{x}}.$$

于是 (15.65) 得证。 □

第二部分： $\boldsymbol{\mu}_k$ 等初始化 $\Rightarrow$ 一次迭代收敛

若初始时对所有 k 都有 $\boldsymbol{\mu}_k^{(0)} = \hat{\boldsymbol{\mu}}$ ，则对任一数据 $\mathbf{x}_n$ ，各分量的似然 $p(\mathbf{x}_n | k)$ 完全相同，于是 E 步得到

$$\gamma^{(0)}(z_{nk}) = \frac{\pi_k^{(0)} p(\mathbf{x}_n | \hat{\boldsymbol{\mu}})}{\sum_j \pi_j^{(0)} p(\mathbf{x}_n | \hat{\boldsymbol{\mu}})} = \pi_k^{(0)} \quad (\text{与 } n \text{ 无关}).$$

据此，M 步更新为

$$N_k^{(0)} = \sum_{n=1}^N \gamma^{(0)}(z_{nk}) = N \pi_k^{(0)}, \quad \boldsymbol{\mu}_k^{(1)} = \frac{1}{N_k^{(0)}} \sum_{n=1}^N \gamma^{(0)}(z_{nk}) \mathbf{x}_n = \frac{1}{N \pi_k^{(0)}} \left(\pi_k^{(0)} \sum_{n=1}^N \mathbf{x}_n \right) = \bar{\mathbf{x}},$$

且

$$\pi_k^{(1)} = \frac{N_k^{(0)}}{N} = \pi_k^{(0)}.$$

因此在下一次 E 步，各分量仍同均值 $\bar{\mathbf{x}}$ ，责任度保持 $\gamma(z_{nk}) = \pi_k^{(1)}$ ，M 步继续给出 $\boldsymbol{\mu}_k^{(2)} = \bar{\mathbf{x}}$ 、 $\pi_k^{(2)} = \pi_k^{(1)}$ 。于是到达不动点，算法在一次迭代后收敛，且解满足

$$\boxed{\boldsymbol{\mu}_k = \bar{\mathbf{x}} \quad (k = 1, \dots, K)}$$

这对应于所有分量相同的退化情形，实践中通常通过合适的初始化来避免。 □

练习 15.16 解答 (★)

题目 考虑伯努利混合的潜在变量 $\mathbf{z}$ 与观测变量 $\mathbf{x}$ 的联合分布, 其由

$$p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu}) \quad (\text{式 15.42}) \quad \text{与} \quad p(\mathbf{z} | \boldsymbol{\pi}) \quad (\text{式 15.43})$$

的乘积给出。证明: 若对 $\mathbf{z}$ 做边缘化, 则得到

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | \boldsymbol{\mu}_k) \quad (\text{式 15.37}).$$

解 设 $\mathbf{z} = (z_1, \dots, z_K)^\top$ 为 one-hot 编码 (1-of- K), 即 $z_k \in \{0, 1\}$ 且 $\sum_k z_k = 1$ 。由 (15.42)、(15.43) 得联合分布

$$\begin{aligned} p(\mathbf{x}, \mathbf{z} | \boldsymbol{\mu}, \boldsymbol{\pi}) &= p(\mathbf{x} | \mathbf{z}, \boldsymbol{\mu}) p(\mathbf{z} | \boldsymbol{\pi}) \\ &= \prod_{k=1}^K \left[p(\mathbf{x} | \boldsymbol{\mu}_k) \right]^{z_k} \prod_{k=1}^K \pi_k^{z_k} = \prod_{k=1}^K \left(\pi_k p(\mathbf{x} | \boldsymbol{\mu}_k) \right)^{z_k}. \end{aligned} \quad (*)$$

对 $\mathbf{z}$ 边缘化 (对所有 one-hot 向量求和):

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{\mathbf{z}} \prod_{k=1}^K \left(\pi_k p(\mathbf{x} | \boldsymbol{\mu}_k) \right)^{z_k}.$$

由于 $\mathbf{z}$ 为 1-of- K , 对任意一项 $\prod_k (\cdot)^{z_k}$ 仅在某个 j 使 $z_j = 1$ 时取值为 $\pi_j p(\mathbf{x} | \boldsymbol{\mu}_j)$, 其余分量为 0。枚举 K 种可能得到

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | \boldsymbol{\mu}_k)$$

这正是式 (15.37)。 □

练习 15.17 解答 (★)

题目 设伯努利混合模型的期望完整数据对数似然为

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \boldsymbol{\pi})] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \sum_{i=1}^D \left[x_{ni} \ln \mu_{ki} + (1 - x_{ni}) \ln(1 - \mu_{ki}) \right] \right\}, \quad (15.45)$$

其中 $\gamma(z_{nk}) = p(z_{nk} = 1 | \mathbf{x}_n)$ 是责任度。证明：在保持 $\gamma(z_{nk})$ (即 E 步结果) 不变的条件下，对 $\boldsymbol{\mu}$ 最大化 (15.45) 可得 M 步更新

$$\boxed{\boldsymbol{\mu}_k = \bar{\mathbf{x}}_k}, \quad \bar{\mathbf{x}}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n, \quad N_k = \sum_{n=1}^N \gamma(z_{nk}), \quad (15.49)$$

即每个分量的参数等于以责任度为权重的样本均值。

证明 对固定的 k ，式 (15.45) 关于 $\boldsymbol{\mu}_k = (\mu_{k1}, \dots, \mu_{kD})^\top$ 按坐标分离，可逐元素最大化：

$$\mathcal{L}_{ki}(\mu_{ki}) = \sum_{n=1}^N \gamma(z_{nk}) \left[x_{ni} \ln \mu_{ki} + (1 - x_{ni}) \ln(1 - \mu_{ki}) \right], \quad 0 < \mu_{ki} < 1.$$

对 μ_{ki} 求导并令其为零：

$$\frac{\partial \mathcal{L}_{ki}}{\partial \mu_{ki}} = \sum_{n=1}^N \gamma(z_{nk}) \left(\frac{x_{ni}}{\mu_{ki}} - \frac{1 - x_{ni}}{1 - \mu_{ki}} \right) = 0.$$

化简得（分母为正，可约去）

$$\sum_{n=1}^N \gamma(z_{nk}) [x_{ni} - \mu_{ki}] = 0 \implies \mu_{ki} = \frac{\sum_{n=1}^N \gamma(z_{nk}) x_{ni}}{\sum_{n=1}^N \gamma(z_{nk})} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_{ni}.$$

把所有 $i = 1, \dots, D$ 的结果合并成向量形式，得到

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n = \bar{\mathbf{x}}_k.$$

为证该驻点为极大点，计算二阶导

$$\frac{\partial^2 \mathcal{L}_{ki}}{\partial \mu_{ki}^2} = - \sum_{n=1}^N \gamma(z_{nk}) \left(\frac{x_{ni}}{\mu_{ki}^2} + \frac{1 - x_{ni}}{(1 - \mu_{ki})^2} \right) < 0,$$

故 $\mathcal{L}_{ki}$ 在 $0 < \mu_{ki} < 1$ 上是严格凹的，所求解为全局极大值。

综上，在保持责任度 $\gamma(z_{nk})$ 不变时，对 $\boldsymbol{\mu}$ 最大化 (15.45) 的 M 步闭式解即式 (15.49)。□

练习 15.18 解答 (★)

题目 已知伯努利混合模型的期望完整数据对数似然为 (见 (15.45))

$$\mathbb{E}_{\mathbf{Z}}[\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \boldsymbol{\pi})] = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \sum_{i=1}^D \left[x_{ni} \ln \mu_{ki} + (1 - x_{ni}) \ln(1 - \mu_{ki}) \right] \right\}, \quad (15.45)$$

其中 $\gamma(z_{nk}) = p(z_{nk} = 1 | \mathbf{x}_n)$ 是责任度。证明：在保持 $\gamma(z_{nk})$ 与 $\boldsymbol{\mu}$ 不变的条件下，对混合系数 $\boldsymbol{\pi}$ 最大化 (15.45)，并使用拉格朗日乘子强制 $\sum_k \pi_k = 1$ ，可得到 M 步更新

$$\boxed{\pi_k = \frac{N_k}{N}}, \quad N_k = \sum_{n=1}^N \gamma(z_{nk}). \quad (15.50)$$

证明 在固定 γ 与 $\boldsymbol{\mu}$ 时，式 (15.45) 与 $\boldsymbol{\pi}$ 有关的部分是

$$\mathcal{L}(\boldsymbol{\pi}) = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \ln \pi_k = \sum_{k=1}^K N_k \ln \pi_k, \quad \text{其中 } N_k = \sum_{n=1}^N \gamma(z_{nk}).$$

为满足约束 $\sum_k \pi_k = 1$ ，引入拉格朗日函数

$$\mathcal{J}(\boldsymbol{\pi}, \lambda) = \sum_{k=1}^K N_k \ln \pi_k + \lambda \left(\sum_{k=1}^K \pi_k - 1 \right).$$

对每个 π_k 求偏导并令其为零：

$$\frac{\partial \mathcal{J}}{\partial \pi_k} = \frac{N_k}{\pi_k} + \lambda = 0 \implies \pi_k = -\frac{N_k}{\lambda}.$$

两边对 k 求和并利用约束 $\sum_k \pi_k = 1$ 与 $\sum_k N_k = \sum_n \sum_k \gamma(z_{nk}) = \sum_n 1 = N$ ，得

$$1 = \sum_k \pi_k = -\frac{1}{\lambda} \sum_k N_k = -\frac{N}{\lambda} \implies \lambda = -N.$$

代回上式可得

$$\pi_k = \frac{N_k}{N}, \quad k = 1, \dots, K,$$

即 (15.50)。由于 $\frac{\partial^2 \mathcal{J}}{\partial \pi_k^2} = -\frac{N_k}{\pi_k^2} \leq 0$ 且无交叉项， $\mathcal{L}(\boldsymbol{\pi})$ 在单纯形内部为严格凹函数，所以上述驻点给出全局最大值（若 $N_k = 0$ ，则最优解自然落在边界 $\pi_k = 0$ ）。□

练习 15.19 解答 (★)

题目 设离散变量 (伯努利向量) $\mathbf{x}_n$ 的混合模型对数似然为

$$\ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{n=1}^N \ln \left\{ \sum_{k=1}^K \pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k) \right\}, \quad (15.41)$$

并注意到对任意 k 与 n 都有 $0 \leq p(\mathbf{x}_n | \boldsymbol{\mu}_k) \leq 1$ 。证明: 不完全数据对数似然有上界, 因而不存在似然趋于无穷大的奇异性。

证明 对伯努利分量,

$$p(\mathbf{x}_n | \boldsymbol{\mu}_k) = \prod_{i=1}^D \mu_{ki}^{x_{ni}} (1 - \mu_{ki})^{1-x_{ni}}, \quad 0 \leq \mu_{ki} \leq 1,$$

其中每一因子都在区间 $[0, 1]$ 内, 因此整体也满足 $0 \leq p(\mathbf{x}_n | \boldsymbol{\mu}_k) \leq 1$ 。又由于混合系数满足 $\pi_k \geq 0$, $\sum_{k=1}^K \pi_k = 1$, 对每个 n 有

$$0 \leq \sum_{k=1}^K \pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k) \leq \sum_{k=1}^K \pi_k \cdot 1 = 1.$$

从而

$$\ln p(\mathbf{X} | \boldsymbol{\mu}, \boldsymbol{\pi}) = \sum_{n=1}^N \ln \left\{ \sum_k \pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k) \right\} \leq \sum_{n=1}^N \ln 1 = 0.$$

因此不完全数据对数似然上界为 0, 不可能趋于 $+\infty$, 即不存在像高斯混合中那样由参数奇异 (例如协方差退化) 导致的似然发散情形。(当且仅当对所有 n , 有 $\sum_k \pi_k p(\mathbf{x}_n | \boldsymbol{\mu}_k) = 1$ 时等号成立; 在一般情形下严格小于 0。)

综上, 伯努利混合模型的对数似然被 0 所上界, 因而没有似然趋于无穷大的奇异性。 $\square$

练习 15.20 解答 (★★★)

题目 设观测为 D 维离散向量 $\mathbf{x} = (x_1, \dots, x_D)$, 其中第 i 维是 M 元多项分布的 1-of- M 表示: 把第 i 维写成二值向量 $(x_{i1}, \dots, x_{iM})$, 满足 $x_{ij} \in \{0, 1\}$ 且 $\sum_{j=1}^M x_{ij} = 1$ 。考虑 K 分量的混合模型

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k p(\mathbf{x} | \boldsymbol{\mu}_k), \quad (15.66)$$

其中

$$p(\mathbf{x} | \boldsymbol{\mu}_k) = \prod_{i=1}^D \prod_{j=1}^M \mu_{kij}^{x_{ij}}, \quad \mu_{kij} \geq 0, \quad \sum_{j=1}^M \mu_{kij} = 1 \quad (\forall k, i). \quad (15.67)$$

给定数据集 $\{\mathbf{x}_n\}_{n=1}^N$, 推导极大似然的 EM 算法的 E 步与 M 步更新式。

解

E 步 (责任度) 利用贝叶斯公式, 有第 n 个样本属于分量 k 的后验概率

$$\gamma(z_{nk}) := p(z_{nk} = 1 | \mathbf{x}_n) = \frac{\pi_k \prod_{i=1}^D \prod_{j=1}^M \mu_{kij}^{x_{nij}}}{\sum_{\ell=1}^K \pi_{\ell} \prod_{i=1}^D \prod_{j=1}^M \mu_{\ell ij}^{x_{nij}}}.$$

M 步 (最大化 Q 函数) 期望完备对数似然为

$$Q = \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \left\{ \ln \pi_k + \sum_{i=1}^D \sum_{j=1}^M x_{nij} \ln \mu_{kij} \right\}.$$

(1) 混合系数 π : 对约束 $\sum_k \pi_k = 1$ 使用拉格朗日乘子可得

$$N_k := \sum_{n=1}^N \gamma(z_{nk}), \quad \boxed{\pi_k = \frac{N_k}{N}} \quad (k = 1, \dots, K).$$

(2) 分量参数 μ_{kij} : 对每个 (k, i) , 在约束 $\sum_{j=1}^M \mu_{kij} = 1$ 下最大化 $\sum_j (\sum_n \gamma_{nk} x_{nij}) \ln \mu_{kij}$ 。设拉格朗日乘子为 λ_{ki} , 令导数为零:

$$\frac{\partial}{\partial \mu_{kij}} \left[\sum_n \gamma_{nk} x_{nij} \ln \mu_{kij} + \lambda_{ki} \left(\sum_{j'} \mu_{kij'} - 1 \right) \right] = 0 \Rightarrow \mu_{kij} \propto \sum_{n=1}^N \gamma_{nk} x_{nij}.$$

对 j 归一化得到

$$\mu_{kij} = \frac{\sum_{n=1}^N \gamma_{nk} x_{nij}}{\sum_{j'=1}^M \sum_{n=1}^N \gamma_{nk} x_{nij'}} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} x_{nij},$$

其中用到了 $\sum_{j'} x_{nij'} = 1$ ，故分母化为 N_k 。由此得到闭式更新

$$\boxed{\mu_{kij} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_{nij}}, \quad i = 1, \dots, D, \quad j = 1, \dots, M, \quad k = 1, \dots, K.$$

结论 混合多项（逐维独立的分类）模型的 EM 迭代为

$$\begin{aligned} \text{E 步: } \gamma(z_{nk}) &= \frac{\pi_k \prod_{i=1}^D \prod_{j=1}^M \mu_{kij}^{x_{nij}}}{\sum_{\ell=1}^K \pi_{\ell} \prod_{i=1}^D \prod_{j=1}^M \mu_{\ell ij}^{x_{nij}}}; \\ \text{M 步: } N_k &= \sum_n \gamma(z_{nk}), \quad \pi_k = \frac{N_k}{N}, \quad \mu_{kij} = \frac{1}{N_k} \sum_n \gamma(z_{nk}) x_{nij}. \end{aligned}$$

这一步把 μ_{kij} 更新为“责任度加权的一元计数比例”，与朴素贝叶斯中对分类概率的极大似然估计一致。 $\square$

练习 15.21 解答 (★)

题目 验证分解

$$\ln p(\mathbf{X} | \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q \| p), \quad (15.52)$$

其中

$$\mathcal{L}(q, \boldsymbol{\theta}) = \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta})}{q(\mathbf{Z})} \right\}, \quad (15.53)$$

$$\text{KL}(q \| p) = - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})}{q(\mathbf{Z})} \right\}. \quad (15.54)$$

证明 从概率乘法公式得到

$$\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\theta}) = \ln p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}) + \ln p(\mathbf{X} | \boldsymbol{\theta}). \quad (15.55)$$

将 (15.55) 代入 (15.53) 可得

$$\begin{aligned} \mathcal{L}(q, \boldsymbol{\theta}) &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \left[\ln p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}) + \ln p(\mathbf{X} | \boldsymbol{\theta}) - \ln q(\mathbf{Z}) \right] \\ &= \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta}) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln q(\mathbf{Z}) + \ln p(\mathbf{X} | \boldsymbol{\theta}) \sum_{\mathbf{Z}} q(\mathbf{Z}) \\ &= \ln p(\mathbf{X} | \boldsymbol{\theta}) - \sum_{\mathbf{Z}} q(\mathbf{Z}) \ln \left\{ \frac{q(\mathbf{Z})}{p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})} \right\}. \end{aligned}$$

注意到最后一项正是 $\text{KL}(q \| p)$ 的定义式 (将符号取反), 于是

$$\mathcal{L}(q, \boldsymbol{\theta}) = \ln p(\mathbf{X} | \boldsymbol{\theta}) - \text{KL}(q \| p) \implies \ln p(\mathbf{X} | \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q \| p),$$

即得所需分解 (15.52)。另外, 由于 $\text{KL}(q \| p) \geq 0$, 可知 $\mathcal{L}(q, \boldsymbol{\theta}) \leq \ln p(\mathbf{X} | \boldsymbol{\theta})$, 且当且仅当 $q(\mathbf{Z}) = p(\mathbf{Z} | \mathbf{X}, \boldsymbol{\theta})$ 时取等号。□

练习 15.22 解答 (★)

题目 证明：由 (15.53) 定义的下界

$$\mathcal{L}(q, \boldsymbol{\theta}) = \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{X}, \mathbf{Z} = \mathbf{z} \mid \boldsymbol{\theta})}{q(\mathbf{z})}$$

当取 $q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\theta}^{(\text{old})})$ 时，在点 $\boldsymbol{\theta} = \boldsymbol{\theta}^{(\text{old})}$ 处，其关于 $\boldsymbol{\theta}$ 的梯度与对数似然 $\ln p(\mathbf{X} \mid \boldsymbol{\theta})$ 的梯度相同。

解 由分解式 (15.52)

$$\ln p(\mathbf{X} \mid \boldsymbol{\theta}) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q \parallel p),$$

其中

$$\text{KL}(q \parallel p) = - \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{Z} = \mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta})}{q(\mathbf{z})}. \quad (*)$$

对 $\boldsymbol{\theta}$ 求梯度并把 q 视为常数（此处 q 只依赖于 $\boldsymbol{\theta}^{(\text{old})}$ ，与 $\boldsymbol{\theta}$ 无关），得

$$\nabla_{\boldsymbol{\theta}} \ln p(\mathbf{X} \mid \boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \mathcal{L}(q, \boldsymbol{\theta}) + \nabla_{\boldsymbol{\theta}} \text{KL}(q \parallel p).$$

由上式 (*) 可得

$$\nabla_{\boldsymbol{\theta}} \text{KL}(q \parallel p) = - \sum_{\mathbf{z}} q(\mathbf{z}) \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{Z} = \mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}).$$

现在令 $q(\mathbf{z}) = p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}^{(\text{old})})$ 并在 $\boldsymbol{\theta} = \boldsymbol{\theta}^{(\text{old})}$ 处评价上式：

$$\nabla_{\boldsymbol{\theta}} \text{KL}(q \parallel p)|_{\boldsymbol{\theta}^{(\text{old})}} = - \sum_{\mathbf{z}} p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}^{(\text{old})}) \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta})|_{\boldsymbol{\theta}^{(\text{old})}}.$$

注意到对任意 $\boldsymbol{\theta}$ 都有 $\sum_{\mathbf{z}} p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}) = 1$ 。对两边求导得到

$$\mathbf{0} = \sum_{\mathbf{z}} \nabla_{\boldsymbol{\theta}} p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}) \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{z} \mid \mathbf{X}, \boldsymbol{\theta}).$$

故在 $\boldsymbol{\theta} = \boldsymbol{\theta}^{(\text{old})}$ 处， $\nabla_{\boldsymbol{\theta}} \text{KL}(q \parallel p) = \mathbf{0}$ 。于是

$$\boxed{\nabla_{\boldsymbol{\theta}} \ln p(\mathbf{X} \mid \boldsymbol{\theta})|_{\boldsymbol{\theta}^{(\text{old})}} = \nabla_{\boldsymbol{\theta}} \mathcal{L}(q, \boldsymbol{\theta})|_{\boldsymbol{\theta}^{(\text{old})}}, \quad q(\mathbf{Z}) = p(\mathbf{Z} \mid \mathbf{X}, \boldsymbol{\theta}^{(\text{old})})}$$

即证。 □

练习 15.23 解答 (★★)

题目 考虑高斯混合模型的增量EM 形式：在第 m 个样本 $\mathbf{x}_m$ 到来/被处理时，仅重新计算该样本的责任度 $\gamma(z_{mk})$ 。从 M 步公式

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n \quad (15.16)$$

与

$$N_k = \sum_{n=1}^N \gamma(z_{nk}) \quad (15.17)$$

出发，推导均值的增量更新式

$$\boldsymbol{\mu}_k^{\text{new}} = \boldsymbol{\mu}_k^{\text{old}} + \frac{\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) \quad (15.60)$$

以及有效样本数的更新式

$$N_k^{\text{new}} = N_k^{\text{old}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}) \quad (15.61).$$

解

第 1 步： N_k 的增量更新 仅第 m 个样本的责任度发生变化，其余样本保持不变，故由 (15.17) 直接得到

$$N_k^{\text{new}} = \sum_{n \neq m} \gamma^{\text{old}}(z_{nk}) + \gamma^{\text{new}}(z_{mk}) = \underbrace{\sum_{n=1}^N \gamma^{\text{old}}(z_{nk})}_{N_k^{\text{old}}} + \gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk}),$$

这就是 (15.61)。

第 2 步：均值的增量更新 记“加权和” $S_k := \sum_{n=1}^N \gamma(z_{nk}) \mathbf{x}_n$ 。由 (15.16) 有 $\boldsymbol{\mu}_k = S_k/N_k$ 。在本次仅更新第 m 个责任度的情形下，

$$S_k^{\text{new}} = \sum_{n \neq m} \gamma^{\text{old}}(z_{nk}) \mathbf{x}_n + \gamma^{\text{new}}(z_{mk}) \mathbf{x}_m = \underbrace{\sum_{n=1}^N \gamma^{\text{old}}(z_{nk}) \mathbf{x}_n}_{S_k^{\text{old}}} + (\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})) \mathbf{x}_m.$$

又由 $S_k^{\text{old}} = N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}}$ 得

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{S_k^{\text{new}}}{N_k^{\text{new}}} = \frac{N_k^{\text{old}} \boldsymbol{\mu}_k^{\text{old}} + (\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})) \mathbf{x}_m}{N_k^{\text{new}}}.$$

在分子中加减 $(\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})) \boldsymbol{\mu}_k^{\text{old}}$ ，并整理为

$$\boldsymbol{\mu}_k^{\text{new}} = \boldsymbol{\mu}_k^{\text{old}} + \frac{\gamma^{\text{new}}(z_{mk}) - \gamma^{\text{old}}(z_{mk})}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}),$$

即得到 (15.60)。 □

练习 15.24 解答 (★★)

题目 当 EM 的 E 步按顺序/增量方式仅对某一个样本 $\mathbf{x}_m$ 更新责任度时 (其余样本的责任度不变), 推导高斯混合模型在 M 步中协方差矩阵与混合系数的增量更新公式, 其形式应当与均值的增量更新式 (15.60) 类似。

记号 对分量 k , 记

$$\gamma_{mk}^{\text{old}} = \gamma^{\text{old}}(z_{mk}), \quad \gamma_{mk}^{\text{new}} = \gamma^{\text{new}}(z_{mk}), \quad \Delta\gamma_{mk} = \gamma_{mk}^{\text{new}} - \gamma_{mk}^{\text{old}}.$$

令

$$N_k^{\text{old}} = \sum_n \gamma^{\text{old}}(z_{nk}), \quad N_k^{\text{new}} = \sum_n \gamma^{\text{new}}(z_{nk}) = N_k^{\text{old}} + \Delta\gamma_{mk}.$$

均值的增量更新 (书中式(15.60)) 为

$$\boldsymbol{\mu}_k^{\text{new}} = \boldsymbol{\mu}_k^{\text{old}} + \frac{\Delta\gamma_{mk}}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}), \quad \Rightarrow \quad \mathbf{x}_m - \boldsymbol{\mu}_k^{\text{new}} = \frac{N_k^{\text{old}}}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}). \quad (*)$$

(一) 协方差的增量更新

采用定义 (批量形式)

$$\boldsymbol{\Sigma}_k = \frac{1}{N_k} \sum_n \gamma(z_{nk}) (\mathbf{x}_n - \boldsymbol{\mu}_k) (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top. \quad (15.18)$$

为推导便捷, 引入 “未中心二阶矩” 充分统计量

$$\mathbf{C}_k \equiv \sum_n \gamma(z_{nk}) \mathbf{x}_n \mathbf{x}_n^\top, \quad \text{则} \quad \boldsymbol{\Sigma}_k = \frac{\mathbf{C}_k}{N_k} - \boldsymbol{\mu}_k \boldsymbol{\mu}_k^\top.$$

在仅改变样本 m 的责任度时,

$$\mathbf{C}_k^{\text{new}} = \mathbf{C}_k^{\text{old}} + \Delta\gamma_{mk} \mathbf{x}_m \mathbf{x}_m^\top.$$

于是

$$\begin{aligned} \boldsymbol{\Sigma}_k^{\text{new}} &= \frac{1}{N_k^{\text{new}}} \left(\mathbf{C}_k^{\text{old}} + \Delta\gamma_{mk} \mathbf{x}_m \mathbf{x}_m^\top \right) - \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^\top \\ &= \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \boldsymbol{\Sigma}_k^{\text{old}} + \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \boldsymbol{\mu}_k^{\text{old}} (\boldsymbol{\mu}_k^{\text{old}})^\top + \frac{\Delta\gamma_{mk}}{N_k^{\text{new}}} \mathbf{x}_m \mathbf{x}_m^\top - \boldsymbol{\mu}_k^{\text{new}} (\boldsymbol{\mu}_k^{\text{new}})^\top. \end{aligned}$$

配方并利用上面的关系(*) 可化为以下两种等价而便于实现的增量形式:

$$\boxed{\boldsymbol{\Sigma}_k^{\text{new}} = \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \boldsymbol{\Sigma}_k^{\text{old}} + \frac{\Delta\gamma_{mk}}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{new}})^\top} \quad (\text{A})$$

或 (仅含旧均值的对称写法)

$$\boxed{\boldsymbol{\Sigma}_k^{\text{new}} = \frac{N_k^{\text{old}}}{N_k^{\text{new}}} \boldsymbol{\Sigma}_k^{\text{old}} + \frac{\Delta\gamma_{mk} N_k^{\text{old}}}{(N_k^{\text{new}})^2} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}}) (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})^\top} \quad (\text{A}')$$

二式等价 (由 $\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{new}} = \frac{N_k^{\text{old}}}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})$ 得到)。

(二) 混合系数的增量更新

批量形式为 $\pi_k = N_k/N$ (式(15.21))。由于 N 为样本总数 (常数),

$$\pi_k^{\text{new}} = \frac{N_k^{\text{new}}}{N} = \pi_k^{\text{old}} + \frac{\Delta\gamma_{mk}}{N} \quad (\text{B})$$

小结 给定对单个样本 m 的责任度变化 $\Delta\gamma_{mk} = \gamma_{mk}^{\text{new}} - \gamma_{mk}^{\text{old}}$, 先用

$$N_k^{\text{new}} = N_k^{\text{old}} + \Delta\gamma_{mk}, \quad \boldsymbol{\mu}_k^{\text{new}} = \boldsymbol{\mu}_k^{\text{old}} + \frac{\Delta\gamma_{mk}}{N_k^{\text{new}}} (\mathbf{x}_m - \boldsymbol{\mu}_k^{\text{old}})$$

更新有效样本数与均值 (即式(15.60)、(15.61)), 再用 (A) (或等价的 (A')) 更新协方差, 最后用 (B) 更新混合系数。这些增量公式与均值的 (15.60) 完全同构, 只需常数时间即可完成一次顺序 M 步更新。