

Solutions to Chapter 16 — *Continuous Latent Variables*

YaoYuzhuo

August , 2025

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 16.1 (★★) 用数学归纳法证明：使投影后数据方差最大的 M 维线性子空间，由数据协方差矩阵 $\mathbf{S}$ （见式(16.3)）的 M 个特征向量所张成，且它们对应于最大的 M 个特征值。在第 16.1 节中已证明了 $M = 1$ 的情形。现在假设该结论对某个一般的 M 成立，证明其对维度 $M + 1$ 亦成立。为此，请按如下步骤进行：

- 令 $\mathbf{u}_{M+1}$ 为数据空间中新方向的单位向量，对投影方差关于 $\mathbf{u}_{M+1}$ 的导数设为零；该优化需满足约束： $\mathbf{u}_{M+1}$ 与已有向量 $\mathbf{u}_1, \dots, \mathbf{u}_M$ 两两正交，且 $\|\mathbf{u}_{M+1}\| = 1$ 。使用拉格朗日乘子来施加这些约束。
- 利用向量 $\mathbf{u}_1, \dots, \mathbf{u}_M$ 的正交归一性质，证明新向量 $\mathbf{u}_{M+1}$ 必为 $\mathbf{S}$ 的一个特征向量。
- 进一步证明：当把该特征向量选为对应特征值 λ_{M+1} 的那个特征向量（特征值按从大到小排序）时，投影方差取得最大值。

练习 16.2 (★★) 设主成分分析（PCA）的投影误差度量 J 由式(16.15)给出。证明：在满足正交归一约束 (16.7) 的条件下，当 $\mathbf{u}_i$ 取为数据协方差矩阵 $\mathbf{S}$ 的特征向量时， J 取得最小值。为此，对每个约束各引入一个拉格朗日乘子，组成矩阵 $\mathbf{H}$ ，从而得到矩阵记号下的修正目标

$$\tilde{J} = \text{Tr}\{\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}\} + \text{Tr}\{\mathbf{H}(\mathbf{I} - \hat{\mathbf{U}}^\top \hat{\mathbf{U}})\}. \quad (16.87)$$

其中， $\hat{\mathbf{U}}$ 为尺寸 $D \times (D-M)$ 的矩阵，其列向量即为 $\mathbf{u}_i$ 。先对 $\hat{\mathbf{U}}$ 最小化 $\tilde{J}$ ，并证明解满足

$$\mathbf{S} \hat{\mathbf{U}} = \hat{\mathbf{U}} \mathbf{H}.$$

显然，一种可能的解是： $\hat{\mathbf{U}}$ 的各列取为 $\mathbf{S}$ 的特征向量，此时 $\mathbf{H}$ 为包含相应特征值的对角矩阵。为得一般解，证明 $\mathbf{H}$ 可取为对称矩阵；再利用其特征分解说明：满足 $\mathbf{S}\hat{\mathbf{U}} = \hat{\mathbf{U}}\mathbf{H}$ 的一般解在 $\tilde{J}$ 上与“ $\hat{\mathbf{U}}$ 的列为 $\mathbf{S}$ 的特征向量”的特解给出相同的目标值。因为这些解等价，故可方便地选取特征向量形式的解。

练习 16.3 (★) 证明（核对）：由式 (16.30) 定义的特征向量 $\mathbf{u}_i$ 已被归一化为单位长度，前提是假设 $\mathbf{v}_i$ 本身为单位长度向量。

练习 16.4 (★) 设在概率 PCA 模型中，将潜在空间的零均值、单位协方差分布 (16.31) 替换为一般高斯分布 $\mathcal{N}(\mathbf{z} | \mathbf{m}, \Sigma)$ 。通过重新定义模型参数，证明：对任意合法的 $\mathbf{m}$ 与 Σ ，所得到的观测变量的边缘分布 $p(\mathbf{x})$ 与原模型完全等同（即给出相同的 $p(\mathbf{x})$ ）。

练习 16.5 (★★) 设 $\mathbf{x}$ 为 D 维随机变量，服从高斯分布 $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \Sigma)$ 。再考虑由

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$$

定义的 M 维随机变量，其中 $\mathbf{A}$ 为 $M \times D$ 矩阵。证明： $\mathbf{y}$ 也服从高斯分布，并给出其均值与协方差的表达式。进一步讨论当 $M < D$ 、 $M = D$ 与 $M > D$ 时该高斯分布的形式有何差别。

练习 16.6 (★★) 利用一般分布的均值与协方差公式 (2.122)、(2.123)，推导概率 PCA 模型中边缘分布 $p(\mathbf{x})$ 的结果 (16.35)。

练习 16.7 (★) 为第 16.2 节所述的概率 PCA 模型绘制一个有向概率图，其中将观测变量 $\mathbf{x}$ 的各个分量显式地作为单独的节点表示。进而验证：该概率 PCA 模型与第 11.2.3 节讨论的朴素贝叶斯模型具有相同的条件独立结构。

练习 16.8 (★★) 利用结果式 (3.100)，证明在概率 PCA 模型中，后验分布 $p(\mathbf{z} | \mathbf{x})$ 的表达式由式 (16.43) 给出。

练习 16.9 (★) 验证：对概率 PCA 模型的对数似然式 (16.44) 关于参数 $\boldsymbol{\mu}$ 求最大化，可得极大似然解 $\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}}$ ，其中 $\bar{\mathbf{x}}$ 为数据向量的样本均值。

练习 16.10 (★★) 通过对概率 PCA 模型的对数似然函数 (16.44) 关于参数 $\boldsymbol{\mu}$ 的二阶导数进行计算，证明驻点 $\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}}$ ($\bar{\mathbf{x}}$ 为样本均值) 是唯一极大值。

练习 16.11 (★★) 证明：当 $\sigma^2 \rightarrow 0$ 时，概率 PCA 模型给出的后验均值对应的映射变为将数据正交投影到主子空间（与常规 PCA 相同）。

练习 16.12 (★★) 证明：当 $\sigma^2 > 0$ 时，概率 PCA 模型中的后验均值相对于正交投影会向原点偏移（即产生向零的收缩）。

练习 16.13 (★★) 证明：在概率 PCA 中，若按照常规 PCA 的最小二乘投影代价来度量重构误差，则单个数据点的最优重构为

$$\tilde{\mathbf{x}} = \mathbf{W}_{\text{ML}}(\mathbf{W}_{\text{ML}}^{\top} \mathbf{W}_{\text{ML}})^{-1} \mathbf{M} \mathbb{E}[\mathbf{z} | \mathbf{x}], \quad (16.88)$$

其中 $\mathbf{M}$ 为式 (16.42) 中定义的矩阵。

练习 16.14 (★) 在具有 M 维潜在空间、 D 维数据空间的概率 PCA 模型中，协方差矩阵中的独立参数个数由式 (16.52) 给出。请验证：当 $M = D - 1$ 时，该独立参数个数与一般协方差高斯分布相同；而当 $M = 0$ 时，它与各向同性协方差高斯分布的独立参数个数相同。

练习 16.15 (★) 推导第 16.2.4 节所述因子分析 (factor analysis) 模型中独立参数的数量表达式。

练习 16.16 (★★) 证明：第 16.2.4 节所述的因子分析模型对潜在空间坐标的旋转不变（即在潜变量坐标系作任意正交旋转时，模型保持不变）。

练习 16.17 (★★) 考虑一个线性-高斯潜变量模型，其潜空间分布为

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} | \mathbf{0}, \mathbf{I}),$$

观测变量的条件分布为

$$p(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Phi}),$$

其中 $\boldsymbol{\Phi}$ 是任意对称正定的噪声协方差矩阵。现对数据变量作非奇异线性变换

$$\mathbf{x} \rightarrow \mathbf{A} \mathbf{x},$$

其中 $\mathbf{A}$ 为 $D \times D$ 矩阵。若 $\boldsymbol{\mu}_{\text{ML}}$ 、 $\mathbf{W}_{\text{ML}}$ 和 $\boldsymbol{\Phi}_{\text{ML}}$ 是对原始（未变换）数据的极大似然解，证明对于变换后的数据集，相应的极大似然解分别为

$$\mathbf{A} \boldsymbol{\mu}_{\text{ML}}, \quad \mathbf{A} \mathbf{W}_{\text{ML}}, \quad \mathbf{A} \boldsymbol{\Phi}_{\text{ML}} \mathbf{A}^{\top}.$$

最后说明模型形式在以下两种情形下保持不变：

- (i) $\mathbf{A}$ 为对角矩阵且 $\boldsymbol{\Phi}$ 为对角矩阵（对应因子分析）。此时变换后的 $\boldsymbol{\Phi}$ 仍为对角矩阵，因此因子分析在对各分量做尺度重缩放下是协变的；
- (ii) $\mathbf{A}$ 为正交矩阵且 $\boldsymbol{\Phi}$ 与单位阵成比例，即 $\boldsymbol{\Phi} = \sigma^2 \mathbf{I}$ （对应概率 PCA）。此时变换后的 $\boldsymbol{\Phi}$ 仍与单位阵成比例，因此概率 PCA 在数据空间坐标轴的旋转下是协变的，这与常规 PCA 相同。

练习 16.18 (★) 验证：对连续潜变量模型，其对数似然可以写成式 (16.57) 的两项之和，且两项分别由式 (16.58) 与 (16.59) 定义。可按如下思路证明：先利用概率的乘法法则

$$p(\mathbf{x}, \mathbf{z} \mid \mathbf{w}) = p(\mathbf{z} \mid \mathbf{x}, \mathbf{w}) p(\mathbf{x} \mid \mathbf{w}) \quad (16.89)$$

然后将式 (16.89) 代入 (16.58) 中 $p(\mathbf{x}, \mathbf{z} \mid \mathbf{w})$ 的位置，即可得到所要求的分解形式。

练习 16.19 (★) 证明：对于一组独立同分布 (i.i.d.) 的数据，证据下界 (evidence lower bound, ELBO) 可写成式 (16.63) 的形式。

练习 16.20 (★★) 画出一个有向概率图，表示离散混合的概率 PCA (probabilistic PCA) 模型，其中混合中的每个 PCA 分量各自拥有参数 $\mathbf{W}$ 、 $\boldsymbol{\mu}$ 与 σ^2 。随后，再画出一个参数共享的变体图：这些参数值在混合各分量之间共享。

练习 16.21 (★★) 由式 (16.65) 给出的完整数据对数似然的期望出发，推导概率 PCA 模型在 EM 算法中的 M 步更新公式 (16.68) 与 (16.69)。

练习 16.22 (★★★) 概率化的主成分分析 (probabilistic PCA, PPCA) 的一个好处是：当数据集中部分分量缺失且满足“随机缺失” (missing at random) 假设时，仍可对模型进行学习。请在这种情形下，推导用于最大化似然函数的 PPCA 的 EM 算法。

说明： 在本设定下，潜变量不仅包括 $\{\mathbf{z}_n\}$ ，还包括各观测向量 $\{\mathbf{x}_n\}$ 中未观测的分量 (缺失值)。请证明：当所有数据分量均被观测到这一特殊情形下，你得到的 EM 算法会退化为第 16.3.2 节中给出的概率 PCA 的 EM 算法。

练习 16.23 (★★) 设 $\mathbf{W}$ 为一个 $D \times M$ 矩阵，其列向量张成嵌入在 D 维数据空间中的一个 M 维线性子空间；设 $\boldsymbol{\mu}$ 为一个 D 维向量。给定数据集 $\{\mathbf{x}_n\}_{n=1}^N$ ，用一组 M 维向量 $\{\mathbf{z}_n\}_{n=1}^N$ 通过线性映射来逼近数据点，使

$$\mathbf{x}_n \approx \mathbf{W}\mathbf{z}_n + \boldsymbol{\mu}.$$

相应的最小二乘重构代价定义为

$$J = \sum_{n=1}^N \|\mathbf{x}_n - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}_n\|^2. \quad (16.90)$$

首先证明：对 $\boldsymbol{\mu}$ 最小化 J 可得到一个与上式“同形”的表达式，但其中 $\mathbf{x}_n$ 与 $\mathbf{z}_n$ 分别被零均值变量 $\mathbf{x}_n - \bar{\mathbf{x}}$ 与 $\mathbf{z}_n - \bar{\mathbf{z}}$ 所取代，其中

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n, \quad \bar{\mathbf{z}} = \frac{1}{N} \sum_{n=1}^N \mathbf{z}_n.$$

然后证明：在保持 $\mathbf{W}$ 不变的情况下，对每个 $\mathbf{z}_n$ 最小化 J 给出 PCA 的 E 步 (式 (16.70))；而在保持 $\{\mathbf{z}_n\}$ 不变时，对 $\mathbf{W}$ 最小化 J 给出 PCA 的 M 步 (式 (16.71))。

练习 16.24 (★★) 推导因子分析 (factor analysis) 模型的 EM 算法中 E 步的公式 (16.72) 与 (16.73)。注意：由练习 16.26 的结论可知，参数 μ 可用样本均值 $\bar{x}$ 代替。

练习 16.25 (★★) 写出因子分析模型的完整数据对数似然的期望（即 EM 中的 Q 函数）的表达式，并据此推导相应的 M 步更新式 (16.75) 与 (16.76)。

练习 16.26 (★★) 通过考察二阶导数，证明：在第 16.2.4 节讨论的因子分析模型中，相对于参数 μ 的对数似然函数只有一个驻点，该驻点由式 (16.1) 给出的样本均值 $\bar{x}$ 。进一步证明该驻点是极大值。

下面将进行详细解答！

练习 16.1 解答 (★★)

目标 用数学归纳法证明：最大化投影方差的 M 维线性子空间由样本协方差矩阵 $\mathbf{S}$ (式(16.3)) 的前 M 个特征向量所张成。已知 $M=1$ 的情形 (见正文)。设该结论对某个 M 已成立，证明对 $M+1$ 也成立。

记号 令 $\mathbf{u}_1, \dots, \mathbf{u}_M$ 为 $\mathbf{S}$ 的前 M 个单位正交特征向量，对应特征值按降序排列 $\lambda_1 \geq \dots \geq \lambda_M$ 。写 $\mathbf{U}_M = [\mathbf{u}_1, \dots, \mathbf{u}_M]$ ，则 $\mathbf{U}_M^\top \mathbf{U}_M = \mathbf{I}_M$ ，且 $\mathbf{S}\mathbf{U}_M = \mathbf{U}_M \mathbf{\Lambda}_M$ ， $\mathbf{\Lambda}_M = \text{diag}(\lambda_1, \dots, \lambda_M)$ 。归纳假设给出当前“已解释方差”

$$\text{Var}_M = \text{tr}(\mathbf{U}_M^\top \mathbf{S} \mathbf{U}_M) = \sum_{i=1}^M \lambda_i.$$

第一步：把 $M+1$ 维问题化为约束最优化 在保持 $\mathbf{U}_M$ 不变的前提下，向子空间再加入一条新方向 $\mathbf{u} \equiv \mathbf{u}_{M+1}$ 。总投影方差增量仅由 $\mathbf{u}$ 决定，为

$$J(\mathbf{u}) = \mathbf{u}^\top \mathbf{S} \mathbf{u}.$$

约束为

$$\mathbf{u}^\top \mathbf{u} = 1, \quad \mathbf{U}_M^\top \mathbf{u} = \mathbf{0} \quad (\text{与已有方向正交}).$$

第二步：拉格朗日乘子与驻点条件 构造拉格朗日函数

$$\mathcal{L}(\mathbf{u}, \lambda, \gamma) = \mathbf{u}^\top \mathbf{S} \mathbf{u} + \lambda(1 - \mathbf{u}^\top \mathbf{u}) - \gamma^\top \mathbf{U}_M^\top \mathbf{u},$$

其中 $\lambda \in \mathbb{R}$ ， $\gamma \in \mathbb{R}^M$ 。对 $\mathbf{u}$ 求导并令其为零 (注意 $\mathbf{S}$ 对称) 得

$$\nabla_{\mathbf{u}} \mathcal{L} = 2\mathbf{S} \mathbf{u} - 2\lambda \mathbf{u} - \mathbf{U}_M \gamma = \mathbf{0}. \quad (1)$$

左乘 $\mathbf{U}_M^\top$ ，并用正交性与谱分解 $\mathbf{U}_M^\top \mathbf{S} = (\mathbf{S} \mathbf{U}_M)^\top = (\mathbf{U}_M \mathbf{\Lambda}_M)^\top = \mathbf{\Lambda}_M \mathbf{U}_M^\top$ ，得到

$$\underbrace{\mathbf{U}_M^\top \mathbf{S} \mathbf{u}}_{= \mathbf{\Lambda}_M \mathbf{U}_M^\top \mathbf{u} = \mathbf{0}} - \lambda \underbrace{\mathbf{U}_M^\top \mathbf{u}}_{= \mathbf{0}} - \underbrace{\mathbf{U}_M^\top \mathbf{U}_M}_{= \mathbf{I}_M} \gamma = \mathbf{0} \implies \gamma = \mathbf{0}.$$

将 $\gamma = \mathbf{0}$ 代回(1)式，得到

$$\mathbf{S} \mathbf{u} = \lambda \mathbf{u},$$

即 $\mathbf{u}$ 必为 $\mathbf{S}$ 的特征向量 (并满足 $\mathbf{U}_M^\top \mathbf{u} = \mathbf{0}$ 与 $\|\mathbf{u}\| = 1$)。

第三步：选取哪一个特征向量使方差最大 因为 $\mathbf{u}$ 与 $\mathbf{u}_1, \dots, \mathbf{u}_M$ 正交，它只能在 $\{\mathbf{u}_{M+1}, \dots, \mathbf{u}_D\}$ 张成的子空间内取值。将 $\mathbf{u} = \sum_{i=M+1}^D \alpha_i \mathbf{u}_i$ ，且 $\sum_{i=M+1}^D \alpha_i^2 = 1$ 代入 Rayleigh 商得

$$J(\mathbf{u}) = \mathbf{u}^\top \mathbf{S} \mathbf{u} = \sum_{i=M+1}^D \lambda_i \alpha_i^2 \leq \lambda_{M+1} \sum_{i=M+1}^D \alpha_i^2 = \lambda_{M+1},$$

当且仅当 $\mathbf{u} = \mathbf{u}_{M+1}$ 时取等号。故最优新方向是对应剩余特征值中最大的特征向量 $\mathbf{u}_{M+1}$ ，此时增量方差为 λ_{M+1} 。

归纳结论 最优的 $(M+1)$ 维子空间由 $\{\mathbf{u}_1, \dots, \mathbf{u}_M, \mathbf{u}_{M+1}\}$ 张成，其总投影方差

$$\text{Var}_{M+1} = \text{Var}_M + \lambda_{M+1} = \sum_{i=1}^{M+1} \lambda_i.$$

由于 $M = 1$ 的基例已成立，归纳完成，命题得证。 ■

备注（重特征值） 若某个特征值有重数，则对应的任意一组单位正交基都是可行的最优方向；只需在该重特征子空间内取与已有方向正交的单位向量即可。

练习 16.2 解答 (★★)

题目摘要 设

$$J = \sum_{i=M+1}^D \mathbf{u}_i^\top \mathbf{S} \mathbf{u}_i = \text{Tr}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}), \quad \hat{\mathbf{U}} = [\mathbf{u}_{M+1}, \dots, \mathbf{u}_D] \in \mathbb{R}^{D \times (D-M)}, \quad (16.15)$$

并满足正交归一约束

$$\hat{\mathbf{U}}^\top \hat{\mathbf{U}} = \mathbf{I}. \quad (16.7)$$

证明: J 的极小值在 $\mathbf{u}_i$ 取为数据协方差矩阵 $\mathbf{S}$ 的特征向量时取得。提示: 用拉格朗日乘子矩阵 $\mathbf{H}$, 令

$$\tilde{J} = \text{Tr}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}) + \text{Tr}(\mathbf{H}(\mathbf{I} - \hat{\mathbf{U}}^\top \hat{\mathbf{U}})). \quad (16.87)$$

证明

(1) 一阶条件 对 $\hat{\mathbf{U}}$ 求导并令梯度为零。用恒等式 $\frac{\partial}{\partial \mathbf{U}} \text{Tr}(\mathbf{U}^\top \mathbf{A} \mathbf{U}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{U}$ 与 $\frac{\partial}{\partial \mathbf{U}} \text{Tr}(-\mathbf{H} \mathbf{U}^\top \mathbf{U}) = -(\mathbf{U}(\mathbf{H} + \mathbf{H}^\top))$, 得

$$(\mathbf{S} + \mathbf{S}^\top) \hat{\mathbf{U}} - \hat{\mathbf{U}}(\mathbf{H} + \mathbf{H}^\top) = \mathbf{0}.$$

由于 $\mathbf{S}$ 为对称矩阵, 化简得

$$\mathbf{S} \hat{\mathbf{U}} = \hat{\mathbf{U}} \mathbf{H}_s, \quad \mathbf{H}_s := \frac{1}{2} (\mathbf{H} + \mathbf{H}^\top). \quad (1)$$

因此, 只需取 对称 的乘子矩阵 (反对称部分不起作用), 并把它记为 $\mathbf{H}$, 便有

$$\boxed{\mathbf{S} \hat{\mathbf{U}} = \hat{\mathbf{U}} \mathbf{H}}. \quad (2)$$

(2) $\mathbf{H}$ 必为对称矩阵 由 (2) 左乘 $\hat{\mathbf{U}}^\top$ 并利用 $\hat{\mathbf{U}}^\top \hat{\mathbf{U}} = \mathbf{I}$, 可得

$$\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}} = \mathbf{H}. \quad (3)$$

左端显然为对称矩阵 ($\mathbf{S}$ 对称), 故 $\mathbf{H}$ 亦必对称, 这与上一步一致。

(3) 从一般解到特征向量解 对称矩阵 $\mathbf{H}$ 可正交对角化: $\mathbf{H} = \mathbf{R} \mathbf{\Lambda} \mathbf{R}^\top$, 其中 $\mathbf{R}$ 为正交矩阵, $\mathbf{\Lambda} = \text{diag}(\lambda_{M+1}, \dots, \lambda_D)$ 。令

$$\hat{\mathbf{U}}' = \hat{\mathbf{U}} \mathbf{R},$$

则仍有 $\hat{\mathbf{U}}'^\top \hat{\mathbf{U}}' = \mathbf{I}$, 并由 (2) 得

$$\mathbf{S} \hat{\mathbf{U}}' = \mathbf{S} \hat{\mathbf{U}} \mathbf{R} = \hat{\mathbf{U}} \mathbf{H} \mathbf{R} = \hat{\mathbf{U}} \mathbf{R} \mathbf{\Lambda} = \hat{\mathbf{U}}' \mathbf{\Lambda}. \quad (4)$$

这表明 $\hat{\mathbf{U}}'$ 的各列向量是 $\mathbf{S}$ 的特征向量 (对应特征值为 $\mathbf{\Lambda}$ 对角元)。因此, 满足一阶条件的一般解与“列即协方差矩阵特征向量”的特定解仅差一个潜在空间内的正交旋转, 二者等价。

(4) 目标值相等且仅依赖所选特征值 在可行域 $\hat{\mathbf{U}}^\top \hat{\mathbf{U}} = \mathbf{I}$ 内，拉格朗日函数的值为

$$\tilde{J} = \text{Tr}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}) + \text{Tr}(\mathbf{H}(\mathbf{I} - \mathbf{I})) = \text{Tr}(\hat{\mathbf{U}}^\top \mathbf{S} \hat{\mathbf{U}}).$$

由 (3) 与迹的相似不变性，任一解均满足

$$\tilde{J} = \text{Tr}(\mathbf{H}) = \text{Tr}(\mathbf{\Lambda}) = \sum_{i=M+1}^D \lambda_i, \quad (5)$$

其中 $\{\lambda_i\}$ 为 $\mathbf{S}$ 的相应特征值。可见 $\tilde{J}$ (亦即 J) 只与所选特征值集合有关，而与子空间中采用的具体正交基 (是否取为特征向量) 无关。

(5) 取极小值 为使 J 最小，应选择使 (5) 最小的一组特征值，即取 $\hat{\mathbf{U}}$ 的列为 $\mathbf{S}$ 的 $D - M$ 个最小特征值对应的特征向量。于是

$$J_{\min} = \sum_{i=M+1}^D \lambda_i, \quad \text{且最优 } \{\mathbf{u}_i\} \text{ 是 } \mathbf{S} \text{ 的特征向量 (对应上述特征值).}$$

(16.18)

□

练习 16.3 解答 (★)

题目 验证由式 (16.30) 定义的特征向量

$$\mathbf{u}_i = \frac{1}{\sqrt{N\lambda_i}} \mathbf{X}^\top \mathbf{v}_i \quad (16.30)$$

(其中 $\mathbf{v}_i$ 是矩阵 $\frac{1}{N}\mathbf{X}\mathbf{X}^\top$ 的单位特征向量, 特征值为 λ_i) 是单位范数的。

解答 由 (16.28) 可知

$$\frac{1}{N}\mathbf{X}\mathbf{X}^\top \mathbf{v}_i = \lambda_i \mathbf{v}_i \iff \mathbf{X}\mathbf{X}^\top \mathbf{v}_i = N\lambda_i \mathbf{v}_i. \quad (16.28)$$

因此

$$\|\mathbf{u}_i\|^2 = \mathbf{u}_i^\top \mathbf{u}_i = \frac{1}{N\lambda_i} \mathbf{v}_i^\top \mathbf{X}\mathbf{X}^\top \mathbf{v}_i = \frac{1}{N\lambda_i} \mathbf{v}_i^\top (N\lambda_i \mathbf{v}_i) = \mathbf{v}_i^\top \mathbf{v}_i = 1,$$

其中最后一步用了题设 “ $\mathbf{v}_i$ 已经单位化”。故由 (16.30) 得到的 $\mathbf{u}_i$ 亦为单位长度, 证毕。

练习 16.4 解答 (★)

题目 在概率 PCA 中, 将潜变量先验

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{0}, \mathbf{I}) \quad (16.31)$$

替换为一般高斯 $p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{m}, \Sigma)$ 。通过重定义模型参数, 证明对任意合法的 $\mathbf{m}, \Sigma$ ($\Sigma \succ 0$) 所得观测变量的边缘分布 $p(\mathbf{x})$ 与原模型为同一族。

解答

概率 PCA 的条件分布保持不变:

$$p(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (16.32)$$

步骤 1: 把一般先验标准化 取 Σ 的任意矩阵平方根 $\mathbf{L}$ (如 Cholesky), 使 $\Sigma = \mathbf{L}\mathbf{L}^\top$ 。定义

$$\mathbf{u} = \mathbf{L}^{-1}(\mathbf{z} - \mathbf{m}) \iff \mathbf{z} = \mathbf{L}\mathbf{u} + \mathbf{m},$$

则 $\mathbf{u} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。代回生成式得到

$$\mathbf{x} = \mathbf{W}(\mathbf{L}\mathbf{u} + \mathbf{m}) + \boldsymbol{\mu} + \boldsymbol{\varepsilon} = (\mathbf{W}\mathbf{L})\mathbf{u} + (\boldsymbol{\mu} + \mathbf{W}\mathbf{m}) + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}).$$

于是与标准 PPCA 形式等价, 只需作参数替换

$$\boxed{\mathbf{W}' = \mathbf{W}\mathbf{L}, \quad \boldsymbol{\mu}' = \boldsymbol{\mu} + \mathbf{W}\mathbf{m}, \quad \sigma'^2 = \sigma^2, \quad p(\mathbf{u}) = \mathcal{N}(\mathbf{0}, \mathbf{I})}.$$

步骤 2: 边缘分布同族 标准 PPCA 给出观测边缘分布

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}', \mathbf{W}'\mathbf{W}'^\top + \sigma'^2 \mathbf{I}). \quad (16.35-16.36)$$

代入上式参数化, 得

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu} + \mathbf{W}\mathbf{m}, \mathbf{W}\Sigma\mathbf{W}^\top + \sigma^2 \mathbf{I}),$$

因为 $\mathbf{W}'\mathbf{W}'^\top = (\mathbf{W}\mathbf{L})(\mathbf{W}\mathbf{L})^\top = \mathbf{W}\Sigma\mathbf{W}^\top$ 。

结论 对任意 $\mathbf{m}, \Sigma \succ 0$, 带一般高斯先验的模型可通过吸收到 $\mathbf{W}, \boldsymbol{\mu}$ 的重参数化变为标准 PPCA, 因而诱导的 $p(\mathbf{x})$ 属于与原模型相同的分布族。这表明潜空间的任意仿射变换不会改变观测边缘分布的模型类。证毕。

练习 16.5 解答 (★★)

题目 设随机向量 $\mathbf{x} \in \mathbb{R}^D$ 服从高斯分布 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。令 $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$ ，其中 $\mathbf{A} \in \mathbb{R}^{M \times D}$ 、 $\mathbf{b} \in \mathbb{R}^M$ 。证明 $\mathbf{y}$ 亦为高斯随机向量，并给出其均值与协方差；讨论 $M < D$ 、 $M = D$ 与 $M > D$ 三种情形下该高斯分布的形式。

(一) 均值与协方差

$$\mathbb{E}[\mathbf{y}] = \mathbb{E}[\mathbf{A}\mathbf{x} + \mathbf{b}] = \mathbf{A} \mathbb{E}[\mathbf{x}] + \mathbf{b} = \boxed{\mathbf{A}\boldsymbol{\mu} + \mathbf{b}}.$$

$$\begin{aligned} \text{cov}(\mathbf{y}) &= \mathbb{E}[(\mathbf{y} - \mathbb{E}[\mathbf{y}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top] \\ &= \mathbb{E}[\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{A}^\top] \\ &= \mathbf{A} \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top] \mathbf{A}^\top \\ &= \boxed{\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top}. \end{aligned}$$

(二) $\mathbf{y}$ 为高斯

用矩母函数（或特征函数）验证：对任意 $\mathbf{t} \in \mathbb{R}^M$ ，

$$\begin{aligned} M_{\mathbf{y}}(\mathbf{t}) &= \mathbb{E}[e^{\mathbf{t}^\top \mathbf{y}}] = e^{\mathbf{t}^\top \mathbf{b}} \mathbb{E}[e^{\mathbf{t}^\top \mathbf{A}\mathbf{x}}] = e^{\mathbf{t}^\top \mathbf{b}} \exp\left(\mathbf{t}^\top \mathbf{A}\boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^\top \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top \mathbf{t}\right) \\ &= \exp\left(\mathbf{t}^\top (\mathbf{A}\boldsymbol{\mu} + \mathbf{b}) + \frac{1}{2} \mathbf{t}^\top (\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top) \mathbf{t}\right), \end{aligned}$$

这恰是均值为 $\mathbf{A}\boldsymbol{\mu} + \mathbf{b}$ 、协方差为 $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ 的高斯向量的矩母函数。故

$$\boxed{\mathbf{y} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)}.$$

(三) 关于维数关系的讨论

设 $\boldsymbol{\Sigma} \succ 0$ 且 $\text{rank}(\mathbf{A}) = r \leq \min\{M, D\}$ 。则 $\text{rank}(\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top) = r$ 。

- $M < D$. 若 $\mathbf{A}$ 满行秩 ($\text{rank}(\mathbf{A}) = M$)，则 $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top \succ 0$ ， $\mathbf{y}$ 是在 $\mathbb{R}^M$ 上的非退化高斯：

$$\mathbf{y} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

若 $\text{rank}(\mathbf{A}) < M$ ，协方差奇异， $\mathbf{y}$ 退化在某个维数为 $\text{rank}(\mathbf{A})$ 的仿射子空间上。

- $M = D$. 若 $\mathbf{A}$ 可逆，则 $\mathbf{y}$ 与 $\mathbf{x}$ 之间一一对应，仍为非退化高斯，协方差为 $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ ；若 $\mathbf{A}$ 不可逆，则出现与上段相同的退化情形。
- $M > D$. 由于 $\text{rank}(\mathbf{A}) \leq D < M$ ， $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ 必然奇异， $\mathbf{y}$ 的分布集中在一个至多 D 维的仿射子空间 $\mathbf{b} + \mathbf{A}\mathbb{R}^D$ 上。因此它是退化高斯（对 $\mathbb{R}^M$ 的勒贝格测度无密度）。

总结 对任意线性-仿射变换 $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$, 若 $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 则必有

$$\mathbf{y} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$$

当 $\mathbf{A}$ 满行秩且 $M \leq D$ 时分布非退化, 否则为退化高斯。

练习 16.6 解答 (★★)

题目 利用一般分布的“全期望/全方差”结论（式 (2.122)、(2.123)），推导概率 PCA 中观测变量的边缘分布式 (16.35)。模型为

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{0}, \mathbf{I}) \quad (16.31)$$

$$p(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (16.32)$$

解答 由 (16.32) 等价地可写生成式

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), \quad \boldsymbol{\varepsilon} \text{ 与 } \mathbf{z} \text{ 独立}. \quad (16.33)$$

记 (2.122)、(2.123) 为

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}_{\mathbf{z}}[\mathbb{E}[\mathbf{x} \mid \mathbf{z}]], \quad \text{cov}[\mathbf{x}] = \mathbb{E}_{\mathbf{z}}[\text{cov}(\mathbf{x} \mid \mathbf{z})] + \text{cov}_{\mathbf{z}}(\mathbb{E}[\mathbf{x} \mid \mathbf{z}]). \quad (2.122-2.123)$$

均值

$$\mathbb{E}[\mathbf{x} \mid \mathbf{z}] = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} \Rightarrow \mathbb{E}[\mathbf{x}] = \mathbb{E}_{\mathbf{z}}[\mathbf{W}\mathbf{z} + \boldsymbol{\mu}] = \mathbf{W} \mathbb{E}[\mathbf{z}] + \boldsymbol{\mu} = \boldsymbol{\mu}. \quad (16.37)$$

协方差

$$\text{cov}(\mathbf{x} \mid \mathbf{z}) = \sigma^2 \mathbf{I} \Rightarrow \mathbb{E}_{\mathbf{z}}[\text{cov}(\mathbf{x} \mid \mathbf{z})] = \sigma^2 \mathbf{I}.$$

又

$$\text{cov}_{\mathbf{z}}(\mathbb{E}[\mathbf{x} \mid \mathbf{z}]) = \text{cov}_{\mathbf{z}}(\mathbf{W}\mathbf{z} + \boldsymbol{\mu}) = \mathbf{W} \text{cov}(\mathbf{z}) \mathbf{W}^{\top} = \mathbf{W}\mathbf{W}^{\top}. \quad (16.38)$$

因此

$$\text{cov}[\mathbf{x}] = \mathbf{W}\mathbf{W}^{\top} + \sigma^2 \mathbf{I}. \quad (16.39)$$

由于 $\mathbf{x}$ 是高斯变量的仿射变换之和，边缘分布仍为高斯，故

$$\boxed{p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \mathbf{C}), \quad \mathbf{C} = \mathbf{W}\mathbf{W}^{\top} + \sigma^2 \mathbf{I}} \quad (16.35, 16.36)$$

这正是所要求的结论。

练习 16.7 解答 (★)

题目 为第 16.2 节的概率 PCA (PPCA) 模型画出一个有向概率图, 其中观测向量 $\mathbf{x} \in \mathbb{R}^D$ 的各个分量 $x_1, \dots, x_D$ 分别作为独立的结点显示; 并据此验证: PPCA 的独立性结构与第 11.2.3 节的朴素贝叶斯模型相同。

解答

1) PPCA 的条件分布与因子分解 PPCA 的先验与条件分布为

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{0}, \mathbf{I}), \quad p(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \sigma^2 \mathbf{I}).$$


设 $\mathbf{W}$ 的第 i 行记为 $\mathbf{w}_i^\top$, $\boldsymbol{\mu}$ 的第 i 个分量为 μ_i 。由于条件协方差为 $\sigma^2 \mathbf{I}$ (各向同性、对角阵), 有

$$p(\mathbf{x} \mid \mathbf{z}) = \prod_{i=1}^D \mathcal{N}(x_i \mid \mathbf{w}_i^\top \mathbf{z} + \mu_i, \sigma^2),$$

从而得到条件独立性

$$x_i \perp\!\!\!\perp x_j \mid \mathbf{z} \quad (i \neq j). \quad (\star)$$

2) **概率图** 下图把观测向量的每个分量都作为单独结点给出; 参数 $\mathbf{W}, \boldsymbol{\mu}, \sigma^2$ 为共享的 (不影响分量间的条件独立性), 因此可不画或以注释标出。



3) **与朴素贝叶斯的独立性结构一致** 朴素贝叶斯图为“单一父结点 $\mathbf{C}$ 指向各特征 $x^{(1)}, \dots, x^{(L)}$ ”, 其关键独立性为 $x^{(i)} \perp\!\!\!\perp x^{(j)} \mid \mathbf{C} \ (i \neq j)$ 。与之对应, 上图中由 (★) 式知: 条件于连续潜变量 $\mathbf{z}$, 所有观测分量 $x_1, \dots, x_D$ 两两独立; 图结构正是“一个公共父结点 $\mathbf{z}$ 指向多个观测结点”, 因此其独立性结构与朴素贝叶斯完全相同 (只是把离散类别变量换成了连续的潜变量)。

□

练习 16.8 解答 (★★)

题目 利用第 3 章中关于线性—高斯模型的结果 (式 (3.100)), 推出概率 PCA 模型的后验分布 $p(\mathbf{z} | \mathbf{x})$ 为式 (16.43)。

解答

概率 PCA 的生成模型为 (见 (16.31)–(16.33))

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} | \mathbf{0}, \mathbf{I}), \quad p(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \sigma^2 \mathbf{I}). \quad (16.31\text{--}16.33)$$

第 3 章 (式 (3.100)) 给出了如下线性—高斯对的条件分布: 若

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}), \quad p(\mathbf{y} | \mathbf{x}) = \mathcal{N}(\mathbf{y} | \mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1}),$$

则

$$p(\mathbf{x} | \mathbf{y}) = \mathcal{N}\left(\mathbf{x} \mid \underbrace{\boldsymbol{\Sigma}\{\mathbf{A}^\top \mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda}\boldsymbol{\mu}\}}_{\text{均值}}, \underbrace{\boldsymbol{\Sigma}}_{\text{协方差}}\right), \quad \boldsymbol{\Sigma} = (\boldsymbol{\Lambda} + \mathbf{A}^\top \mathbf{L} \mathbf{A})^{-1}. \quad (3.100)$$

将 (3.100) 与 PPCA 对应起来, 取

$$\mathbf{x} \mapsto \mathbf{z}, \quad \mathbf{y} \mapsto \mathbf{x}, \quad \boldsymbol{\Lambda} = \mathbf{I}, \quad \boldsymbol{\mu} = \mathbf{0}, \quad \mathbf{A} = \mathbf{W}, \quad \mathbf{b} = \boldsymbol{\mu}, \quad \mathbf{L} = \sigma^{-2} \mathbf{I}.$$

于是

$$\boldsymbol{\Sigma} = (\mathbf{I} + \mathbf{W}^\top (\sigma^{-2} \mathbf{I}) \mathbf{W})^{-1} = (\mathbf{I} + \sigma^{-2} \mathbf{W}^\top \mathbf{W})^{-1}.$$

利用恒等式 $(\mathbf{I} + \sigma^{-2} \mathbf{A})^{-1} = \sigma^2 (\sigma^2 \mathbf{I} + \mathbf{A})^{-1}$, 令 $\mathbf{M} = \mathbf{W}^\top \mathbf{W} + \sigma^2 \mathbf{I}$ (见 (16.42)), 得

$$\boldsymbol{\Sigma} = \sigma^2 \mathbf{M}^{-1}. \quad (*)$$

后验均值为

$$\boldsymbol{\mu}_{z|x} = \boldsymbol{\Sigma} \mathbf{W}^\top (\sigma^{-2} \mathbf{I})(\mathbf{x} - \boldsymbol{\mu}) = (\sigma^{-2} \boldsymbol{\Sigma}) \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) = \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}),$$

其中最后一步由 (*) 得到 $\sigma^{-2} \boldsymbol{\Sigma} = \mathbf{M}^{-1}$ 。

综上,

$$\boxed{p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}), \sigma^2 \mathbf{M}^{-1})} \quad (16.43)$$

这正是教材式 (16.43) 的结论。证毕。

练习 16.9 解答 (★)

题目 验证：在概率 PCA 的对数似然

$$\ln p(\mathbf{X} \mid \boldsymbol{\mu}, \mathbf{W}, \sigma^2) = -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln |\mathbf{C}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}) \quad (16.44)$$

中，对参数 $\boldsymbol{\mu}$ 最大化得到 $\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}}$ ，其中 $\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$ 为样本均值；这里 $\mathbf{C} = \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}$ 与 $\boldsymbol{\mu}$ 无关。

证明 对 $\boldsymbol{\mu}$ 的依赖只在最后一项。令 $\mathcal{L}(\boldsymbol{\mu}) := \ln p(\mathbf{X} \mid \boldsymbol{\mu}, \mathbf{W}, \sigma^2)$ 中与 $\boldsymbol{\mu}$ 有关的部分为

$$\mathcal{L}_\mu(\boldsymbol{\mu}) = -\frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}).$$

利用恒等式（当 $\mathbf{A}$ 对称时） $\frac{\partial}{\partial \boldsymbol{\mu}} (\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{A} (\mathbf{x} - \boldsymbol{\mu}) = -2\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})$ ，得梯度

$$\nabla_{\boldsymbol{\mu}} \mathcal{L}(\boldsymbol{\mu}) = \nabla_{\boldsymbol{\mu}} \mathcal{L}_\mu(\boldsymbol{\mu}) = -\frac{1}{2} \sum_{n=1}^N (-2\mathbf{C}^{-1}(\mathbf{x}_n - \boldsymbol{\mu})) = \sum_{n=1}^N \mathbf{C}^{-1}(\mathbf{x}_n - \boldsymbol{\mu}) = \mathbf{C}^{-1} \left(\sum_{n=1}^N \mathbf{x}_n - N\boldsymbol{\mu} \right).$$

令其为零，得到 $\sum_{n=1}^N \mathbf{x}_n - N\boldsymbol{\mu} = \mathbf{0} \Rightarrow \boldsymbol{\mu} = \bar{\mathbf{x}}$ 。

为证其为极大值，计算 Hessian：

$$\nabla_{\boldsymbol{\mu}}^2 \mathcal{L}(\boldsymbol{\mu}) = -N \mathbf{C}^{-1} \prec 0,$$

因为 $\mathbf{C}^{-1}$ 正定。故 $\boldsymbol{\mu} = \bar{\mathbf{x}}$ 是对数似然的唯一极大点，即

$$\boxed{\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}}}.$$

□

练习 16.10 解答 (★★)

题目 对概率 PCA 的对数似然

$$\ln p(\mathbf{X} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) = -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln |\mathbf{C}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}), \quad (16.44)$$

其中 $\mathbf{C} = \mathbf{W}\mathbf{W}^\top + \sigma^2 \mathbf{I}$, 计算其关于 $\boldsymbol{\mu}$ 的二阶导数, 证明驻点 $\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}}$ (样本均值) 是唯一极大值。

解答 注意 $\mathbf{C}$ 与 $\boldsymbol{\mu}$ 无关, 因此对数似然中依赖 $\boldsymbol{\mu}$ 的只有二次型项。令

$$\ell(\boldsymbol{\mu}) := \ln p(\mathbf{X} | \mathbf{W}, \boldsymbol{\mu}, \sigma^2) = \text{const} - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}).$$

一阶导数 (梯度) 利用恒等式 $\nabla_{\boldsymbol{\mu}} [(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{A} (\mathbf{x} - \boldsymbol{\mu})] = -2\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})$ ($\mathbf{A}$ 对称) 得

$$\nabla_{\boldsymbol{\mu}} \ell(\boldsymbol{\mu}) = \sum_{n=1}^N \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}) = \mathbf{C}^{-1} \left(\sum_{n=1}^N \mathbf{x}_n - N\boldsymbol{\mu} \right).$$

令其为零可得唯一驻点

$$\boxed{\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}} := \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n}.$$

二阶导数 (Hessian) 与凹性 对梯度再求导,

$$\nabla_{\boldsymbol{\mu}}^2 \ell(\boldsymbol{\mu}) = -N \mathbf{C}^{-1}.$$

由于

$$\forall \mathbf{v} \neq \mathbf{0}: \quad \mathbf{v}^\top \mathbf{C} \mathbf{v} = \|\mathbf{W}^\top \mathbf{v}\|^2 + \sigma^2 \|\mathbf{v}\|^2 > 0,$$

故 $\mathbf{C} \succ 0$ 从而 $\mathbf{C}^{-1} \succ 0$ 。于是 $\nabla_{\boldsymbol{\mu}}^2 \ell(\boldsymbol{\mu}) = -N\mathbf{C}^{-1} \prec 0$ 为负定, $\ell(\boldsymbol{\mu})$ 是关于 $\boldsymbol{\mu}$ 的严格凹二次函数。

严格凹函数的驻点必为全局且唯一的极大点, 故

$$\boxed{\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}} \text{ 是唯一最大化 (16.44) 的解}}.$$

□

练习 16.11 解答 (★★)

题目 证明：在概率 PCA 中，当 $\sigma^2 \rightarrow 0$ 时，后验均值给出的重建成为把数据正交投影到主子空间（与常规 PCA 相同）。

证明 概率 PCA 的生成模型为

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}).$$

已知（式(16.43)）后验分布

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}\left(\mathbf{z} \left| \underbrace{\mathbf{M}^{-1}\mathbf{W}^\top(\mathbf{x} - \boldsymbol{\mu})}_{\text{后验均值}}, \sigma^2 \mathbf{M}^{-1} \right. \right), \quad \mathbf{M} = \mathbf{W}^\top \mathbf{W} + \sigma^2 \mathbf{I}.$$

因此用后验均值作重建得到（数据空间中的后验均值）

$$\hat{\mathbf{x}} = \mathbb{E}[\mathbf{x} | \mathbf{x}] = \boldsymbol{\mu} + \mathbf{W}\mathbf{M}^{-1}\mathbf{W}^\top(\mathbf{x} - \boldsymbol{\mu}). \quad (1)$$

对最大似然解（式(16.46)）

$$\mathbf{W}_{\text{ML}} = \mathbf{U}_M(\mathbf{L}_M - \sigma^2 \mathbf{I})^{1/2} \mathbf{R},$$

其中 $\mathbf{U}_M = [\mathbf{u}_1, \dots, \mathbf{u}_M]$ 为数据协方差矩阵 $\mathbf{S}$ 的前 M 个特征向量， $\mathbf{L}_M = \text{diag}(\lambda_1, \dots, \lambda_M)$ ， $\mathbf{R}$ 为任意 $M \times M$ 正交阵。由此有

$$\mathbf{M} = \mathbf{W}^\top \mathbf{W} + \sigma^2 \mathbf{I} = \mathbf{R}^\top \mathbf{L}_M \mathbf{R} \Rightarrow \mathbf{M}^{-1} = \mathbf{R}^\top \mathbf{L}_M^{-1} \mathbf{R}.$$

代回得

$$\mathbf{W}\mathbf{M}^{-1}\mathbf{W}^\top = \mathbf{U}_M(\mathbf{L}_M - \sigma^2 \mathbf{I})^{1/2} \mathbf{L}_M^{-1} (\mathbf{L}_M - \sigma^2 \mathbf{I})^{1/2} \mathbf{U}_M^\top = \mathbf{U}_M(\mathbf{I} - \sigma^2 \mathbf{L}_M^{-1}) \mathbf{U}_M^\top.$$

令 $\sigma^2 \rightarrow 0$ ，即得

$$\lim_{\sigma^2 \rightarrow 0} \mathbf{W}\mathbf{M}^{-1}\mathbf{W}^\top = \mathbf{U}_M \mathbf{U}_M^\top.$$

把它代入(1)式，

$$\hat{\mathbf{x}} \xrightarrow{\sigma^2 \rightarrow 0} \boldsymbol{\mu} + \mathbf{U}_M \mathbf{U}_M^\top (\mathbf{x} - \boldsymbol{\mu}).$$

矩阵 $\mathbf{P} = \mathbf{U}_M \mathbf{U}_M^\top$ 满足 $\mathbf{P}^\top = \mathbf{P}$ 且 $\mathbf{P}^2 = \mathbf{P}$ ，因此是到由 $\{\mathbf{u}_1, \dots, \mathbf{u}_M\}$ 张成的主子空间上的正交投影算子。故在 $\sigma^2 \rightarrow 0$ 极限下，概率 PCA 的后验均值重建恰为将数据正交投影到主子空间，与常规 PCA 完全一致。

□

练习 16.12 解答 (★★)

题目 在概率 PCA 中, 证明当 $\sigma^2 > 0$ 时, 相比于将 $\mathbf{x}$ 正交投影到主子空间的结果, 后验均值对应的重构 (或 “投影”) 会向原点 (均值 $\boldsymbol{\mu}$) 收缩。

解答 由书中式 (16.43), 后验分布 $p(\mathbf{z} | \mathbf{x})$ 为

$$\mathbf{z} | \mathbf{x} \sim \mathcal{N}\left(\underbrace{\mathbf{M}^{-1}\mathbf{W}^\top(\mathbf{x} - \boldsymbol{\mu})}_{\mathbb{E}[\mathbf{z} | \mathbf{x}]}, \sigma^2\mathbf{M}^{-1}\right), \quad \mathbf{M} = \mathbf{W}^\top\mathbf{W} + \sigma^2\mathbf{I}.$$

将这一后验均值映回数据空间得到

$$\hat{\mathbf{x}}_{\text{post}} = \boldsymbol{\mu} + \mathbf{W} \mathbb{E}[\mathbf{z} | \mathbf{x}] = \boldsymbol{\mu} + \mathbf{W}\mathbf{M}^{-1}\mathbf{W}^\top(\mathbf{x} - \boldsymbol{\mu}). \quad (1)$$

在最大似然解处 (式 (16.46); 为简便取 $\mathbf{R} = \mathbf{I}$)

$$\mathbf{W} = \mathbf{U}_M(\mathbf{L}_M - \sigma^2\mathbf{I})^{1/2}, \quad \mathbf{L}_M = \text{diag}(\lambda_1, \dots, \lambda_M),$$

其中 $\mathbf{U}_M$ 含 M 个主成分特征向量 (正交), λ_i 为对应特征值。于是

$$\mathbf{M} = \mathbf{W}^\top\mathbf{W} + \sigma^2\mathbf{I} = (\mathbf{L}_M - \sigma^2\mathbf{I}) + \sigma^2\mathbf{I} = \mathbf{L}_M,$$

从而

$$\mathbf{W}\mathbf{M}^{-1}\mathbf{W}^\top = \mathbf{U}_M(\mathbf{L}_M - \sigma^2\mathbf{I})^{1/2} \mathbf{L}_M^{-1} (\mathbf{L}_M - \sigma^2\mathbf{I})^{1/2}\mathbf{U}_M^\top = \mathbf{U}_M(\mathbf{I} - \sigma^2\mathbf{L}_M^{-1})\mathbf{U}_M^\top. \quad (2)$$

另一方面, 将 $\mathbf{x}$ 正交投影到主子空间为

$$\hat{\mathbf{x}}_{\text{orth}} = \boldsymbol{\mu} + \mathbf{U}_M\mathbf{U}_M^\top(\mathbf{x} - \boldsymbol{\mu}). \quad (3)$$

比较 (2) 与 (3), 代入 (1) 得

$$\hat{\mathbf{x}}_{\text{post}} - \boldsymbol{\mu} = \mathbf{U}_M(\mathbf{I} - \sigma^2\mathbf{L}_M^{-1})\mathbf{U}_M^\top(\mathbf{x} - \boldsymbol{\mu}) = \mathbf{U}_M\left(\text{diag}\left(1 - \frac{\sigma^2}{\lambda_i}\right)_{i=1}^M\right)\mathbf{U}_M^\top(\mathbf{x} - \boldsymbol{\mu}). \quad (4)$$

由于 $\lambda_i > 0$ 且 $\sigma^2 > 0$, 有 $0 < 1 - \sigma^2/\lambda_i < 1$ ($i = 1, \dots, M$)。即在每个主轴方向 $\mathbf{u}_i$ 上, 系数从 1 被缩放为 $1 - \sigma^2/\lambda_i$ 。因此, 与正交投影 $\hat{\mathbf{x}}_{\text{orth}}$ 相比,

$$\hat{\mathbf{x}}_{\text{post}} - \boldsymbol{\mu} = \left(\text{按各主轴因子 } 1 - \sigma^2/\lambda_i \text{ 的收缩}\right) \cdot (\hat{\mathbf{x}}_{\text{orth}} - \boldsymbol{\mu}),$$

从而 $\hat{\mathbf{x}}_{\text{post}}$ 位于与 $\hat{\mathbf{x}}_{\text{orth}}$ 相同的主子空间内, 但离均值 $\boldsymbol{\mu}$ 更近 (当数据已中心化 $\boldsymbol{\mu} = \mathbf{0}$ 时, 即 “更靠近原点”)。这就证明了: 当 $\sigma^2 > 0$ 时, 概率 PCA 的后验均值相对于正交投影发生了向原点的收缩 (*shrinkage*)。□

练习 16.13 解答 (★★)

题目 证明在概率 PCA 下，按传统 PCA 的最小二乘投影代价得到的最优重构为

$$\tilde{\mathbf{x}} = \mathbf{W}_{ML}(\mathbf{W}_{ML}^\top \mathbf{W}_{ML})^{-1} \mathbf{M} \mathbb{E}[\mathbf{z} | \mathbf{x}], \quad (16.88)$$

其中 $\mathbf{M} = \mathbf{W}^\top \mathbf{W} + \sigma^2 \mathbf{I}$ ，而 $\mathbb{E}[\mathbf{z} | \mathbf{x}] = \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu})$ 见式 (16.43)。

证明 按照“最小二乘重构”的定义，我们用某个潜变量向量 $\tilde{\mathbf{z}}$ 来重构（中心化后的）数据

$$\tilde{\mathbf{x}} - \boldsymbol{\mu} = \mathbf{W} \tilde{\mathbf{z}}.$$

并令 $\tilde{\mathbf{z}}$ 使平方误差

$$J(\mathbf{z}) = \|\mathbf{x} - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}\|^2$$

最小。把梯度置零得到法方程

$$\frac{\partial J}{\partial \mathbf{z}} = -2 \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}) = \mathbf{0} \implies \tilde{\mathbf{z}} = (\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}). \quad (1)$$

另一方面，在概率 PCA 中的后验均值（式 16.43）为

$$\mathbb{E}[\mathbf{z} | \mathbf{x}] = \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) \implies \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) = \mathbf{M} \mathbb{E}[\mathbf{z} | \mathbf{x}]. \quad (2)$$

将 (2) 代入 (1) 得到

$$\tilde{\mathbf{z}} = (\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{M} \mathbb{E}[\mathbf{z} | \mathbf{x}].$$

于是最优重构为

$$\boxed{\tilde{\mathbf{x}} = \boldsymbol{\mu} + \mathbf{W} \tilde{\mathbf{z}} = \boldsymbol{\mu} + \mathbf{W}(\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{M} \mathbb{E}[\mathbf{z} | \mathbf{x}].}$$

若仅对中心化向量进行重构（即用 $\tilde{\mathbf{x}} - \boldsymbol{\mu}$ 表示），即得到题设的 (16.88)。注意利用 $\mathbb{E}[\mathbf{z} | \mathbf{x}] = \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu})$ 还可化为

$$\tilde{\mathbf{x}} - \boldsymbol{\mu} = \mathbf{W}(\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}),$$

这正是将 $\mathbf{x}$ 正交投影到 $\text{span}(\mathbf{W})$ 的结果。在最大似然解 $\mathbf{W}_{ML}$ 处，其列空间即主子空间，故上式给出按最小二乘代价的最优重构。 $\square$

练习 16.14 解答 (★)

题目 概率 PCA (PPCA) 在数据维度为 D 、潜在维度为 M 时, 其边缘协方差矩阵

$$\mathbf{C} = \mathbf{W}\mathbf{W}^\top + \sigma^2\mathbf{I}_D$$

的独立参数个数由式 (16.52) 给出:

$$N_{\text{PPCA}}(D, M) = DM + 1 - \frac{M(M-1)}{2}. \quad (16.52)$$

验证: 当 $M = D - 1$ 时, N_{PPCA} 等于一般协方差高斯 (全协方差) 的参数数目; 当 $M = 0$ 时, N_{PPCA} 等于各向同性协方差高斯的参数数目。

解答

回顾各模型的参数个数

- 一般 D 维高斯的协方差矩阵对称, 独立参数数为

$$N_{\text{full}}(D) = \frac{D(D+1)}{2}.$$

- 各向同性协方差 $\sigma^2\mathbf{I}_D$ 只有一个尺度参数,

$$N_{\text{iso}}(D) = 1.$$

情形一: $M = D - 1$ 把 $M = D - 1$ 代入 (16.52):

$$\begin{aligned} N_{\text{PPCA}}(D, D-1) &= D(D-1) + 1 - \frac{(D-1)(D-2)}{2} \\ &= \frac{2D^2 - 2D + 2 - (D^2 - 3D + 2)}{2} = \frac{D^2 + D}{2} = \frac{D(D+1)}{2}. \end{aligned}$$

这恰好等于 $N_{\text{full}}(D)$, 即与一般协方差高斯的自由度相同。

情形二: $M = 0$ 把 $M = 0$ 代入 (16.52):

$$N_{\text{PPCA}}(D, 0) = D \cdot 0 + 1 - \frac{0 \cdot (-1)}{2} = 1,$$

这与各向同性协方差高斯的自由度 $N_{\text{iso}}(D) = 1$ 完全一致。

结论 式 (16.52) 在两个极端情形下分别退化为:

$$M = D - 1 \Rightarrow N_{\text{PPCA}} = \frac{D(D+1)}{2} = N_{\text{full}}(D);$$

$$M = 0 \Rightarrow N_{\text{PPCA}} = 1 = N_{\text{iso}}(D).$$

因此已证。 □

练习 16.15 解答 (★)

题目 推导第 16.2.4 节所述因子分析 (Factor Analysis, FA) 模型中独立参数 (degrees of freedom, DoF) 的个数。

模型回顾 因子分析的线性—高斯生成式为

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_M), \quad \mathbf{x} \mid \mathbf{z} \sim \mathcal{N}(\mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi}),$$

其中 $\mathbf{W} \in \mathbb{R}^{D \times M}$ 为载荷矩阵 (factor loadings), $\boldsymbol{\mu} \in \mathbb{R}^D$ 为均值, $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_D)$ 为对角噪声协方差。边缘分布的协方差为

$$\mathbf{C} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi}.$$

参数计数

- $\mathbf{W}$ 含 $D \times M$ 个自由参数;
- $\boldsymbol{\Psi}$ 为对角阵, 含 D 个自由参数;
- (可选) $\boldsymbol{\mu}$ 含 D 个自由参数。

然而该模型对潜在空间的任意正交旋转不变: 对任意 $\mathbf{R} \in \mathbb{R}^{M \times M}$ 且 $\mathbf{R}^\top \mathbf{R} = \mathbf{I}$, 令 $\widetilde{\mathbf{W}} = \mathbf{W}\mathbf{R}$ 、 $\widetilde{\mathbf{z}} = \mathbf{R}^\top \mathbf{z}$, 则 $\widetilde{\mathbf{z}} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 且 $\mathbf{W}\mathbf{z} = \widetilde{\mathbf{W}}\widetilde{\mathbf{z}}$, 从而 $\mathbf{C} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi}$ 不变。因此 $\mathbf{W}$ 的参数存在

$$\underbrace{\frac{1}{2}M(M-1)}_{\text{正交群 } O(M) \text{ 的连续自由度}}$$

个冗余 (旋转不定)。

结论

$$\boxed{\# \text{独立参数 (不计均值)} = DM + D - \frac{1}{2}M(M-1)}$$

若将均值向量 $\boldsymbol{\mu}$ 也计入模型参数 (在实际中常通过居中消去), 则

$$\boxed{\# \text{独立参数 (计入均值)} = DM + 2D - \frac{1}{2}M(M-1)}.$$

上述结果体现: 因子分析的可辨识自由度等于“显式参数数目”减去“潜在空间旋转不定性”的自由度。 $\square$

练习 16.16 解答 (★★)

题目 证明第 16.2.4 节所述的因子分析模型在潜在空间坐标的旋转下不变。

模型 因子分析 (Factor Analysis, FA) 假设

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{0}, \mathbf{I}), \quad p(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi}),$$

其中 $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_D)$ 为对角矩阵。据式 (16.54)，其边缘分布为

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \mathbf{C}), \quad \mathbf{C} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi}. \quad (16.54)$$

证明 (旋转不变性) 令 $\mathbf{R}$ 为任意正交矩阵 (旋转)，即 $\mathbf{R}^\top \mathbf{R} = \mathbf{I}$ 。在潜在空间作坐标变换

$$\tilde{\mathbf{z}} = \mathbf{R}^\top \mathbf{z}, \quad \tilde{\mathbf{W}} = \mathbf{W}\mathbf{R}.$$

则 (1) 由于标准正态的旋转不变性，

$$p(\tilde{\mathbf{z}}) = \mathcal{N}(\tilde{\mathbf{z}} \mid \mathbf{0}, \mathbf{I}) = p(\mathbf{z}).$$

(2) 条件分布保持同形：

$$p(\mathbf{x} \mid \tilde{\mathbf{z}}) = \mathcal{N}(\mathbf{x} \mid \tilde{\mathbf{W}}\tilde{\mathbf{z}} + \boldsymbol{\mu}, \boldsymbol{\Psi}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{R}\tilde{\mathbf{z}} + \boldsymbol{\mu}, \boldsymbol{\Psi}).$$

注意到变换 $\mathbf{z} = \mathbf{R}\tilde{\mathbf{z}}$ 的雅可比行列式为 $|\mathbf{R}| = 1$ ，于是联合分布在变量替换下保持不变：

$$p(\mathbf{x}, \mathbf{z}) d\mathbf{z} = p(\mathbf{x}, \tilde{\mathbf{z}}) d\tilde{\mathbf{z}}.$$

从而边缘分布亦不变：

$$p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \int p(\mathbf{x}, \tilde{\mathbf{z}}) d\tilde{\mathbf{z}}.$$

也可直接由协方差矩阵验证：旋转后的边缘协方差为

$$\tilde{\mathbf{C}} = \tilde{\mathbf{W}}\tilde{\mathbf{W}}^\top + \boldsymbol{\Psi} = \mathbf{W}\mathbf{R}(\mathbf{W}\mathbf{R})^\top + \boldsymbol{\Psi} = \mathbf{W}\mathbf{R}\mathbf{R}^\top\mathbf{W}^\top + \boldsymbol{\Psi} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi} = \mathbf{C},$$

均值仍为 $\boldsymbol{\mu}$ 。因此 $p(\mathbf{x})$ 在任意潜在空间旋转 $\mathbf{R}$ 下保持不变。

□

练习 16.17 解答 (★★)

题目 在线性-高斯潜变量模型中

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{0}, \mathbf{I}), \quad p(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Phi}),$$

其中 $\boldsymbol{\Phi}$ 为任意对称正定矩阵。令 $\{\mathbf{x}_n\}_{n=1}^N$ 为观测数据，并考虑对数据做非奇异线性变换 $\mathbf{x} \mapsto \mathbf{x}' = \mathbf{A}\mathbf{x}$ ，其中 $\mathbf{A} \in \mathbb{R}^{D \times D}$ 可逆。设原数据的极大似然解为 $(\boldsymbol{\mu}_{ML}, \mathbf{W}_{ML}, \boldsymbol{\Phi}_{ML})$ 。证明：变换后数据 $\{\mathbf{x}'_n\}$ 的对应极大似然解为

$$\boxed{\boldsymbol{\mu}'_{ML} = \mathbf{A}\boldsymbol{\mu}_{ML}, \quad \mathbf{W}'_{ML} = \mathbf{A}\mathbf{W}_{ML}, \quad \boldsymbol{\Phi}'_{ML} = \mathbf{A}\boldsymbol{\Phi}_{ML}\mathbf{A}^\top.}$$

并说明当 (i) $\mathbf{A}$ 为对角矩阵且 $\boldsymbol{\Phi}$ 为对角阵（因而是因子分析），或 (ii) $\mathbf{A}$ 为正交矩阵且 $\boldsymbol{\Phi} = \sigma^2 \mathbf{I}$ （因而是概率 PCA）时，模型形式保持不变（共变性）。

证明

1. 边缘分布与似然函数 边缘化潜变量得

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \mathbf{C}), \quad \mathbf{C} = \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Phi}.$$

数据对数似然为（常数项 $-\frac{ND}{2} \ln(2\pi)$ 省略）

$$\mathcal{L}(\boldsymbol{\mu}, \mathbf{W}, \boldsymbol{\Phi}; \mathbf{X}) = -\frac{N}{2} \ln |\mathbf{C}| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}). \quad (1)$$

2. 线性变换后的模型与似然 对参数作对应变换

$$\boldsymbol{\mu}' = \mathbf{A}\boldsymbol{\mu}, \quad \mathbf{W}' = \mathbf{A}\mathbf{W}, \quad \boldsymbol{\Phi}' = \mathbf{A}\boldsymbol{\Phi}\mathbf{A}^\top,$$

则变换后的条件分布为

$$p(\mathbf{x}' \mid \mathbf{z}) = \mathcal{N}(\mathbf{x}' \mid \mathbf{A}\mathbf{W}\mathbf{z} + \mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Phi}\mathbf{A}^\top),$$

其边缘协方差 $\mathbf{C}' = \mathbf{W}'\mathbf{W}'^\top + \boldsymbol{\Phi}' = \mathbf{A}(\mathbf{W}\mathbf{W}^\top + \boldsymbol{\Phi})\mathbf{A}^\top = \mathbf{A}\mathbf{C}\mathbf{A}^\top$ 。

对变换后数据 $\mathbf{x}'_n = \mathbf{A}\mathbf{x}_n$ 的对数似然为

$$\mathcal{L}'(\boldsymbol{\mu}', \mathbf{W}', \boldsymbol{\Phi}'; \mathbf{X}') = -\frac{N}{2} \ln |\mathbf{C}'| - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}'_n - \boldsymbol{\mu}')^\top \mathbf{C}'^{-1} (\mathbf{x}'_n - \boldsymbol{\mu}'). \quad (2)$$

利用行列式与逆的恒等式

$$|\mathbf{C}'| = |\mathbf{A}\mathbf{C}\mathbf{A}^\top| = |\mathbf{A}|^2 |\mathbf{C}|, \quad \mathbf{C}'^{-1} = (\mathbf{A}\mathbf{C}\mathbf{A}^\top)^{-1} = \mathbf{A}^{-\top} \mathbf{C}^{-1} \mathbf{A}^{-1},$$

以及 $\mathbf{x}'_n - \boldsymbol{\mu}' = \mathbf{A}(\mathbf{x}_n - \boldsymbol{\mu})$, 可得

$$(\mathbf{x}'_n - \boldsymbol{\mu}')^\top \mathbf{C}'^{-1}(\mathbf{x}'_n - \boldsymbol{\mu}') = (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1}(\mathbf{x}_n - \boldsymbol{\mu}).$$

代回(2)并与(1)比较, 得到

$$\mathcal{L}'(\boldsymbol{\mu}', \mathbf{W}', \boldsymbol{\Phi}'; \mathbf{X}') = \mathcal{L}(\boldsymbol{\mu}, \mathbf{W}, \boldsymbol{\Phi}; \mathbf{X}) - N \ln |\mathbf{A}|,$$

其中 $-N \ln |\mathbf{A}|$ 与模型参数无关, 是常数项。因此若 $(\boldsymbol{\mu}_{ML}, \mathbf{W}_{ML}, \boldsymbol{\Phi}_{ML})$ 最大化(1), 则

$$(\boldsymbol{\mu}'_{ML}, \mathbf{W}'_{ML}, \boldsymbol{\Phi}'_{ML}) = (\mathbf{A}\boldsymbol{\mu}_{ML}, \mathbf{A}\mathbf{W}_{ML}, \mathbf{A}\boldsymbol{\Phi}_{ML}\mathbf{A}^\top)$$

最大化(2)。命题第一部分得证。

3. “模型形式保持” 的两种情形 (共变性)

- (i) **因子分析 (FA) 情形:** 若假设 $\boldsymbol{\Phi}$ 为对角阵, 且 $\mathbf{A}$ 为对角非奇异矩阵, 则 $\boldsymbol{\Phi}' = \mathbf{A}\boldsymbol{\Phi}\mathbf{A}^\top$ 仍为对角阵 (对角元素按分量尺度被重新缩放), 因而保持了 *FA* 的结构假设。这表明因子分析对逐分量缩放是**共变**的。
- (ii) **概率 PCA (PPCA) 情形:** 若 $\boldsymbol{\Phi} = \sigma^2\mathbf{I}$ 而 $\mathbf{A}$ 为正交矩阵 ($\mathbf{A}\mathbf{A}^\top = \mathbf{I}$), 则 $\boldsymbol{\Phi}' = \mathbf{A}(\sigma^2\mathbf{I})\mathbf{A}^\top = \sigma^2\mathbf{I}$ 仍为各向同性噪声, 保持了 *PPCA* 的结构假设。因此概率 PCA 对数据空间的任意旋转是**共变**的, 与常规 PCA 在旋转下的不变性一致。

□

练习 16.18 解答 (★)

题目 验证含连续隐变量的模型的对数似然可写为

$$\ln p(\mathbf{x}|\mathbf{w}) = \mathcal{L}(\mathbf{w}) + \text{KL}(q(\mathbf{z}) \| p(\mathbf{z}|\mathbf{x}, \mathbf{w})) \quad (16.57)$$

其中

$$\mathcal{L}(q, \mathbf{w}) = \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{x}, \mathbf{z}|\mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z}, \quad (16.58)$$

$$\text{KL}(q(\mathbf{z}) \| p(\mathbf{z}|\mathbf{x}, \mathbf{w})) = - \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{z}|\mathbf{x}, \mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z}. \quad (16.59)$$

提示使用乘积分解

$$p(\mathbf{x}, \mathbf{z}|\mathbf{w}) = p(\mathbf{z}|\mathbf{x}, \mathbf{w}) p(\mathbf{x}|\mathbf{w}). \quad (16.89)$$

证明 从 (16.58) 出发并代入 (16.89):

$$\begin{aligned} \mathcal{L}(q, \mathbf{w}) &= \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{z}|\mathbf{x}, \mathbf{w}) p(\mathbf{x}|\mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z} \\ &= \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{z}|\mathbf{x}, \mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z} + \int q(\mathbf{z}) \ln p(\mathbf{x}|\mathbf{w}) d\mathbf{z}. \end{aligned}$$

注意 $\ln p(\mathbf{x}|\mathbf{w})$ 与 $\mathbf{z}$ 无关, 因此

$$\mathcal{L}(q, \mathbf{w}) = \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{z}|\mathbf{x}, \mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z} + \ln p(\mathbf{x}|\mathbf{w}).$$

将第一项按 (16.59) 识别为负的 Kullback-Leibler 散度, 得

$$\mathcal{L}(q, \mathbf{w}) = -\text{KL}(q(\mathbf{z}) \| p(\mathbf{z}|\mathbf{x}, \mathbf{w})) + \ln p(\mathbf{x}|\mathbf{w}),$$

等价变形即为

$$\boxed{\ln p(\mathbf{x}|\mathbf{w}) = \mathcal{L}(q, \mathbf{w}) + \text{KL}(q(\mathbf{z}) \| p(\mathbf{z}|\mathbf{x}, \mathbf{w}))}$$

这正是式 (16.57)。证毕。

练习 16.19 解答 (★)

题目 证明：对一组 i.i.d. 数据，证据下界 (ELBO) 可写成

$$\mathcal{L}(q, \mathbf{w}) = \sum_{n=1}^N \int q(\mathbf{z}_n) \ln \left\{ \frac{p(\mathbf{x}_n, \mathbf{z}_n | \mathbf{w})}{q(\mathbf{z}_n)} \right\} d\mathbf{z}_n. \quad (16.63)$$

证明 对任意变分分布 $q(\mathbf{Z})$ ($\mathbf{Z} = \{\mathbf{z}_n\}_{n=1}^N$)，由 Jensen 不等式，

$$\begin{aligned} \ln p(\mathbf{X} | \mathbf{w}) &= \ln \int p(\mathbf{X}, \mathbf{Z} | \mathbf{w}) d\mathbf{Z} \\ &= \ln \int q(\mathbf{Z}) \frac{p(\mathbf{X}, \mathbf{Z} | \mathbf{w})}{q(\mathbf{Z})} d\mathbf{Z} \\ &\geq \int q(\mathbf{Z}) \ln \left\{ \frac{p(\mathbf{X}, \mathbf{Z} | \mathbf{w})}{q(\mathbf{Z})} \right\} d\mathbf{Z} \equiv \mathcal{L}(q, \mathbf{w}). \end{aligned} \quad (A)$$

若观测数据是 i.i.d.，则联合分布分解为

$$p(\mathbf{X}, \mathbf{Z} | \mathbf{w}) = \prod_{n=1}^N p(\mathbf{x}_n, \mathbf{z}_n | \mathbf{w}), \quad \mathbf{X} = \{\mathbf{x}_n\}_{n=1}^N. \quad (B)$$

对每个数据点各引入一个变分分布并令其按样本独立因子化，

$$q(\mathbf{Z}) = \prod_{n=1}^N q(\mathbf{z}_n). \quad (C)$$

将 (B) 与 (C) 代入 (A)，利用 $\ln \prod = \sum \ln$ 和积分可按因子化拆分，得到

$$\begin{aligned} \mathcal{L}(q, \mathbf{w}) &= \int \left(\prod_{n=1}^N q(\mathbf{z}_n) \right) \sum_{n=1}^N \ln \left\{ \frac{p(\mathbf{x}_n, \mathbf{z}_n | \mathbf{w})}{q(\mathbf{z}_n)} \right\} d\mathbf{z}_1 \cdots d\mathbf{z}_N \\ &= \sum_{n=1}^N \int q(\mathbf{z}_n) \ln \left\{ \frac{p(\mathbf{x}_n, \mathbf{z}_n | \mathbf{w})}{q(\mathbf{z}_n)} \right\} d\mathbf{z}_n, \end{aligned}$$

这正是所需的 ELBO 形式 (16.63)。

□

练习 16.20 解答 (★★)

题目 画出由离散混合的概率 PCA (mixture of PPCA) 组成的有向概率图：每个分量 k 各自拥有 $\mathbf{W}_k, \boldsymbol{\mu}_k, \sigma_k^2$ 。随后，再画出把这些参数在各个分量之间共享后的改进图。

模型回顾 (混合的 PPCA)：

$$c_n \sim \text{Cat}(\boldsymbol{\pi}),$$

$$\mathbf{z}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

$$\mathbf{x}_n \mid \mathbf{z}_n, c_n = k \sim \mathcal{N}(\mathbf{W}_k \mathbf{z}_n + \boldsymbol{\mu}_k, \sigma_k^2 \mathbf{I}).$$

其中 $\boldsymbol{\pi}$ 为混合权重, $k = 1, \dots, K$ 。




图 1: *

(a) 混合的 PPCA：每个分量各自拥有 $\mathbf{W}_k, \boldsymbol{\mu}_k, \sigma_k^2$ 。




图 2: *

(b) 参数共享的混合：所有分量共用 $\mathbf{W}, \boldsymbol{\mu}, \sigma^2$ 。

说明 图(a)中，参数节点位于大小为 K 的“分量”外框内，表示每个分量有各自的 $\mathbf{W}_k, \boldsymbol{\mu}_k, \sigma_k^2$ ；观测外框大小为 N ，每个样本先从 $\text{Cat}(\boldsymbol{\pi})$ 采样 c_n ，再采样 $\mathbf{z}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，最后生成 $\mathbf{x}_n$ 。图(b)把 $\mathbf{W}, \boldsymbol{\mu}, \sigma^2$ 移到分量外框之外，表示它们在分量之间共享；此时混合只保留了不同的 c_n (权重 $\boldsymbol{\pi}$)，而生成均依赖于同一组共享参数。

练习 16.21 解答 (★★)

题目 通过最大化 (16.65) 给出的期望完全数据对数似然, 推导概率 PCA 的 M 步更新式 (16.68) 与 (16.69)。

解答

模型为

$$z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \mathbf{x} | z \sim \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \sigma^2 \mathbf{I}).$$

E 步给出后验的一阶与二阶矩 (见 (16.66)、(16.67))

$$\langle \mathbf{z}_n \rangle = \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x}_n - \boldsymbol{\mu}), \quad \langle \mathbf{z}_n \mathbf{z}_n^\top \rangle = \sigma^2 \mathbf{M}^{-1} + \langle \mathbf{z}_n \rangle \langle \mathbf{z}_n \rangle^\top, \quad \mathbf{M} = \mathbf{W}^\top \mathbf{W} + \sigma^2 \mathbf{I}. \quad (\text{E})$$

为书写简洁, 定义期望充分统计量

$$\mathbf{S}_{xz} := \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu}) \langle \mathbf{z}_n \rangle^\top, \quad \mathbf{S}_{zz} := \sum_{n=1}^N \langle \mathbf{z}_n \mathbf{z}_n^\top \rangle, \quad S_{xx} := \sum_{n=1}^N \|\mathbf{x}_n - \boldsymbol{\mu}\|^2. \quad (\text{S})$$

忽略与 $\mathbf{W}, \sigma^2$ 无关的常数, 式 (16.65) 的期望完全数据对数似然可写为

$$\begin{aligned} Q(\mathbf{W}, \sigma^2) &= \mathbb{E}[\ln p(\mathbf{X}, \mathbf{Z} | \boldsymbol{\mu}, \mathbf{W}, \sigma^2)] \\ &= -\frac{ND}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \left\{ S_{xx} - 2 \text{Tr}(\mathbf{W}^\top \mathbf{S}_{xz}) + \text{Tr}(\mathbf{W}^\top \mathbf{W} \mathbf{S}_{zz}) \right\}. \end{aligned} \quad (\text{Q})$$

(i) 对 $\mathbf{W}$ 求极值 利用迹微积分恒等式 $\frac{\partial}{\partial \mathbf{W}} \text{Tr}(\mathbf{A}^\top \mathbf{W}) = \mathbf{A}$, $\frac{\partial}{\partial \mathbf{W}} \text{Tr}(\mathbf{W}^\top \mathbf{W} \mathbf{B}) = \mathbf{W}(\mathbf{B} + \mathbf{B}^\top)$, 而 $\mathbf{S}_{zz}$ 为对称矩阵, 有

$$\frac{\partial Q}{\partial \mathbf{W}} = \frac{1}{\sigma^2} (\mathbf{S}_{xz} - \mathbf{W} \mathbf{S}_{zz}).$$

令其为零得

$$\boxed{\mathbf{W}_{\text{new}} = \mathbf{S}_{xz} \mathbf{S}_{zz}^{-1} = \left[\sum_n (\mathbf{x}_n - \boldsymbol{\mu}) \langle \mathbf{z}_n \rangle^\top \right] \left[\sum_n \langle \mathbf{z}_n \mathbf{z}_n^\top \rangle \right]^{-1}.} \quad (16.68)$$

(ii) 对 σ^2 求极值 由 (Q) 对 σ^2 求导并令其为零:

$$-\frac{ND}{2\sigma^2} + \frac{1}{2\sigma^4} \left\{ S_{xx} - 2 \text{Tr}(\mathbf{W}^\top \mathbf{S}_{xz}) + \text{Tr}(\mathbf{W}^\top \mathbf{W} \mathbf{S}_{zz}) \right\} = 0,$$

从而

$$\boxed{\sigma_{\text{new}}^2 = \frac{1}{ND} \left\{ S_{xx} - 2 \text{Tr}(\mathbf{W}_{\text{new}}^\top \mathbf{S}_{xz}) + \text{Tr}(\mathbf{W}_{\text{new}}^\top \mathbf{W}_{\text{new}} \mathbf{S}_{zz}) \right\}.} \quad (*)$$

将迹形式逐样本展开 (并在 M 步用 $\boldsymbol{\mu} = \bar{\mathbf{x}}$, 见 (16.45)), 得到教材等价的逐样本表达式

$$\boxed{\sigma_{\text{new}}^2 = \frac{1}{ND} \sum_{n=1}^N \left\{ \|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 - 2 \langle \mathbf{z}_n \rangle^\top \mathbf{W}_{\text{new}}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) + \text{Tr}(\langle \mathbf{z}_n \mathbf{z}_n^\top \rangle \mathbf{W}_{\text{new}}^\top \mathbf{W}_{\text{new}}) \right\},} \quad (16.69)$$

这与 (16.69) 一致。

综上, 由最大化 (16.65) 可得概率 PCA 的 M 步更新 (16.68) 与 (16.69), 证毕。

练习 16.22 解答 (★★★)

题目 在概率 PCA (PPCA) 中,

$$\mathbf{z}_n \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_M), \quad \mathbf{x}_n | \mathbf{z}_n \sim \mathcal{N}(\mathbf{W}\mathbf{z}_n + \boldsymbol{\mu}, \sigma^2 \mathbf{I}_D).$$

若数据集中每个样本 $\mathbf{x}_n \in \mathbb{R}^D$ 有部分分量缺失 (随机缺失), 推导极大化似然的 EM 算法; 并证明当没有缺失时它退化为第 16.3.2 节给出的 PPCA 的 EM 更新式 (16.68)–(16.69)。

记号与选择矩阵 对第 n 个样本, 记其观测到的坐标索引为 $\Omega_n \subset \{1, \dots, D\}$, 缺失坐标为 $\bar{\Omega}_n$ 。令 $\mathbf{R}_{\Omega_n} \in \mathbb{R}^{|\Omega_n| \times D}$ 为行选择矩阵, 抽取 $\mathbf{x}_n$ 的观测分量: $\mathbf{x}_{n,\Omega} := \mathbf{R}_{\Omega_n} \mathbf{x}_n$, $\boldsymbol{\mu}_\Omega := \mathbf{R}_{\Omega_n} \boldsymbol{\mu}$, $\mathbf{W}_\Omega := \mathbf{R}_{\Omega_n} \mathbf{W}$ 。同理定义 $\mathbf{R}_{\bar{\Omega}_n}$ 、 $\mathbf{x}_{n,\bar{\Omega}}$ 、 $\boldsymbol{\mu}_{\bar{\Omega}}$ 、 $\mathbf{W}_{\bar{\Omega}}$ 。

E 步 对给定参数 $\{\mathbf{W}, \boldsymbol{\mu}, \sigma^2\}$, 后验 $p(\mathbf{z}_n | \mathbf{x}_{n,\Omega})$ 为高斯, 均值与协方差为

$$\mathbf{M}_n := \mathbf{W}_\Omega^\top \mathbf{W}_\Omega + \sigma^2 \mathbf{I}_M, \quad (\text{E1})$$

$$\hat{\mathbf{z}}_n := \mathbb{E}[\mathbf{z}_n | \mathbf{x}_{n,\Omega}] = \mathbf{M}_n^{-1} \mathbf{W}_\Omega^\top (\mathbf{x}_{n,\Omega} - \boldsymbol{\mu}_\Omega), \quad (\text{E2})$$

$$\mathbf{S}_n := \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top | \mathbf{x}_{n,\Omega}] = \sigma^2 \mathbf{M}_n^{-1} + \hat{\mathbf{z}}_n \hat{\mathbf{z}}_n^\top. \quad (\text{E3})$$

同时 (可选) 对缺失分量的条件期望

$$\hat{\mathbf{x}}_{n,\bar{\Omega}} := \mathbb{E}[\mathbf{x}_{n,\bar{\Omega}} | \mathbf{x}_{n,\Omega}] = \boldsymbol{\mu}_{\bar{\Omega}} + \mathbf{W}_{\bar{\Omega}} \hat{\mathbf{z}}_n. \quad (\text{E4})$$

该插补仅作分析或预测用途, M 步并不需要。

Q 函数 采用 “仅以 $\{\mathbf{z}_n\}$ 为潜变量” 的标准做法 (直接对观测似然做 ELBO), 忽略与参数无关的常数, 有

$$\mathcal{Q}(\mathbf{W}, \boldsymbol{\mu}, \sigma^2) = -\frac{N_{\text{obs}}}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N \mathbb{E} \left[\left\| \mathbf{x}_{n,\Omega} - \boldsymbol{\mu}_\Omega - \mathbf{W}_\Omega \mathbf{z}_n \right\|^2 | \mathbf{x}_{n,\Omega} \right] \quad (\text{E5}^*)$$

其中 $N_{\text{obs}} := \sum_{n=1}^N |\Omega_n|$ 为被观测到的标量总数。把 (E2)–(E3) 代入即可显式展开期望项。

M 步— $\boldsymbol{\mu}$ 的更新 对每个坐标 i , 令 $\mathcal{N}_i := \{n : i \in \Omega_n\}$, 由 (E5*) 对 μ_i 求导置零得

$$\mu_i^{\text{new}} = \frac{1}{|\mathcal{N}_i|} \sum_{n \in \mathcal{N}_i} (x_{ni} - \mathbf{w}_i^{\text{old}^\top} \hat{\mathbf{z}}_n). \quad (\text{M}\mu)$$

M 步— $\mathbf{W}$ 的更新 (逐行封闭解)

记号提示：下式采用“行向量更新”的记法，即直接更新第 i 行 $\mathbf{w}_i^\top$ （因此右侧为行向量）。若按列向量 $\mathbf{w}_i$ 的记法阅读，只需对等式两边同时取转置即可得到完全等价的列向量形式，数值结果不变。

$$\mathbf{w}_i^{\text{new}} \left(\sum_{n \in \mathcal{N}_i} \mathbf{S}_n \right) = \sum_{n \in \mathcal{N}_i} (x_{ni} - \mu_i^{\text{new}}) \hat{\mathbf{z}}_n^\top, \quad \Rightarrow \quad \mathbf{w}_i^{\text{new}} = \left(\sum_{n \in \mathcal{N}_i} (x_{ni} - \mu_i^{\text{new}}) \hat{\mathbf{z}}_n^\top \right) \left(\sum_{n \in \mathcal{N}_i} \mathbf{S}_n \right)^{-1}. \quad (\text{MW})$$

写成矩阵式亦可，但逐行更新最为简洁且适合稀疏缺失模式。

M 步— 噪声方差 σ^2 的更新 由 (E5*) 对 σ^2 求导得

$$\sigma_{\text{new}}^2 = \frac{1}{N_{\text{obs}}} \sum_{n=1}^N \left(\|\mathbf{x}_{n,\Omega} - \boldsymbol{\mu}_{\Omega}^{\text{new}}\|^2 - 2 \hat{\mathbf{z}}_n^\top \mathbf{W}_{\Omega}^{\text{new}^\top} (\mathbf{x}_{n,\Omega} - \boldsymbol{\mu}_{\Omega}^{\text{new}}) + \text{Tr}(\mathbf{W}_{\Omega}^{\text{new}^\top} \mathbf{W}_{\Omega}^{\text{new}} \mathbf{S}_n) \right). \quad (\text{Ms2})$$

注意分母是 N_{obs} ，只由观测到的标量数决定。

E–M 小结（带缺失的 PPCA） 给定当前参数，按 (E1)–(E3) 计算 $\hat{\mathbf{z}}_n$ 与 $\mathbf{S}_n$ ；然后用 (M μ)、(MW) 与 (Ms2) 更新 $\boldsymbol{\mu}, \mathbf{W}, \sigma^2$ ，直至收敛。该算法的每一步都仅在观测到的坐标上做求和，天然适配稀疏缺失模式，时间开销与观测量 N_{obs} 成正比。

无缺失极限与教材公式的一致性 若对所有 n 都有 $\Omega_n = \{1, \dots, D\}$ （即无缺失），则 $N_{\text{obs}} = ND$ ， $\mathbf{R}_{\Omega_n} = \mathbf{I}_D$ ， $\mathbf{W}_{\Omega} = \mathbf{W}$ ， $\boldsymbol{\mu}_{\Omega} = \boldsymbol{\mu}$ 。此时 (M μ) 化为 $\mu_i^{\text{new}} = \frac{1}{N} \sum_{n=1}^N (x_{ni} - \mathbf{w}_i^{\text{old}^\top} \hat{\mathbf{z}}_n)$ 。由于 PPCA 的对数似然关于 $\boldsymbol{\mu}$ 是二次凸函数，其最大值给出样本均值 $\boldsymbol{\mu}_{ML} = \bar{\mathbf{x}}$ （见 16.3.1），因此把 $\boldsymbol{\mu}$ 固定为样本均值 $\bar{\mathbf{x}}$ ，(MW) 与 (Ms2) 便分别化为

$$\begin{aligned} \mathbf{W}_{\text{new}} &= \left[\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \hat{\mathbf{z}}_n^\top \right] \left[\sum_{n=1}^N \mathbf{S}_n \right]^{-1}, \\ \sigma_{\text{new}}^2 &= \frac{1}{ND} \sum_{n=1}^N \left(\|\mathbf{x}_n - \bar{\mathbf{x}}\|^2 - 2 \hat{\mathbf{z}}_n^\top \mathbf{W}_{\text{new}}^\top (\mathbf{x}_n - \bar{\mathbf{x}}) + \text{Tr}(\mathbf{W}_{\text{new}}^\top \mathbf{W}_{\text{new}} \mathbf{S}_n) \right), \end{aligned}$$

与教材 (16.68)–(16.69) 完全一致。

注 若改为把缺失的 $\mathbf{x}_{n,\bar{\Omega}}$ 也并入“完备数据”，则 Q 中会出现 $-\frac{ND}{2} \ln \sigma^2$ 与 $-\frac{1}{2\sigma^2} \sum_{n,i \in \bar{\Omega}_n} \mathbb{E}[(x_{ni} - \mu_i - \mathbf{w}_i^\top \mathbf{z}_n)^2]$ ，其中该期望等于 $|\bar{\Omega}_n| \sigma^2$ （使用旧参数）。那样得到的 σ^2 更新式会带一个 $N_{\text{miss}} \sigma_{\text{old}}^2$ 项。本文采用的做法（潜变量只取 $\{\mathbf{z}_n\}$ ）更简洁，并得到上面的闭式 (Ms2)。

□

练习 16.23 解答 (★★)

题目 给定数据集 $\{\mathbf{x}_n\}_{n=1}^N \subset \mathbb{R}^D$, 用 $\mathbf{W} \in \mathbb{R}^{D \times M}$ 与 $\boldsymbol{\mu} \in \mathbb{R}^D$ 以及一组 $\mathbf{z}_n \in \mathbb{R}^M$ 近似 $\mathbf{x}_n \simeq \mathbf{W}\mathbf{z}_n + \boldsymbol{\mu}$ 。考虑重构平方和

$$J(\boldsymbol{\mu}, \mathbf{W}, \{\mathbf{z}_n\}) = \sum_{n=1}^N \|\mathbf{x}_n - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}_n\|^2. \quad (16.90)$$

(1) 先对 $\boldsymbol{\mu}$ 最小化, 证明可将 J 写成关于零均值变量 $\tilde{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}$ 与 $\tilde{\mathbf{z}}_n = \mathbf{z}_n - \bar{\mathbf{z}}$ 的同型形式, 其中 $\bar{\mathbf{x}} = \frac{1}{N} \sum_n \mathbf{x}_n$ 、 $\bar{\mathbf{z}} = \frac{1}{N} \sum_n \mathbf{z}_n$ 。(2) 固定 $\mathbf{W}$, 对 $\{\mathbf{z}_n\}$ 最小化得到 PCA 的 E 步 (16.70); 固定 $\{\mathbf{z}_n\}$, 对 $\mathbf{W}$ 最小化得到 M 步 (16.71)。

(1) 先对 $\boldsymbol{\mu}$ 最小化并中心化

对 $\boldsymbol{\mu}$ 求导并令其为零:

$$\frac{\partial J}{\partial \boldsymbol{\mu}} = -2 \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}_n) = \mathbf{0} \implies \boldsymbol{\mu}^* = \bar{\mathbf{x}} - \mathbf{W}\bar{\mathbf{z}}.$$

把 $\boldsymbol{\mu}^*$ 代回残差:

$$\mathbf{x}_n - \boldsymbol{\mu}^* - \mathbf{W}\mathbf{z}_n = (\mathbf{x}_n - \bar{\mathbf{x}}) - \mathbf{W}(\mathbf{z}_n - \bar{\mathbf{z}}) = \tilde{\mathbf{x}}_n - \mathbf{W}\tilde{\mathbf{z}}_n.$$

因此最优 $\boldsymbol{\mu}$ 下

$$J(\boldsymbol{\mu}^*, \mathbf{W}, \{\mathbf{z}_n\}) = \sum_{n=1}^N \|\tilde{\mathbf{x}}_n - \mathbf{W}\tilde{\mathbf{z}}_n\|^2,$$

即把原问题等价地化为对中心化后的 $\tilde{\mathbf{x}}_n, \tilde{\mathbf{z}}_n$ 的同型最小二乘问题。

(2) 固定 $\mathbf{W}$, 对 $\mathbf{z}_n$ 最小化——E 步

在 $\boldsymbol{\mu}^*$ 下, J 对每个 $\tilde{\mathbf{z}}_n$ 的梯度为

$$\frac{\partial J}{\partial \tilde{\mathbf{z}}_n} = -2 \mathbf{W}^\top (\tilde{\mathbf{x}}_n - \mathbf{W}\tilde{\mathbf{z}}_n).$$

令梯度为零得正则方程

$$\mathbf{W}^\top \mathbf{W} \tilde{\mathbf{z}}_n = \mathbf{W}^\top \tilde{\mathbf{x}}_n \implies \tilde{\mathbf{z}}_n = (\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{W}^\top \tilde{\mathbf{x}}_n.$$

将 $\tilde{\mathbf{z}}_n$ 作为 E 步中的 $\mathbb{E}[\mathbf{z}_n]$ 。设 $\tilde{\mathbf{X}} \in \mathbb{R}^{N \times D}$ 的第 n 行为 $\tilde{\mathbf{x}}_n^\top$, 并令 $\boldsymbol{\Omega} \in \mathbb{R}^{M \times N}$ 的第 n 列为 $\mathbb{E}[\mathbf{z}_n] = \tilde{\mathbf{z}}_n$ 。则

$$\boxed{\boldsymbol{\Omega} = (\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{W}^\top \tilde{\mathbf{X}}^\top} \quad (16.70)$$

即教材给出的 PCA E 步。

(3) 固定 $\{\mathbf{z}_n\}$, 对 $\mathbf{W}$ 最小化——M 步

在中心化形式下,

$$J(\mathbf{W}) = \sum_{n=1}^N \|\tilde{\mathbf{x}}_n - \mathbf{W}\tilde{\mathbf{z}}_n\|^2 = \text{Tr} \left[(\tilde{\mathbf{X}} - \mathbf{Z}^\top \mathbf{W}^\top)(\tilde{\mathbf{X}} - \mathbf{Z}^\top \mathbf{W}^\top)^\top \right],$$

其中 $\mathbf{Z} = [\tilde{\mathbf{z}}_1, \dots, \tilde{\mathbf{z}}_N] \in \mathbb{R}^{M \times N}$ 。对 $\mathbf{W}$ 求导并令其为零:

$$\frac{\partial J}{\partial \mathbf{W}} = -2 \sum_{n=1}^N (\tilde{\mathbf{x}}_n - \mathbf{W}\tilde{\mathbf{z}}_n)\tilde{\mathbf{z}}_n^\top = \mathbf{0} \implies \sum_{n=1}^N \tilde{\mathbf{x}}_n \tilde{\mathbf{z}}_n^\top = \mathbf{W} \sum_{n=1}^N \tilde{\mathbf{z}}_n \tilde{\mathbf{z}}_n^\top.$$

故

$$\boxed{\mathbf{W}_{\text{new}} = \left[\sum_{n=1}^N \tilde{\mathbf{x}}_n \tilde{\mathbf{z}}_n^\top \right] \left[\sum_{n=1}^N \tilde{\mathbf{z}}_n \tilde{\mathbf{z}}_n^\top \right]^{-1} = \tilde{\mathbf{X}}^\top \boldsymbol{\Omega}^\top (\boldsymbol{\Omega} \boldsymbol{\Omega}^\top)^{-1}} \quad (16.71)$$

即教材给出的 PCA M 步。

小结 最小化 J 对 $\boldsymbol{\mu}$ 给出 $\boldsymbol{\mu}^* = \bar{\mathbf{x}} - \mathbf{W}\bar{\mathbf{z}}$, 从而问题可在中心化数据 $\tilde{\mathbf{x}}_n, \tilde{\mathbf{z}}_n$ 上求解; 随后固定 $\mathbf{W}$ 、 $\{\mathbf{z}_n\}$ 交替最小化分别得到 E 步 (16.70) 和 M 步 (16.71)。

练习 16.24 解答 (★★)

题目回顾 推导因子分析 (FA) 的 EM 算法中 E 步的两条公式 (16.72) 与 (16.73)。根据练习 16.26, 可将参数 $\boldsymbol{\mu}$ 取为样本均值 $\bar{\mathbf{x}}$ 。

模型 因子分析的生成模型为

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_M), \quad \mathbf{x} \mid \mathbf{z} \sim \mathcal{N}(\mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi}),$$

其中 $\boldsymbol{\Psi} \in \mathbb{R}^{D \times D}$ 为对角的、正定的噪声协方差矩阵。对第 n 个样本, 用 $\mathbf{x}_n$ 、 $\mathbf{z}_n$ 表示相应的观测与潜变量。

求后验 $p(\mathbf{z}_n \mid \mathbf{x}_n)$ 由于是线性—高斯模型, 后验仍为高斯。对 $\mathbf{z}$ 写出对数联合密度并配方:

$$\begin{aligned} \ln p(\mathbf{z} \mid \mathbf{x}) &= \text{const} - \frac{1}{2}(\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu})^\top \boldsymbol{\Psi}^{-1}(\mathbf{x} - \mathbf{W}\mathbf{z} - \boldsymbol{\mu}) - \frac{1}{2}\mathbf{z}^\top \mathbf{z} \\ &= \text{const} - \frac{1}{2} \left[\mathbf{z}^\top \underbrace{(\mathbf{I} + \mathbf{W}^\top \boldsymbol{\Psi}^{-1} \mathbf{W})}_{=: \mathbf{G}^{-1}} \mathbf{z} - 2 \mathbf{z}^\top \mathbf{W}^\top \boldsymbol{\Psi}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right]. \end{aligned}$$

令

$$\boxed{\mathbf{G} = (\mathbf{I} + \mathbf{W}^\top \boldsymbol{\Psi}^{-1} \mathbf{W})^{-1}} \quad (16.74)$$

把上式配方为

$$\ln p(\mathbf{z} \mid \mathbf{x}) = \text{const} - \frac{1}{2}(\mathbf{z} - \mathbf{m})^\top \mathbf{G}^{-1}(\mathbf{z} - \mathbf{m}), \quad \mathbf{m} = \mathbf{G} \mathbf{W}^\top \boldsymbol{\Psi}^{-1}(\mathbf{x} - \boldsymbol{\mu}).$$

因此

$$p(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z} \mid \mathbf{m}, \mathbf{G}).$$

E 步的两条期望 对每个样本 n , 取 $\mathbf{x} = \mathbf{x}_n$, 并 (按练习 16.26) 以 $\boldsymbol{\mu} = \bar{\mathbf{x}}$ 代入, 得到

$$\boxed{\mathbb{E}[\mathbf{z}_n] = \mathbf{G} \mathbf{W}^\top \boldsymbol{\Psi}^{-1}(\mathbf{x}_n - \bar{\mathbf{x}})} \quad (16.72)$$

以及 (用高斯二阶矩公式 $\mathbb{E}[\mathbf{z}\mathbf{z}^\top] = \text{Cov}[\mathbf{z}] + \mathbb{E}[\mathbf{z}]\mathbb{E}[\mathbf{z}]^\top$)

$$\boxed{\mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] = \mathbf{G} + \mathbb{E}[\mathbf{z}_n] \mathbb{E}[\mathbf{z}_n]^\top} \quad (16.73)$$

这正是教材中因子分析 EM 算法的 E 步结果, 其中 $\mathbf{G}$ 见 (16.74)。

□

练习 16.25 解答 (★★)

题目回顾 给出因子分析 (FA) 模型的期望完备数据对数似然表达式, 并据此推出 EM 算法的 M 步更新式 (16.75) 与 (16.76)。

模型

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_M), \quad p(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi}),$$

其中 $\boldsymbol{\Psi} = \text{diag}(\psi_1, \dots, \psi_D)$ 为对角阵。记样本均值 $\bar{\mathbf{x}}$, 样本协方差

$$\mathbf{S} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^\top.$$

在 E 步保持 $\{\mathbf{W}, \boldsymbol{\Psi}\}$ 固定, 得到 (见式(16.72)–(16.74))

$$\hat{\mathbf{z}}_n := \mathbb{E}[\mathbf{z}_n | \mathbf{x}_n] = \mathbf{G} \mathbf{W}^\top \boldsymbol{\Psi}^{-1} (\mathbf{x}_n - \bar{\mathbf{x}}), \quad (5)$$

$$\widehat{\mathbf{Z}}_n := \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top | \mathbf{x}_n] = \mathbf{G} + \hat{\mathbf{z}}_n \hat{\mathbf{z}}_n^\top, \quad (6)$$

$$\mathbf{G} = (\mathbf{I} + \mathbf{W}^\top \boldsymbol{\Psi}^{-1} \mathbf{W})^{-1}. \quad (7)$$

为书写简洁, 定义

$$\mathbf{C}_{xz} := \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \hat{\mathbf{z}}_n^\top \in \mathbb{R}^{D \times M}, \quad \mathbf{C}_{zz} := \frac{1}{N} \sum_{n=1}^N \widehat{\mathbf{Z}}_n \in \mathbb{R}^{M \times M}.$$

期望完备数据对数似然 忽略与参数无关的常数, 有

$$\begin{aligned} \mathcal{Q}(\mathbf{W}, \boldsymbol{\Psi}) &= \mathbb{E}_{q(\mathbf{z})} \left[\sum_{n=1}^N \ln p(\mathbf{x}_n, \mathbf{z}_n | \mathbf{W}, \boldsymbol{\Psi}, \bar{\mathbf{x}}) \right] \\ &= -\frac{N}{2} \left\{ \ln |\boldsymbol{\Psi}| + \text{Tr} \left(\boldsymbol{\Psi}^{-1} \underbrace{\mathbb{E}[(\mathbf{x} - \bar{\mathbf{x}} - \mathbf{W}\mathbf{z})(\mathbf{x} - \bar{\mathbf{x}} - \mathbf{W}\mathbf{z})^\top]}_{\mathbf{S} - \mathbf{C}_{xz} \mathbf{W}^\top - \mathbf{W} \mathbf{C}_{xz}^\top + \mathbf{W} \mathbf{C}_{zz} \mathbf{W}^\top} \right) \right\} + \text{const.} \end{aligned}$$

于是

$$\mathcal{Q}(\mathbf{W}, \boldsymbol{\Psi}) = -\frac{N}{2} \left\{ \ln |\boldsymbol{\Psi}| + \text{Tr}(\boldsymbol{\Psi}^{-1} \mathbf{S}) - 2 \text{Tr}(\boldsymbol{\Psi}^{-1} \mathbf{W} \mathbf{C}_{xz}^\top) + \text{Tr}(\boldsymbol{\Psi}^{-1} \mathbf{W} \mathbf{C}_{zz} \mathbf{W}^\top) \right\} + \text{const.} \quad (8)$$

M 步: 更新 $\mathbf{W}$ 对 (8) 求 $\partial/\partial \mathbf{W}$ 并令其为零:

$$-2 \boldsymbol{\Psi}^{-1} \mathbf{C}_{xz} + 2 \boldsymbol{\Psi}^{-1} \mathbf{W} \mathbf{C}_{zz} = \mathbf{0} \implies \boxed{\mathbf{W}_{\text{new}} = \mathbf{C}_{xz} \mathbf{C}_{zz}^{-1}}.$$

将平均的定义还原成求和, 即

$$\boxed{\mathbf{W}_{\text{new}} = \left[\sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}}) \mathbb{E}[\mathbf{z}_n]^\top \right] \left[\sum_{n=1}^N \mathbb{E}[\mathbf{z}_n \mathbf{z}_n^\top] \right]^{-1}}, \quad (16.75)$$

M 步：更新 Ψ 对 (8) 以 Ψ 为变量最优化（或对 Ψ^{-1} 求导）得非对角受限的最优解

$$\Psi^* = \mathbf{S} - \mathbf{W}\mathbf{C}_{xz}^\top - \mathbf{C}_{xz}\mathbf{W}^\top + \mathbf{W}\mathbf{C}_{zz}\mathbf{W}^\top.$$

由于 FA 规定 Ψ 为对角阵，取其对角部分作为更新；再代入 $\mathbf{W}_{\text{new}} = \mathbf{C}_{xz}\mathbf{C}_{zz}^{-1}$ 可化简为

$$\Psi_{\text{new}} = \text{diag}(\mathbf{S} - \mathbf{W}_{\text{new}}\mathbf{C}_{xz}^\top).$$

写成求和形式即

$$\Psi_{\text{new}} = \text{diag}\left\{\mathbf{S} - \mathbf{W}_{\text{new}}\left(\frac{1}{N}\sum_{n=1}^N\mathbb{E}[\mathbf{z}_n](\mathbf{x}_n - \bar{\mathbf{x}})^\top\right)\right\}, \quad (16.76)$$

其中 $\text{diag}\{\cdot\}$ 将非对角元置零，仅保留对角元素。

结论 由期望完备似然 (8) 出发，可直接得到 FA 的 M 步闭式更新式 (16.75) 与 (16.76)，与教材一致。 $\square$

练习 16.26 解答 (★★)

题目回顾 考虑第 16.2.4 节的因子分析模型

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \mathbf{x} \mid \mathbf{z} \sim \mathcal{N}(\mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \boldsymbol{\Psi}),$$

其中 $\boldsymbol{\Psi}$ 为对角且正定。证明：关于参数 $\boldsymbol{\mu}$ 的对数似然的唯一驻点为样本均值

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n,$$

并进一步证明该驻点是极大值。

解答

1) 边缘分布与只含 $\boldsymbol{\mu}$ 的部分。对任意固定的 $\mathbf{W}, \boldsymbol{\Psi}$, 边缘分布为

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \mathbf{C}), \quad \mathbf{C} := \mathbf{W}\mathbf{W}^\top + \boldsymbol{\Psi} \succ 0.$$

因此 (忽略与 $\boldsymbol{\mu}$ 无关的常数项),

$$\ell(\boldsymbol{\mu}) := \sum_{n=1}^N \ln p(\mathbf{x}_n) = -\frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^\top \mathbf{C}^{-1} (\mathbf{x}_n - \boldsymbol{\mu}) + \text{const}.$$

2) 一阶导数与驻点。利用恒等式 $\nabla_{\boldsymbol{\mu}}(\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{A}(\mathbf{x} - \boldsymbol{\mu}) = -2\mathbf{A}(\mathbf{x} - \boldsymbol{\mu})$ ($\mathbf{A}$ 对称), 可得

$$\nabla_{\boldsymbol{\mu}} \ell(\boldsymbol{\mu}) = \sum_{n=1}^N \mathbf{C}^{-1}(\mathbf{x}_n - \boldsymbol{\mu}) = N \mathbf{C}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}).$$

令梯度为零即得唯一解

$$\boxed{\boldsymbol{\mu}_{\text{ML}} = \bar{\mathbf{x}}}.$$

3) 二阶导数与极大性。Hessian 为

$$\nabla_{\boldsymbol{\mu}}^2 \ell(\boldsymbol{\mu}) = -N \mathbf{C}^{-1}.$$

由于 $\mathbf{C}^{-1} \succ 0$, 故 $-N\mathbf{C}^{-1}$ 负定, $\ell(\boldsymbol{\mu})$ 关于 $\boldsymbol{\mu}$ 为严格凹函数, 从而其唯一驻点 $\boldsymbol{\mu} = \bar{\mathbf{x}}$ 为全局极大值。

4) 配方法 (等价验证, 可选)。将上式配方可写为

$$\ell(\boldsymbol{\mu}) = -\frac{N}{2} (\boldsymbol{\mu} - \bar{\mathbf{x}})^\top \mathbf{C}^{-1} (\boldsymbol{\mu} - \bar{\mathbf{x}}) + \text{const},$$

显然在且仅在 $\boldsymbol{\mu} = \bar{\mathbf{x}}$ 处取最大值。

□

Copyright

© 2025 YaoYuzhuo (yaoyuzhuo6@gmail.com).

本作品仅供学术与研究用途。任何形式的商业使用、转载或牟利性衍生作品，须经版权所有者书面许可。任何侵权行为将依法追究责任。

All rights reserved. This work is made available exclusively for academic and research purposes. Any form of commercial use, redistribution, or derivative work for profit requires prior written authorization from the copyright holder. Any unlawful infringement will be prosecuted in accordance with applicable laws and regulations.
