

Solutions to Chapter 17 — *Generative Adversarial Networks*

YaoYuzhuo

September, 2025

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 17.1 (★★★) 我们希望 GAN 的误差函数 (17.6) 具有这样的性质：当生成器分布 $p_G(x)$ 与真实数据分布 $p_{\text{data}}(x)$ 相匹配时（并假设神经网络具有足够的表达能力、可在整个函数空间上优化），其驻点就出现在该处。更具体地，假设判别器模型在一个内层循环中被优化到极致，从而得到关于生成器的一个有效代价泛函。首先，在数据样本数趋于无穷大的极限下，GAN 的误差函数 (17.6) 可改写为

$$E(p_G) = - \int p_{\text{data}}(x) \ln d(x) dx - \int p_G(x) \ln(1 - d(x)) dx. \quad (17.14)$$

其中 $p_{\text{data}}(x)$ 是真实数据点的固定分布。现在在所有函数 $d(x)$ 上做变分优化。证明：在固定生成器网络的情况下，使 E 最小的判别器为

$$d^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}. \quad (17.15)$$

由此证明：误差函数 E 可以改写为关于生成器分布 $p_G(x)$ 的函数

$$\begin{aligned} C(p_G) = & - \int p_{\text{data}}(x) \ln \left\{ \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)} \right\} dx \\ & - \int p_G(x) \ln \left\{ \frac{p_G(x)}{p_{\text{data}}(x) + p_G(x)} \right\} dx. \end{aligned} \quad (17.16)$$

进一步证明它还能写成

$$C(p_G) = -\ln 4 + \text{KL} \left(P_{\text{data}} \left\| \frac{P_{\text{data}} + P_G}{2} \right\| \right) + \text{KL} \left(P_G \left\| \frac{P_{\text{data}} + P_G}{2} \right\| \right), \quad (17.17)$$

其中 Kullback–Leibler 散度 $\text{KL}(p\|q)$ 定义见式 (2.100)。最后，利用性质 $\text{KL}(p\|q) \geq 0$ ，且当且仅当 $p(x) = q(x)$ （对所有 x ）时取等，证明 $C(p_G)$ 的最小值在 $p_G(x) = p_{\text{data}}(x)$ 处取得。注意：式 (17.17) 中两个 KL 项之和称为 P_{data} 与 P_G 的 Jensen–Shannon (JS) 散度；它与 KL 一样非负，且仅当两分布相等时为 0，但与 KL 不同的是它是对称的（并且有界）。

练习 17.2 (★★★) 在本题中我们探究 GAN 训练的对抗性可能引发的问题。考虑一个定义在两个参数 a 与 b 上的代价函数 $E(a, b) = ab$ ，它们分别类似于生成网络和判别网络的参数。证明点 $a = 0, b = 0$ 是该代价函数的一个驻点。再沿直线 $b = a$ 与 $b = -a$ 考察二阶导数，证明点 $a = 0, b = 0$ 是一个鞍点。

现在设我们用无穷小步长来优化该误差函数，使得变量成为连续时间函数 $a(t), b(t)$ ，并由一个连续时间的梯度法所定义：生成网络的参数 $a(t)$ 以增大 $E(a, b)$ 的方向更新，而判别网络的参数 $b(t)$ 以减小 $E(a, b)$ 的方向更新。证明参数的演化满足

$$\frac{da}{dt} = \eta \frac{\partial E}{\partial a}, \quad \frac{db}{dt} = -\eta \frac{\partial E}{\partial b}. \quad (17.18)$$

进一步证明 $a(t)$ 满足二阶微分方程

$$\frac{d^2 a}{dt^2} = -\eta^2 a(t). \quad (17.19)$$

验证下式是 (17.19) 的一个解：

$$a(t) = C \cos(\eta t) + D \sin(\eta t), \quad (17.20)$$

其中 C, D 为任意常数。若系统在 $t = 0$ 时初始化为 $a = 1, b = 0$ ，求出 C 与 D ，并据此说明所得 $a(t)$ 与 $b(t)$ 在 $a-b$ 平面上围绕原点描出半径为 1 的圆，因而它们永远不会收敛到该鞍点。

练习 17.3 (★) 考虑一个 GAN：训练集由猫和狗的图像构成，且两类数量相等；并且生成器网络已经学会生成高质量的狗图像。证明：当向判别器输入一张狗的图像时，若判别器被训练为输出“该图像为真实样本的概率”，其最优输出应为 $1/3$ 。

下面将进行详细解答！

练习 17.1 解答 (★★★)

题目 我们希望 GAN 的误差函数 (式(17.6)) 具有如下性质: 当神经网络具有足够的灵活性时, 平稳点出现在生成分布与真实分布相等之处, 即 $p_G(x) = p_{\text{data}}(x)$ 。本题在“网络具有无限灵活性”的理想化设定下, 通过分别在全部生成分布 $p_G(x)$ 与全部判别函数 $d(x)$ 上优化来证明这一结果。具体要求如下。首先, 假设判别器在内层被优化到最优, 从而得到关于生成器的有效外层目标; 并在样本数无穷大的极限下, 证明式(17.6)可以改写为

$$E(p_G, d) = - \int p_{\text{data}}(x) \ln d(x) dx - \int p_G(x) \ln(1 - d(x)) dx, \quad (\text{即式(17.14)}).$$

其中 $p_{\text{data}}(x)$ 为固定的真实数据分布。接着, 在固定 p_G 的前提下, 对所有函数 $d(x)$ 做变分优化, 证明最小化 E 的解为

$$d^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)} \quad (\text{式(17.15)}).$$

因此, 证明误差函数可写成只关于生成器分布 $p_G(x)$ 的函数, 形式为

$$C(p_G) = - \int p_{\text{data}}(x) \ln \left\{ \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)} \right\} dx - \int p_G(x) \ln \left\{ \frac{p_G(x)}{p_{\text{data}}(x) + p_G(x)} \right\} dx, \quad (\text{式(17.16)}).$$

进一步, 把它改写为

$$C(p_G) = -\ln 4 + \text{KL} \left(p_{\text{data}} \left\| \frac{p_{\text{data}} + p_G}{2} \right\| \right) + \text{KL} \left(p_G \left\| \frac{p_{\text{data}} + p_G}{2} \right\| \right), \quad (\text{式(17.17)}).$$

最后, 利用 $\text{KL}(p\|q) \geq 0$, 且当且仅当 $p(x) = q(x)$ (对所有 x) 时取等式, 证明 $C(p_G)$ 的最小值出现在 $p_G(x) = p_{\text{data}}(x)$ 。注意到, 式(17.17) 中两项 KL 的和即 Jensen-Shannon 散度; 它与 KL 一样非负, 且当且仅当两分布相等时为零, 但与 KL 不同之处在于它关于两分布是对称的。

目标 证明当判别器在内层被最优地训练后, GAN 的生成器所对应的外层目标在且仅在 $p_G(x) = p_{\text{data}}(x)$ 时达到最小值。并按题意依次推导 (17.14)–(17.17)。

(a) 由经验和转为分布积分 式(17.6) 的经验和在样本数 $\rightarrow \infty$ 的极限下变为对真实分布 p_{data} 与生成分布 p_G 的期望:

$$E(p_G, d) = - \int p_{\text{data}}(x) \ln d(x) dx - \int p_G(x) \ln(1 - d(x)) dx, \quad (17.14)$$

这只是把经验均值换成了分布期望 (大数定律)。

(b) 固定 p_G , 对 d 的变分最优化 把 E 视为关于函数 $d(\cdot)$ 的泛函。对每个 x 的函数值取一阶变分并令其为零:

$$\frac{\delta E}{\delta d(x)} = - \frac{p_{\text{data}}(x)}{d(x)} + \frac{p_G(x)}{1 - d(x)} = 0.$$

解得最优判别器

$$d^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}. \quad (17.15)$$

同时二阶变分 $\delta^2 E / \delta d(x)^2 = p_{\text{data}}(x)/d(x)^2 + p_G(x)/(1-d(x))^2 > 0$, 故该驻点为极小值。

(c) 消去 d 得到仅依赖 p_G 的目标 为与教材 (17.17) 的 “外层最小化目标” 一致, 定义

$$C(p_G) := -E(p_G, d^*);$$

(因 (17.6) 定义的是要最小化的误差 E , 而 Goodfellow 原始 $V(D, G)$ 是最大化的价值函数, 二者相差一负号。) 将 d^* 代回 (17.14) 得

$$C(p_G) = \int p_{\text{data}}(x) \ln \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)} dx + \int p_G(x) \ln \frac{p_G(x)}{p_{\text{data}}(x) + p_G(x)} dx. \quad (17.16)$$

(d) 化为 KL 散度之和 记 $m(x) = \frac{1}{2}(p_{\text{data}}(x) + p_G(x))$, 则 $p_{\text{data}} + p_G = 2m$, 从而

$$\begin{aligned} C(p_G) &= \int p_{\text{data}}(\ln p_{\text{data}} - \ln(2m)) + \int p_G(\ln p_G - \ln(2m)) \\ &= \int p_{\text{data}} \ln p_{\text{data}} + \int p_G \ln p_G - 2 \ln 2 - \int (p_{\text{data}} + p_G) \ln m. \end{aligned}$$

利用 $\text{KL}(p||q) = \int p \ln \frac{p}{q}$, 可得

$$\begin{aligned} - \int (p_{\text{data}} + p_G) \ln m &= - \int p_{\text{data}} \ln m - \int p_G \ln m \\ &= \left(\text{KL}(p_{\text{data}}||m) - \int p_{\text{data}} \ln p_{\text{data}} \right) + \left(\text{KL}(p_G||m) - \int p_G \ln p_G \right) \\ &= \text{KL}(p_{\text{data}}||m) + \text{KL}(p_G||m) - \int p_{\text{data}} \ln p_{\text{data}} - \int p_G \ln p_G. \end{aligned}$$

代回并化简得到

$$C(p_G) = -\ln 4 + \text{KL}\left(p_{\text{data}} \parallel \frac{p_{\text{data}} + p_G}{2}\right) + \text{KL}\left(p_G \parallel \frac{p_{\text{data}} + p_G}{2}\right). \quad (17.17)$$

上式中两项 KL 之和等于 2 倍 Jensen-Shannon 散度 $\text{JS}(p_{\text{data}} || p_G)$ 。

(e) 结论: $p_G = p_{\text{data}}$ 时达到最小 由 KL 散度的非负性及其等号条件 ($\text{KL}(p||q) \geq 0$, 且当且仅当 $p(x) \equiv q(x)$ 时取零), 知

$$C(p_G) \geq -\ln 4, \quad \text{且当且仅当 } p_G(x) = p_{\text{data}}(x) \text{ 对所有 } x \text{ 成立时取等号.}$$

因此, 在函数空间中 (网络足够灵活) 生成器目标 $C(p_G)$ 的最小点正是 $p_G = p_{\text{data}}$, 与题意相符。□

注 若以 $V(G) = \int p_{\text{data}} \ln d^* + \int p_G \ln(1-d^*)$ 为价值函数, 则 $V(G) = -\ln 4 + 2 \text{JS}(p_{\text{data}}||p_G)$, 而本题的 $C(p_G) = V(G)$ (因 $C = -E$)。

练习 17.2 解答 (★★★)

题目 考虑代价函数 $E(a, b) = ab$, 其中 a, b 分别类比为生成器与判别器的参数。(1) 证明点 $(a, b) = (0, 0)$ 为驻点, 并通过沿直线 $b = a$ 与 $b = -a$ 的二阶导数说明该点是鞍点。(2) 若用连续时间的对抗梯度更新: 生成器沿使 E 增大的方向、判别器沿使 E 减小的方向, 证明参数演化满足

$$\frac{da}{dt} = \eta \frac{\partial E}{\partial a}, \quad \frac{db}{dt} = -\eta \frac{\partial E}{\partial b} \quad (17.18)$$

并由此推出 $a(t)$ 满足二阶微分方程

$$\frac{d^2 a}{dt^2} = -\eta^2 a(t). \quad (17.19)$$

(3) 验证

$$a(t) = C \cos(\eta t) + D \sin(\eta t) \quad (17.20)$$

是式 (17.19) 的解。若初值为 $a(0) = 1, b(0) = 0$, 求 C, D , 并据此说明轨迹在 (a, b) 平面上是以原点为中心、半径为 1 的圆, 因而永不收敛到鞍点 $(0, 0)$ 。

解答

(1) 驻点与鞍点 有

$$\nabla E(a, b) = \left(\frac{\partial E}{\partial a}, \frac{\partial E}{\partial b} \right) = (b, a),$$

故 $(0, 0)$ 为驻点。沿 $b = a$ 与 $b = -a$:

$$E(a, a) = a^2 \Rightarrow \frac{d^2}{da^2} E(a, a)|_{a=0} = 2 > 0, \quad E(a, -a) = -a^2 \Rightarrow \frac{d^2}{da^2} E(a, -a)|_{a=0} = -2 < 0.$$

一方向二阶导正、另一方向二阶导负, 故 $(0, 0)$ 为鞍点。

(2) 连续时间对抗更新与二阶方程 按题意, 连续时间极限的对抗梯度给出

$$\frac{da}{dt} = \eta \frac{\partial E}{\partial a} = \eta b, \quad \frac{db}{dt} = -\eta \frac{\partial E}{\partial b} = -\eta a, \quad (17.18)$$

其中 $\eta > 0$ 。对第一式再对 t 求导并用第二式代入:

$$\frac{d^2 a}{dt^2} = \eta \frac{db}{dt} = \eta(-\eta a) = -\eta^2 a(t),$$

即得式 (17.19)。

(3) 解的验证与初值常数 令

$$a(t) = C \cos(\eta t) + D \sin(\eta t), \quad (17.20)$$

则 $a''(t) = -\eta^2(C \cos(\eta t) + D \sin(\eta t)) = -\eta^2 a(t)$, 满足式 (17.19)。由式 (17.18) 的第一式得

$$b(t) = \frac{1}{\eta} \frac{da}{dt} = -C \sin(\eta t) + D \cos(\eta t).$$

初值 $a(0) = 1$, $b(0) = 0$ 给出

$$C = 1, \quad D = 0,$$

于是

$$a(t) = \cos(\eta t), \quad b(t) = -\sin(\eta t).$$

从而

$$a(t)^2 + b(t)^2 = \cos^2(\eta t) + \sin^2(\eta t) = 1,$$

表明参数轨迹在 (a, b) 平面上沿半径为 1 的圆周运动, 中心在原点, 因此不会收敛到鞍点 $(0, 0)$ 。

□

练习 17.3 解答 (★)

题目 设某 GAN 的训练集中猫与狗图片数量相等；判别器输出 $d(x) \in (0, 1)$ ，表示“该图像为真实的概率”。假定生成器已经学会生成高质量的狗图像（几不可与真实狗区分）。证明：当输入是一张狗图像时，判别器的最优输出是 $1/3$ 。

解答 在交叉熵训练下，判别器的最优函数（Bayes 最优解）为

$$d^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)},$$

其中 p_{data} 为真实数据分布， p_G 为生成分布。题设“猫与狗数量相等”意味着

$$p_{\text{data}}(x) = \frac{1}{2} p_{\text{cat}}(x) + \frac{1}{2} p_{\text{dog}}(x).$$

又因生成器只能生成狗，且“高质量”表示 $p_G(x) \approx p_{\text{dog}}(x)$ 。当 x 是一张狗图像时， $p_{\text{cat}}(x) \approx 0$ ，于是

$$p_{\text{data}}(x) \approx \frac{1}{2} p_{\text{dog}}(x), \quad p_G(x) \approx p_{\text{dog}}(x).$$

代入最优式可得

$$d^*(x) = \frac{\frac{1}{2} p_{\text{dog}}(x)}{\frac{1}{2} p_{\text{dog}}(x) + p_{\text{dog}}(x)} = \frac{\frac{1}{2}}{\frac{3}{2}} = \boxed{\frac{1}{3}}.$$

直观计数法（等价） 若每次用等量真实与生成样本训练判别器，则总体中“真实猫：真实狗：生成狗 = $\frac{1}{4} : \frac{1}{4} : \frac{1}{2}$ ”。因此在“狗”这一条件下，真实的先验概率为 $\frac{\frac{1}{4}}{\frac{1}{4} + \frac{1}{2}} = \frac{1}{3}$ ，与上式一致。 $\square$

Copyright

© 2025 YaoYuzhuo (yaoyuzhuo6@gmail.com).

本作品仅供学术与研究用途。任何形式的商业使用、转载或牟利性衍生作品，须经版权所有者书面许可。任何侵权行为将依法追究责任。

All rights reserved. This work is made available exclusively for academic and research purposes. Any form of commercial use, redistribution, or derivative work for profit requires prior written authorization from the copyright holder. Any unlawful infringement will be prosecuted in accordance with applicable laws and regulations.
