

# Solutions to Chapter 19 — *Autoencoders*

YaoYuzhuo

September , 2025

*Based on the textbook Deep Learning: Foundations and Concepts*

## 练习题中文译文及解答

练习 19.1 (★★) 证明：对任意分布  $q(z | \phi)$  与任意函数  $G(z)$ ，恒有

$$\nabla_{\phi} \int q(z | \phi) G(z) dz = \int q(z | \phi) G(z) \nabla_{\phi} \ln q(z | \phi) dz. \quad (19.20)$$

进而说明：式 (19.20) 左端可用如下蒙特卡罗估计近似

$$\nabla_{\phi} \int q(z | \phi) G(z) dz \simeq \sum_i G(z^{(i)}) \nabla_{\phi} \ln q(z^{(i)} | \phi), \quad (19.21)$$

其中样本  $\{z^{(i)}\}$  从分布  $q(z | \phi)$  独立抽取。请验证该估计是无偏的：即对 (19.21) 右端在样本分布上的平均，等于 (19.20) 的左端。原则上，令  $G(z) = p(\mathbf{x} | z, \mathbf{w})$  时，可在不使用重参数化技巧的情况下，计算式 (19.14) 右端第二项关于  $\phi$  的梯度。又因为这种方法是无偏的，当样本数趋于无穷大时将得到精确答案。然而，重参数化技巧通常更高效：它直接计算由  $\phi$  的变化经由  $z$  引起的  $p(\mathbf{x} | z, \mathbf{w})$  的变化，因而在达到同等精度时所需样本更少。

练习 19.2 (★) 验证：若随机变量  $\epsilon$  服从零均值、单位方差的高斯分布，则由

$$z = \sigma \epsilon + \mu \quad (19.17)$$

定义的变量  $z$  也服从高斯分布，其均值为  $\mu$ 、方差为  $\sigma^2$ 。

练习 19.3 (★★) 在本题中，我们把对角协方差的 VAE 编码器（式 (19.13)）推广到具有一般协方差矩阵的情形。设  $\epsilon \in \mathbb{R}^K$  为一个从标准高斯分布中抽取的  $K$  维随机向量：

$$\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (19.22)$$

并进行如下线性变换

$$\mathbf{z} = \boldsymbol{\mu} + \mathbf{L} \epsilon, \quad (19.23)$$

其中  $\mathbf{L}$  是一个下三角矩阵 (即  $K \times K$  矩阵, 主对角线以上的元素全为 0)。证明:  $\mathbf{z}$  服从  $\mathcal{N}(\mathbf{z}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$  分布, 并写出  $\boldsymbol{\Sigma}$  关于  $\mathbf{L}$  的表达式。解释为什么  $\mathbf{L}$  的对角元必须非负。说明如何将  $\boldsymbol{\mu}$  与  $\mathbf{L}$  表示为一个神经网络的输出, 并讨论输出单元激活函数的合适选择。

**练习 19.4 (★★)** 计算式 (19.14) 中的 Kullback–Leibler 散度项。进而说明: 在训练编码器与解码器网络时, 如何分别对参数  $\mathbf{w}$  与  $\phi$  求出该项的梯度。

**练习 19.5 (★)** 已知由 (19.11) 给出的 ELBO 可以写成 (19.14) 的形式。请证明它还可以写为

$$\mathcal{L}_n(\mathbf{w}, \phi) = \int q(\mathbf{z}_n|\mathbf{x}_n, \phi) \ln \{ p(\mathbf{x}_n|\mathbf{z}_n, \mathbf{w}) p(\mathbf{z}_n) \} d\mathbf{z}_n - \int q(\mathbf{z}_n|\mathbf{x}_n, \phi) \ln q(\mathbf{z}_n|\mathbf{x}_n, \phi) d\mathbf{z}_n. \quad (19.24)$$

**练习 19.6 (★)** 证明: 由 (19.11) 给出的 ELBO 亦可写为

$$\mathcal{L}_n(\mathbf{w}, \phi) = \int q(\mathbf{z}_n|\mathbf{x}_n, \phi) \ln p(\mathbf{z}_n) d\mathbf{z}_n + \int q(\mathbf{z}_n|\mathbf{x}_n, \phi) \ln \left\{ \frac{p(\mathbf{x}_n|\mathbf{z}_n, \mathbf{w})}{q(\mathbf{z}_n|\mathbf{x}_n, \phi)} \right\} d\mathbf{z}_n. \quad (19.25)$$

下面将进行详细解答!

## 练习 19.1 解答 (★★)

**题目** 设  $q(\mathbf{z} | \phi)$  为关于  $\mathbf{z}$  的任意概率分布,  $G(\mathbf{z})$  为任意 (与  $\phi$  无关的) 函数。证明

$$\nabla_{\phi} \int q(\mathbf{z} | \phi) G(\mathbf{z}) d\mathbf{z} = \int q(\mathbf{z} | \phi) G(\mathbf{z}) \nabla_{\phi} \ln q(\mathbf{z} | \phi) d\mathbf{z}. \quad (19.20)$$

进而说明左侧可用如下蒙特卡罗估计来近似

$$\nabla_{\phi} \int q(\mathbf{z} | \phi) G(\mathbf{z}) d\mathbf{z} \simeq \frac{1}{L} \sum_{l=1}^L G(\mathbf{z}^{(l)}) \nabla_{\phi} \ln q(\mathbf{z}^{(l)} | \phi), \quad \mathbf{z}^{(l)} \stackrel{\text{i.i.d.}}{\sim} q(\mathbf{z} | \phi). \quad (19.21)$$

并验证该估计量是无偏的。

**解答**

**(a) 证明等式 (19.20)** 记  $J(\phi) = \int q(\mathbf{z} | \phi) G(\mathbf{z}) d\mathbf{z}$ 。在满足可将梯度移入积分号的常规条件 (例如存在与  $\phi$  无关的可积主导函数, 且  $q$  的支持集不随  $\phi$  变化) 下, 有

$$\nabla_{\phi} J(\phi) = \int \nabla_{\phi} q(\mathbf{z} | \phi) G(\mathbf{z}) d\mathbf{z}.$$

利用对数导数技巧  $\nabla_{\phi} q = q \nabla_{\phi} \ln q$ , 得到

$$\nabla_{\phi} J(\phi) = \int q(\mathbf{z} | \phi) G(\mathbf{z}) \nabla_{\phi} \ln q(\mathbf{z} | \phi) d\mathbf{z},$$

即得 (19.20)。

**(b) 得到蒙特卡罗形式 (19.21)** 由 (19.20) 可知

$$\nabla_{\phi} J(\phi) = \mathbb{E}_{\mathbf{z} \sim q(\cdot | \phi)} [G(\mathbf{z}) \nabla_{\phi} \ln q(\mathbf{z} | \phi)].$$

因此用  $L$  个独立样本的样本均值给出无偏估计

$$\widehat{\nabla_{\phi} J} = \frac{1}{L} \sum_{l=1}^L G(\mathbf{z}^{(l)}) \nabla_{\phi} \ln q(\mathbf{z}^{(l)} | \phi),$$

这就是 (19.21)。

**(c) 无偏性验证** 由期望的线性性与 i.i.d., 有

$$\mathbb{E}[\widehat{\nabla_{\phi} J}] = \frac{1}{L} \sum_{l=1}^L \mathbb{E}_q [G(\mathbf{z}) \nabla_{\phi} \ln q(\mathbf{z} | \phi)] = \nabla_{\phi} J(\phi),$$

故估计量无偏。

(d) 应用于 ELBO (19.14) 时的正确设定 在 (19.14) 的第一项

$$\int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) d\mathbf{z}_n,$$

对  $\phi$  求梯度时应当取

$$G(\mathbf{z}) = \ln p(\mathbf{x}_n | \mathbf{z}, \mathbf{w}),$$

从而得到无需重参数化的 score-function (REINFORCE) 梯度

$$\nabla_{\phi} \int q \ln p(\mathbf{x}_n | \mathbf{z}, \mathbf{w}) d\mathbf{z} = \int q \ln p(\mathbf{x}_n | \mathbf{z}, \mathbf{w}) \nabla_{\phi} \ln q d\mathbf{z}.$$

注意：若误把  $G$  取为  $p(\mathbf{x}_n | \mathbf{z}, \mathbf{w})$ ，则对应的目标已与 ELBO 第一项不符。另一方面，(19.14) 的第二项是高斯对高斯的 KL，具有解析式，对  $\phi$  的梯度可由解析式链式求导，无需使用 (19.20)。

(e) 方差降低 (可选) 对任意与  $\phi$  无关的 baseline (控制变量)  $b$ ,

$$\mathbb{E}_q[(G(\mathbf{z}) - b) \nabla_{\phi} \ln q(\mathbf{z} | \phi)] = \mathbb{E}_q[G(\mathbf{z}) \nabla_{\phi} \ln q(\mathbf{z} | \phi)],$$

在不改变无偏性的同时常可显著降低方差；实践中常取  $b$  为小批均值或学习得到的值。

□

## 练习 19.2 解答 (★)

题目 设  $\epsilon \sim \mathcal{N}(0, 1)$  为零均值、单位方差的一维高斯随机变量。验证若

$$z = \sigma \epsilon + \mu \quad (\text{教材式 (19.17)}),$$

则  $z$  服从均值为  $\mu$ 、方差为  $\sigma^2$  的高斯分布，即  $z \sim \mathcal{N}(\mu, \sigma^2)$ 。

解法一：由仿射变换性质直接得到

高斯分布在仿射变换下封闭：若  $\epsilon \sim \mathcal{N}(0, 1)$ ，则对任何常数  $\sigma$ 、 $\mu$ ，

$$\mathbb{E}[z] = \mathbb{E}[\sigma \epsilon + \mu] = \sigma \mathbb{E}[\epsilon] + \mu = \mu,$$

$$\text{Var}(z) = \text{Var}(\sigma \epsilon + \mu) = \sigma^2 \text{Var}(\epsilon) = \sigma^2.$$

因此  $z$  为均值  $\mu$ 、方差  $\sigma^2$  的高斯： $z \sim \mathcal{N}(\mu, \sigma^2)$ 。 □

解法二：密度函数的变量代换

标准高斯的密度为  $p_\epsilon(e) = \frac{1}{\sqrt{2\pi}} e^{-e^2/2}$ 。由  $z = \sigma e + \mu$  得  $e = (z - \mu)/\sigma$ ，并有  $\left| \frac{de}{dz} \right| = \frac{1}{|\sigma|}$ 。于是

$$p_z(z) = p_\epsilon\left(\frac{z - \mu}{\sigma}\right) \frac{1}{|\sigma|} = \frac{1}{\sqrt{2\pi} |\sigma|} \exp\left(-\frac{(z - \mu)^2}{2\sigma^2}\right),$$

这正是  $\mathcal{N}(\mu, \sigma^2)$  的密度。 □

(可选) 向量情形的推广与再次验证

若  $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_M)$ ，取

$$\mathbf{z} = \boldsymbol{\mu} + \text{diag}(\boldsymbol{\sigma}) \epsilon,$$

其中  $\text{diag}(\boldsymbol{\sigma})$  为对角矩阵（将各维度的标准差放在对角线上）。则各分量独立且  $z_j \sim \mathcal{N}(\mu_j, \sigma_j^2)$ ，从而

$$\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^{\circ 2})),$$

其中  $\boldsymbol{\sigma}^{\circ 2}$  表示按分量平方。该结果与 VAE 中式 (19.17)–(19.19) 的设定一致。

## 练习 19.3 解答 (★★)

题目摘要 设  $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_K)$ ，并定义线性变换

$$\mathbf{z} = \boldsymbol{\mu} + \mathbf{L}\epsilon \quad (19.23)$$

其中  $\mathbf{L} \in \mathbb{R}^{K \times K}$  为下三角矩阵。(1) 证明  $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  并写出  $\boldsymbol{\Sigma}$  关于  $\mathbf{L}$  的表达式；(2) 解释为何  $\mathbf{L}$  的主对角元应当非负；(3) 说明在 VAE 编码器中如何把  $\boldsymbol{\mu}$  与  $\mathbf{L}$  作为神经网络的输出，并讨论合适的输出激活函数。

### (1) 分布与协方差表达式

由于高斯在仿射变换下封闭，对任意常数矩阵  $\mathbf{A}$ 、向量  $\mathbf{b}$ ，若  $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  则  $\mathbf{b} + \mathbf{A}\mathbf{x} \sim \mathcal{N}(\mathbf{b}, \mathbf{A}\mathbf{A}^\top)$ 。令  $\mathbf{A} = \mathbf{L}$ ， $\mathbf{b} = \boldsymbol{\mu}$  得

$$\boxed{\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \quad \boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^\top.}$$

也可直接由矩估计验证： $\mathbb{E}[\mathbf{z}] = \boldsymbol{\mu} + \mathbf{L}\mathbb{E}[\epsilon] = \boldsymbol{\mu}$ ， $\text{Cov}[\mathbf{z}] = \mathbf{L} \text{Cov}[\epsilon] \mathbf{L}^\top = \mathbf{L}\mathbf{L}^\top$ 。

### (2) 对角元取非负的理由

对称正定矩阵  $\boldsymbol{\Sigma}$  的 *Cholesky* 分解唯一满足  $\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^\top$ ，且  $\mathbf{L}$  为下三角并具有严格正的对角元。若允许对角元为负，则存在符号不唯一性（例如把  $\mathbf{L}$  的第  $j$  列乘以  $-1$  并同时把第  $j$  个对角元取相反数， $\mathbf{L}\mathbf{L}^\top$  不变），导致参数不可辨识且训练不稳定。因此在建模时通常约束

$$\boxed{L_{jj} > 0 \quad (\text{或至少 } L_{jj} \geq 0 \text{ 以保证 } \boldsymbol{\Sigma} \succeq \mathbf{0})}.$$

当  $L_{jj} > 0$  时， $\mathbf{L}$  可逆且  $\boldsymbol{\Sigma}$  正定；允许  $L_{jj} = 0$  会得到半正定协方差（退化分布），一般在 VAE 中不采用。

### (3) 在编码器中的参数化与激活函数选择

令编码器网络以观测  $\mathbf{x}$  为输入，输出  $\boldsymbol{\mu}(\mathbf{x})$  与  $\mathbf{L}(\mathbf{x})$  的参数。具体做法如下：

- 均值向量  $\boldsymbol{\mu}$ . 维度为  $K$ ，元素无约束，输出激活用恒等映射（线性层）。
- 下三角矩阵  $\mathbf{L}$ . 需要  $K(K+1)/2$  个自由参数。

– 主对角元：网络先输出无约束向量  $\mathbf{s} \in \mathbb{R}^K$ ，然后设

$$L_{jj} = \text{softplus}(s_j) + \varepsilon_{\min} \quad \text{或} \quad L_{jj} = \exp(s_j),$$

以确保  $L_{jj} > 0$ 。其中  $\varepsilon_{\min} \in (10^{-6} \sim 10^{-4})$  用于数值稳定。相比  $\exp(\cdot)$ ，*softplus* 在负区间梯度更稳定。

– 严格下三角元：其余  $K(K-1)/2$  个元素可由线性输出，允许取任意实数。

将上述标量填充到下三角位置（可用  $\text{tril}(\cdot)$  辅助），得到  $\mathbf{L}(\mathbf{x})$ ，再构造  $\Sigma(\mathbf{x}) = \mathbf{L}(\mathbf{x})\mathbf{L}(\mathbf{x})^\top$ 。

这样一来，编解码器中的近似后验采用一般协方差高斯

$$q(\mathbf{z} \mid \mathbf{x}, \phi) = \mathcal{N}(\mathbf{z} \mid \boldsymbol{\mu}(\mathbf{x}; \phi), \mathbf{L}(\mathbf{x}; \phi)\mathbf{L}(\mathbf{x}; \phi)^\top),$$

并且重参数化采样可写为  $\mathbf{z} = \boldsymbol{\mu} + \mathbf{L}\boldsymbol{\epsilon}$ ,  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_K)$ ，从而允许误差通过  $\boldsymbol{\mu}$  与  $\mathbf{L}$  反向传播。

□

## 练习 19.4 解答 (★★)

**题目** 计算 (19.14) 中的 Kullback–Leibler (KL) 散度项。进一步给出该项关于解码器参数  $\mathbf{w}$  与编码器参数  $\phi$  的梯度，以说明如何在训练中计算它们。

**设定** 在 VAE 中，对第  $n$  个样本，编码器输出对角高斯

$$q(\mathbf{z}_n | \mathbf{x}_n, \phi) = \mathcal{N}(\mathbf{z}_n | \boldsymbol{\mu}(\mathbf{x}_n, \phi), \text{diag}(\boldsymbol{\sigma}^2(\mathbf{x}_n, \phi))),$$

先验为  $p(\mathbf{z}) = \mathcal{N}(\mathbf{z} | \mathbf{0}, \mathbf{I})$ 。ELBO 的第二项是  $\text{KL}(q(\mathbf{z}_n | \mathbf{x}_n, \phi) \| p(\mathbf{z}))$ 。

### (一) KL 散度的解析形式

由可分性，向量情形可化为各维一维高斯之和。对一维情形，

$$\text{KL}(\mathcal{N}(z | \mu, \sigma^2) \| \mathcal{N}(z | 0, 1)) = \mathbb{E}_q[\ln q(z) - \ln p(z)].$$

利用  $\ln \mathcal{N}(z | \mu, \sigma^2) = -\frac{1}{2}(\ln(2\pi\sigma^2) + (z - \mu)^2/\sigma^2)$ ,  $\ln \mathcal{N}(z | 0, 1) = -\frac{1}{2}(\ln(2\pi) + z^2)$ , 以及  $\mathbb{E}_q[(z - \mu)^2] = \sigma^2$ ,  $\mathbb{E}_q[z^2] = \mu^2 + \sigma^2$ , 得

$$\text{KL}(\mathcal{N}(z | \mu, \sigma^2) \| \mathcal{N}(z | 0, 1)) = \frac{1}{2}(\mu^2 + \sigma^2 - 1 - \ln \sigma^2).$$

于是对  $M$  维对角协方差情形，

$$\boxed{\text{KL}(q(\mathbf{z}_n | \mathbf{x}_n, \phi) \| p(\mathbf{z})) = \frac{1}{2} \sum_{j=1}^M (\mu_{nj}^2 + \sigma_{nj}^2 - 1 - \ln \sigma_{nj}^2)}, \quad (\star)$$

其中  $\mu_{nj} = \mu_j(\mathbf{x}_n, \phi)$ ,  $\sigma_{nj}^2 = \sigma_j^2(\mathbf{x}_n, \phi)$ . (若将该式带入 (19.14) 的  $\mathcal{L}_n = \mathbb{E}_q[\ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w})] - \text{KL}(\cdot)$ , 即可得到教材 (19.15) 中常见的 “-KL” 形式  $\frac{1}{2} \sum_j \{1 + \ln \sigma_{nj}^2 - \mu_{nj}^2 - \sigma_{nj}^2\}$ .)

### (二) 关于 $\mathbf{w}$ 与 $\phi$ 的梯度

由先验  $p(\mathbf{z})$  与  $q(\mathbf{z}_n | \mathbf{x}_n, \phi)$  均与  $\mathbf{w}$  无关，故

$$\boxed{\nabla_{\mathbf{w}} \text{KL}(q(\mathbf{z}_n | \mathbf{x}_n, \phi) \| p(\mathbf{z})) = \mathbf{0}}.$$

因此解码器参数  $\mathbf{w}$  的更新完全由  $\mathbb{E}_q[\ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w})]$  项通过重参数技巧来驱动。

对编码器参数  $\phi$ , 记  $s_{nj} := \ln \sigma_{nj}^2$  (常用对数方差作为网络的未约束输出)。由  $(\star)$  得单样本的偏导

$$\frac{\partial \text{KL}}{\partial \mu_{nj}} = \mu_{nj}, \quad \frac{\partial \text{KL}}{\partial s_{nj}} = \frac{1}{2}(e^{s_{nj}} - 1) = \frac{1}{2}(\sigma_{nj}^2 - 1).$$

于是链式法则给出

$$\nabla_{\phi} \text{KL}(q(\mathbf{z}_n | \mathbf{x}_n, \phi) \| p(\mathbf{z})) = \sum_{j=1}^M \left[ \mu_{nj} \frac{\partial \mu_{nj}}{\partial \phi} + \frac{1}{2} (e^{s_{nj}} - 1) \frac{\partial s_{nj}}{\partial \phi} \right].$$

若网络直接输出  $\sigma_{nj} > 0$  (例如通过 softplus), 也可用  $\frac{\partial \text{KL}}{\partial \sigma_{nj}} = \frac{1}{2} \left( 2\sigma_{nj} - \frac{2}{\sigma_{nj}} \right) = \sigma_{nj} - \sigma_{nj}^{-1}$  再链式回传。

**小结** (19.14) 中的 KL 项可按 (★) 解析计算; 其对  $\mathbf{w}$  的梯度为 0, 对  $\phi$  的梯度由上式直接从编码器的输出  $\boldsymbol{\mu}, \ln \boldsymbol{\sigma}^2$  反传获得。这使得在训练 VAE 时无需采样即可精确、低方差地处理 KL 正则项。

## 练习 19.5 解答 (★)

题目 由式 (19.11) 可将 ELBO 写成 (19.14) 的形式。证明还可写为

$$\mathcal{L}_n(\mathbf{w}, \phi) = \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln \{p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) p(\mathbf{z}_n)\} d\mathbf{z}_n - \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln q(\mathbf{z}_n | \mathbf{x}_n, \phi) d\mathbf{z}_n. \quad (19.24)$$

证明 从 (19.11) 的单样本 ELBO 出发 (记  $q_n(\mathbf{z}_n) \equiv q(\mathbf{z}_n | \mathbf{x}_n, \phi)$ ):

$$\begin{aligned} \mathcal{L}_n(\mathbf{w}, \phi) &= \int q_n(\mathbf{z}_n) \ln \left\{ \frac{p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) p(\mathbf{z}_n)}{q_n(\mathbf{z}_n)} \right\} d\mathbf{z}_n \\ &= \int q_n(\mathbf{z}_n) \left[ \ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) + \ln p(\mathbf{z}_n) - \ln q_n(\mathbf{z}_n) \right] d\mathbf{z}_n \\ &= \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln \{p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) p(\mathbf{z}_n)\} d\mathbf{z}_n - \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln q(\mathbf{z}_n | \mathbf{x}_n, \phi) d\mathbf{z}_n. \end{aligned} \quad (1)$$

这正是 (19.24)。等价地, 也可由 (19.14)

$$\mathcal{L}_n = \int q \ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) d\mathbf{z}_n - \text{KL}(q \| p(\mathbf{z}_n))$$

出发, 利用  $\text{KL}(q \| p) = \int q \ln \frac{q}{p} d\mathbf{z} = \int q \ln q d\mathbf{z} - \int q \ln p d\mathbf{z}$  将第二项展开, 即得同样结果。

因此

$$\mathcal{L}_n(\mathbf{w}, \phi) = \mathbb{E}_q[\ln p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) + \ln p(\mathbf{z}_n)] + H[q(\mathbf{z}_n | \mathbf{x}_n, \phi)]$$

其中  $H[q] = -\int q \ln q$  为  $q$  的熵。

□

## 练习 19.6 解答 (★)

题目 证明将 ELBO (19.11)

$$\mathcal{L}_n(\mathbf{w}, \phi) = \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln \left\{ \frac{p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w}) p(\mathbf{z}_n)}{q(\mathbf{z}_n | \mathbf{x}_n, \phi)} \right\} d\mathbf{z}_n$$

等价改写为 (19.25)

$$\mathcal{L}_n(\mathbf{w}, \phi) = \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln p(\mathbf{z}_n) d\mathbf{z}_n + \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln \left\{ \frac{p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w})}{q(\mathbf{z}_n | \mathbf{x}_n, \phi)} \right\} d\mathbf{z}_n.$$

解答 记  $q_n(\mathbf{z}) := q(\mathbf{z}_n | \mathbf{x}_n, \phi)$ 、 $p_x(\mathbf{z}) := p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w})$ 、 $p_z(\mathbf{z}) := p(\mathbf{z}_n)$  以简化记号。由对数恒等式  $\ln(ab/c) = \ln a + \ln b - \ln c$  得

$$\begin{aligned} \mathcal{L}_n(\mathbf{w}, \phi) &= \int q_n(\mathbf{z}) \left[ \ln p_x(\mathbf{z}) + \ln p_z(\mathbf{z}) - \ln q_n(\mathbf{z}) \right] d\mathbf{z} \\ &= \underbrace{\int q_n(\mathbf{z}) \ln p_z(\mathbf{z}) d\mathbf{z}}_{\text{第一项}} + \underbrace{\int q_n(\mathbf{z}) \left[ \ln p_x(\mathbf{z}) - \ln q_n(\mathbf{z}) \right] d\mathbf{z}}_{\text{第二项}} \\ &= \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln p(\mathbf{z}_n) d\mathbf{z}_n + \int q(\mathbf{z}_n | \mathbf{x}_n, \phi) \ln \left\{ \frac{p(\mathbf{x}_n | \mathbf{z}_n, \mathbf{w})}{q(\mathbf{z}_n | \mathbf{x}_n, \phi)} \right\} d\mathbf{z}_n, \end{aligned}$$

这正是式 (19.25)。证毕。

---

## Copyright

© 2025 YaoYuzhuo (yaoyuzhuo6@gmail.com).

本作品仅供学术与研究用途。任何形式的商业使用、转载或牟利性衍生作品，须经版权所有者书面许可。任何侵权行为将依法追究责任。

*All rights reserved. This work is made available exclusively for academic and research purposes. Any form of commercial use, redistribution, or derivative work for profit requires prior written authorization from the copyright holder. Any unlawful infringement will be prosecuted in accordance with applicable laws and regulations.*

---