

Solutions to Chapter 20 — *Diffusion Models*

YaoYuzhuo

September , 2025

Based on the textbook Deep Learning: Foundations and Concepts

练习题中文译文及解答

练习 20.1 (★) 使用 (20.3), 把 $\mathbf{z}_t$ 的均值与协方差用 $\mathbf{z}_{t-1}$ 的均值与协方差表示。进而证明: 当 $0 < \beta_t < 1$ 时, $\mathbf{z}_t$ 的分布的均值比 $\mathbf{z}_{t-1}$ 的均值更接近于零, 且 $\mathbf{z}_t$ 的协方差比 $\mathbf{z}_{t-1}$ 的协方差更接近单位矩阵 $\mathbf{I}$ 。

练习 20.2 (★) 证明: 变换 (20.1) 可改写为与之等价的形式 (20.2)。

练习 20.3 (★★★) 本题用数学归纳法证明: 对按 (20.4) 给出的扩散模型前向过程, 其 $\mathbf{z}_t$ 的边缘分布由 (20.6) 给出, 其中 α_t 由 (20.7) 定义。先验证当 $t = 1$ 时 (20.6) 成立; 随后假设 (20.6) 对某个给定的 t 成立, 推导 $t+1$ 时的对应结论。为此, 最便捷的做法是采用表示式 (20.3) 来写出前向过程, 并使用结论 (3.212): 两个相互独立的高斯随机变量之和仍为高斯, 且其均值与协方差分别等于两者均值与协方差之和。

练习 20.4 (★) 利用 (20.6) (其中 α_t 由 (20.7) 定义), 证明在极限 $T \rightarrow \infty$ 时可得到 (20.9)。

练习 20.5 (★★) 设 a 与 b 为两个相互独立的随机变量, λ 为给定标量。证明

$$\text{cov}[a + b] = \text{cov}[a] + \text{cov}[b], \quad (20.61)$$

$$\text{cov}[\lambda a] = \lambda^2 \text{cov}[a]. \quad (20.62)$$

利用上述结果说明: 若 $\mathbf{z}_{t-1}$ 的分布具有零均值与单位协方差, 则无论 β_t 取何值, 由 (20.3) 定义的 $\mathbf{z}_t$ 的分布也同样具有零均值与单位协方差。

练习 20.6 (★★★) 本题用配方 (completing the square) 技巧, 从贝叶斯定理 (20.13) 出发推导结果 (20.15)。首先注意到 (20.13) 右端分子中的两项 (由 (20.4) 与 (20.6) 给出) 都是关于 $\mathbf{z}_{t-1}$ 的二次函数的指数形式。因而所求分布必为高斯分布, 我们只需找出其均值与协方差。为此, 仅保留指数中依赖于 $\mathbf{z}_{t-1}$ 的项, 并利用 “两个指数

的乘积等于指数幂相加”的事实。将所有关于 $\mathbf{z}_{t-1}$ 的二次项与一次项收集起来，并把它们整理为

$$(\mathbf{z}_{t-1} - \mathbf{m}_t)^\top \mathbf{S}_t^{-1} (\mathbf{z}_{t-1} - \mathbf{m}_t)$$

的形式。随后通过观察写出 $\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t)$ 与 $\mathbf{S}_t$ 的表达式。注意：与 $\mathbf{z}_{t-1}$ 无关的加性常数项可忽略不计。

练习 20.7 (★★★) 本题将说明：当噪声方差较小时，扩散模型前向噪声过程的条件分布 $q(\mathbf{z}_t | \mathbf{z}_{t-1})$ 的反向条件分布 $q(\mathbf{z}_{t-1} | \mathbf{z}_t)$ 可近似为高斯分布。考虑由贝叶斯定理写成 (20.11) 形式的反向条件分布，其中前向分布 $q(\mathbf{z}_t | \mathbf{z}_{t-1})$ 由 (20.4) 给出。对 (20.11) 两边取对数，并围绕 $\mathbf{z}_t$ 对 $q(\mathbf{z}_{t-1})$ 作泰勒展开，证明：当噪声方差 β_t 取小值时，分布 $q(\mathbf{z}_{t-1} | \mathbf{z}_t)$ 近似为均值 $\mathbf{z}_t$ 、协方差 $\beta_t \mathbf{I}$ 的高斯分布。进一步，分别给出均值与协方差的最低阶修正项，写成关于 β_t 的幂级数展开。

练习 20.8 (★) 将概率乘积法则以 (20.24) 的形式代入扩散模型的 ELBO 定义式 (20.22)，并利用 Kullback–Leibler 散度的定义 (20.23)，核验对数似然函数可按 (20.21) 写成一个下界与一个 KL 散度之和。

练习 20.9 (★) 验证：由式 (20.31) 给出的扩散模型的 ELBO 可以被改写为式 (20.32) 的形式，其中 Kullback–Leibler 散度按式 (20.23) 定义。

练习 20.10 (★★) 在推导式 (20.32) 所示的扩散模型 ELBO 时，我们在式 (20.26) 中省略了第一项与第三项，因为它们与参数 $\mathbf{w}$ 无关；同样，在式 (20.30) 右端也省略了第二项，因为它同样与 $\mathbf{w}$ 无关。证明：如果把这些被省略的项全部保留，那么单个数据点的 ELBO $\mathcal{L}(\mathbf{x})$ 中将会额外出现如下项：

$$\text{KL}(q(\mathbf{z}_T | \mathbf{x}) \| p(\mathbf{z}_T)). \quad (20.63)$$

注：噪声过程的构造使得 $q(\mathbf{z}_T | \mathbf{x}) = \mathcal{N}(\mathbf{z}_T | \mathbf{0}, \mathbf{I})$ ；同样地， $p(\mathbf{z}_T)$ 也被定义为 $\mathcal{N}(\mathbf{z}_T | \mathbf{0}, \mathbf{I})$ 。因而 (20.63) 中的两分布相同，该 Kullback–Leibler 散度为 0。

练习 20.11 (★★) 利用式 (20.15) 给出的分布 $q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x})$ 与式 (20.18) 给出的分布 $p(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{w})$ ，证明在 (20.32) 的一致性项中出现的 Kullback–Leibler 散度可写为式 (20.33) 的形式。

练习 20.12 (★★) 将式 (20.34) 代入式 (20.16)，把均值 $\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t)$ 用原始数据向量 $\mathbf{x}$ 与噪声 ϵ 表达，得到式 (20.35) 的形式，其中 α_t 由 (20.7) 定义。

练习 20.13 (★★) 证明：扩散模型的 ELBO 中的重构项 (20.38) 可以改写为式 (20.39)。为此，请用 (20.36) 对 $\mu(\mathbf{z}_1, \mathbf{w}, 1)$ 进行代换，用 (20.1) 对 $\mathbf{x}$ 进行代换，并使用由 (20.7) 推出的恒等式 $\alpha_1 = (1 - \beta_1)$ 。

练习 20.14 (★) 记分数函数 (score function) 定义为 $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} p(\mathbf{x} | \mathbf{w})$, 因而它与输入向量 $\mathbf{x}$ 具有相同的维度。考虑由下式给出的矩阵元素

$$M_{ij} = \frac{\partial s_i}{\partial x_j} - \frac{\partial s_j}{\partial x_i}. \quad (20.64)$$

证明: 如果将分数函数表示为某个单输出神经网络 $\phi(\mathbf{x})$ 的梯度, 即 $\mathbf{s} = \nabla_{\mathbf{x}} \phi(\mathbf{x})$, 则对任意成对的指标 i, j 都有 $M_{ij} = 0$ 。注意: 若改为直接用一个深度神经网络 (其输出维数与输入维数相同) 来表示分数函数 $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} p(\mathbf{x} | \mathbf{w})$, 那么仅有对角元 $M_{ii} = 0$; 因此该网络的一般输出并不对应于某个标量函数的梯度。

练习 20.15 (★★) 设分数函数按式 (20.42) 给出, 并用一个深度神经网络表示为 $\mathbf{s}(\mathbf{x}, \mathbf{w})$, 其中 $\mathbf{x}$ 与 $\mathbf{s}$ 的维度均为 D 。比较两种实现评估分数函数的计算复杂度:

- (a) 直接用一个具有 D 个输出的网络来表示分数函数 $\mathbf{s}(\mathbf{x}, \mathbf{w})$;
- (b) 用一个单输出标量网络 $\phi(\mathbf{x}, \mathbf{w})$ 来表示某个标量函数, 再通过自动微分间接计算其梯度 $\nabla_{\mathbf{x}} \phi(\mathbf{x}, \mathbf{w})$ 作为分数函数。

证明: 通常情形下, 方案 (b) 的计算代价更高。

练习 20.16 (★★★) 我们无法直接最小化记分 (score) 损失 (20.43), 因为我们并不知道真实数据密度 $p(\mathbf{x})$ 的函数形式, 从而也就无法写出其得分函数 $\nabla_{\mathbf{x}} \ln p(\mathbf{x})$ 的显式表达式。然而, 利用分部积分 (Hyvärinen, 2005), 可以把 (20.43) 改写为

$$J(\mathbf{w}) = \int \left\{ \nabla_{\mathbf{x}} \cdot \mathbf{s}(\mathbf{x}, \mathbf{w}) + \frac{1}{2} \|\mathbf{s}(\mathbf{x}, \mathbf{w})\|^2 \right\} p(\mathbf{x}) d\mathbf{x} + \text{const} \quad (20.65)$$

其中 “const” 是不依赖于网络参数 $\mathbf{w}$ 的常数项; 并且散度 $\nabla_{\mathbf{x}} \cdot \mathbf{s}(\mathbf{x}, \mathbf{w})$ 定义为

$$\nabla_{\mathbf{x}} \cdot \mathbf{s} = \sum_{i=1}^D \frac{\partial s_i}{\partial x_i} = \sum_{i=1}^D \frac{\partial^2 \ln p(\mathbf{x})}{\partial x_i^2}, \quad (20.66)$$

这里 D 是 $\mathbf{x}$ 的维度。

请推导结果 (20.65): 先把 (20.43) 中的平方项完全展开, 并注意其中出现的 $\|\mathbf{s}(\mathbf{x}, \mathbf{w})\|^2$ 项已经包含在 (20.65) 的加法常数中; 令 $\mathbf{s}_D = \nabla_{\mathbf{x}} \ln p_D(\mathbf{x})$ 。接着考虑两个函数乘积的求导公式

$$\frac{d}{dx} \{p(x)g(x)\} = \frac{dp(x)}{dx} g(x) + p(x) \frac{dg(x)}{dx}, \quad (20.67)$$

对其两边关于 x 积分并整理, 可得到分部积分公式:

$$\int_{-\infty}^{\infty} \frac{dp(x)}{dx} g(x) dx = - \int_{-\infty}^{\infty} \frac{dg(x)}{dx} p(x) dx, \quad (20.68)$$

其中我们假设 $p(\infty) = p(-\infty) = 0$ 。将该结果与 $\mathbf{s}_D = \nabla_{\mathbf{x}} \ln p(\mathbf{x})$ 的定义结合, 把 $\mathbf{s}(\mathbf{x}, \mathbf{w})^\top \mathbf{s}_D$ 一项替换为 $\nabla_{\mathbf{x}} \cdot \mathbf{s}(\mathbf{x}, \mathbf{w})$ 即可完成证明。

注意：(20.66) 中的二阶导数在计算时需要为每个分量做一次反向传播，总的计算量随着数据维度 D 近似二次增长 (Martens, Sutskever, and Swersky, 2012)。这使得该损失在高维空间中直接应用代价过高，因此提出了诸如 *sliced score matching* (Song et al., 2019) 等技术来缓解这一低效性。

练习 20.17 (★★) 本题要证明：记分函数损失 (20.50) 与 (20.49) 至多相差一个加性常数，即它们等价于一个常数项。为此，请按如下步骤进行：先将 (20.49) 中的平方项完全展开，并利用 (20.47) 证明：来自 (20.49) 的 $\mathbf{s}^\top \mathbf{s}$ 项与展开 (20.50) 后得到的对应项相同。接着注意到：(20.49) 中的 $\|\nabla_{\mathbf{z}} \ln q\|^2$ 项与 (20.50) 中的对应项都与 $\mathbf{w}$ 无关，因此在损失函数中可视为加性常数，在训练中不起作用。最后，比较 (20.49) 的交叉项；将 (20.47) 代入以表示 $q(\mathbf{z})$ ，证明该交叉项与 (20.50) 的对应交叉项相等。由此得出结论：两种损失函数仅相差一个加性常数，因此等价。

练习 20.18 (★) 考虑由两个不相交分布构成的混合概率分布（即在任一点 $\mathbf{x}$ 上，只要其中一个分布取非零值，另一个就必为零），其形式为

$$p(\mathbf{x}) = \lambda p_A(\mathbf{x}) + (1 - \lambda) p_B(\mathbf{x}). \quad (20.69)$$

证明：当在任意给定点 $\mathbf{x}$ 处计算由式 (20.42) 定义的 score 函数 $s(\mathbf{x}) = \nabla_{\mathbf{x}} \ln p(\mathbf{x})$ 时，混合系数 λ 不会出现在结果中（亦即 $s(\mathbf{x})$ 与 λ 无关；在 p_A 的支撑集上 $s(\mathbf{x}) = \nabla_{\mathbf{x}} \ln p_A(\mathbf{x})$ ，在 p_B 的支撑集上 $s(\mathbf{x}) = \nabla_{\mathbf{x}} \ln p_B(\mathbf{x})$ ）。由此推出：按 (14.61) 所定义的 Langevin 动力学从该混合分布采样时，无法按正确比例从两个分量分布中取样。说明：该问题可通过向数据加入一个宽的噪声分布来解决，详见正文讨论。

练习 20.19 (★★) 在离散步长下，扩散模型的前向加噪过程由式 (20.3) 给出。现在取连续时间极限，并把该过程改写为一条随机微分方程 (SDE)。为此先引入随时间连续变化的方差函数 $\beta(t)$ ，使得 $\beta_t = \beta(t) \Delta t$ 。对 (20.3) 右端第一项中的平方根作泰勒展开，进而证明无穷小更新可写成

$$d\mathbf{z} = -\frac{1}{2} \beta(t) \mathbf{z} dt + \sqrt{\beta(t)} d\mathbf{v}. \quad (20.70)$$

由此可见，上式是一般 SDE (20.55) 的一个特例。

练习 20.20 (★) 用式 (20.58) 将 (20.59) 中的项 $\nabla_{\mathbf{x}} \ln p(c | \mathbf{x})$ 进行替换，证明 (20.59) 给出的 score 函数可以改写为式 (20.60) 的形式。

下面将进行详细解答！

练习 20.1 解答 (★)

题目 利用式 (20.3)

$$\mathbf{z}_t = \sqrt{1 - \beta_t} \mathbf{z}_{t-1} + \sqrt{\beta_t} \boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

写出 $\mathbf{z}_t$ 的均值与协方差, 用 $\mathbf{z}_{t-1}$ 的均值与协方差表示。从而证明: 当 $0 < \beta_t < 1$ 时, $\mathbf{z}_t$ 的均值相比于 $\mathbf{z}_{t-1}$ 更接近于零, 并且 $\mathbf{z}_t$ 的协方差相比于 $\mathbf{z}_{t-1}$ 更接近于单位阵 $\mathbf{I}$ 。

解答

记

$$\boldsymbol{\mu}_{t-1} := \mathbb{E}[\mathbf{z}_{t-1}], \quad \boldsymbol{\Sigma}_{t-1} := \text{cov}(\mathbf{z}_{t-1}),$$

并假设 $\boldsymbol{\epsilon}_t$ 与 $\mathbf{z}_{t-1}$ 独立。

1) 均值

$$\begin{aligned} \boldsymbol{\mu}_t &:= \mathbb{E}[\mathbf{z}_t] = \sqrt{1 - \beta_t} \mathbb{E}[\mathbf{z}_{t-1}] + \sqrt{\beta_t} \mathbb{E}[\boldsymbol{\epsilon}_t] \\ &= \sqrt{1 - \beta_t} \boldsymbol{\mu}_{t-1}. \\ \boldsymbol{\mu}_t &= \sqrt{1 - \beta_t} \boldsymbol{\mu}_{t-1}. \end{aligned} \tag{A}$$

由于 $0 < \sqrt{1 - \beta_t} < 1$, 有 $\|\boldsymbol{\mu}_t\| = \sqrt{1 - \beta_t} \|\boldsymbol{\mu}_{t-1}\| \leq \|\boldsymbol{\mu}_{t-1}\|$ (当 $\boldsymbol{\mu}_{t-1} \neq \mathbf{0}$ 时为严格不等), 故均值更接近于 $\mathbf{0}$ 。

2) 协方差 设 $\mathbf{A} = \sqrt{1 - \beta_t} \mathbf{I}$ 、 $\mathbf{B} = \sqrt{\beta_t} \mathbf{I}$ 。由独立性与线性变换的方差公式

$$\text{cov}(\mathbf{A}\mathbf{u} + \mathbf{B}\mathbf{v}) = \mathbf{A} \text{cov}(\mathbf{u}) \mathbf{A}^\top + \mathbf{B} \text{cov}(\mathbf{v}) \mathbf{B}^\top,$$

得

$$\begin{aligned} \boldsymbol{\Sigma}_t &:= \text{cov}(\mathbf{z}_t) = (1 - \beta_t) \boldsymbol{\Sigma}_{t-1} + \beta_t \mathbf{I}. \\ \boldsymbol{\Sigma}_t &= (1 - \beta_t) \boldsymbol{\Sigma}_{t-1} + \beta_t \mathbf{I}. \end{aligned} \tag{B}$$

进一步改写为

$$\boldsymbol{\Sigma}_t - \mathbf{I} = (1 - \beta_t)(\boldsymbol{\Sigma}_{t-1} - \mathbf{I}). \tag{C}$$

于是, 对任意向量 $\mathbf{v}$,

$$\mathbf{v}^\top (\boldsymbol{\Sigma}_t - \mathbf{I}) \mathbf{v} = (1 - \beta_t) \mathbf{v}^\top (\boldsymbol{\Sigma}_{t-1} - \mathbf{I}) \mathbf{v}.$$

因为 $0 < 1 - \beta_t < 1$, 上式说明 $\boldsymbol{\Sigma}_t$ 与 $\mathbf{I}$ 的偏离缩小了系数 $1 - \beta_t$ 倍, 例如 $\|\boldsymbol{\Sigma}_t - \mathbf{I}\|_F = (1 - \beta_t) \|\boldsymbol{\Sigma}_{t-1} - \mathbf{I}\|_F$ 。因此 $\boldsymbol{\Sigma}_t$ 比 $\boldsymbol{\Sigma}_{t-1}$ 更接近 $\mathbf{I}$ 。

结论 由 (A) 与 (B)/(C) 得

$$\boxed{\boldsymbol{\mu}_t = \sqrt{1 - \beta_t} \boldsymbol{\mu}_{t-1}, \quad \boldsymbol{\Sigma}_t = (1 - \beta_t) \boldsymbol{\Sigma}_{t-1} + \beta_t \mathbf{I}}$$

并且当 $0 < \beta_t < 1$ 时, $\mathbf{z}_t$ 的均值更接近于 $\mathbf{0}$, 其协方差更接近于 $\mathbf{I}$ 。 □

练习 20.2 解答 (★)

题目 证明：式 (20.1)

$$\mathbf{z}_1 = \sqrt{1 - \beta_1} \mathbf{x} + \sqrt{\beta_1} \boldsymbol{\epsilon}_1, \quad \boldsymbol{\epsilon}_1 \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

可等价地写成条件分布形式 (20.2):

$$q(\mathbf{z}_1 | \mathbf{x}) = \mathcal{N}(\mathbf{z}_1 | \sqrt{1 - \beta_1} \mathbf{x}, \beta_1 \mathbf{I}).$$

解答 在给定 $\mathbf{x}$ 的条件下, $\mathbf{z}_1$ 是对高斯噪声 $\boldsymbol{\epsilon}_1$ 的仿射变换:

$$\mathbf{z}_1 = \underbrace{\sqrt{1 - \beta_1} \mathbf{x}}_{\text{常量偏移}} + \underbrace{\sqrt{\beta_1} \mathbf{I}}_{\text{线性变换}} \boldsymbol{\epsilon}_1.$$

仿射变换对高斯分布保持封闭性, 因此 $\mathbf{z}_1 | \mathbf{x}$ 仍为高斯分布, 其均值与协方差为

$$\mathbb{E}[\mathbf{z}_1 | \mathbf{x}] = \sqrt{1 - \beta_1} \mathbf{x} + \sqrt{\beta_1} \mathbb{E}[\boldsymbol{\epsilon}_1] = \sqrt{1 - \beta_1} \mathbf{x},$$

$$\text{cov}(\mathbf{z}_1 | \mathbf{x}) = \sqrt{\beta_1} \mathbf{I} \text{cov}(\boldsymbol{\epsilon}_1) (\sqrt{\beta_1} \mathbf{I})^\top = \beta_1 \mathbf{I}.$$

于是

$$\boxed{\mathbf{z}_1 | \mathbf{x} \sim \mathcal{N}(\sqrt{1 - \beta_1} \mathbf{x}, \beta_1 \mathbf{I})}$$

即

$$q(\mathbf{z}_1 | \mathbf{x}) = (2\pi\beta_1)^{-D/2} \exp\left\{-\frac{1}{2\beta_1} \left\|\mathbf{z}_1 - \sqrt{1 - \beta_1} \mathbf{x}\right\|^2\right\},$$

这与教材中的式 (20.2) 完全一致。证毕。

练习 20.3 解答 (★★★)

题目 利用归纳法证明：对扩散模型的前向过程 (20.4)，其边缘分布

$$q(\mathbf{z}_t | \mathbf{x})$$

满足 (20.6)

$$q(\mathbf{z}_t | \mathbf{x}) = \mathcal{N}(\mathbf{z}_t | \sqrt{\alpha_t} \mathbf{x}, (1 - \alpha_t) \mathbf{I}),$$

其中 (20.7)

$$\alpha_t = \prod_{\tau=1}^t (1 - \beta_\tau).$$

先验证 $t = 1$ 的情形；再假设某个 t 成立，推出 $t+1$ 成立。证明时用到表示式 (20.3)

$$\mathbf{z}_t = \sqrt{1 - \beta_t} \mathbf{z}_{t-1} + \sqrt{\beta_t} \boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

以及结果 (3.212)：两相互独立的高斯随机变量之和仍为高斯，且其均值与协方差分别等于两者均值与协方差之和。

证明

(1) 基例 $t = 1$ 由 (20.1) 或 (20.3) 可得

$$\mathbf{z}_1 = \sqrt{1 - \beta_1} \mathbf{x} + \sqrt{\beta_1} \boldsymbol{\epsilon}_1, \quad \boldsymbol{\epsilon}_1 \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

因此

$$q(\mathbf{z}_1 | \mathbf{x}) = \mathcal{N}(\mathbf{z}_1 | \sqrt{1 - \beta_1} \mathbf{x}, \beta_1 \mathbf{I}).$$

注意到 $\alpha_1 = 1 - \beta_1$ 、 $1 - \alpha_1 = \beta_1$ ，于是 (20.6) 在 $t = 1$ 时成立。

(2) 归纳步 $t \rightarrow t+1$ 归纳假设：对某个 $t \geq 1$,

$$q(\mathbf{z}_t | \mathbf{x}) = \mathcal{N}(\mathbf{z}_t | \sqrt{\alpha_t} \mathbf{x}, (1 - \alpha_t) \mathbf{I}), \quad \alpha_t = \prod_{\tau=1}^t (1 - \beta_\tau).$$

由 (20.3) 有

$$\mathbf{z}_{t+1} = \sqrt{1 - \beta_{t+1}} \mathbf{z}_t + \sqrt{\beta_{t+1}} \boldsymbol{\epsilon}_{t+1}, \quad \boldsymbol{\epsilon}_{t+1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

并且 $\boldsymbol{\epsilon}_{t+1}$ 与 $\mathbf{z}_t$ 独立。对给定 $\mathbf{x}$ ，由线性变换与 (3.212)， $\sqrt{1 - \beta_{t+1}} \mathbf{z}_t$ 为

$$\mathcal{N}\left(\sqrt{1 - \beta_{t+1}} \sqrt{\alpha_t} \mathbf{x}, (1 - \beta_{t+1})(1 - \alpha_t) \mathbf{I}\right),$$

而 $\sqrt{\beta_{t+1}} \boldsymbol{\epsilon}_{t+1}$ 为 $\mathcal{N}(\mathbf{0}, \beta_{t+1} \mathbf{I})$ 。两者独立相加得到

$$q(\mathbf{z}_{t+1} | \mathbf{x}) = \mathcal{N}\left(\mathbf{z}_{t+1} | \sqrt{(1 - \beta_{t+1})\alpha_t} \mathbf{x}, ((1 - \beta_{t+1})(1 - \alpha_t) + \beta_{t+1}) \mathbf{I}\right).$$

化简均值与协方差系数:

$$\sqrt{(1 - \beta_{t+1})\alpha_t} = \sqrt{\alpha_{t+1}}, \quad (1 - \beta_{t+1})(1 - \alpha_t) + \beta_{t+1} = 1 - \alpha_t(1 - \beta_{t+1}) = 1 - \alpha_{t+1},$$

其中 $\alpha_{t+1} := \alpha_t(1 - \beta_{t+1}) = \prod_{\tau=1}^{t+1} (1 - \beta_\tau)$ 。因此

$$q(\mathbf{z}_{t+1} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z}_{t+1} \mid \sqrt{\alpha_{t+1}}\mathbf{x}, (1 - \alpha_{t+1})\mathbf{I}),$$

即命题对 $t+1$ 成立。

(3) 结论 由数学归纳法知, 对所有 $t \geq 1$, 均有

$$q(\mathbf{z}_t \mid \mathbf{x}) = \mathcal{N}(\mathbf{z}_t \mid \sqrt{\alpha_t}\mathbf{x}, (1 - \alpha_t)\mathbf{I}), \quad \alpha_t = \prod_{\tau=1}^t (1 - \beta_\tau).$$

附注 上式也等价于写成 (20.8) 的显式形式 $\mathbf{z}_t = \sqrt{\alpha_t}\mathbf{x} + \sqrt{1 - \alpha_t}\boldsymbol{\epsilon}_t$, $\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

练习 20.4 解答 (★)

题目 利用结果 (20.6)，其中 α_t 由 (20.7) 定义，证明：当 $T \rightarrow \infty$ 时可得到 (20.9)。

已知 由扩散核 (20.6) 可得

$$q(\mathbf{z}_t \mid \mathbf{x}) = \mathcal{N}(\mathbf{z}_t \mid \sqrt{\alpha_t} \mathbf{x}, (1 - \alpha_t) \mathbf{I}),$$

其中

$$\alpha_t = \prod_{\tau=1}^t (1 - \beta_\tau), \quad 0 < \beta_\tau < 1.$$

目标 证明当 $t = T \rightarrow \infty$ 时， $\sqrt{\alpha_T} \mathbf{x} \rightarrow \mathbf{0}$ 且 $(1 - \alpha_T) \mathbf{I} \rightarrow \mathbf{I}$ ，从而 $q(\mathbf{z}_T \mid \mathbf{x}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，这正是 (20.9)。

证明

首先注意 $0 < 1 - \beta_\tau < 1$ ，故 $\alpha_t \in (0, 1)$ 且随 t 单调不增。对任意 $u \in (0, 1)$ 有 $\ln(1 - u) \leq -u$ 。因此

$$\ln \alpha_t = \sum_{\tau=1}^t \ln(1 - \beta_\tau) \leq -\sum_{\tau=1}^t \beta_\tau.$$

若 $\sum_{\tau=1}^{\infty} \beta_\tau = +\infty$ (扩散模型中常见的设定：每步噪声方差为正，且累计噪声无限增大)，则 $\ln \alpha_t \rightarrow -\infty$ ，从而 $\alpha_t \rightarrow 0$ 并且 $\sqrt{\alpha_t} \mathbf{x} \rightarrow \mathbf{0}$ ；同时 $1 - \alpha_t \rightarrow 1$ ，即 $(1 - \alpha_t) \mathbf{I} \rightarrow \mathbf{I}$ 。

于是，

$$q(\mathbf{z}_T \mid \mathbf{x}) = \mathcal{N}(\mathbf{z}_T \mid \sqrt{\alpha_T} \mathbf{x}, (1 - \alpha_T) \mathbf{I}) \xrightarrow{T \rightarrow \infty} \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

这就得到 (20.9)。

说明 即便不显式要求 $\sum_{\tau} \beta_\tau = +\infty$ ，在实际调度 (例如把 T 取为很大且每步 $\beta_\tau > 0$) 下， α_T 也会极小，从而 $q(\mathbf{z}_T \mid \mathbf{x})$ 近似于 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

□

练习 20.5 解答 (★★)

题目 设 $\mathbf{a}$ 与 $\mathbf{b}$ 为相互独立的随机向量, λ 为常数。证明

$$\text{cov}[\mathbf{a} + \mathbf{b}] = \text{cov}[\mathbf{a}] + \text{cov}[\mathbf{b}], \quad \text{cov}[\lambda \mathbf{a}] = \lambda^2 \text{cov}[\mathbf{a}].$$

据此证明: 若 $\mathbf{z}_{t-1}$ 的分布具有零均值与单位协方差, 则由

$$\mathbf{z}_t = \sqrt{1 - \beta_t} \mathbf{z}_{t-1} + \sqrt{\beta_t} \boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \boldsymbol{\epsilon}_t \text{ 与 } \mathbf{z}_{t-1} \text{ 独立},$$

所定义的 $\mathbf{z}_t$ 也具有零均值与单位协方差, 且与 β_t 的取值无关。

证明

(a) 协方差的两条恒等式 记 $\boldsymbol{\mu}_a = \mathbb{E}[\mathbf{a}]$ 、 $\boldsymbol{\mu}_b = \mathbb{E}[\mathbf{b}]$, 并用

$$\text{cov}[\mathbf{u}] = \mathbb{E}[(\mathbf{u} - \mathbb{E}[\mathbf{u}])(\mathbf{u} - \mathbb{E}[\mathbf{u}])^\top].$$

则

$$\begin{aligned} \text{cov}[\mathbf{a} + \mathbf{b}] &= \mathbb{E}\left[\left((\mathbf{a} - \boldsymbol{\mu}_a) + (\mathbf{b} - \boldsymbol{\mu}_b)\right)\left((\mathbf{a} - \boldsymbol{\mu}_a) + (\mathbf{b} - \boldsymbol{\mu}_b)\right)^\top\right] \\ &= \text{cov}[\mathbf{a}] + \text{cov}[\mathbf{b}] + \underbrace{\mathbb{E}[(\mathbf{a} - \boldsymbol{\mu}_a)(\mathbf{b} - \boldsymbol{\mu}_b)^\top]}_{= \mathbf{0}} + \underbrace{\mathbb{E}[(\mathbf{b} - \boldsymbol{\mu}_b)(\mathbf{a} - \boldsymbol{\mu}_a)^\top]}_{= \mathbf{0}}. \end{aligned}$$

上式两项交叉协方差之所以为零, 是因为独立 $\Rightarrow$ 积分可分, 从而 $\mathbb{E}[(\mathbf{a} - \boldsymbol{\mu}_a)(\mathbf{b} - \boldsymbol{\mu}_b)^\top] = \mathbb{E}[\mathbf{a} - \boldsymbol{\mu}_a] \mathbb{E}[\mathbf{b} - \boldsymbol{\mu}_b]^\top = \mathbf{0}$ 。因此

$$\boxed{\text{cov}[\mathbf{a} + \mathbf{b}] = \text{cov}[\mathbf{a}] + \text{cov}[\mathbf{b}]}$$

对任意常数 λ , 由线性变换的协方差公式 $\text{cov}[A\mathbf{u}] = A \text{cov}[\mathbf{u}] A^\top$ (取 $A = \lambda \mathbf{I}$) 可得

$$\boxed{\text{cov}[\lambda \mathbf{a}] = \lambda^2 \text{cov}[\mathbf{a}]}$$

(b) 应用于 $\mathbf{z}_t$ 的均值与协方差 若 $\mathbb{E}[\mathbf{z}_{t-1}] = \mathbf{0}$ 、 $\text{cov}[\mathbf{z}_{t-1}] = \mathbf{I}$, 则

$$\mathbb{E}[\mathbf{z}_t] = \sqrt{1 - \beta_t} \mathbb{E}[\mathbf{z}_{t-1}] + \sqrt{\beta_t} \mathbb{E}[\boldsymbol{\epsilon}_t] = \mathbf{0}.$$

又由(a)及 $\boldsymbol{\epsilon}_t \perp \mathbf{z}_{t-1}$ (交叉项为零),

$$\begin{aligned} \text{cov}[\mathbf{z}_t] &= \text{cov}[\sqrt{1 - \beta_t} \mathbf{z}_{t-1}] + \text{cov}[\sqrt{\beta_t} \boldsymbol{\epsilon}_t] \\ &= (1 - \beta_t) \text{cov}[\mathbf{z}_{t-1}] + \beta_t \text{cov}[\boldsymbol{\epsilon}_t] \\ &= (1 - \beta_t) \mathbf{I} + \beta_t \mathbf{I} = \mathbf{I}. \end{aligned}$$

因此 $\mathbf{z}_t$ 具有零均值与单位协方差, 且结论与 β_t 的具体取值无关。证毕。

补充说明

- 上述“和的协方差等于协方差之和”并不要求独立，只需不相关（交叉协方差为零）即成立。
- 在(b)中并不需要 ϵ_t 为高斯分布；只要满足 $\mathbb{E}[\epsilon_t] = \mathbf{0}$ 、 $\text{cov}[\epsilon_t] = \mathbf{I}$ ，且与 $\mathbf{z}_{t-1}$ 不相关（通常取独立）即可。
- 更一般地，对任意均值与协方差 $(\boldsymbol{\mu}_{t-1}, \boldsymbol{\Sigma}_{t-1})$ ，由线性变换可得

$$\boldsymbol{\mu}_t = \sqrt{1 - \beta_t} \boldsymbol{\mu}_{t-1}, \quad \boldsymbol{\Sigma}_t = (1 - \beta_t) \boldsymbol{\Sigma}_{t-1} + \beta_t \mathbf{I}.$$

于是 $(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = (\mathbf{0}, \mathbf{I})$ 是该一步更新的不变点。

练习 20.6 解答 (★★★)

题目 从贝叶斯公式

$$q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x}) = \frac{q(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x}) q(\mathbf{z}_{t-1} | \mathbf{x})}{q(\mathbf{z}_t | \mathbf{x})}$$

出发, 利用“配方”(completing the square) 推导式 (20.15) 中 $q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x}) = \mathcal{N}(\mathbf{z}_{t-1} | \mathbf{m}_t(\mathbf{x}, \mathbf{z}_t), \mathbf{S}_t)$ 的均值 $\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t)$ 与协方差 $\mathbf{S}_t$ 。提示: 只保留指数里关于 $\mathbf{z}_{t-1}$ 的二次与一次项, 并使用 (20.4)、(20.6) 以及 $\alpha_t = \alpha_{t-1}(1 - \beta_t)$ (见 (20.7))。

解答

由马尔可夫性质 $q(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x}) = q(\mathbf{z}_t | \mathbf{z}_{t-1})$, 而分母 $q(\mathbf{z}_t | \mathbf{x})$ 与 $\mathbf{z}_{t-1}$ 无关, 可并入归一化常数。因此

$$q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x}) \propto q(\mathbf{z}_t | \mathbf{z}_{t-1}) q(\mathbf{z}_{t-1} | \mathbf{x}).$$

把 (20.4) 与 (20.6) 写成指数二次型:

$$\begin{aligned} q(\mathbf{z}_t | \mathbf{z}_{t-1}) &\propto \exp\left[-\frac{1}{2\beta_t} \|\mathbf{z}_t - \sqrt{1-\beta_t} \mathbf{z}_{t-1}\|^2\right], \\ q(\mathbf{z}_{t-1} | \mathbf{x}) &\propto \exp\left[-\frac{1}{2(1-\alpha_{t-1})} \|\mathbf{z}_{t-1} - \sqrt{\alpha_{t-1}} \mathbf{x}\|^2\right]. \end{aligned}$$

两式相乘并合并指数, 只保留与 $\mathbf{z}_{t-1}$ 有关的项, 得到

$$\begin{aligned} \log q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x}) = & -\frac{1}{2} \left[\underbrace{\mathbf{z}_{t-1}^\top \left(\frac{1-\beta_t}{\beta_t} \mathbf{I} + \frac{1}{1-\alpha_{t-1}} \mathbf{I} \right) \mathbf{z}_{t-1}}_{\mathbf{\Lambda}} \right. \\ & \left. - 2 \underbrace{\left(\frac{\sqrt{1-\beta_t}}{\beta_t} \mathbf{z}_t + \frac{\sqrt{\alpha_{t-1}}}{1-\alpha_{t-1}} \mathbf{x} \right)^\top \mathbf{z}_{t-1}}_{\boldsymbol{\eta}} \right] + \text{const.} \end{aligned}$$

其中“const”与 $\mathbf{z}_{t-1}$ 无关, 可忽略。把二次型配方为 $-\frac{1}{2}(\mathbf{z}_{t-1} - \mathbf{m})^\top \mathbf{\Lambda}(\mathbf{z}_{t-1} - \mathbf{m})$ 的形式, 可知

$$\mathbf{S}_t = \mathbf{\Lambda}^{-1}, \quad \mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) = \mathbf{S}_t \boldsymbol{\eta}.$$

协方差 对角形式给出

$$\mathbf{\Lambda} = \left(\frac{1-\beta_t}{\beta_t} + \frac{1}{1-\alpha_{t-1}} \right) \mathbf{I} = \frac{1-\alpha_t}{\beta_t(1-\alpha_{t-1})} \mathbf{I},$$

其中用到了 $\alpha_t = \alpha_{t-1}(1 - \beta_t)$ 。于是

$$\boxed{\mathbf{S}_t = \sigma_t^2 \mathbf{I}, \quad \sigma_t^2 = \frac{\beta_t(1-\alpha_{t-1})}{1-\alpha_t}}$$

这就是 (20.17)。

均值 由 $\mathbf{m}_t = \mathbf{S}_t \boldsymbol{\eta}$ 得

$$\begin{aligned}\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) &= \frac{\beta_t(1 - \alpha_{t-1})}{1 - \alpha_t} \left(\frac{\sqrt{1 - \beta_t}}{\beta_t} \mathbf{z}_t + \frac{\sqrt{\alpha_{t-1}}}{1 - \alpha_{t-1}} \mathbf{x} \right) \\ &= \frac{(1 - \alpha_{t-1})\sqrt{1 - \beta_t}}{1 - \alpha_t} \mathbf{z}_t + \frac{\sqrt{\alpha_{t-1}}\beta_t}{1 - \alpha_t} \mathbf{x}.\end{aligned}$$

即

$$\boxed{\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) = \frac{(1 - \alpha_{t-1})\sqrt{1 - \beta_t}}{1 - \alpha_t} \mathbf{z}_t + \frac{\sqrt{\alpha_{t-1}}\beta_t}{1 - \alpha_t} \mathbf{x}}$$

这与教材 (20.16) 一致。

综上，利用配方把 $q(\mathbf{z}_t | \mathbf{z}_{t-1}) q(\mathbf{z}_{t-1} | \mathbf{x})$ 写成关于 $\mathbf{z}_{t-1}$ 的高斯形式，即得 (20.15)–(20.17)。

□

练习 20.7 解答 (★★★)

题目 考虑正向噪声过程的条件分布

$$q(\mathbf{z}_t | \mathbf{z}_{t-1}) = \mathcal{N}(\mathbf{z}_t | \sqrt{1 - \beta_t} \mathbf{z}_{t-1}, \beta_t \mathbf{I}).$$

利用贝叶斯公式

$$q(\mathbf{z}_{t-1} | \mathbf{z}_t) = \frac{q(\mathbf{z}_t | \mathbf{z}_{t-1}) q(\mathbf{z}_{t-1})}{q(\mathbf{z}_t)}$$

对两边取对数，并把 $q(\mathbf{z}_{t-1})$ 在 $\mathbf{z}_t$ 处作泰勒展开，证明：当噪声方差 β_t 很小时， $q(\mathbf{z}_{t-1} | \mathbf{z}_t)$ 近似为均值 $\mathbf{z}_t$ 、协方差 $\beta_t \mathbf{I}$ 的高斯分布。进一步，给出均值与协方差关于 β_t 的最低阶修正项。

解答

记 $\mathbf{u} = \mathbf{z}_{t-1}$ 、 $\mathbf{z} = \mathbf{z}_t$ ，令

$$s(\mathbf{z}) := \nabla_{\mathbf{z}} \ln q(\mathbf{z}), \quad \mathbf{H}(\mathbf{z}) := \nabla_{\mathbf{z}}^2 \ln q(\mathbf{z})$$

分别为边缘分布 $q(\mathbf{z})$ 的 score 与其 Hessian，均在 $\mathbf{z}$ 处求值。由贝叶斯公式，有

$$\ln q(\mathbf{u} | \mathbf{z}) = \ln q(\mathbf{z} | \mathbf{u}) + \ln q(\mathbf{u}) - \ln q(\mathbf{z}).$$

最后一项与 $\mathbf{u}$ 无关，可视为常数。把 $\ln q(\mathbf{u})$ 在 $\mathbf{z}$ 处做二阶泰勒展开，记 $\boldsymbol{\delta} := \mathbf{u} - \mathbf{z}$ ，得

$$\ln q(\mathbf{u}) = \ln q(\mathbf{z}) + s(\mathbf{z})^\top \boldsymbol{\delta} + \frac{1}{2} \boldsymbol{\delta}^\top \mathbf{H}(\mathbf{z}) \boldsymbol{\delta} + \mathcal{O}(\|\boldsymbol{\delta}\|^3). \quad (1)$$

另一方面，正向核 $q(\mathbf{z} | \mathbf{u}) = \mathcal{N}(\sqrt{1 - \beta_t} \mathbf{u}, \beta_t \mathbf{I})$ 给出

$$\ln q(\mathbf{z} | \mathbf{u}) = -\frac{1}{2\beta_t} \left\| \mathbf{z} - \sqrt{1 - \beta_t} \mathbf{u} \right\|^2 + \text{const.}$$

当 β_t 很小时， $\sqrt{1 - \beta_t} = 1 - \frac{1}{2}\beta_t + \mathcal{O}(\beta_t^2)$ ，于是

$$\mathbf{z} - \sqrt{1 - \beta_t} \mathbf{u} = \mathbf{z} - \mathbf{u} + \frac{1}{2}\beta_t \mathbf{u} + \mathcal{O}(\beta_t^2) = -\boldsymbol{\delta} + \frac{1}{2}\beta_t(\mathbf{z} + \boldsymbol{\delta}) + \mathcal{O}(\beta_t^2).$$

保留到 $\mathcal{O}(\beta_t)$ ，平方并代回得

$$\ln q(\mathbf{z} | \mathbf{u}) = -\frac{1}{2\beta_t} \|\boldsymbol{\delta}\|^2 + \frac{1}{2} \boldsymbol{\delta}^\top \boldsymbol{\delta} + \frac{1}{2} \mathbf{z}^\top \boldsymbol{\delta} + \mathcal{O}(\beta_t). \quad (2)$$

把 (1) 与 (2) 相加（并丢弃与 $\mathbf{u}$ 无关的常数），得到

$$\ln q(\mathbf{u} | \mathbf{z}) = -\frac{1}{2\beta_t} \|\boldsymbol{\delta}\|^2 + \frac{1}{2} \boldsymbol{\delta}^\top (\mathbf{I} + \mathbf{H}(\mathbf{z})) \boldsymbol{\delta} + (s(\mathbf{z}) + \frac{1}{2}\mathbf{z})^\top \boldsymbol{\delta} + \mathcal{O}(\beta_t). \quad (3)$$

读出近似的高斯形式 把 (3) 写成标准二次型

$$\ln q(\mathbf{u} \mid \mathbf{z}) = -\frac{1}{2} \boldsymbol{\delta}^\top \boldsymbol{\Lambda} \boldsymbol{\delta} + \mathbf{b}^\top \boldsymbol{\delta} + \text{const} + \mathcal{O}(\beta_t),$$

其中

$$\boldsymbol{\Lambda} = \frac{1}{\beta_t} \left[\mathbf{I} - \beta_t (\mathbf{I} + \mathbf{H}(\mathbf{z})) \right], \quad \mathbf{b} = s(\mathbf{z}) + \frac{1}{2} \mathbf{z}. \quad (4)$$

因此

$$q(\mathbf{u} \mid \mathbf{z}) \approx \mathcal{N}(\mathbf{u} \mid \boldsymbol{\mu}_t(\mathbf{z}), \boldsymbol{\Sigma}_t(\mathbf{z})), \quad \boldsymbol{\Sigma}_t = \boldsymbol{\Lambda}^{-1}, \quad \boldsymbol{\mu}_t = \mathbf{z} + \boldsymbol{\Lambda}^{-1} \mathbf{b}.$$

零阶结论 (题干要求) 对 (4) 做 Neumann 级数展开,

$$\boldsymbol{\Lambda}^{-1} = \beta_t \left[\mathbf{I} + \beta_t (\mathbf{I} + \mathbf{H}(\mathbf{z})) \right] + \mathcal{O}(\beta_t^3),$$

从而

$$\boldsymbol{\Sigma}_t = \beta_t \mathbf{I} + \mathcal{O}(\beta_t^2), \quad \boldsymbol{\mu}_t = \mathbf{z} + \mathcal{O}(\beta_t).$$

这就证明了当 $\beta_t \rightarrow 0$ 时,

$$q(\mathbf{z}_{t-1} \mid \mathbf{z}_t) \approx \mathcal{N}(\mathbf{z}_t, \beta_t \mathbf{I}).$$

最低阶修正项 保留 $\mathcal{O}(\beta_t)$ 与 $\mathcal{O}(\beta_t^2)$ 的首项, 得到

$$\boldsymbol{\mu}_t(\mathbf{z}) = \mathbf{z} + \beta_t \left(s(\mathbf{z}) + \frac{1}{2} \mathbf{z} \right) + \beta_t^2 \left(\mathbf{I} + \mathbf{H}(\mathbf{z}) \right) \left(s(\mathbf{z}) + \frac{1}{2} \mathbf{z} \right) + \mathcal{O}(\beta_t^3), \quad (5)$$

$$\boldsymbol{\Sigma}_t(\mathbf{z}) = \beta_t \mathbf{I} + \beta_t^2 (\mathbf{I} + \mathbf{H}(\mathbf{z})) + \mathcal{O}(\beta_t^3). \quad (6)$$

因此, 均值的一阶修正为 $\beta_t (s(\mathbf{z}_t) + \frac{1}{2} \mathbf{z}_t)$, 协方差的一阶修正为 $\beta_t^2 (\mathbf{I} + \mathbf{H}(\mathbf{z}_t))$ 。

小结 当噪声方差 β_t 很小时,

$$q(\mathbf{z}_{t-1} \mid \mathbf{z}_t) = \mathcal{N}(\mathbf{z}_t, \beta_t \mathbf{I}) \quad \text{的近似成立,}$$

且其最低阶修正由 (5)–(6) 给出, 其中 $s(\mathbf{z}) = \nabla_{\mathbf{z}} \ln q(\mathbf{z})$ 为边缘分布的 score, $\mathbf{H}(\mathbf{z}) = \nabla_{\mathbf{z}}^2 \ln q(\mathbf{z})$ 为对应 Hessian。 $\square$

练习 20.8 解答 (★★)

题目 将概率的乘法法则

$$p(\mathbf{x}, \mathbf{z} | \mathbf{w}) = p(\mathbf{z} | \mathbf{x}, \mathbf{w}) p(\mathbf{x} | \mathbf{w}) \quad (20.24)$$

代入扩证下界 (ELBO) 的定义

$$\mathcal{L}(\mathbf{w}) = \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{x}, \mathbf{z} | \mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z} \quad (20.22)$$

并利用 Kullback–Leibler 散度的定义

$$\text{KL}(f \| g) = \int f(\mathbf{z}) \ln \frac{f(\mathbf{z})}{g(\mathbf{z})} d\mathbf{z} \quad (20.23),$$

验证

$$\ln p(\mathbf{x} | \mathbf{w}) = \mathcal{L}(\mathbf{w}) + \text{KL}(q(\mathbf{z}) \| p(\mathbf{z} | \mathbf{x}, \mathbf{w})) \quad (20.21).$$

证明 由 (20.22) 与 (20.24),

$$\begin{aligned} \mathcal{L}(\mathbf{w}) &= \int q(\mathbf{z}) \ln \left\{ \frac{p(\mathbf{z} | \mathbf{x}, \mathbf{w}) p(\mathbf{x} | \mathbf{w})}{q(\mathbf{z})} \right\} d\mathbf{z} \\ &= \int q(\mathbf{z}) [\ln p(\mathbf{z} | \mathbf{x}, \mathbf{w}) - \ln q(\mathbf{z})] d\mathbf{z} + \ln p(\mathbf{x} | \mathbf{w}). \end{aligned}$$

将第一项改写为

$$\int q(\mathbf{z}) [\ln p(\mathbf{z} | \mathbf{x}, \mathbf{w}) - \ln q(\mathbf{z})] d\mathbf{z} = - \int q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z} | \mathbf{x}, \mathbf{w})} d\mathbf{z} = - \text{KL}(q(\mathbf{z}) \| p(\mathbf{z} | \mathbf{x}, \mathbf{w})),$$

其中最后一步用到了 (20.23) 的定义。于是

$$\mathcal{L}(\mathbf{w}) = \ln p(\mathbf{x} | \mathbf{w}) - \text{KL}(q(\mathbf{z}) \| p(\mathbf{z} | \mathbf{x}, \mathbf{w})),$$

等价地得到

$$\ln p(\mathbf{x} | \mathbf{w}) = \mathcal{L}(\mathbf{w}) + \text{KL}(q(\mathbf{z}) \| p(\mathbf{z} | \mathbf{x}, \mathbf{w}))$$

即式 (20.21)。证毕。

练习 20.9 解答 (★★)

由书中式 (20.31), 证

$$\mathcal{L}(\mathbf{w}) = \int q(\mathbf{z}_1|\mathbf{x}) \ln p(\mathbf{x}|\mathbf{z}_1, \mathbf{w}) d\mathbf{z}_1 - \sum_{t=2}^T \int \text{KL}(q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x}) \| p(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{w})) q(\mathbf{z}_t|\mathbf{x}) d\mathbf{z}_t,$$

其中 KL 由 (20.23) 定义。

证明 记 (见 (20.27)) 期望算子

$$\mathbb{E}_q[\cdot] = \int q(\mathbf{z}_1|\mathbf{x}) \prod_{t=2}^T q(\mathbf{z}_t|\mathbf{z}_{t-1}) [\cdot] d\mathbf{z}_1 \cdots d\mathbf{z}_T.$$

从 (20.31) 出发,

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_q \left[\sum_{t=2}^T \ln \frac{p(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x})} + \ln p(\mathbf{x}|\mathbf{z}_1, \mathbf{w}) \right].$$

先看“重构项”:

$$\mathbb{E}_q[\ln p(\mathbf{x}|\mathbf{z}_1, \mathbf{w})] = \int q(\mathbf{z}_1|\mathbf{x}) \ln p(\mathbf{x}|\mathbf{z}_1, \mathbf{w}) d\mathbf{z}_1.$$

对每个 $t = 2, \dots, T$, 考虑“比值项”的期望。由 q 的马尔可夫结构, 上式中的积分可以把除 $(\mathbf{z}_{t-1}, \mathbf{z}_t)$ 之外的变量全部积掉, 得

$$\begin{aligned} \mathbb{E}_q \left[\ln \frac{p(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x})} \right] &= \int q(\mathbf{z}_t|\mathbf{x}) \left[\int q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x}) \ln \frac{p(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x})} d\mathbf{z}_{t-1} \right] d\mathbf{z}_t \\ &= - \int q(\mathbf{z}_t|\mathbf{x}) \text{KL}(q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x}) \| p(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{w})) d\mathbf{z}_t, \end{aligned}$$

其中最后一步使用了 (20.23) 的定义 $\text{KL}(f\|g) = \int f(\mathbf{z}) \ln \frac{f(\mathbf{z})}{g(\mathbf{z})} d\mathbf{z}$ (注意我们这里出现的是 $\int q \ln \frac{p}{q} = -\text{KL}(q\|p)$)。

把上述两部分代回 (20.31), 并把对 t 的求和展开, 即得

$$\mathcal{L}(\mathbf{w}) = \int q(\mathbf{z}_1|\mathbf{x}) \ln p(\mathbf{x}|\mathbf{z}_1, \mathbf{w}) d\mathbf{z}_1 - \sum_{t=2}^T \int \text{KL}(q(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{x}) \| p(\mathbf{z}_{t-1}|\mathbf{z}_t, \mathbf{w})) q(\mathbf{z}_t|\mathbf{x}) d\mathbf{z}_t$$

这正是书中式 (20.32)。 □

练习 20.10 解答 (★★)

题目 在推导式 (20.32) 给出的扩散模型的 ELBO 时, 我们在式 (20.26) 中省略了第一、三项 (它们与参数 $\mathbf{w}$ 无关), 并在式 (20.30) 的右端省略了第二项 (同样与 $\mathbf{w}$ 无关)。证明: 如果将这些被省略的项都保留, 则 ELBO 中会额外出现一项

$$\text{KL}(q(\mathbf{z}_T | \mathbf{x}) \parallel p(\mathbf{z}_T)).$$

并说明在本书构造的噪声过程中该项为 0。

解答

从式 (20.26) 出发, 并把 $q(\mathbf{z})$ 取为前向马尔可夫链 $q(\mathbf{z}_1 | \mathbf{x}) \prod_{t=2}^T q(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x})$, 可写为

$$\mathcal{L}(\mathbf{w}) = \mathbb{E}_q \left[\ln p(\mathbf{z}_T) + \sum_{t=2}^T \ln \frac{p(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x})} - \ln q(\mathbf{z}_1 | \mathbf{x}) + \ln p(\mathbf{x} | \mathbf{z}_1, \mathbf{w}) \right]. \quad \star$$

利用式 (20.29) 的恒等式

$$q(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x}) = \frac{q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x}) q(\mathbf{z}_t | \mathbf{x})}{q(\mathbf{z}_{t-1} | \mathbf{x})},$$

可将求和中的每一项改写为

$$\ln \frac{p(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_t | \mathbf{z}_{t-1}, \mathbf{x})} = \ln \frac{p(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x})} + \ln q(\mathbf{z}_{t-1} | \mathbf{x}) - \ln q(\mathbf{z}_t | \mathbf{x}).$$

对 $t = 2, \dots, T$ 求和得到望文可知的望远镜求和 (telescoping):

$$\sum_{t=2}^T [\ln q(\mathbf{z}_{t-1} | \mathbf{x}) - \ln q(\mathbf{z}_t | \mathbf{x})] = \ln q(\mathbf{z}_1 | \mathbf{x}) - \ln q(\mathbf{z}_T | \mathbf{x}).$$

将其代回 ($\star$), $\ln q(\mathbf{z}_1 | \mathbf{x})$ 与 $-\ln q(\mathbf{z}_1 | \mathbf{x})$ 抵消, 得到

$$\mathcal{L}_{\text{full}}(\mathbf{w}) = \mathbb{E}_q \left[\underbrace{\ln p(\mathbf{z}_T) - \ln q(\mathbf{z}_T | \mathbf{x})}_{\text{仅含 } \mathbf{z}_T} + \sum_{t=2}^T \ln \frac{p(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{w})}{q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x})} + \ln p(\mathbf{x} | \mathbf{z}_1, \mathbf{w}) \right].$$

注意括号中的第一部分只依赖于边缘 $q(\mathbf{z}_T | \mathbf{x})$, 因此

$$\mathbb{E}_q[\ln p(\mathbf{z}_T) - \ln q(\mathbf{z}_T | \mathbf{x})] = \mathbb{E}_{q(\mathbf{z}_T | \mathbf{x})}[\ln p(\mathbf{z}_T) - \ln q(\mathbf{z}_T | \mathbf{x})] = -\text{KL}(q(\mathbf{z}_T | \mathbf{x}) \parallel p(\mathbf{z}_T)).$$

于是相对于式 (20.32) (其中省略了与 $\mathbf{w}$ 无关的常数), 完整的 ELBO 为

$$\begin{aligned} \mathcal{L}_{\text{full}}(\mathbf{w}) = & \int q(\mathbf{z}_1 | \mathbf{x}) \ln p(\mathbf{x} | \mathbf{z}_1, \mathbf{w}) d\mathbf{z}_1 \\ & - \sum_{t=2}^T \int q(\mathbf{z}_t | \mathbf{x}) \text{KL}(q(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{x}) \parallel p(\mathbf{z}_{t-1} | \mathbf{z}_t, \mathbf{w})) d\mathbf{z}_t \\ & - \text{KL}(q(\mathbf{z}_T | \mathbf{x}) \parallel p(\mathbf{z}_T)) \end{aligned}$$

其中最后一项就是把先前被省略的项保留后新增的贡献。如果把与 $\mathbf{w}$ 无关的常数整体从 ELBO 中剥离并记为 $\mathcal{L}(\mathbf{x}) := \mathcal{L}_{\text{full}}(\mathbf{w}) + \text{KL}(q(\mathbf{z}_T | \mathbf{x}) \| p(\mathbf{z}_T))$ ，那么该常数正是题目所述的 $\text{KL}(q(\mathbf{z}_T | \mathbf{x}) \| p(\mathbf{z}_T))$ 。

进一步说明 在本书的构造中（见式 (20.9)）， $q(\mathbf{z}_T | \mathbf{x}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，而先验 $p(\mathbf{z}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。因此二者相同，从而

$$\text{KL}(q(\mathbf{z}_T | \mathbf{x}) \| p(\mathbf{z}_T)) = 0,$$

该额外项在数值上消失，完整的 ELBO 便退化回式 (20.32)。 □

练习 20.11 解答 (★★)

题目 利用 (20.15) 中 $q(\mathbf{z}_{t-1} \mid \mathbf{z}_t, \mathbf{x}) = \mathcal{N}(\mathbf{z}_{t-1} \mid \mathbf{m}_t(\mathbf{x}, \mathbf{z}_t), \sigma_t^2 \mathbf{I})$ (其中 $\sigma_t^2 = \beta_t(1 - \alpha_{t-1})/(1 - \alpha_t)$) 与 (20.18) 中 $p(\mathbf{z}_{t-1} \mid \mathbf{z}_t, \mathbf{w}) = \mathcal{N}(\mathbf{z}_{t-1} \mid \boldsymbol{\mu}(\mathbf{z}_t, \mathbf{w}, t), \beta_t \mathbf{I})$, 证明出现在 (20.32) 一致性项中的 Kullback–Leibler 散度满足 (20.33)。

解答 记

$$\mathbf{m}_q := \mathbf{m}_t(\mathbf{x}, \mathbf{z}_t), \quad \mathbf{m}_p := \boldsymbol{\mu}(\mathbf{z}_t, \mathbf{w}, t), \quad \Sigma_q := \sigma_t^2 \mathbf{I}, \quad \Sigma_p := \beta_t \mathbf{I},$$

并设数据维数为 d 。对两个 d 维高斯分布 $\mathcal{N}(\mathbf{m}_q, \Sigma_q)$ 与 $\mathcal{N}(\mathbf{m}_p, \Sigma_p)$ 有标准公式

$$\text{KL}(\mathcal{N}(\mathbf{m}_q, \Sigma_q) \parallel \mathcal{N}(\mathbf{m}_p, \Sigma_p)) = \frac{1}{2} \left[\text{tr}(\Sigma_p^{-1} \Sigma_q) + (\mathbf{m}_p - \mathbf{m}_q)^\top \Sigma_p^{-1} (\mathbf{m}_p - \mathbf{m}_q) - d + \ln \frac{\det \Sigma_p}{\det \Sigma_q} \right].$$

代入 $\Sigma_q = \sigma_t^2 \mathbf{I}$ 、 $\Sigma_p = \beta_t \mathbf{I}$ 得

$$\text{tr}(\Sigma_p^{-1} \Sigma_q) = \text{tr}((\beta_t^{-1} \mathbf{I})(\sigma_t^2 \mathbf{I})) = d \frac{\sigma_t^2}{\beta_t}, \quad (\mathbf{m}_p - \mathbf{m}_q)^\top \Sigma_p^{-1} (\mathbf{m}_p - \mathbf{m}_q) = \frac{1}{\beta_t} \|\mathbf{m}_p - \mathbf{m}_q\|^2,$$

$$\ln \frac{\det \Sigma_p}{\det \Sigma_q} = \ln \frac{\beta_t^d}{(\sigma_t^2)^d} = d \ln \frac{\beta_t}{\sigma_t^2}.$$

于是

$$\text{KL}(q(\mathbf{z}_{t-1} \mid \mathbf{z}_t, \mathbf{x}) \parallel p(\mathbf{z}_{t-1} \mid \mathbf{z}_t, \mathbf{w})) = \frac{1}{2\beta_t} \|\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) - \boldsymbol{\mu}(\mathbf{z}_t, \mathbf{w}, t)\|^2 + \frac{1}{2} \left[d \frac{\sigma_t^2}{\beta_t} - d + d \ln \frac{\beta_t}{\sigma_t^2} \right].$$

右侧第二项仅依赖于 σ_t^2, β_t, d , 与网络参数 $\mathbf{w}$ 无关, 因此在 (20.32) 的优化中可并入常数项 const 。从而得到

$$\text{KL}(q(\mathbf{z}_{t-1} \mid \mathbf{z}_t, \mathbf{x}) \parallel p(\mathbf{z}_{t-1} \mid \mathbf{z}_t, \mathbf{w})) = \frac{1}{2\beta_t} \|\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) - \boldsymbol{\mu}(\mathbf{z}_t, \mathbf{w}, t)\|^2 + \text{const}$$

这正是式 (20.33)。

□

练习 20.12 解答 (★★)

题目 将式 (20.34)

$$\mathbf{x} = \frac{1}{\sqrt{\alpha_t}} \mathbf{z}_t - \frac{\sqrt{1-\alpha_t}}{\sqrt{\alpha_t}} \boldsymbol{\epsilon}_t \quad (\boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})) \quad (20.34)$$

代入式 (20.16)

$$\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) = \frac{(1 - \alpha_{t-1})\sqrt{1-\beta_t} \mathbf{z}_t + \sqrt{\alpha_{t-1}} \beta_t \mathbf{x}}{1 - \alpha_t}, \quad (20.16)$$

并利用 (20.7) 中 $\alpha_t = \prod_{\tau=1}^t (1-\beta_\tau) \Rightarrow \alpha_t = (1-\beta_t)\alpha_{t-1}$ (从而 $\sqrt{\alpha_{t-1}/\alpha_t} = 1/\sqrt{1-\beta_t}$), 把 $\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t)$ 化为 (20.35)。

解答 将 (20.34) 代入 (20.16) 得

$$\begin{aligned} \mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) &= \frac{(1 - \alpha_{t-1})\sqrt{1-\beta_t} \mathbf{z}_t + \sqrt{\alpha_{t-1}} \beta_t \left(\frac{1}{\sqrt{\alpha_t}} \mathbf{z}_t - \frac{\sqrt{1-\alpha_t}}{\sqrt{\alpha_t}} \boldsymbol{\epsilon}_t \right)}{1 - \alpha_t} \\ &= \frac{\left[(1 - \alpha_{t-1})\sqrt{1-\beta_t} + \beta_t \sqrt{\alpha_{t-1}/\alpha_t} \right] \mathbf{z}_t - \beta_t \sqrt{\alpha_{t-1}/\alpha_t} \sqrt{1-\alpha_t} \boldsymbol{\epsilon}_t}{1 - \alpha_t}. \end{aligned}$$

由 $\alpha_t = (1 - \beta_t)\alpha_{t-1}$ 可得 $\sqrt{\alpha_{t-1}/\alpha_t} = \frac{1}{\sqrt{1-\beta_t}}$ 并且

$$(1 - \alpha_{t-1})(1 - \beta_t) + \beta_t = 1 - \alpha_t.$$

于是

$$\begin{aligned} \mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) &= \frac{(1 - \alpha_t) \mathbf{z}_t / \sqrt{1-\beta_t} - \beta_t \sqrt{1-\alpha_t} \boldsymbol{\epsilon}_t / \sqrt{1-\beta_t}}{1 - \alpha_t} \\ &= \frac{1}{\sqrt{1-\beta_t}} \left(\mathbf{z}_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \boldsymbol{\epsilon}_t \right), \end{aligned}$$

这正是书中式

$$\boxed{\mathbf{m}_t(\mathbf{x}, \mathbf{z}_t) = \frac{1}{\sqrt{1-\beta_t}} \left(\mathbf{z}_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \boldsymbol{\epsilon}_t \right)} \quad (20.35)$$

所要求的形式。 □

练习 20.13 解答 (★★)

题目 证明重构项 (20.38)

$$\ln p(\mathbf{x} \mid \mathbf{z}_1, \mathbf{w}) = -\frac{1}{2\beta_1} \|\mathbf{x} - \boldsymbol{\mu}(\mathbf{z}_1, \mathbf{w}, 1)\|^2 + \text{const} \quad (20.38)$$

可写成 (20.39) 的形式。提示：用 (20.36) 代入

$$\boldsymbol{\mu}(\mathbf{z}_t, \mathbf{w}, t) = \frac{1}{\sqrt{1-\beta_t}} \left(\mathbf{z}_t - \frac{\beta_t}{\sqrt{1-\alpha_t}} \mathbf{g}(\mathbf{z}_t, \mathbf{w}, t) \right), \quad (20.36)$$

再用 (20.1) 代入

$$\mathbf{z}_1 = \sqrt{1-\beta_1} \mathbf{x} + \sqrt{\beta_1} \boldsymbol{\epsilon}_1, \quad \boldsymbol{\epsilon}_1 \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (20.1)$$

并利用 (20.7) 给出的 $\alpha_1 = 1 - \beta_1$ 。

解答 由 $\alpha_1 = 1 - \beta_1 \Rightarrow \sqrt{1-\alpha_1} = \sqrt{\beta_1}$, 把 $t = 1$ 代入 (20.36) 得

$$\boldsymbol{\mu}(\mathbf{z}_1, \mathbf{w}, 1) = \frac{1}{\sqrt{1-\beta_1}} \left(\mathbf{z}_1 - \sqrt{\beta_1} \mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) \right).$$

进一步将 (20.1) 的 $\mathbf{z}_1$ 代入：

$$\begin{aligned} \mathbf{x} - \boldsymbol{\mu}(\mathbf{z}_1, \mathbf{w}, 1) &= \mathbf{x} - \frac{1}{\sqrt{1-\beta_1}} \left(\sqrt{1-\beta_1} \mathbf{x} + \sqrt{\beta_1} \boldsymbol{\epsilon}_1 - \sqrt{\beta_1} \mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) \right) \\ &= -\frac{\sqrt{\beta_1}}{\sqrt{1-\beta_1}} \left(\boldsymbol{\epsilon}_1 - \mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) \right) = \frac{\sqrt{\beta_1}}{\sqrt{1-\beta_1}} \left(\mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) - \boldsymbol{\epsilon}_1 \right). \end{aligned}$$

于是

$$\|\mathbf{x} - \boldsymbol{\mu}(\mathbf{z}_1, \mathbf{w}, 1)\|^2 = \frac{\beta_1}{1-\beta_1} \|\mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) - \boldsymbol{\epsilon}_1\|^2.$$

代回 (20.38)：

$$\ln p(\mathbf{x} \mid \mathbf{z}_1, \mathbf{w}) = -\frac{1}{2\beta_1} \cdot \frac{\beta_1}{1-\beta_1} \|\mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) - \boldsymbol{\epsilon}_1\|^2 + \text{const} = -\frac{1}{2(1-\beta_1)} \|\mathbf{g}(\mathbf{z}_1, \mathbf{w}, 1) - \boldsymbol{\epsilon}_1\|^2 + \text{const}. \quad (20.39)$$

这正是所需的重构项形式。 $\square$

练习 20.14 解答 (★)

题目 分数函数 (score) $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} p(\mathbf{x} | \mathbf{w})$ 与输入同维。令

$$M_{ij} = \frac{\partial s_i}{\partial x_j} - \frac{\partial s_j}{\partial x_i}. \quad (20.64)$$

证明: 若把 $\mathbf{s}$ 表示为某一标量网络输出 $\phi(\mathbf{x})$ 的梯度 $\mathbf{s} = \nabla_{\mathbf{x}} \phi(\mathbf{x})$, 则 $\forall i, j, M_{ij} = 0$ 。并说明: 若直接用有 d 个输出 (与输入维数相同) 的网络来表示 $\mathbf{s}(\mathbf{x})$, 一般只有对角元 $M_{ii} = 0$, 非对角元不必为零, 因此该网络的输出通常不是任何标量函数的梯度。

证明

(1) 若 $\mathbf{s} = \nabla \phi$ 则 $M_{ij} = 0$ 设 $\phi: \mathbb{R}^d \rightarrow \mathbb{R}$ 二阶连续可导, 则

$$s_i(\mathbf{x}) = \frac{\partial \phi}{\partial x_i}, \quad \frac{\partial s_i}{\partial x_j} = \frac{\partial^2 \phi}{\partial x_j \partial x_i}, \quad \frac{\partial s_j}{\partial x_i} = \frac{\partial^2 \phi}{\partial x_i \partial x_j}.$$

由 Clairaut-Schwarz 混合偏导可交换定理 (Hessian 的对称性) $\frac{\partial^2 \phi}{\partial x_j \partial x_i} = \frac{\partial^2 \phi}{\partial x_i \partial x_j}$, 从而

$$M_{ij} = \frac{\partial^2 \phi}{\partial x_j \partial x_i} - \frac{\partial^2 \phi}{\partial x_i \partial x_j} = 0, \quad \forall i, j.$$

故当 $\mathbf{s}$ 是某个标量势函数的梯度时, 矩阵 M 的全部元素皆为零; 等价地说, $\nabla \phi$ 的 Jacobian (即 Hessian) 是对称的。

(2) 若 $\mathbf{s}$ 由任意 d 维向量网络直接给出 此时 $s_i = s_i(\mathbf{x})$ 为网络的第 i 个输出。显然

$$M_{ii} = \frac{\partial s_i}{\partial x_i} - \frac{\partial s_i}{\partial x_i} = 0,$$

但对 $i \neq j$ 并无任何保证使 $\frac{\partial s_i}{\partial x_j} = \frac{\partial s_j}{\partial x_i}$ 。例如在二维中取 $\mathbf{s}(\mathbf{x}) = (x_2, 0)^\top$ (完全可由一个浅层网络表示), 则

$$M_{12} = \frac{\partial s_1}{\partial x_2} - \frac{\partial s_2}{\partial x_1} = 1 - 0 = 1 \neq 0.$$

因此一般只有 $M_{ii} = 0$ 成立, 而非对角元不必为零。这说明该向量场的 Jacobian 通常不对称, 从而它不是任何标量函数的梯度 (非保守场)。

结论 $\mathbf{s}$ 能被写成某个标量函数的梯度 $\nabla \phi$ 的充分必要条件 是在单连通域内矩阵 M 全为零 (或等价地, Jacobian 对称)。直接用网络逐分量建模 $\mathbf{s}$ 时并不满足该条件, 因此一般不对应于任何标量势函数的梯度。□

练习 20.15 解答 (★★)

题目 设分数函数 (score) 满足 $\mathbf{s}(\mathbf{x}, \mathbf{w}) \in \mathbb{R}^D$, 比较两种实现的计算复杂度: (i) 用一个有 D 个输出的网络直接回归 $\mathbf{s}$; (ii) 用一个标量网络 $\phi(\mathbf{x}, \mathbf{w})$, 再用自动微分求 $\nabla_{\mathbf{x}}\phi(\mathbf{x}, \mathbf{w})$ 。证明第二种通常更耗时 (计算量更大)。

解答 以 L 层全连接网络为例 (卷积网络情形结论相同), 记每层宽度为 $n_0 = D, n_1, \dots, n_{L-1}, n_L$, 线性层的主要计算量与矩阵乘法 $n_\ell n_{\ell-1}$ 成正比。

(A) 直接回归 $\mathbf{s}$ 末层输出维为 $n_L = D$ 。一次前向传播的计算量为

$$\text{Cost}_{\text{dir}}^{\text{fwd}} = \sum_{\ell=1}^L n_\ell n_{\ell-1} = \underbrace{\sum_{\ell=1}^{L-1} n_\ell n_{\ell-1}}_{\text{隐藏层相同}} + n_{L-1} D =: C_{\text{hid}} + n_{L-1} D.$$

评估 $\mathbf{s}(\mathbf{x}, \mathbf{w})$ 只需这一次前向, 因此总复杂度就是 $\text{Cost}_{\text{dir}} = C_{\text{hid}} + n_{L-1} D$ 。

(B) 通过 ϕ 间接求梯度 标量网络末层 $n_L = 1$, 故一次前向为 $\text{Cost}_{\phi}^{\text{fwd}} = C_{\text{hid}} + n_{L-1}$ 。而要得到 $\nabla_{\mathbf{x}}\phi$, 需在自动微分的反向模式下, 把标量输出对输入 $\mathbf{x}$ 的梯度一次性反传出来。对常见的线性层与逐点非线性, 一遍反向的计算量与一遍前向为同阶, 记为 $\text{Cost}_{\phi}^{\text{bwd}} \asymp C_{\text{hid}} + n_{L-1}$ 。因此

$$\text{Cost}_{\text{pot}} = \text{Cost}_{\phi}^{\text{fwd}} + \text{Cost}_{\phi}^{\text{bwd}} \approx 2(C_{\text{hid}} + n_{L-1}).$$

(C) 比较与结论 两者之比大致为

$$\frac{\text{Cost}_{\text{pot}}}{\text{Cost}_{\text{dir}}} \approx \frac{2(C_{\text{hid}} + n_{L-1})}{C_{\text{hid}} + n_{L-1} D} \leq 2,$$

当且仅当 $D = 1$ 时取等号; 当 $C_{\text{hid}} \gg n_{L-1}$ 时, 比值趋近于 2 (但除非 $D = 1$ 不会严格等于 2)。当网络的主要计算量集中在隐藏层 (实践中极常见: 卷积主干或大隐藏层主导) 时, $C_{\text{hid}} \gg n_{L-1}$, 于是

$$\text{Cost}_{\text{dir}} \approx C_{\text{hid}}, \quad \text{Cost}_{\text{pot}} \approx 2C_{\text{hid}},$$

即通过标量势函数再做一次反向传播, 通常比直接回归 $\mathbf{s}$ 约多一倍计算 ($\approx 2\times$)。另一方面, 在极端情形: 若末层主导并且 $n_{L-1} D \gg C_{\text{hid}}$, 则

$$\frac{\text{Cost}_{\text{pot}}}{\text{Cost}_{\text{dir}}} \approx \frac{2n_{L-1}}{n_{L-1} D} = \frac{2}{D} \ll 1,$$

此时势函数法反而可能更省。

$$\text{Cost}_{\text{pot}} \leq 2 \text{Cost}_{\text{dir}} \quad (\text{对任意 } D \geq 1 \text{ 恒成立, 忽略实现常数})$$

且在常见的 $C_{\text{hid}} \gg n_{L-1}$ 的条件下有 $\text{Cost}_{\text{pot}} \approx 2 \text{Cost}_{\text{dir}}$ 。

补充：内存与卷积网络 反向模式还需要保留前向激活，显著增加显存占用；在卷积网络（如 U-Net）里，末层从 1 到 D 的区别只体现在很薄的 1×1 卷积上，代价微小；而多出的一次全网反向仍占主导。因此通过 ϕ 再取梯度的方案在时间与内存上都通常更昂贵（工程上常观测到 $2 \sim 3 \times$ 的总时耗，系数大于理论 2 源于反向阶段更大的实现常数）。

□

练习 20.16 解答 (★★★)

题目 由于不知道真实数据密度 $p(\mathbf{x})$ 的解析形式, 不能直接最小化

$$J(\mathbf{w}) = \frac{1}{2} \int \|\mathbf{s}(\mathbf{x}, \mathbf{w}) - \nabla_{\mathbf{x}} \ln p(\mathbf{x})\|^2 p(\mathbf{x}) d\mathbf{x}. \quad (20.43)$$

中的真分数函数 $\nabla_{\mathbf{x}} \ln p(\mathbf{x})$ 。请用分部积分把 (20.43) 改写为

$$J(\mathbf{w}) = \int \left\{ \nabla \cdot \mathbf{s}(\mathbf{x}, \mathbf{w}) + \frac{1}{2} \|\mathbf{s}(\mathbf{x}, \mathbf{w})\|^2 \right\} p(\mathbf{x}) d\mathbf{x} + \text{const}, \quad (20.65)$$

其中散度定义为 $\nabla \cdot \mathbf{s} = \sum_{i=1}^D \frac{\partial s_i}{\partial x_i}$; 并且当 $\mathbf{s} = \nabla \ln p(\mathbf{x})$ 时有 $\nabla \cdot \mathbf{s} = \sum_{i=1}^D \frac{\partial^2 \ln p(\mathbf{x})}{\partial x_i^2}$ (式 (20.66))。

解答 记真分数函数为 $\mathbf{s}_p(\mathbf{x}) := \nabla_{\mathbf{x}} \ln p(\mathbf{x})$ 。将 (20.43) 中的平方展开:

$$\begin{aligned} J(\mathbf{w}) &= \frac{1}{2} \int \left(\|\mathbf{s}\|^2 - 2 \mathbf{s}^\top \mathbf{s}_p + \|\mathbf{s}_p\|^2 \right) p d\mathbf{x} \\ &= \frac{1}{2} \int \|\mathbf{s}(\mathbf{x}, \mathbf{w})\|^2 p(\mathbf{x}) d\mathbf{x} - \int \mathbf{s}(\mathbf{x}, \mathbf{w})^\top \mathbf{s}_p(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} + \frac{1}{2} \int \|\mathbf{s}_p(\mathbf{x})\|^2 p(\mathbf{x}) d\mathbf{x}. \end{aligned}$$

注意到 $\mathbf{s}_p p = \nabla p$ (因 $\mathbf{s}_p = \nabla \ln p = (\nabla p)/p$), 故第二项化为

$$- \int \mathbf{s}^\top \mathbf{s}_p p d\mathbf{x} = - \int \mathbf{s}(\mathbf{x}, \mathbf{w})^\top \nabla p(\mathbf{x}) d\mathbf{x}. \quad (7)$$

对 (7) 做分部积分。逐坐标写作

$$- \int s_i(\mathbf{x}, \mathbf{w}) \frac{\partial p(\mathbf{x})}{\partial x_i} d\mathbf{x} = - \underbrace{\int \frac{\partial}{\partial x_i} (p(\mathbf{x}) s_i(\mathbf{x}, \mathbf{w})) d\mathbf{x}}_{\text{边界项}} + \int p(\mathbf{x}) \frac{\partial s_i(\mathbf{x}, \mathbf{w})}{\partial x_i} d\mathbf{x}.$$

在常见假设 $p(\mathbf{x}) s_i(\mathbf{x}, \mathbf{w}) \rightarrow 0$ 当 $\|\mathbf{x}\| \rightarrow \infty$ 下 (即一维情形的 (20.67)–(20.68) 在高维逐坐标相加的推广), 边界项为 0。将 $i = 1, \dots, D$ 求和得到

$$- \int \mathbf{s}^\top \nabla p d\mathbf{x} = \int p(\mathbf{x}) \left(\sum_{i=1}^D \frac{\partial s_i}{\partial x_i} \right) d\mathbf{x} = \int p(\mathbf{x}) (\nabla \cdot \mathbf{s}(\mathbf{x}, \mathbf{w})) d\mathbf{x}. \quad (8)$$

把 (8) 代回 $J(\mathbf{w})$, 并把 $\frac{1}{2} \int \|\mathbf{s}_p\|^2 p d\mathbf{x} = \frac{1}{2} \int \frac{\|\nabla p\|^2}{p} d\mathbf{x}$ 视为与网络参数 $\mathbf{w}$ 无关的常数项 (可并入 “const”), 使得

$$J(\mathbf{w}) = \int \left\{ \nabla \cdot \mathbf{s}(\mathbf{x}, \mathbf{w}) + \frac{1}{2} \|\mathbf{s}(\mathbf{x}, \mathbf{w})\|^2 \right\} p(\mathbf{x}) d\mathbf{x} + \text{const},$$

即式 (20.65)。

最后, 由定义 $\mathbf{s}_p = \nabla \ln p$ 可得

$$\nabla \cdot \mathbf{s}_p = \sum_{i=1}^D \frac{\partial}{\partial x_i} \left(\frac{\partial \ln p}{\partial x_i} \right) = \sum_{i=1}^D \frac{\partial^2 \ln p(\mathbf{x})}{\partial x_i^2},$$

这就是 (20.66) 的后半部分, 因而证明完成。 $\square$

练习 20.17 解答 (★★)

题目 证明损失

$$J(\mathbf{w}) = \frac{1}{2} \iint \left\| \mathbf{s}(\mathbf{z}, \mathbf{w}) - \nabla_z \ln q(\mathbf{z} | \mathbf{x}, \sigma) \right\|^2 q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{z} d\mathbf{x} + \text{const} \quad (20.50)$$

与

$$J(\mathbf{w}) = \frac{1}{2} \int \left\| \mathbf{s}(\mathbf{z}, \mathbf{w}) - \nabla_z \ln q_\sigma(\mathbf{z}) \right\|^2 q_\sigma(\mathbf{z}) d\mathbf{z} \quad (20.49)$$

在一个与 $\mathbf{w}$ 无关的常数项意义下等价。其中

$$q_\sigma(\mathbf{z}) = \int q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{x} \quad (20.47)$$

为 Parzen (核密度) 估计。

解答

(i) 展开式 (20.49) 把平方项展开, 得到

$$\begin{aligned} J_{49}(\mathbf{w}) &= \frac{1}{2} \int \|\mathbf{s}(\mathbf{z}, \mathbf{w})\|^2 q_\sigma(\mathbf{z}) d\mathbf{z} - \int \mathbf{s}(\mathbf{z}, \mathbf{w})^\top \nabla_z \ln q_\sigma(\mathbf{z}) q_\sigma(\mathbf{z}) d\mathbf{z} \\ &\quad + \frac{1}{2} \int \|\nabla_z \ln q_\sigma(\mathbf{z})\|^2 q_\sigma(\mathbf{z}) d\mathbf{z}. \end{aligned}$$

注意最后一项与网络参数 $\mathbf{w}$ 无关, 可视作常数项。

用 (20.47) 把第一、二项改写:

$$\int \|\mathbf{s}\|^2 q_\sigma = \iint \|\mathbf{s}(\mathbf{z}, \mathbf{w})\|^2 q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{x} d\mathbf{z},$$

而

$$\nabla_z \ln q_\sigma(\mathbf{z}) q_\sigma(\mathbf{z}) = \nabla_z q_\sigma(\mathbf{z}) = \nabla_z \left(\int q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{x} \right) = \int \nabla_z q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{x}.$$

于是交叉项变为

$$- \int \mathbf{s}^\top \nabla_z q_\sigma = - \iint \mathbf{s}(\mathbf{z}, \mathbf{w})^\top (\nabla_z q(\mathbf{z} | \mathbf{x}, \sigma)) p(\mathbf{x}) d\mathbf{x} d\mathbf{z}.$$

(ii) 展开式 (20.50) 同样展开平方得

$$\begin{aligned} J_{50}(\mathbf{w}) &= \frac{1}{2} \iint \|\mathbf{s}(\mathbf{z}, \mathbf{w})\|^2 q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{z} d\mathbf{x} \\ &\quad - \iint \mathbf{s}(\mathbf{z}, \mathbf{w})^\top \nabla_z \ln q(\mathbf{z} | \mathbf{x}, \sigma) q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{z} d\mathbf{x} \\ &\quad + \frac{1}{2} \iint \|\nabla_z \ln q(\mathbf{z} | \mathbf{x}, \sigma)\|^2 q(\mathbf{z} | \mathbf{x}, \sigma) p(\mathbf{x}) d\mathbf{z} d\mathbf{x}. \end{aligned}$$

注意第三项同样与 $\mathbf{w}$ 无关, 是常数。第二项可写为

$$- \iint \mathbf{s}^\top (\nabla_z q(\mathbf{z} | \mathbf{x}, \sigma)) p(\mathbf{x}) d\mathbf{z} d\mathbf{x},$$

这与上一段由 (20.49) 得到的交叉项完全一致; 第一项也与 (20.49) 展开所得第一项一致 (见上式)。

(iii) 结论 两种损失的非常数部分逐项相同，而各自额外的

$$\frac{1}{2} \int \|\nabla_z \ln q_\sigma\|^2 q_\sigma \, d\mathbf{z} \quad \text{与} \quad \frac{1}{2} \iint \|\nabla_z \ln q(\mathbf{z} \mid \mathbf{x}, \sigma)\|^2 q(\mathbf{z} \mid \mathbf{x}, \sigma) p(\mathbf{x}) \, d\mathbf{z} \, d\mathbf{x}$$

均与 $\mathbf{w}$ 无关，因而可并入同一个加性常数。故

$$J_{49}(\mathbf{w}) = J_{50}(\mathbf{w}) + \text{const},$$

即式 (20.49) 与式 (20.50) 在训练时等价（相差常数）。

□

练习 20.18 解答 (★)

题目 设概率密度为两“互不相交”(disjoint)分布的混合:

$$p(\mathbf{x}) = \lambda p_A(\mathbf{x}) + (1 - \lambda) p_B(\mathbf{x}), \quad 0 < \lambda < 1, \quad (20.69)$$

并满足对任意 $\mathbf{x}$, $p_A(\mathbf{x}) > 0 \Rightarrow p_B(\mathbf{x}) = 0$, 且 $p_B(\mathbf{x}) > 0 \Rightarrow p_A(\mathbf{x}) = 0$ (即两者支持集互不相交)。求证该分布的分数函数 (score) $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} \ln p(\mathbf{x})$ 在几乎处处等于对应分量的分数函数:

$$\mathbf{s}(\mathbf{x}) = \begin{cases} \nabla_{\mathbf{x}} \ln p_A(\mathbf{x}), & \mathbf{x} \in \text{supp}(p_A), \\ \nabla_{\mathbf{x}} \ln p_B(\mathbf{x}), & \mathbf{x} \in \text{supp}(p_B). \end{cases}$$

解答 由“互不相交”的假设, 任取 $\mathbf{x}$, 要么 $p_A(\mathbf{x}) > 0$ 而 $p_B(\mathbf{x}) = 0$, 要么相反。于是由 (20.69),

$$p(\mathbf{x}) = \begin{cases} \lambda p_A(\mathbf{x}), & \mathbf{x} \in \text{supp}(p_A), \\ (1 - \lambda) p_B(\mathbf{x}), & \mathbf{x} \in \text{supp}(p_B). \end{cases}$$

两种情形分别求梯度可得

$$\nabla_{\mathbf{x}} \ln p(\mathbf{x}) = \begin{cases} \nabla_{\mathbf{x}} \ln(\lambda p_A(\mathbf{x})) = \nabla_{\mathbf{x}} \ln p_A(\mathbf{x}), & \mathbf{x} \in \text{supp}(p_A), \\ \nabla_{\mathbf{x}} \ln((1 - \lambda) p_B(\mathbf{x})) = \nabla_{\mathbf{x}} \ln p_B(\mathbf{x}), & \mathbf{x} \in \text{supp}(p_B), \end{cases}$$

因为 λ 与 $1 - \lambda$ 为常数, 对 $\mathbf{x}$ 的梯度为零。从而结论成立。

备注 若去掉“互不相交”的假设, 对一般混合 $p = \lambda p_A + (1 - \lambda) p_B$ 有

$$\nabla_{\mathbf{x}} \ln p(\mathbf{x}) = \frac{\lambda p_A(\mathbf{x}) \nabla_{\mathbf{x}} \ln p_A(\mathbf{x}) + (1 - \lambda) p_B(\mathbf{x}) \nabla_{\mathbf{x}} \ln p_B(\mathbf{x})}{\lambda p_A(\mathbf{x}) + (1 - \lambda) p_B(\mathbf{x})},$$

即为各分量分数函数的后验加权平均。在本题的互不相交情形中, 该式在各自支持集上简化为上面的逐块等式。边界上若出现 $p_A = p_B = 0$ 或不可微分的点, 其贡献在 Lebesgue 意义下为零, 可忽略不计 (“几乎处处”结论)。□

练习 20.19 解答 (★★)

题目 离散前向噪声过程由

$$\mathbf{z}_t = \sqrt{1 - \beta_t} \mathbf{z}_{t-1} + \sqrt{\beta_t} \boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (20.3)$$

给出。取连续时间极限，并设存在连续函数 $\beta(t)$ 使 $\beta_t = \beta(t) \Delta t$ 。对右端第一项的平方根做泰勒展开，证明无穷小更新可写成

$$d\mathbf{z} = -\frac{1}{2} \beta(t) \mathbf{z} dt + \sqrt{\beta(t)} d\boldsymbol{\nu}, \quad (20.70)$$

其中 $d\boldsymbol{\nu}$ 为标准维纳过程增量。

解答 取均匀时间网格 $t_k = k \Delta t$ ，记 $\mathbf{z}_k = \mathbf{z}(t_k)$ ， $\beta_k = \beta(t_k) \Delta t$ 。由 (20.3) 得到一步增量

$$\Delta \mathbf{z} := \mathbf{z}_{k+1} - \mathbf{z}_k = (\sqrt{1 - \beta_k} - 1) \mathbf{z}_k + \sqrt{\beta_k} \boldsymbol{\epsilon}_k.$$

对 $\sqrt{1-x}$ 在 $x=0$ 处作一阶泰勒展开， $\sqrt{1-x} = 1 - \frac{1}{2}x + \mathcal{O}(x^2)$ 。代入 $x = \beta_k = \beta(t_k) \Delta t$ ，得

$$\sqrt{1 - \beta_k} - 1 = -\frac{1}{2} \beta(t_k) \Delta t + \mathcal{O}(\Delta t^2).$$

于是

$$\Delta \mathbf{z} = -\frac{1}{2} \beta(t_k) \mathbf{z}_k \Delta t + \underbrace{\sqrt{\beta(t_k)} \sqrt{\Delta t} \boldsymbol{\epsilon}_k}_{:= \Delta \boldsymbol{\nu}_k} + \mathcal{O}(\Delta t^2).$$

令 $\Delta \boldsymbol{\nu}_k := \sqrt{\Delta t} \boldsymbol{\epsilon}_k$ ，则 $\Delta \boldsymbol{\nu}_k \sim \mathcal{N}(\mathbf{0}, \Delta t \mathbf{I})$ ，满足维纳增量的性质 $\mathbb{E}[\Delta \boldsymbol{\nu}_k] = \mathbf{0}$ ， $\mathbb{E}[\Delta \boldsymbol{\nu}_k \Delta \boldsymbol{\nu}_k^\top] = \Delta t \mathbf{I}$ 。令 $\Delta t \rightarrow 0$ ，得到 Itô 型 SDE

$$d\mathbf{z} = -\frac{1}{2} \beta(t) \mathbf{z} dt + \sqrt{\beta(t)} d\boldsymbol{\nu},$$

这即为式 (20.70)。

与一般形式的 SDE

$$d\mathbf{z} = \mathbf{f}(\mathbf{z}, t) dt + g(t) d\boldsymbol{\nu} \quad (20.55)$$

对比可知本题为其特例，取 $\mathbf{f}(\mathbf{z}, t) = -\frac{1}{2} \beta(t) \mathbf{z}$ ， $g(t) = \sqrt{\beta(t)}$ 。□

练习 20.20 解答 (★)

题目 利用 (20.58) 将 $\nabla_{\mathbf{x}} \ln p(c | \mathbf{x})$ 代入 (20.59), 证明分数函数可写成 (20.60)。

解答 由贝叶斯公式 $p(\mathbf{x} | c) = \frac{p(c | \mathbf{x})p(\mathbf{x})}{p(c)}$ 并注意到 $p(c)$ 与 $\mathbf{x}$ 无关, 得

$$\nabla_{\mathbf{x}} \ln p(\mathbf{x} | c) = \nabla_{\mathbf{x}} \ln p(\mathbf{x}) + \nabla_{\mathbf{x}} \ln p(c | \mathbf{x}). \quad (20.58)$$

于是

$$\nabla_{\mathbf{x}} \ln p(c | \mathbf{x}) = \nabla_{\mathbf{x}} \ln p(\mathbf{x} | c) - \nabla_{\mathbf{x}} \ln p(\mathbf{x}).$$

把上式代入分类器引导的打分函数

$$\text{score}(\mathbf{x}, c, \lambda) = \nabla_{\mathbf{x}} \ln p(\mathbf{x}) + \lambda \nabla_{\mathbf{x}} \ln p(c | \mathbf{x}) \quad (20.59)$$

可得

$$\begin{aligned} \text{score}(\mathbf{x}, c, \lambda) &= \nabla_{\mathbf{x}} \ln p(\mathbf{x}) + \lambda (\nabla_{\mathbf{x}} \ln p(\mathbf{x} | c) - \nabla_{\mathbf{x}} \ln p(\mathbf{x})) \\ &= \lambda \nabla_{\mathbf{x}} \ln p(\mathbf{x} | c) + (1 - \lambda) \nabla_{\mathbf{x}} \ln p(\mathbf{x}). \end{aligned}$$

因此

$$\boxed{\text{score}(\mathbf{x}, c, \lambda) = \lambda \nabla_{\mathbf{x}} \ln p(\mathbf{x} | c) + (1 - \lambda) \nabla_{\mathbf{x}} \ln p(\mathbf{x})} \quad (20.60)$$

即为所求。 □

Copyright

© 2025 YaoYuzhuo (yaoyuzhuo6@gmail.com).

本作品仅供学术与研究用途。任何形式的商业使用、转载或牟利性衍生作品，须经版权所有者书面许可。任何侵权行为将依法追究责任。

All rights reserved. This work is made available exclusively for academic and research purposes. Any form of commercial use, redistribution, or derivative work for profit requires prior written authorization from the copyright holder. Any unlawful infringement will be prosecuted in accordance with applicable laws and regulations.
